IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Agrupar, resumir, recomendar y premiar

Sin respuestas correctas · un recorrido por clustering, PCA, recomendadores y refuerzo

Sprint 9 · recorrido global de los cuadernos S09_01 a S09_04

DÓNDE ESTAMOS

Tres formas de aprender: hoy, las dos nuevas

Supervisado (S07 y S08)

Cada ejemplo **trae la respuesta**: la reserva canceló o no.

El modelo aprende a **predecirla**.

Se mide con el **AUC** o el error.

Sin supervisar (S09)

No hay respuesta: solo datos.

El algoritmo **descubre estructura**: grupos, ejes, gustos.

No hay «acierto»: hay que **juzgar si sirve**.

Por refuerzo (S09)

No hay respuesta correcta, hay **premios y castigos**.

Un agente **prueba** y aprende qué le conviene.

Se mide con la **recompensa total**.

Hoy ya no hay columna objetivo. Cambia lo que le pedimos al algoritmo y también cómo sabemos si lo ha hecho bien.

Todo el Sprint 9 usa los datos de TurisData: 1 200 huéspedes, sus valoraciones de experiencias y un pasillo de hotel.

LOS TEMAS DE HOY

Cuatro ideas, cuatro preguntas distintas

Idea	La pregunta que responde	Cuaderno
Clustering	¿Hay **grupos de huéspedes** parecidos entre sí?	S09_01
PCA	¿Puedo **resumir 7 columnas** en 2 y dibujarlas?	S09_02
Recomendadores	¿Qué **experiencia** le gustará a este huésped?	S09_03
Q-learning	¿Qué **hacer paso a paso** para ganar lo máximo?	S09_04

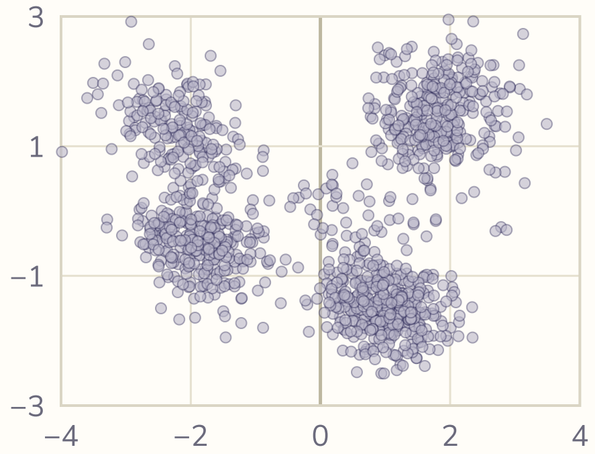
Un hilo común: ningún algoritmo da la respuesta final. Siempre hay que interpretar, comparar y decidir.

Recorrido: 1 · Clustering → 2 · PCA → 3 · Recomendadores → 4 · Refuerzo.

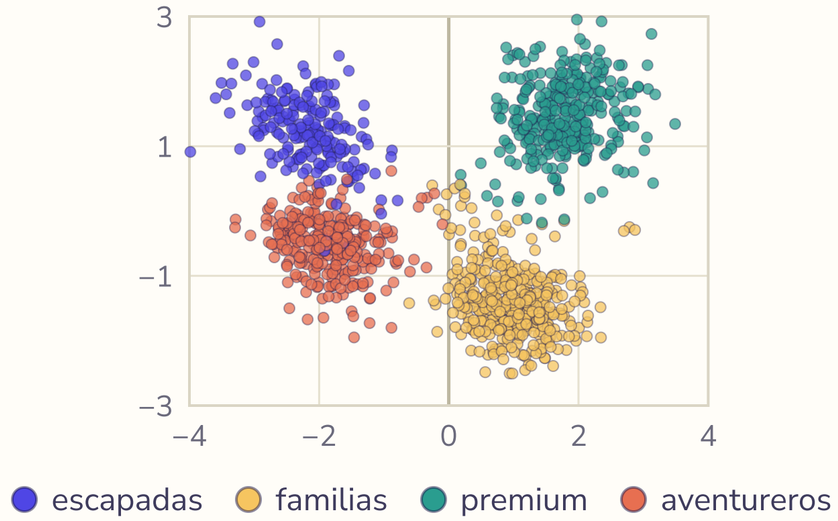
1 · CLUSTERING

Nadie dice el grupo: el algoritmo lo encuentra

Lo que tenemos: 1 200 puntos, sin etiqueta



Lo que busca el clustering: grupos

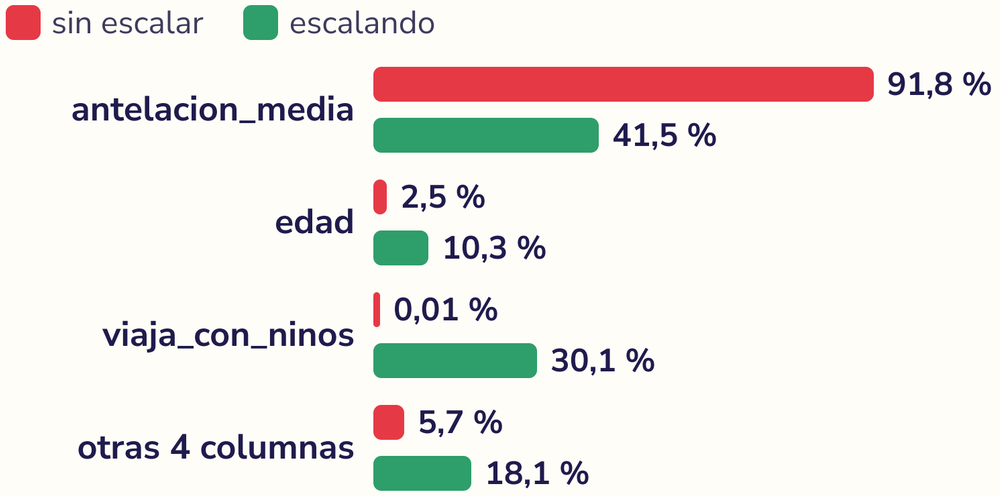


Cada punto es **un huésped** (siete columnas resumidas en un mapa de 2D). El clustering **agrupa a los parecidos.**

1 · CLUSTERING

Primero, poner todas las columnas a la misma escala

Cuánto aporta cada columna a la distancia entre dos huéspedes



Por qué

El clustering **mide distancias**.

Si el gasto va en euros y «viaja con niños» vale 0 o 1, **manda la columna grande** y la pequeña no cuenta.

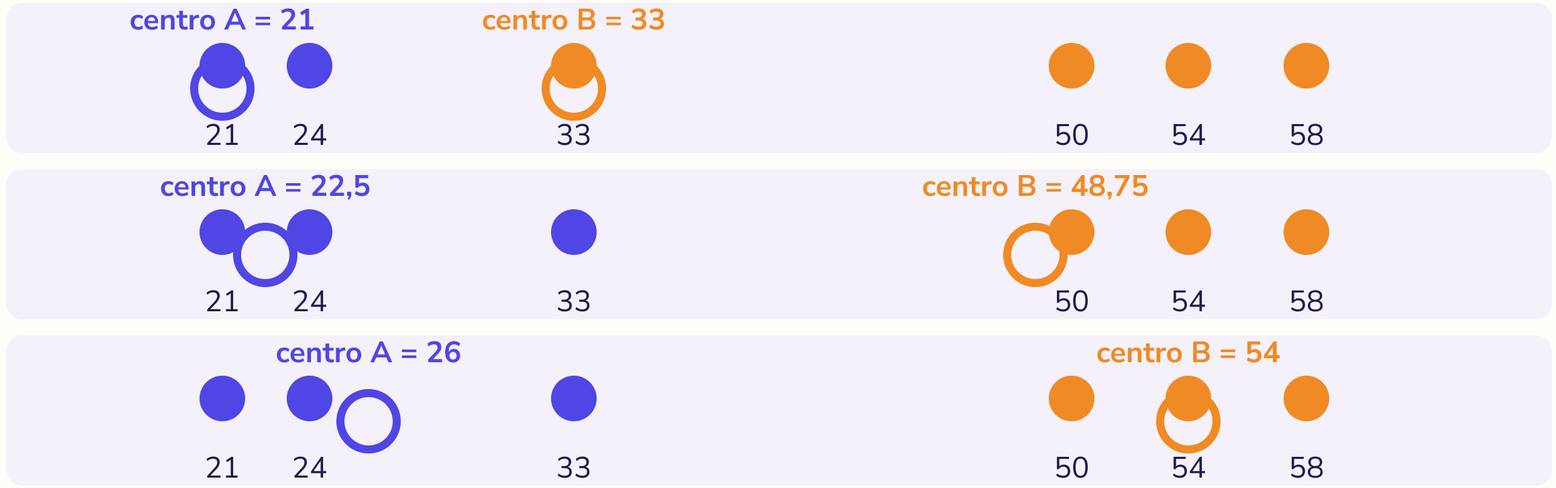
La solución

Estandarizar: restar la media y dividir por la desviación típica.

Todas quedan con media 0 y desviación 1.

Sin escalar, la antelación decide el 92 % de la distancia y «con niños» el 0,01 %. Escalando, todas pesan.

k-means: centros que se mueven hasta parar



Azul = grupo A, naranja = grupo B. El círculo hueco es el **centro**: tras cada ronda pasa a la **media** de su grupo. En la ronda 3 **no cambia nadie**: fin.

Tú eliges k (aquí 2): se repite asignar cada huésped al centro más cercano y recalcular los centros. ¿Y cuántos grupos son los buenos? Lo mide la silueta.

La silueta puntúa cada k: gana la más alta

Silueta media según el número de grupos (TurisData)



Verde = el mejor k. De −1 a 1: cuanto más alta, grupos más compactos y separados.

Cómo se lee

Cada huésped se compara con **su grupo** y con el **grupo vecino**.

Más de **0,5**: buena estructura. Entre **0,25 y 0,5**: aceptable.

En tu cuaderno

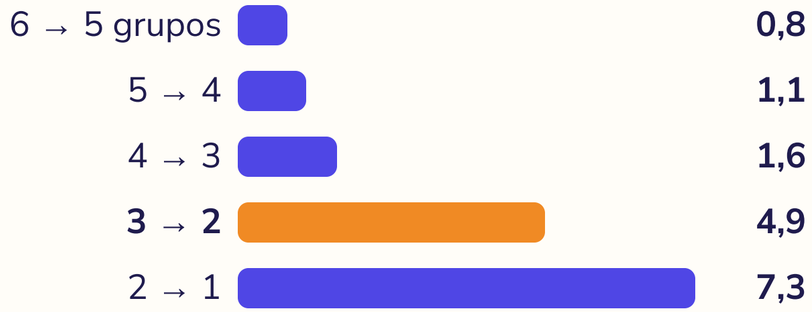
El mejor es **k = 4** (silueta **0,431**).

k = 3, 4 y 5 casi empatan: **decide el negocio**.

A partir de k = 6 la silueta cae: se **parten grupos** que eran uno solo.

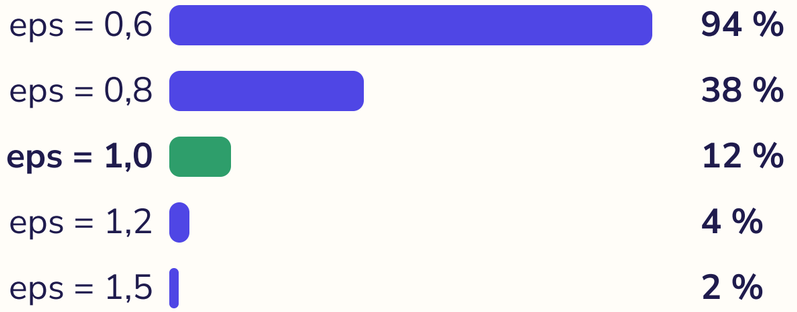
Jerárquico y DBSCAN: otras dos formas

Jerárquico · altura de cada fusión (ejemplo pequeño)



Se corta **antes del salto grande**: juntar 3 en 2 cuesta 4,9, el triple que el paso anterior (1,6). Se queda en 3 grupos.

DBSCAN · % de huéspedes que quedan como ruido



Con eps = 1,0 salen **5 grupos** y **149 huéspedes atípicos** (ruido). Muy pequeño: casi todo es ruido; muy grande: todo se junta.

Jerárquico

Cada huésped empieza solo y se **fusionan los más parecidos**, paso a paso: el **dendrograma**.

Con 4 grupos: silueta **0,424** (k-means: 0,431).

DBSCAN

Un grupo es una **zona densa**; lo que queda fuera es **ruido**. No se dice cuántos grupos.

Útil para **detectar casos raros**.

Ponle nombre y acción a cada grupo

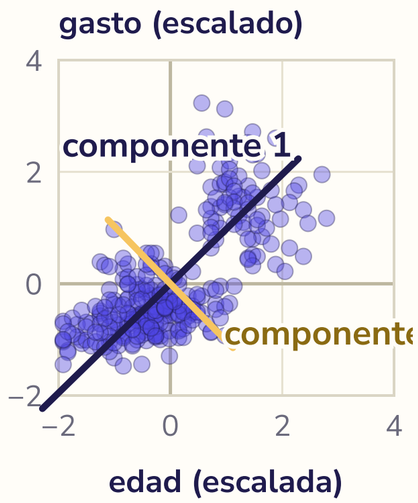
Grupo	Huéspedes	Qué lo define	Acción comercial
0 · Escapadas cortas	194	2,6 noches, última hora, muchas reservas	Oferta de última hora
1 · Familias	402	Niños (0,9), antelación de 110 días	Paquetes con actividades para niños
2 · Descanso premium	317	57 años, 211 € al día	Servicios premium
3 · Aventureros	287	29 años, 75 % del gasto en actividades	Excursiones y deportes

Los nombres salen del perfil de cada grupo, no de una intuición previa. Sin nombre y acción, el clustering no sirve.

El algoritmo solo numera los grupos (0, 1, 2, 3): **las personas** les damos significado.

Un eje nuevo a lo largo de la nube

300 de 1 200 huéspedes · solo edad y gasto



La idea

Una nube alargada se describe mejor con **un eje a lo largo de ella**. PCA busca esos ejes.

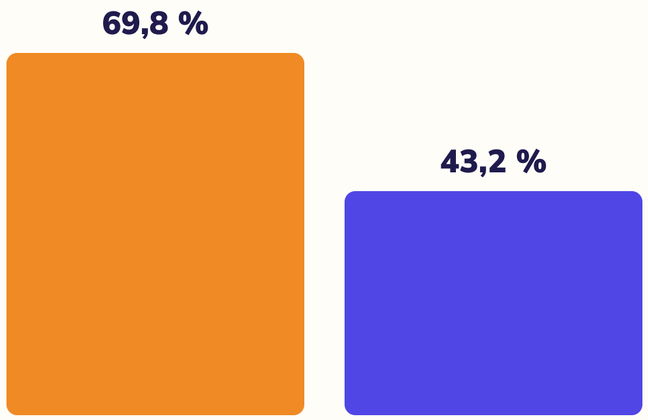
Qué da cada eje

Componente 1: la dirección con **más variación**.
Componente 2: perpendicular, la siguiente.

PCA no usa etiquetas: solo mira la forma de la nube. Aquí, el componente 1 recoge el 86,9 % de la variación de edad y gasto.

Escalar también aquí: si no, manda el gasto

Varianza del componente 1



El 1.º componente sin escalar parece más fuerte… pero solo mide el gasto.

Sin escalar

El componente 1 es **casi solo el gasto en euros** (carga 0,95).

Con **2** componentes ya llega al 90 %: es un **espejismo**.

Escalando (el cuaderno)

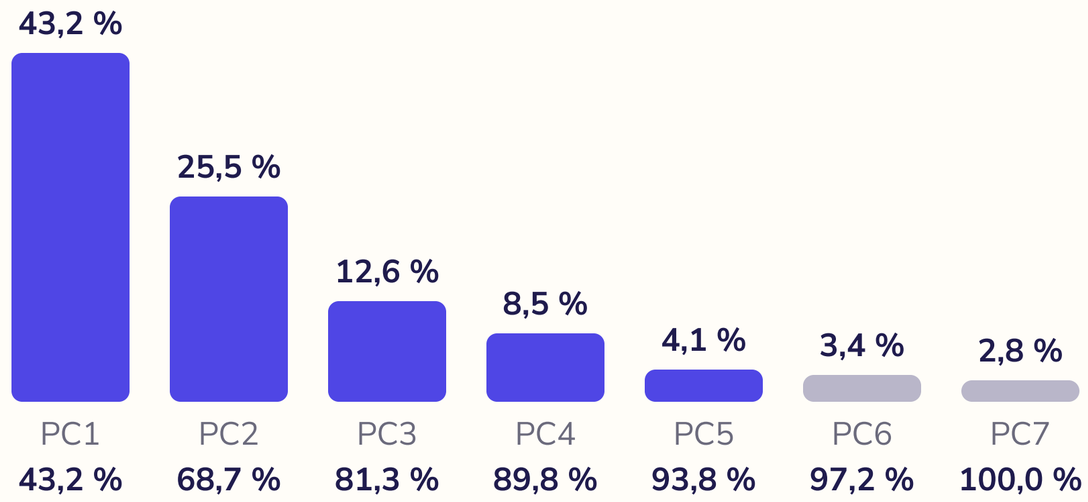
El componente 1 mezcla **edad, antelación, noches y % de actividades**.

Hacen falta **5** componentes para llegar al 90 %.

PCA busca **varianza**, y la varianza depende de las **unidades**. Misma regla que en el clustering: **escalar primero**.

Cuánta información conserva cada componente

Varianza explicada (arriba) y acumulada (debajo)



Los componentes van de más a menos información; las 7 barras suman el 100 %.

Cómo se lee

La **acumulada** suma de izquierda a derecha.

Para conservar el **90 %**, se coge el primer componente que lo supera.

En tu cuaderno

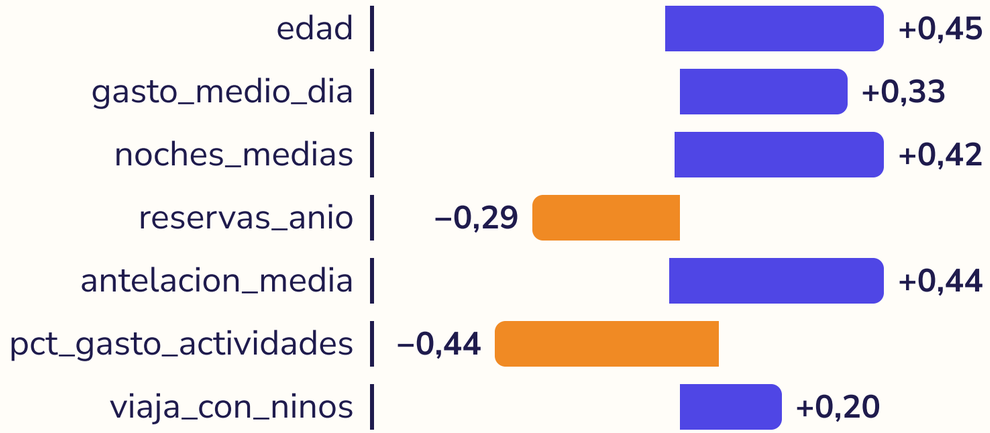
Con **5** componentes: **93,8 %** (con 4 se queda en 89,8 %).

Pasar de 7 a 5 variables es **un 29 % menos** conservando el 90 %.

Con 2 componentes se conserva el **68,7 %**: suficiente para **dibujar**, no siempre para **entrenar un modelo preciso**.

Un componente es una receta con ingredientes

Cargas del componente 1 (PC1)



Azul = sube con el componente · naranja = baja. El **signo** es arbitrario: importa qué variables **van juntas**.

Cada componente es una mezcla

PC1 = 0,45·edad + 0,33·gasto + 0,42·noches − 0,29·reservas + 0,44·antelación − 0,44·actividades + 0,20·niños.

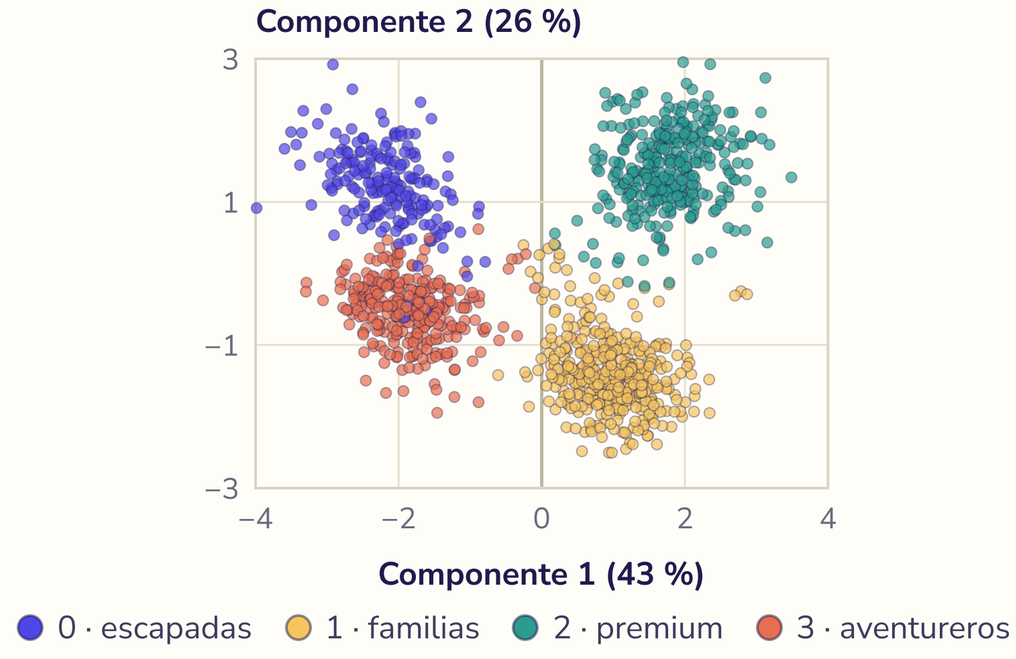
En lenguaje de negocio

PC1: «**mayor, planificador, de estancias largas**» frente a «**activo y viajero frecuente**».

Los mayores **reservan menos veces al año**.

2 · PCA · PARA QUÉ SIRVE

Dibujar en 2D… y agrupar con menos columnas



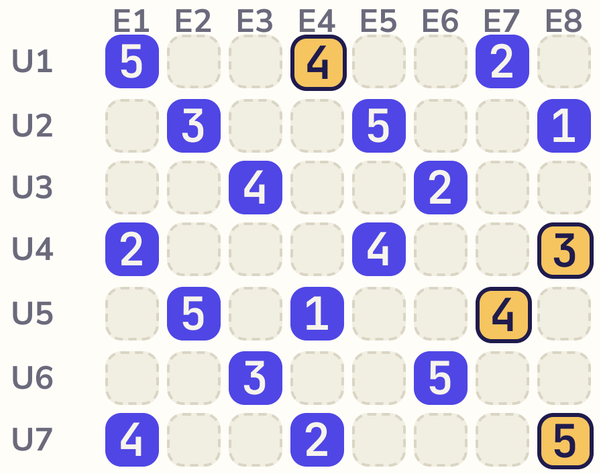
Una sombra

Con **2 componentes** se ve el 68,7 % de la información: **lo que ves es una sombra** de los datos.

Componentes	Información	Mismos grupos (ARI)
2	68,7 %	0,94
3	81,3 %	0,97
5	93,8 %	1,00
7 (todos)	100 %	1,00

ARI = cuánto coinciden los grupos con los originales: **1** = idénticos · **0** = como el azar. Con 5 componentes salen los **mismos 4 grupos**.

Una tabla casi vacía: adivinar los huecos



■ nota que se usa · ■ nota escondida (prueba) · □ casilla vacía

Cómo se lee

Cada fila es un **usuario**, cada columna una **experiencia** y cada casilla, su **nota de 1 a 5**.

Casi todas están **vacías**: nadie ha probado todo.

En TurisData

300 usuarios × 25 experiencias: solo el **24 %** de casillas tiene nota.

Se **esconde el 20 %** de las notas (doradas) para examinar.

Recomendar es adivinar las casillas vacías con lo que dicen las casillas llenas.

Dos medidas: error de nota y acierto de lista

RMSE: ¿cuánto se equivoca en la nota?

Nota real	Predicción	Error	Error²
5	4	−1	1
4	4	0	0
2	4	+2	4
3	2	−1	1

RMSE = √(6 ÷ 4) = **1,22 estrellas** · menos es mejor

precision@3: ¿acierta con la lista corta?

Recomendada	¿Le gustó?
8	sí
11	no
20	no

precision@3 = 1 ÷ 3 = **0,33** · más es mejor

El cliente **no ve notas: ve 3 sugerencias**. Se acierta si en la prueba le gustó (**4 estrellas o más**). Punto de partida: predecir siempre la media global (RMSE **1,275**) o recomendar **al azar** (precision@3 **0,081**).

De lo más simple a lo más personal

Método	La idea en una frase	¿Personaliza?	Su punto débil
Popularidad	Lo **mejor valorado**, para todos por igual	No	Misma lista para todos; sirve con un huésped **nuevo**
Contenido	Si te gusta el **mar**, más experiencias de mar	Sí	Descripción gruesa: no siempre mejora a la popularidad
Colaborativo	La **gente como tú** también valoró…	Sí	Con pocos datos, similitudes **ruidosas**
Factorización	**Gustos ocultos** que se aprenden de los datos	Sí	Demasiados gustos (k) → se ajusta al **ruido**

Colaborativo: item-item compara experiencias (columnas) y user-user compara usuarios (filas), con el coseno entre residuos.

Un **residuo** es la nota menos lo normal: así se compara a quien puntúa alto siempre con quien puntúa bajo siempre.

¿Quién gana? Los personalizados, por poco





Factorización gana en las dos medidas. **Contenido** pierde con la popularidad en RMSE (1,066 frente a 1,029).

Cambiar de medida cambia el orden, y 0,01 es ruido

El orden cambia

Contenido pierde con popularidad en RMSE, pero la supera en precision@3.

User-user es 2.º en RMSE y **3.º** en precision@3 (el 2.º es item-item).

Pocos usuarios, mucho ruido

Solo hay **115 usuarios evaluables**.

Una diferencia de **0,01** en precision@3 es **ruido**: no se la vendas al cliente.

Sesgo de popularidad

Con popularidad, las listas de los 300 usuarios usan solo **8 de las 25** experiencias.

Con item-item usan **18**: más variedad.

Elegir k (factorización)

Con k = 2, 3, 4 y 6 gustos el RMSE es **0,875 · 0,860 · 0,867 · 0,870**.

k = 3 es el mejor; con más, **empeora un poco**.

Mira **más de un número**, compara con un **punto de partida** y **desconfía** de lo pequeño.

Aprender probando: un botones en el pasillo

Pieza	En el hotel
Agente y entorno	El **botones virtual** y el pasillo del hotel
Estado	La **casilla** donde está (20 posibles)
Acción	Arriba, abajo, izquierda o derecha
Recompensa	**−1** por paso · **−5** en obras · **+10** al llegar a la habitación
Política	Qué hacer en **cada casilla**
Episodio	Una partida: de recepción a la habitación (o 50 pasos)

No hay respuesta correcta: el agente **prueba, recibe premios o castigos y aprende** qué le conviene.

El pasillo: 20 casillas, obras y una meta



Salida: casilla 0 (recepción) · el número pequeño es el estado

Dos caminos de 7 pasos

Por las obras: −7 − 5 + 10 = **−2**.

Rodeándolas: −7 + 10 = **+3**.

La meta

Llegar a la habitación con **la mayor recompensa total**, no solo llegar.

Al chocar con una pared, el botones **se queda donde está** y pierde 1.

El número pequeño de cada casilla es su **estado** (0 a 19). Salida: casilla 0, la recepción.

La tabla Q: cuánto espero ganar si hago esto aquí

Una actualización de ejemplo

Q[s, a] antes	2,00
recompensa r del paso	-1,00
mejor futuro: max Q[s']	5,00
objetivo = r + gamma · max Q[s'] (gamma 0,95)	-1 + 0,95 · 5 = 3,75
Q nuevo = antes + alpha · (objetivo – antes) (alpha 0,2)	**2,00 + 0,2 · 1,75 = 2,35**

alpha (0 a 1)

Velocidad de aprendizaje: alto, se cree lo último; bajo, cambia despacio.

gamma (0 a 1)

Cuánto importa el futuro. Con 0, solo mira la recompensa inmediata.

Q empieza en ceros

20 filas × 4 columnas: una por casilla y acción.

A veces hay que probar algo al azar

epsilon	Qué hace el agente	Consecuencia
0,0	Siempre la **mejor acción que conoce**	**Nunca descubre** caminos mejores
0,2 (por defecto)	**1 de cada 5** pasos, al azar	**Aprende** y sigue explorando
1,0	**Siempre al azar**	**Nunca aprovecha** lo aprendido

Con pasos gratis (coste 0)

Sin explorar, epsilon 0: recompensa media **0,0** (se queda parado).

Explorando, epsilon 0,3: **9,1**.

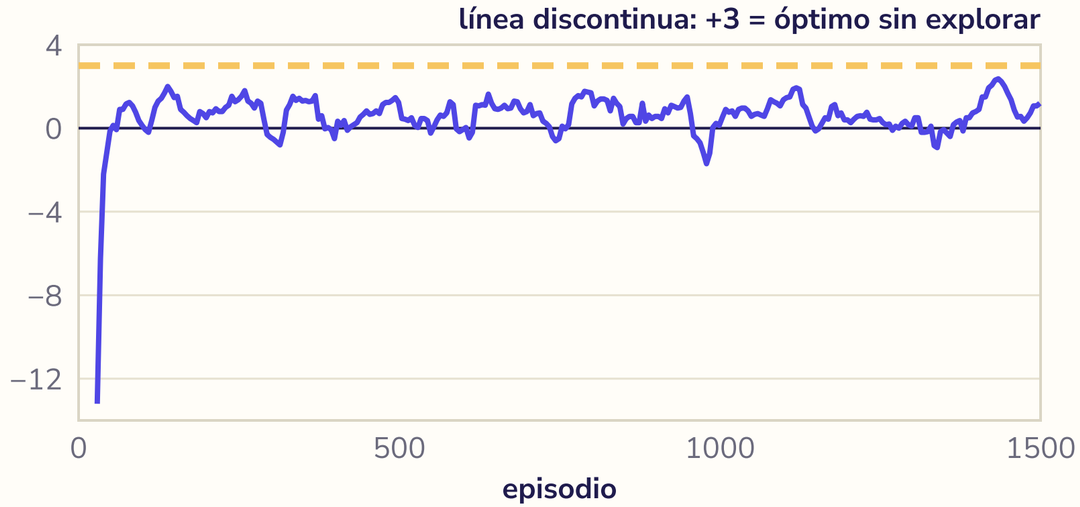
Mirando solo el premio inmediato

Con gamma = 0, el agente ignora el futuro: **−49,5** de recompensa media.

Epsilon-greedy: casi siempre lo mejor conocido y, de vez en cuando, una prueba.

1 500 partidas y la recompensa mejora

Recompensa total por episodio (media móvil de 30)



−8,0 → 0,9

recompensa media: primeros 50 → últimos 50 episodios

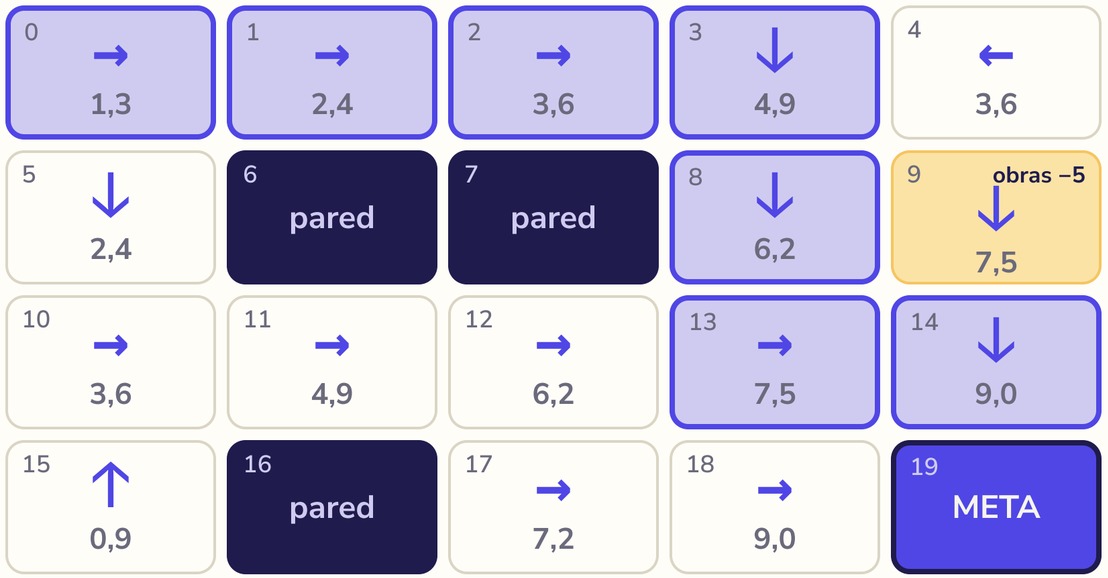
Aprende pronto

Desde el episodio **26** la política **sin explorar** ya es la óptima: **+3**.

¿Por qué no llega a +3?

Con epsilon 0,2, **1 de cada 5 pasos es al azar** durante el entrenamiento.

La política: qué hacer en cada casilla



Flecha = mejor acción · número = valor de la casilla (max Q) · recuadro = camino aprendido

El camino aprendido

0 → 1 → 2 → 3 → 8 → 13 → 14 → 19.

7 pasos y +3: evita las obras y llega a la habitación.

Cómo se lee

Flecha = la mejor acción de cada casilla.

Número = lo que vale estar ahí (max Q).

La política **sale de la tabla Q**: en cada casilla, la acción con el valor más alto.

Recompensa mal diseñada, conducta no deseada

Cambio de reglas en las obras	Camino aprendido (sin explorar)	Recompensa	¿Llega?
−5 (las reglas originales)	Rodea las obras, 7 pasos	+3	**Sí**
−20 (reclamaciones)	El mismo camino	+3	**Sí**
+5 (una «recompensa» por pasar)	Llega a las obras **y se queda en ellas**	+180	**No**

El agente hace lo que **maximiza la recompensa**, no lo que **nosotros queríamos**. Con +5 en las obras, **se queda cobrando**.

Misma lección que en las métricas: **lo que medimos** es lo que el sistema acaba optimizando.

QUÉ ALGORITMO USO

Según lo que tengas y lo que busques

Tengo…	Familia	Algoritmos del curso
Un **número** que predecir	Regresión	Lineal y polinómica, Ridge y Lasso, árboles, Random Forest, boosting
Una **categoría** (sí o no, tipo)	Clasificación	Logística, k-NN, Naive Bayes, árboles, SVM, boosting
Datos **sin etiqueta**	No supervisado	**Clustering** para agrupar, **PCA** para resumir
Gustos de usuarios y productos	Recomendación	Popularidad, contenido, colaborativo, factorización
Decisiones en secuencia con premios	Refuerzo	**Q-learning**

Empieza por lo simple y complica solo si la validación lo justifica.

Las filas de arriba (S07 y S08) y las de abajo (S09) forman el **mapa completo** del aprendizaje automático clásico.

MAPA FINAL

Idea, cómo sabes si funciona y la trampa típica

Idea	Cómo sabes si funciona	La trampa típica
Clustering	**Silueta** media y el perfil de cada grupo	No **escalar**; ponerle nombre sin mirar el perfil
PCA	**Varianza acumulada** (90 %) y el ARI	No escalar; creer que **2 componentes** lo cuentan todo
Recomendadores	**RMSE** y **precision@k** frente a un punto de partida	Fiarse de **0,01** de diferencia; olvidar el arranque en frío
Q-learning	**Recompensa** por episodio y el camino aprendido	Una **recompensa** mal diseñada; no explorar

Sin etiqueta no hay «acierto»: la calidad se juzga con medidas propias, con un punto de partida y con sentido común.

PARA LLEVARSE

Lo que tienes que poder decir

Clustering

Escala primero; elige k con la **silueta**; **nombra** cada grupo.

PCA

Ejes nuevos con la **varianza explicada**. **2 componentes = una sombra**.

Recomendadores

Adivina las **casillas vacías**. Compara con la **popularidad**.

Refuerzo

Probar y recibir premios. La **recompensa** define el comportamiento.

Los detalles, en las presentaciones S09_01 a S09_04 y en los cuadernos.