IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Agrupar huéspedes sin etiquetas

Teoría, práctica y, al final, material de consulta

Sprint 9 · S09_01 · teoría breve (20 min el 13/11), 45 min de práctica en clase y material de consulta

LA IDEA · APRENDER SIN RESPUESTAS

Aquí nadie dice el grupo de cada huésped

TurisData tiene **1 200 huéspedes** y les manda a todos la misma newsletter. Dirección pregunta: ¿hay grupos parecidos entre sí y merece la pena tratarlos distinto? De cada huésped sabemos 7 cosas: edad, gasto diario, noches, reservas al año, antelación, % de gasto en actividades y si viaja con niños.

Supervisado

Hay una columna objetivo (**cancelada**). El modelo aprende a predecirla.

No supervisado

No hay objetivo. El algoritmo **descubre estructura**: grupos (clustering) o ejes de variación (PCA, el cuaderno siguiente).

El trabajo no acaba con el algoritmo: hay que ponerle nombre y acción comercial a cada grupo.

LA IDEA · ESCALAR PRIMERO

El clustering agrupa por distancia

Si el gasto va en euros y **viaja_con_ninos** vale 0 ó 1, **la columna grande manda** y la pequeña no cuenta. Ejemplo: cuánto aporta cada columna a la distancia entre los huéspedes 1 y 2 del fichero.

Columna	Huésped 1	Huésped 2	Aporta sin escalar	Aporta escalando
antelacion_media	24	115	91,8 %	41,5 %
edad	26	41	2,5 %	10,3 %
viaja_con_ninos	0	1	0,01 %	30,1 %
otras 4 columnas	…	…	5,7 %	18,1 %

Solución: estandarizar (restar la media y dividir por la desviación típica). Todas las columnas quedan con media 0 y desviación 1.

LA IDEA · K-MEANS

Centros que se mueven hasta quedarse quietos

Tú eliges **k**. El algoritmo coloca **k** centros, **asigna** cada huésped al más cercano, **recalcula** los centros como la media de su grupo y repite. Ejemplo con 6 edades y k = 2:

Ronda	Centros A / B	Edades en A	Edades en B
1 · centros iniciales	21 / 33	21 · 24	33 · 50 · 54 · 58
2 · se recalculan	22,5 / 48,75	21 · 24 · 33	50 · 54 · 58
3 · se recalculan	26 / 54	21 · 24 · 33	50 · 54 · 58

En la ronda 3 no cambia nadie: fin

Con otros datos, otros grupos. ¿Es 2 el número bueno de grupos? Hace falta una medida: la silueta.

La silueta: ¿encaja cada huésped en su grupo?

Para cada huésped se compara **a** (lo lejos que está, de media, de los de su grupo) con **b** (lo lejos que está del grupo vecino). Va de −1 a 1.

Huésped (números inventados)	a	b	silueta (b − a) / máx(a, b)
Bien situado: lejos del vecino	1,0	2,5	0,6
En la frontera	2,0	2,0	0
Mal situado: más cerca del vecino	2,5	1,0	−0,6

Cómo se lee la silueta media

Más de **0,5**: buena estructura. Entre **0,25 y 0,5**: aceptable. Cuanto más alta, grupos más compactos y separados.

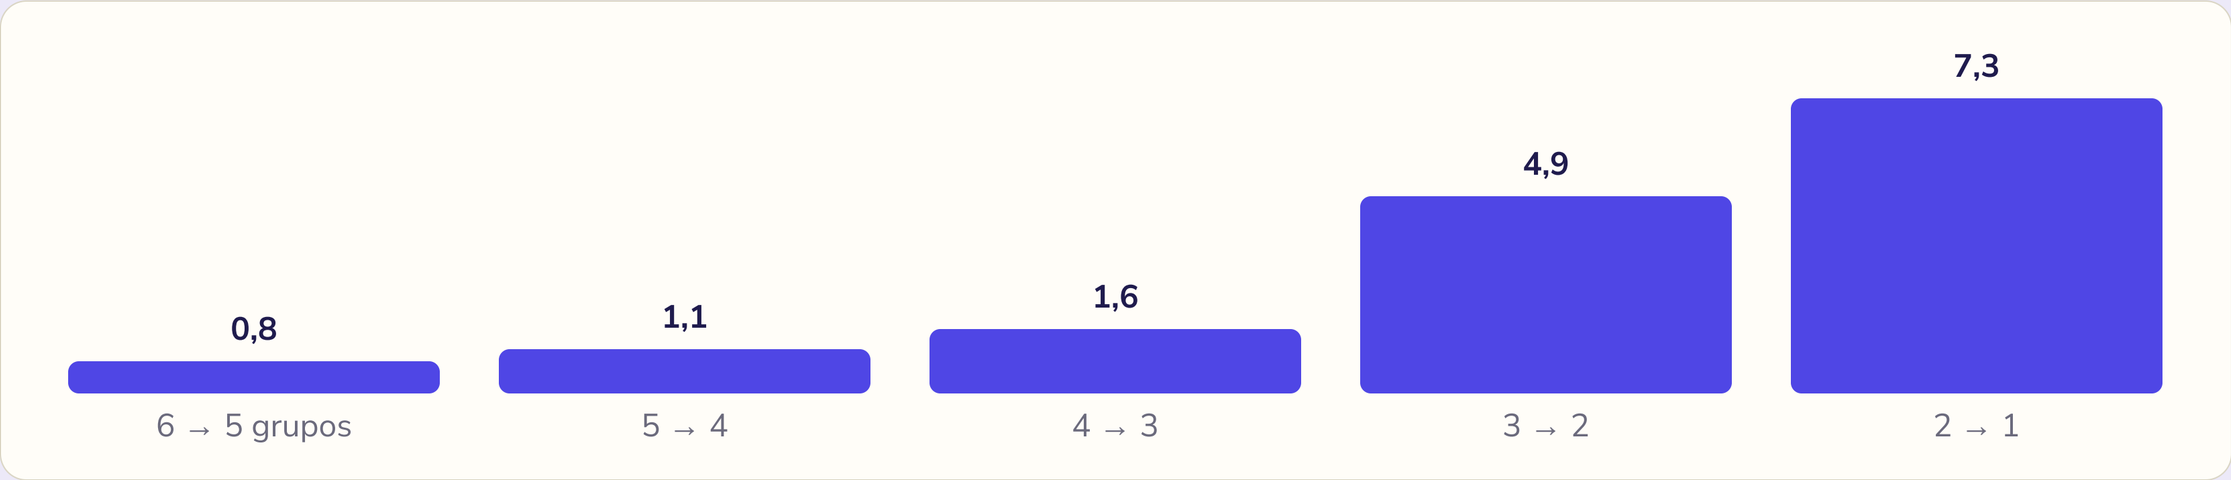
Cuántos grupos

Se prueban varios **k** y se elige el de **silueta media más alta**. Si dos casi empatan, decide el negocio.

JERÁRQUICO

Un árbol de parecidos: el dendrograma

Cada huésped empieza solo y se **fusionan los dos grupos más parecidos**, paso a paso. Altura de cada fusión en un ejemplo pequeño:



Se corta antes del salto grande: juntar 3 grupos en 2 cuesta 4,9, el triple que el paso anterior (1,6). Se queda en 3 grupos.

DBSCAN

Grupos por densidad, y el ruido

No se dice cuántos grupos. Un grupo es una **zona densa**: **eps** es el radio de vecindad y **min_samples** cuántos vecinos hacen falta. Lo que queda fuera es **ruido** (etiqueta −1).

Radio **eps**	Qué pasa
Muy pequeño	Casi nadie tiene vecinos: **casi todo es ruido**
Intermedio	Zonas densas separadas y **algo de ruido**
Muy grande	Todo se junta en **uno o dos grupos**

Útil para detectar casos raros, pero sensible a eps: se prueban varios valores.

PRÁCTICA · CUADERNO S09_01

Lo que haremos en el cuaderno

Parte	Qué haremos	Dónde
Preparación	Cargar los 1 200 huéspedes y ver las escalas	Clase
Ejercicio 1	Estandarizar todas las columnas	Clase
Ejemplo	k-means con k = 3	Clase
Ejercicio 2	Elegir k con la silueta, de 2 a 8	Clase
Ejercicio 3	Familias y aventureros (con perfil y mapa de calor)	Casa
Ejercicio 4	Clustering jerárquico con 4 grupos	Casa
Ejercicio 5	DBSCAN con eps = 1,0	Casa
Mini-reto	Ponle nombre a tus segmentos	Casa

Cada ejercicio: **lee** → **escribe** → **ejecuta** → **comprueba el ✔**. La solución está plegada: ábrela tras intentarlo.

CONSULTA

Material de consulta: código y aclaraciones

Cuándo abrirlo

Después de intentar el ejercicio, o cuando algo no te salga. En clase no se proyecta.

Cómo está ordenado

En el **mismo orden que el cuaderno**: ejercicios 1 a 5 y mini-reto. Cada uno trae su código y sus aclaraciones.

Ejercicio	Tema	Diapositivas
1	Estandarizar las columnas	10 y 11
2	Elegir k con la silueta	12 y 13
3	Familias y aventureros	14 y 15
4	Clustering jerárquico	16 y 17
5	DBSCAN	18 y 19
Mini-reto	Ponle nombre a tus segmentos	20 y 21

CONSULTA · EJERCICIO 1

Estandarizar todas las columnas (ejercicio 1)

```
variables = [c for c in huespedes.columns if c not in ("id_huesped", "grupo")]
X = StandardScaler().fit_transform(huespedes[variables])
X.shape    # (1200, 7)
```

1 200 × 7

matriz X

media 0 · desviación 1

cada columna

Antes, **edad** variaba 12,1 y **gasto_medio_dia** 60,9: ahora todas pesan igual.

CONSULTA · ACLARACIONES · EJERCICIO 1

Leer la matriz estandarizada (ejercicio 1)

Por qué se quita **id_huesped**

Es solo un número de identificación: **no describe el comportamiento**. Si se deja, se agruparía por un número sin significado.

fit_transform(...) devuelve una matriz

Un array de NumPy de 1200 × 7, **sin nombres de columna**: los nombres se guardan aparte en **variables**.

Media 0, desviación 1

Cada columna de **X**: lo comprueba el **assert**. 0 es «en la media» y 1, «una desviación por encima».

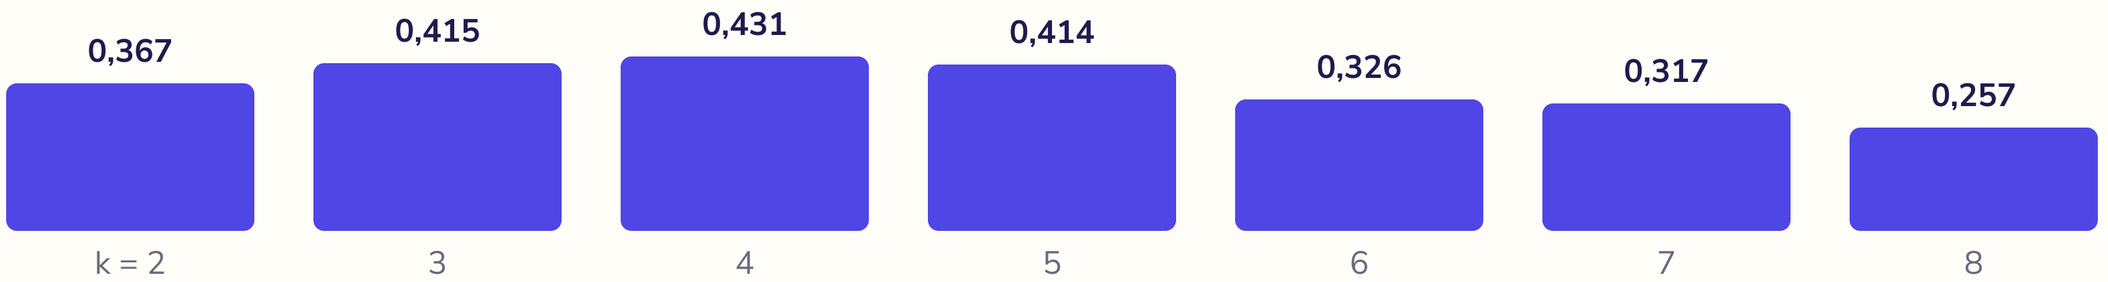
Para el clustering

Todas las variables pesan lo mismo al calcular distancias, sea cual sea la unidad. Ejemplo: 53 años con media 41,2 y desviación 12,1 → **+1,0**.

CONSULTA · EJERCICIO 2

Elegir k con la silueta (ejercicio 2)

```
for k in range(2, 9):
    etiquetas = KMeans(n_clusters=k, n_init=10, random_state=SEMILLA).fit_predict(X)
    siluetas[k] = silhouette_score(X, etiquetas)
k_mejor = max(siluetas, key=siluetas.get)    # 4
```



La mejor es k = 4, con silueta 0,431: estructura aceptable.

CONSULTA · ACLARACIONES · EJERCICIO 2

Leer la silueta de cada k (ejercicio 2)

key=siluetas.get

max(siluetas) compara las **claves** (2 a 8) y daría 8. Con **key=siluetas.get** compara los **valores**.

random_state=SEMILLA

k-means empieza con centros al azar: con la misma semilla **todos obtienen los mismos grupos**.

0,431: aceptable

Entre 0,25 y 0,5: hay grupos, pero no muy separados. Con **k = 3, 4 y 5** (0,415 · 0,431 · 0,414) casi empatan: puede decidir el negocio.

A partir de k = 6

La silueta **cae** (0,326 · 0,317 · 0,257): se parten grupos que eran uno solo.

CONSULTA · EJERCICIO 3

Familias y aventureros (ejercicio 3)

```
grupo_familias = huespedes.groupby("grupo")["viaja_con_ninos"].mean().idxmax()          # 1
grupo_aventura = huespedes.groupby("grupo")["pct_gasto_actividades"].mean().idxmax()    # 3
```

Grupo	Huéspedes	Edad	Gasto/día	Noches	Con niños	% en actividades	Nombre posible
0	194	34,6	120,4 €	2,6	0,1	41,2	Escapadas cortas
1	402	40,3	95,2 €	7,4	0,9	26,0	Familias
2	317	57,2	211,4 €	8,1	0,0	20,0	Descanso premium
3	287	29,3	71,2 €	6,1	0,0	74,6	Aventureros

El grupo 1 son las familias (0,9 con niños) y el 3, los aventureros (74,6 % en actividades).

CONSULTA · ACLARACIONES · EJERCICIO 3

Leer el perfil de los grupos (ejercicio 3)

.idxmax(), no .max()

.max() da **el valor** más alto (0,91); **.idxmax()** da **el grupo** donde está (1). Aquí queremos el grupo.

KeyError: 'grupo'

Falta el ejemplo del perfil, que crea la columna **grupo**. Repetir esa celda no la duplica.

Mapa de calor

Cada casilla son desviaciones típicas sobre (rojo) o bajo (azul) la media. Grupo 1: niños **+1,2** · grupo 2: edad **+1,3** y gasto **+1,4** · grupo 3: actividades **+1,5**.

El grupo 0

Estancias cortas (noches −1,7), **última hora** (antelación −1,5) y **muchas reservas** (+1,2). Los otros grupos con niños: 0,06 · 0,02 · 0,05.

CONSULTA · EJERCICIO 4

Clustering jerárquico con 4 grupos (ejercicio 4)

```
etiquetas_jer = AgglomerativeClustering(n_clusters=4, linkage="ward").fit_predict(X)
silueta_jer = silhouette_score(X, etiquetas_jer)    # 0.424
```

0,424

silueta jerárquico

0,431

silueta k-means (k = 4)

Grupos de 414, 192, 307 y 287 huéspedes: casi equivalentes a los de k-means.

CONSULTA · ACLARACIONES · EJERCICIO 4

Leer el jerárquico y el dendrograma (ejercicio 4)

n_clusters=4, linkage="ward"

Une primero los grupos que menos aumentan la dispersión. Hay que usar **X** (escalada) para la silueta.

Muestra de 150

Con 1 200 hojas el dendrograma sería **ilegible**: la muestra basta para ver la estructura.

0,424 frente a 0,431

K-means gana por muy poco: en la práctica son **equivalentes**. El jerárquico da el dendrograma, a cambio de ser **más lento**.

Dendrograma

4 ramas de color. Las tres últimas fusiones están muy arriba (17,5 · 20,4 · 29,3) y la anterior en 8,7: se unen grupos **muy distintos**, así que se corta antes.

CONSULTA · EJERCICIO 5

DBSCAN con eps = 1,0 (ejercicio 5)

```
etiquetas_db = DBSCAN(eps=1.0, min_samples=10).fit_predict(X)
n_grupos_db = len(set(etiquetas_db)) - (1 if -1 in etiquetas_db else 0)    # 5
n_ruido = int((etiquetas_db == -1).sum())                                  # 149
```

5

grupos encontrados

149 (12 %)

huéspedes atípicos (ruido)

eps (min_samples = 10)	0,6	0,8	1,0	1,2	1,5
Grupos encontrados	4	4	**5**	3	2
Huéspedes como ruido	94 %	38 %	**12 %**	4 %	2 %

CONSULTA · ACLARACIONES · EJERCICIO 5

Leer DBSCAN y el ruido (ejercicio 5)

Por qué se resta 1

La etiqueta **−1 no es un grupo**: es el cajón del ruido. Si aparece, hay que descontarla al contar grupos.

n_ruido

Cuenta los huéspedes con etiqueta −1 con **(etiquetas_db == -1).sum()**: no las etiquetas distintas.

5 grupos y 149 atípicos

El 12,4 % de los huéspedes no entra en ningún grupo. Con **eps = 1,0** sale el mayor número de grupos.

Un grupo de 11 huéspedes

Los cinco tienen 352 · 260 · 153 · 275 · 11. El pequeño puede ser un **nicho real** o un trozo de otro: **mírelo antes de actuar**.

CONSULTA · MINI-RETO

Ponle nombre a tus segmentos (mini-reto)

```
nombres_segmentos = {0: "Escapadas cortas", 1: "Familias",
                     2: "Descanso premium", 3: "Aventureros"}
```

Grupo	Huéspedes	Qué lo define	Acción comercial
0 · Escapadas cortas	194	2,6 noches, última hora, muchas reservas	Oferta de última hora
1 · Familias	402	Niños (0,9), antelación de 110 días	Paquetes con actividades para niños
2 · Descanso premium	317	57 años, 211 € al día	Servicios premium
3 · Aventureros	287	29 años, 75 % en actividades	Excursiones y deportes

Los nombres salen del perfil, no de una intuición previa.

CONSULTA · ACLARACIONES · MINI-RETO

Leer los segmentos (mini-reto, casa)

Grupo 3: «Aventureros»

El más joven (29 años), con el **75 %** del gasto en actividades y poco gasto al día (–0,9 desviaciones).

nombres_segmentos

Debe tener **tantas claves como k_mejor** (4). Los nombres y las acciones van en una celda de texto: no se autocorrigen.

Acción para «Familias»

402 huéspedes: **paquetes con actividades para niños** y reserva anticipada (reservan con 110 días).

Por qué el perfil manda

Los grupos los han creado los **datos**: un nombre solo vale si describe lo que hay en el grupo (tamaño, edad, gasto…).