IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Agrupar huéspedes sin etiquetas

Escalar, k-means, silueta, clustering jerárquico y DBSCAN con los 1 200 huéspedes de TurisData

Sprint 9 · S09_01 · cuaderno: 45 min en clase (ejercicios 1 y 2)

LA IDEA · APRENDER SIN RESPUESTAS

Aquí nadie dice el grupo de cada huésped

TurisData tiene **1 200 huéspedes** y les manda a todos la misma newsletter. Dirección pregunta: ¿hay grupos parecidos entre sí y merece la pena tratarlos distinto? De cada huésped sabemos 7 cosas: edad, gasto diario, noches, reservas al año, antelación, % de gasto en actividades y si viaja con niños.

Supervisado

Hay una columna objetivo (**cancelada**). El modelo aprende a predecirla.

No supervisado

No hay objetivo. El algoritmo **descubre estructura**: grupos (clustering) o ejes de variación (PCA, el cuaderno siguiente).

El trabajo no acaba con el algoritmo: hay que ponerle nombre y acción comercial a cada grupo.

LA IDEA · ESCALAR PRIMERO

El clustering agrupa por distancia

Si el gasto va en euros y **viaja_con_ninos** vale 0 ó 1, **la columna grande manda** y la pequeña no cuenta. Ejemplo: cuánto aporta cada columna a la distancia entre los huéspedes 1 y 2 del fichero.

Columna	Huésped 1	Huésped 2	Aporta sin escalar	Aporta escalando
antelacion_media	24	115	91,8 %	41,5 %
edad	26	41	2,5 %	10,3 %
viaja_con_ninos	0	1	0,01 %	30,1 %
otras 4 columnas	…	…	5,7 %	18,1 %

Solución: estandarizar (restar la media y dividir por la desviación típica). Todas las columnas quedan con media 0 y desviación 1.

LA IDEA · K-MEANS

Centros que se mueven hasta quedarse quietos

Tú eliges **k**. El algoritmo coloca **k** centros, **asigna** cada huésped al más cercano, **recalcula** los centros como la media de su grupo y repite. Ejemplo con 6 edades y k = 2:

Ronda	Centros A / B	Edades en A	Edades en B
1 · centros iniciales	21 / 33	21 · 24	33 · 50 · 54 · 58
2 · se recalculan	22,5 / 48,75	21 · 24 · 33	50 · 54 · 58
3 · se recalculan	26 / 54	21 · 24 · 33	50 · 54 · 58

```
km3 = KMeans(n_clusters=3, n_init=10,
             random_state=SEMILLA).fit(X)
np.bincount(km3.labels_)    # [317 480 403]
```

En la ronda 3 no cambia nadie: fin

Con k = 3 en el cuaderno salen grupos de **317, 480 y 403** huéspedes. ¿Es 3 el número bueno? Hace falta una medida.

La silueta: ¿encaja cada huésped en su grupo?

Para cada huésped se compara **a** (lo lejos que está, de media, de los de su grupo) con **b** (lo lejos que está del grupo vecino). Va de −1 a 1.

Huésped (números inventados)	a	b	silueta (b − a) / máx(a, b)
Bien situado: lejos del vecino	1,0	2,5	0,6
En la frontera	2,0	2,0	0
Mal situado: más cerca del vecino	2,5	1,0	−0,6

Cómo se lee la silueta media

Más de **0,5**: buena estructura. Entre **0,25 y 0,5**: aceptable. Cuanto más alta, grupos más compactos y separados.

0,431

silueta media con k = 4 en TurisData: estructura aceptable

EJERCICIO 1 · CUADERNO (CLASE)

Estandarizar todas las columnas

```
variables = [c for c in huespedes.columns
             if c not in ("id_huesped", "grupo")]
X = StandardScaler().fit_transform(huespedes[variables])
X.shape    # (1200, 7)
```

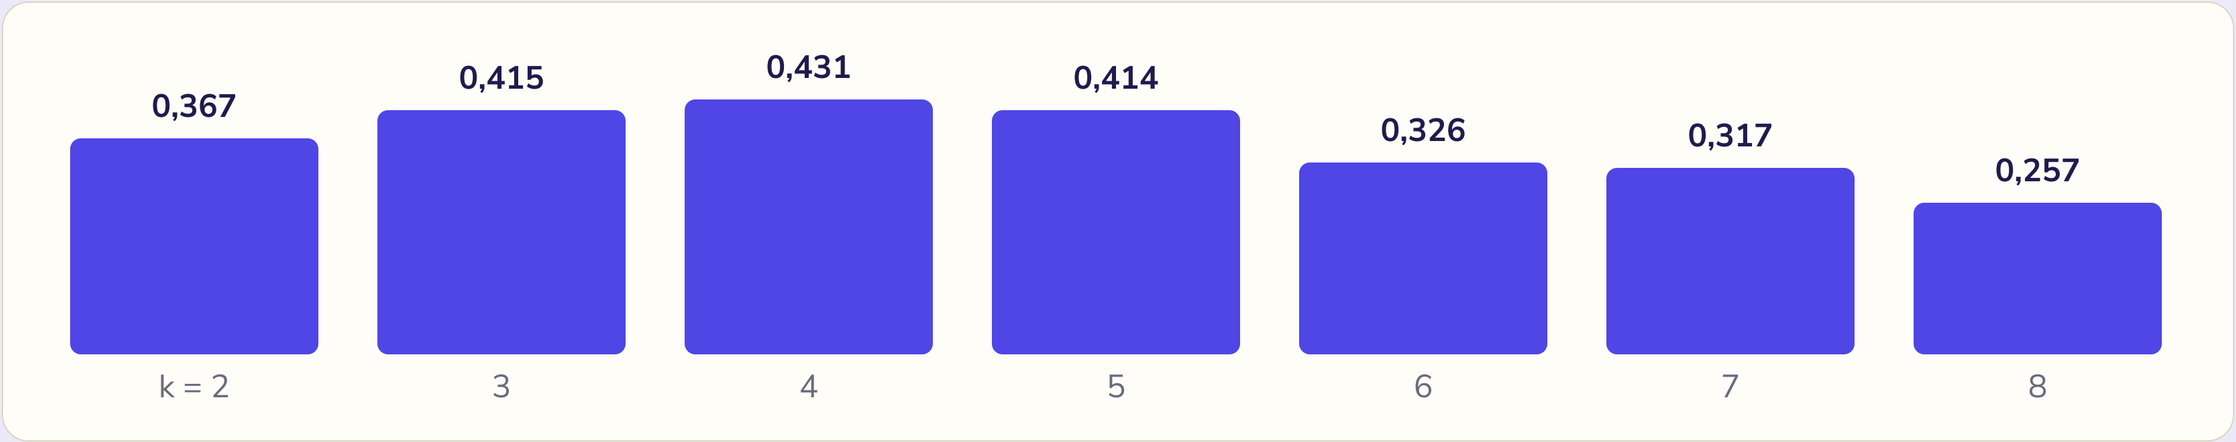
Columna	Desv. típica antes	Después
edad	12,1	1
gasto_medio_dia	60,9	1
antelacion_media	36,5	1
viaja_con_ninos	0,47	1

Una matriz sin id ni grupo

X tiene **1 200 filas y 7 columnas**: sin **id_huesped** y sin la columna **grupo**, que aparece más abajo.

EJERCICIO 2 · CUADERNO (CLASE)

Elegir k con la silueta, de 2 a 8




```
for k in range(2, 9):
    et = KMeans(n_clusters=k, n_init=10,
                random_state=SEMILLA).fit_predict(X)
    siluetas[k] = silhouette_score(X, et)
k_mejor = max(siluetas, key=siluetas.get)    # 4
```

k = 4

silueta con k = 4: el máximo. k = 3 y k = 5 casi empatan.

INTERPRETAR · EJERCICIO 3 (CASA)

¿Quién es cada grupo?

Grupo	Huéspedes	Edad	Gasto/día	Noches	Con niños	% en actividades	Nombre posible
0	194	34,6	120,4 €	2,6	0,1	41,2	Escapadas cortas
1	402	40,3	95,2 €	7,4	0,9	26,0	Familias
2	317	57,2	211,4 €	8,1	0,0	20,0	Descanso premium
3	287	29,3	71,2 €	6,1	0,0	74,6	Aventureros

```
perfil = huespedes.groupby("grupo")[variables].mean()
grupo_familias = perfil["viaja_con_ninos"].idxmax()          # 1
grupo_aventura = perfil["pct_gasto_actividades"].idxmax()    # 3
```

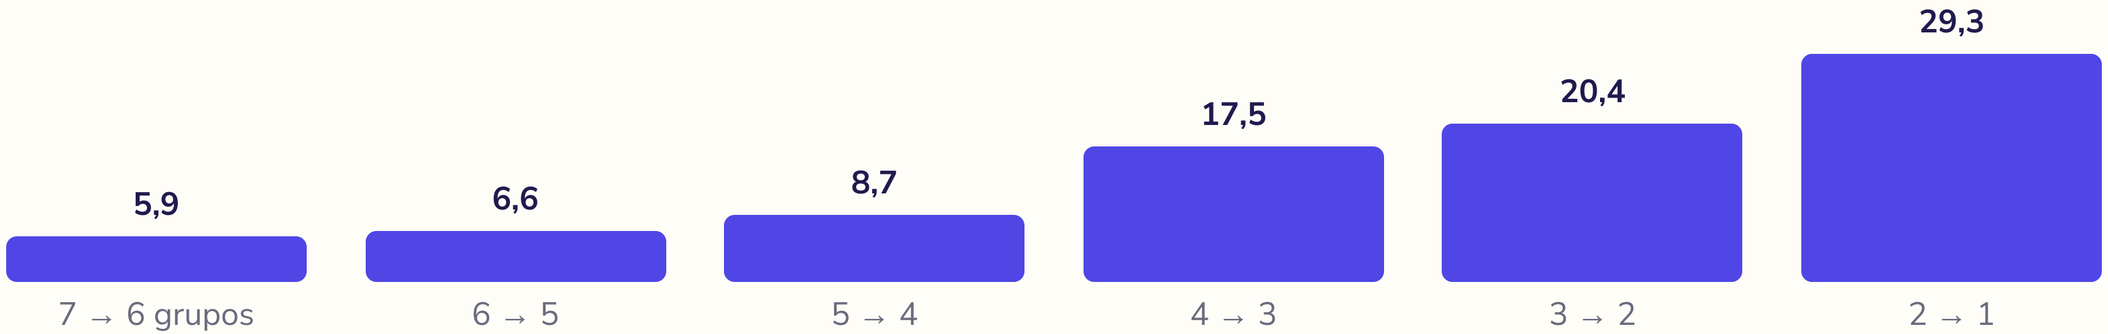
Léelo como un cliente típico

Un grupo sin nombre no sirve al negocio. Cambiar la semilla puede cambiar el **número** del grupo, no su significado.

JERÁRQUICO · EJERCICIO 4 (CASA)

Un árbol de parecidos: el dendrograma

Cada huésped empieza solo y se **fusionan los dos grupos más parecidos**, paso a paso. Altura de cada fusión en una muestra de 150 huéspedes (**ward**):




```
jer = AgglomerativeClustering(
    n_clusters=4, linkage="ward")
etiquetas_jer = jer.fit_predict(X)
```

Se corta antes del salto grande

Juntar 4 grupos en 3 cuesta 17,5, el **doble** que el paso anterior: se corta con 4 grupos. Silueta: **0,424** (k-means 0,431).

DBSCAN · EJERCICIO 5 (CASA)

Grupos por densidad, y el ruido

No se dice cuántos grupos. Un grupo es una **zona densa**: **eps** es el radio de vecindad y **min_samples** cuántos vecinos hacen falta. Lo que queda fuera es **ruido** (etiqueta −1).

eps (min_samples = 10)	0,6	0,8	1,0	1,2	1,5
Grupos encontrados	4	4	**5**	3	2
Huéspedes como ruido	94 %	38 %	**12 %**	4 %	2 %

```
db = DBSCAN(eps=1.0, min_samples=10)
etiquetas_db = db.fit_predict(X)
n_ruido = int((etiquetas_db == -1).sum())    # 149
```

Útil para casos raros, sensible a eps

Con **eps = 1,0**: **5 grupos** y **149 atípicos**. Uno de los 5 grupos tiene solo 11 huéspedes.

MINI-RETO · CUADERNO (CASA)

Tres métodos, una decisión de negocio

Método	¿Dices cuántos grupos?	En TurisData	Para qué sirve
k-means	Sí: **k**	4 grupos · silueta 0,431	Rápido y fácil de explicar a dirección
Jerárquico	Sí, al cortar el árbol	4 grupos · silueta 0,424	Ver cómo se juntan los grupos
DBSCAN	No: **eps** y **min_samples**	5 grupos · 12 % de ruido	Detectar clientes raros

Tu mini-reto

Elige un método y justifícalo en una frase. Para cada grupo: **nombre**, **descripción de una línea** y **acción comercial**. Alimenta el reto «Conocer al huésped».

Para pensar

Un segmento «familias» sale de datos de comportamiento, no de una etiqueta oficial. ¿Qué riesgos hay si se usa para decidir a quién se ofrecen descuentos?

HOY HAS APRENDIDO

Agrupar sin etiquetas y ponerle nombre

Escalar y elegir k

Se escala antes de medir distancias; k-means pide **k** y la silueta ayuda a elegirlo (aquí **4**)

Tres métodos

k-means (rápido), jerárquico (dendrograma) y DBSCAN (densidad y **ruido**)

El negocio decide

Un segmento solo sirve con **nombre, tamaño y acción**

Siguiente: S09_02 · PCA, ver los grupos en un mapa de 2D