IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Siete variables, un mapa de 2D

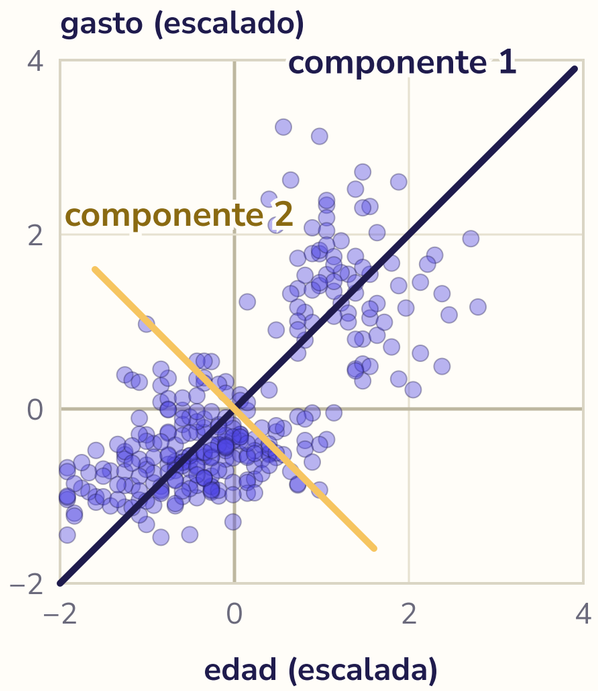
Teoría, práctica y, al final, material de consulta

Sprint 9 · S09_02 · teoría breve (10 min el 13/11), 30 min de práctica en clase y material de consulta

LA IDEA · EJES NUEVOS

Un eje a lo largo de la nube

300 de 1 200 huéspedes · solo edad y gasto



Una nube con forma de puro se describe mejor con un **eje a lo largo del puro** que con los ejes de la habitación.

PCA busca esos ejes

El **componente 1** es la dirección con más variación; el **2**, perpendicular, la siguiente… Cada uno es una **mezcla** de las variables y trae su % de **varianza explicada**.

86,9 %

de la variación de edad y gasto cabe en el componente 1

LA IDEA · ESCALAR ANTES

PCA busca varianza, y depende de las unidades

Si no se escala, el gasto en euros decide casi todo: tiene los números más grandes. Comparación con los 1 200 huéspedes:

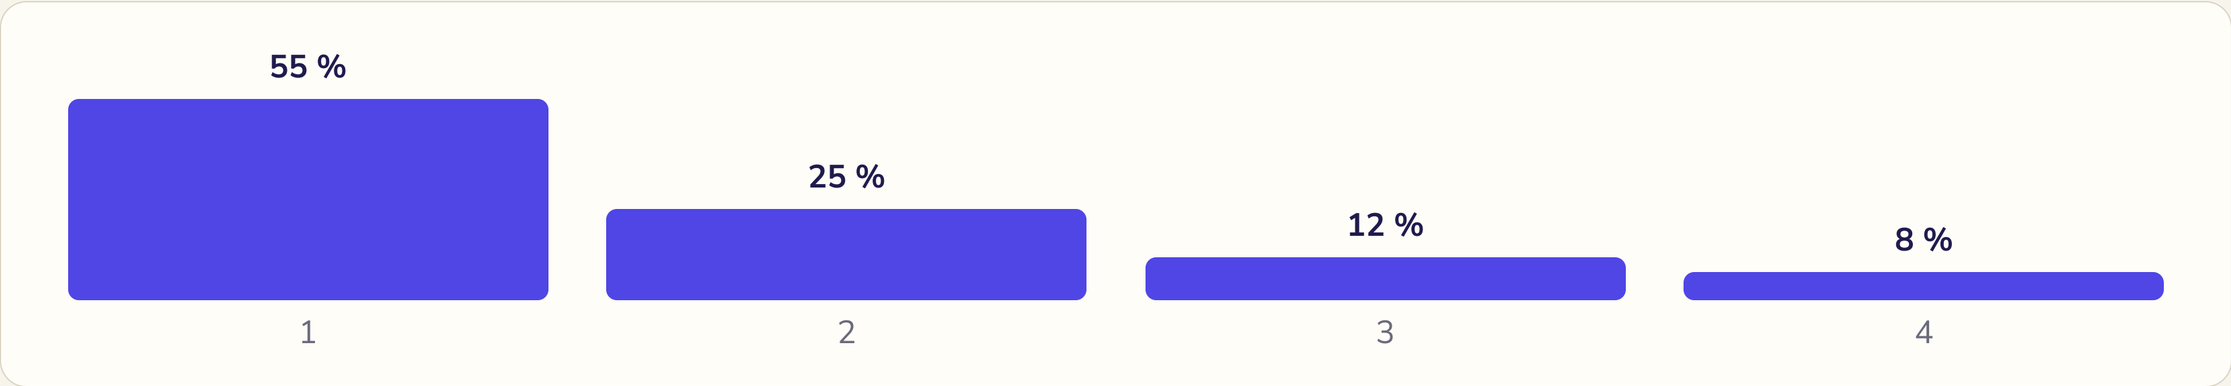
	Sin escalar	Escalando (cuaderno)
Componente 1: varianza explicada	69,8 %	43,2 %
Variable que lo domina	`gasto_medio_dia` (carga 0,95)	Mezcla de edad, antelación, noches y % de actividades (cargas de 0,42 a 0,45)
Componentes para llegar al 90 %	2	5

Que 2 componentes «basten» sin escalar es un espejismo: solo se ha medido el gasto y la antelación.

LA IDEA · VARIANZA EXPLICADA

Cuánta información conserva cada componente

Ejemplo con 4 variables inventadas: cada componente explica un porcentaje de la variación total, de mayor a menor, y suman 100 %.



Componentes que se conservan	1	2	3	4
Varianza acumulada	55 %	80 %	**92 %**	100 %

Para conservar al menos el 90 % hacen falta 3 componentes: con 2 se queda en el 80 %.

CARGAS

¿Qué significa cada componente?

Variable (ejemplo)	PC1
edad	0,58
antelacion_media	0,58
reservas_anio	**−0,58**

Un componente es una receta

PC1 = 0,58·edad + 0,58·antelación − 0,58·reservas. Los pesos son las **cargas**.

Qué variables van juntas

Edad y antelación suben a la vez; **las reservas, en sentido contrario**: mayores que planifican y reservan poco.

El signo de un componente es arbitrario: importa qué variables van **juntas** y cuáles **en sentido contrario**.

Agrupar sobre menos columnas

Se aplica PCA y se agrupa con k-means sobre los primeros **n** componentes. **ARI** mide cuánto coinciden esos grupos con los del clustering original.

ARI	Qué significa
1,00	Grupos **idénticos** a los originales
0,80 a 0,99	**Casi iguales**: unos pocos huéspedes cambian de grupo
Cerca de 0	Como **repartirlos al azar**

Aviso: la silueta en espacios de distinta dimensión no es comparable. Por eso se usa el ARI.

UNA MENCIÓN · T-SNE

t-SNE: para explorar, no para demostrar

	PCA	t-SNE (y su primo UMAP)
Tipo de transformación	Lineal	**No lineal**: muy buena mostrando grupos
Distancias entre grupos	Significan algo	**No significan nada**
Resultado	Mismo cada vez (salvo el signo)	Cambia con los parámetros y la semilla
Interpretación	Cargas: qué variables componen cada eje	Sin cargas que interpretar

Para explorar

Úsalo para **ver** si hay grupos, no para sacar conclusiones cuantitativas sobre ellos.

PRÁCTICA · CUADERNO S09_02

Lo que haremos en el cuaderno

Parte	Qué haremos	Dónde
Preparación	Cargar los huéspedes y ver la varianza explicada	Clase
Ejercicio 1	La varianza acumulada y el 90 %	Clase
Ejemplo	Gráficos de la varianza y proyección a 2 componentes	Clase
Ejercicio 2	El mapa de huéspedes en 2D	Clase
Ejercicio 3	Las variables opuestas a la edad (con la tabla de cargas)	Casa
Ejercicio 4	Agrupar con el 90 % de la varianza	Casa
Ejemplo	t-SNE de los huéspedes	Casa
Mini-reto	¿Valen 2 componentes?	Casa

Cada ejercicio: **lee** → **escribe** → **ejecuta** → **comprueba el** ✔. La solución está plegada: ábrela tras intentarlo.

CONSULTA

Material de consulta: código y aclaraciones

Cuándo abrirlo

Después de intentar el ejercicio, o cuando algo no te salga. En clase no se proyecta.

Cómo está ordenado

En el **mismo orden que el cuaderno**: ejercicios 1 a 4 y mini-reto. Cada uno trae su código y sus aclaraciones.

Ejercicio	Tema	Diapositivas
1	Varianza acumulada y el 90 %	10 y 11
2	Mapa de huéspedes en 2D	12 y 13
3	Cargas y variables opuestas	14 y 15
4	PCA antes del clustering	16 y 17
Mini-reto	¿Valen 2 componentes?	18 y 19

CONSULTA · EJERCICIO 1

Varianza acumulada y el 90 % (ejercicio 1)

```
varianza_acum = np.cumsum(varianza)                    # suma hacia la derecha
n_comp_90 = int(np.argmax(varianza_acum >= 0.90)) + 1    # 5
```

Componentes	Varianza acumulada	¿Llega al 90 %?	**argmax** mira la posición
3	81,3 %	no	2
4	89,8 %	no	3
5	93,8 %	**sí**	**4**

argmax devuelve la primera posición que cumple, **contando desde 0**: por eso se suma 1 y salen 5 componentes.

CONSULTA · ACLARACIONES · EJERCICIO 1

Leer la varianza acumulada (ejercicio 1)

np.cumsum(varianza)

Suma hacia la derecha: la acumulada va de 43,2 % a 100 % con 7 valores.

np.argmax(... >= 0.90) + 1

argmax da la **posición** (desde 0): se suma 1. Con 4 componentes: **89,8 %**, por debajo; hace falta el quinto (93,8 %).

43,2 % y 25,5 %

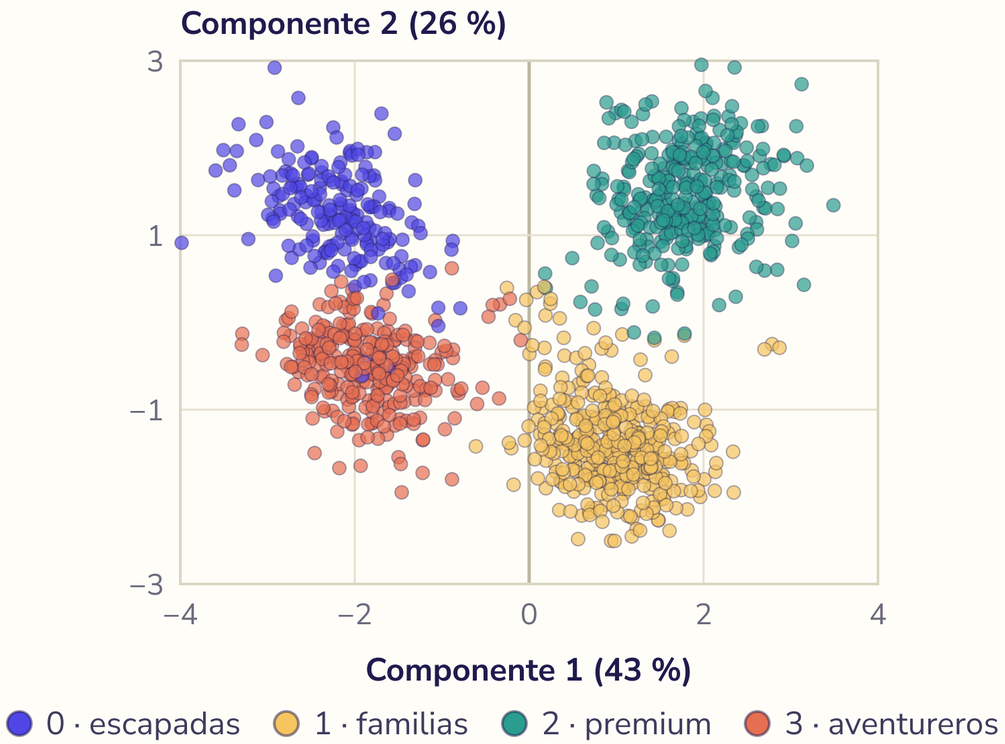
Lo que explican los componentes 1 y 2. Los componentes 5 a 7: 4,1 % · 3,4 % · 2,8 %, y bajan porque PCA busca primero la dirección con **más variación**.

Gráficos y ahorro

La curva cruza el 90 % en el 5.º. Pasar de 7 variables a 5 (**29 % menos**) conserva el 90 %. Pasar de 5 a 7 solo sube del 93,8 % al 100 %.

CONSULTA · EJERCICIO 2

Mapa de huéspedes en 2D (ejercicio 2)




```
pca2 = PCA(n_components=2,
           random_state=SEMILLA)
Z2 = pca2.fit_transform(X)
ax.scatter(Z2[:, 0], Z2[:, 1],
           c=grupo, cmap="tab10")
```

68,7 %

de la información en 2 componentes: lo que ves es una **sombra**

CONSULTA · ACLARACIONES · EJERCICIO 2

Leer el mapa de 2D (ejercicio 2)

PCA(n_components=2)

`fit_transform(X)` da `Z2` de **(1200, 2)**: una fila por huésped y sus coordenadas en los componentes 1 y 2.

El % en los ejes

Dice **cuánta información** lleva cada eje: el 1 (≈ 43 %) casi el doble que el 2 (≈ 26 %).

68,7 % = una sombra

43,2 % + 25,5 %: se pierde el **31,3 %**. Lo que ves es una sombra de los datos, no toda la verdad.

Segmentos separados

Los 4 se ven distintos: el clustering **tiene sentido**. Los más cercanos: el **0** y el **3**, que casi se tocan.

CONSULTA · EJERCICIO 3

Variables opuestas a la edad (ejercicio 3)

```
signo_edad = np.sign(cargas.loc["edad", "PC1"])
opuestas_a_edad = [v for v in cargas.index if np.sign(cargas.loc[v, "PC1"]) != signo_edad]    # 2 variables
```

Variable	PC1	PC2
edad	0,45	0,37
gasto_medio_dia	0,33	0,55
noches_medias	0,42	−0,16
reservas_anio	**−0,29**	0,30
antelacion_media	0,44	−0,34
pct_gasto_actividades	**−0,44**	−0,14
viaja_con_ninos	0,20	−0,55

CONSULTA · ACLARACIONES · EJERCICIO 3

Leer las cargas (ejercicio 3)

np.sign(...) != signo_edad

Compara el signo **relativo a la edad**, no el absoluto: si el componente saliera invertido, **saldrían las mismas dos**.

Las dos que salen

reservas_anio (–0,29) y **pct_gasto_actividades** (–0,44), frente a la edad (+0,45) en PC1.

En lenguaje de negocio

PC1: «**mayor, planificador, de estancias largas**» frente a «**activo y viajero frecuente**». Los mayores reservan menos veces al año.

En PC2

gasto_medio_dia (+0,55) y **viaja_con_ninos** (–0,55) **se oponen**. Con signos invertidos sigue valiendo qué variables van juntas.

CONSULTA · EJERCICIO 4

Agrupar con el 90 % de la varianza (ejercicio 4)

k-means con 4 grupos sobre los primeros **n** componentes. **ARI** mide cuánto coinciden los grupos con los del clustering original: 1 = idénticos, 0 = al azar.

Componentes	Varianza acumulada	ARI con el clustering original
2	68,7 %	0,94
3	81,3 %	0,97
5 (el 90 %)	93,8 %	**1,00**
7 (todos)	100 %	**1,00**

```
Z90 = PCA(n_components=n_comp_90)
    .fit_transform(X)
```

Aviso

La silueta en espacios de distinta dimensión **no es comparable**: aquí solo se comprueba si los grupos son estables.

CONSULTA · ACLARACIONES · EJERCICIO 4

Leer PCA antes del clustering (ejercicio 4)

Z90 de (1200, 5)

Los **5 componentes** necesarios para el 90 %. Se agrupa **Z90**, no **X**, y con el mismo **k = 4**.

ARI = 1,00

Los **mismos 4 grupos** que con las 7 variables, con dos columnas menos. Con 2 componentes: 0,94; con 3: 0,97.

Por qué reducir antes

Menos columnas sin cambiar el resultado: con muchas variables, el **ahorro de tiempo y de ruido** puede ser grande.

t-SNE (ejemplo)

4 **islas**, que coinciden con los segmentos. Las distancias entre islas **no significan nada** y cambian con la semilla: sirve para **explorar**, no para demostrar.

CONSULTA · MINI-RETO

¿Valen 2 componentes? (mini-reto)

Componentes	Información conservada	Información que se pierde
2	68,7 %	31,3 %
3	81,3 %	18,7 %
5	93,8 %	6,2 %
7	100 %	0 %

Tu mini-reto (3 o 4 líneas)

Un compañero dice: «con 2 componentes ya vale, quita los demás». ¿Estás de acuerdo para **(a)** dibujar los huéspedes y **(b)** entrenar un modelo que necesite precisión? Apóyate en **varianza_acum**.

Para pensar

PCA no mira ninguna etiqueta: es **no supervisada**. ¿Puede ayudar a un modelo de cancelaciones? ¿Qué se pierde en interpretabilidad?

CONSULTA · ACLARACIONES · MINI-RETO

Leer la respuesta (mini-reto, casa)

Para dibujar: sí

Con 2 componentes se conserva el **68,7 %** (**varianza_acum[1]** = 0,687): alcanza para ver cómo se separan los segmentos.

Para un modelo preciso

No necesariamente: el 31 % que falta puede contener información útil. Compara la precisión con 2, 5 y todos.

Qué cifra citar

0,687 (2 componentes) para dibujar y **0,938** (5 componentes) como referencia para el modelo; el 90 % exige 5.

La respuesta mínima

3 o 4 líneas, unas 25 palabras, apoyadas en **varianza_acum**: **respuesta_reto** no puede quedarse en **"..."**.