IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Siete variables, un mapa de 2D

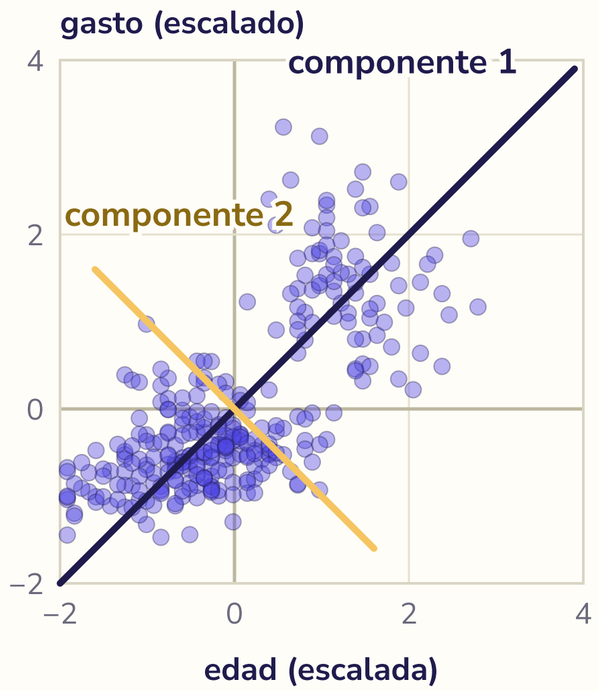
PCA: varianza explicada, cargas, PCA antes del clustering y una mención a t-SNE

Sprint 9 · S09_02 · cuaderno: 30 min en clase (ejercicios 1 y 2)

LA IDEA · EJES NUEVOS

Un eje a lo largo de la nube

300 de 1 200 huéspedes · solo edad y gasto



Una nube con forma de puro se describe mejor con un **eje a lo largo del puro** que con los ejes de la habitación.

PCA busca esos ejes

El **componente 1** es la dirección con más variación; el **2**, perpendicular, la siguiente… Cada uno es una **mezcla** de las variables y trae su % de **varianza explicada**.

86,9 %

de la variación de edad y gasto cabe en el componente 1

LA IDEA · ESCALAR ANTES

PCA busca varianza, y depende de las unidades

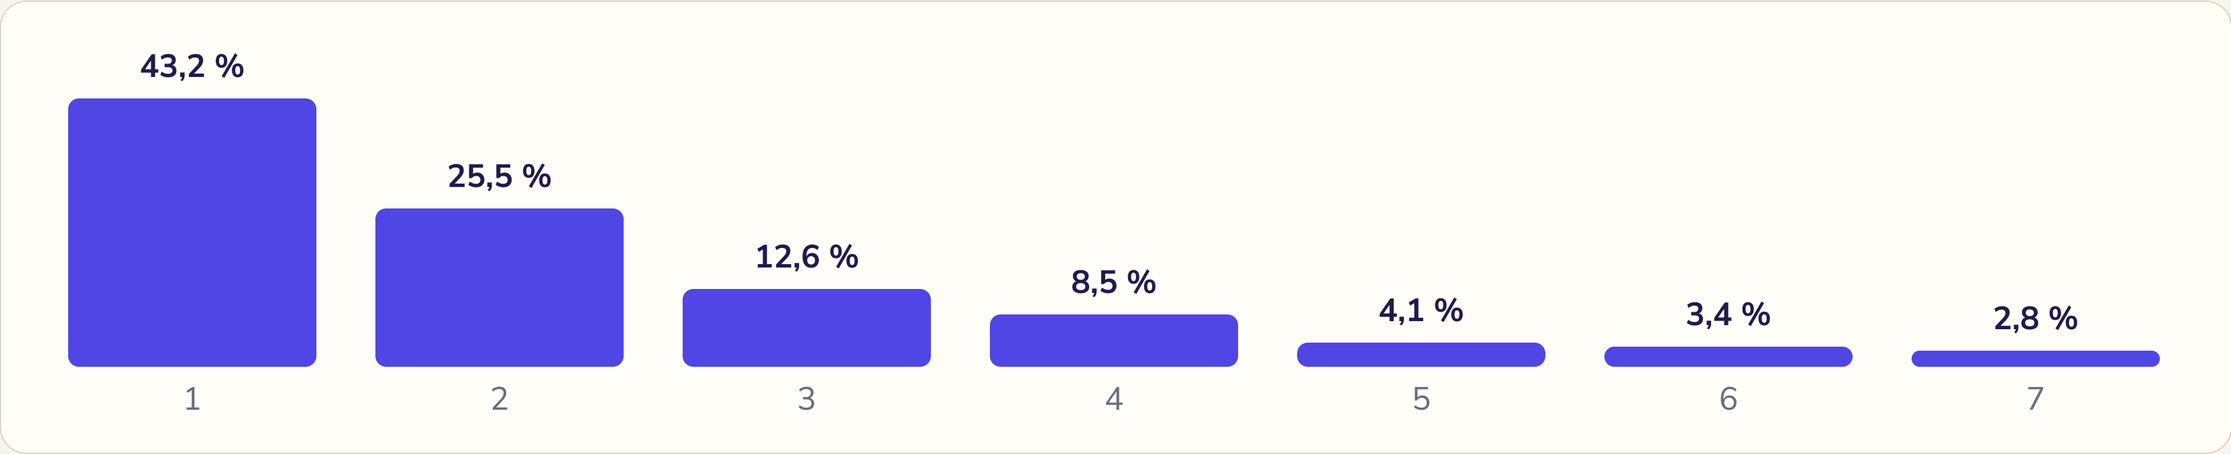
Si no se escala, el gasto en euros decide casi todo: tiene los números más grandes. Comparación con los 1 200 huéspedes:

	Sin escalar	Escalando (cuaderno)
Componente 1: varianza explicada	69,8 %	43,2 %
Variable que lo domina	`gasto_medio_dia` (carga 0,95)	Mezcla de edad, antelación, noches y % de actividades (cargas de 0,42 a 0,45)
Componentes para llegar al 90 %	2	5

Que 2 componentes «basten» sin escalar es un espejismo: solo se ha medido el gasto y la antelación.

LA IDEA · VARIANZA EXPLICADA

Cuánta información conserva cada componente



Componentes que se conservan	1	2	3	4	5	6	7
Varianza acumulada	43,2 %	68,7 %	81,3 %	**89,8 %**	**93,8 %**	97,2 %	100 %

Con 4 componentes se llega al 89,8 %, justo por debajo del 90 %: hacen falta 5.

EJERCICIO 1 · CUADERNO (CLASE)

Cuántos componentes para el 90 %

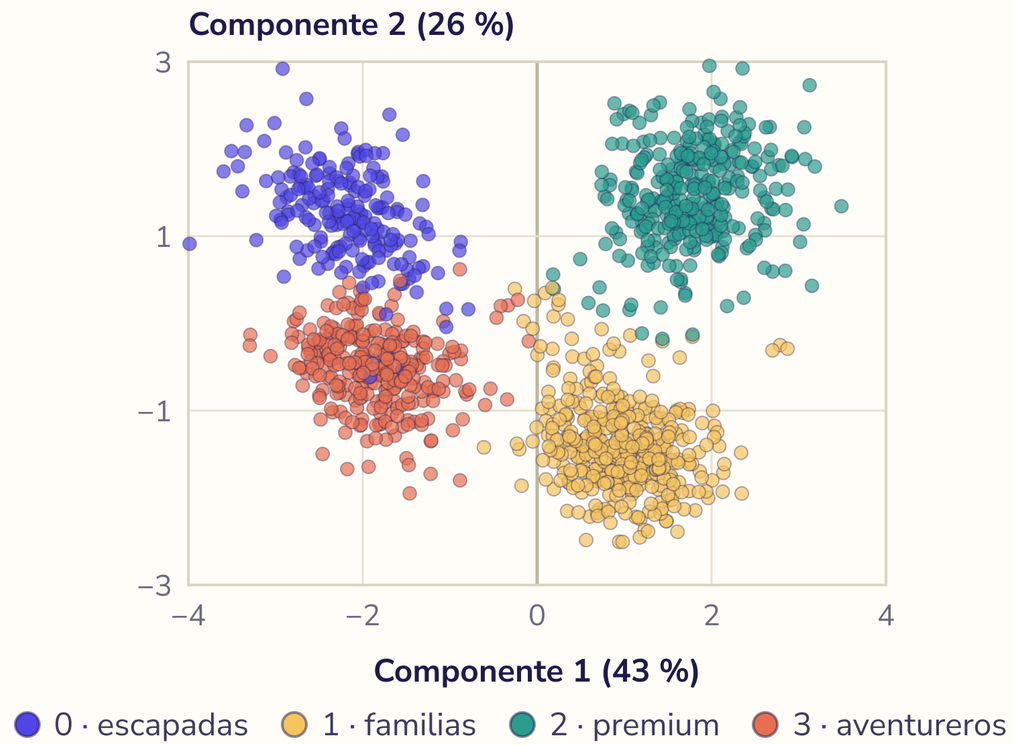
```
varianza_acum = np.cumsum(varianza)                    # suma hacia la derecha
n_comp_90 = int(np.argmax(varianza_acum >= 0.90)) + 1    # 5
```

Componentes	Varianza acumulada	¿Llega al 90 %?	**argmax** mira la posición
3	81,3 %	no	2
4	89,8 %	no	3
5	93,8 %	**sí**	**4**

argmax devuelve la primera posición que cumple, **contando desde 0**: por eso se suma 1 y salen 5 componentes.

EJERCICIO 2 · CUADERNO (CLASE)

Los huéspedes en un mapa de 2D




```
pca2 = PCA(n_components=2,
           random_state=SEMILLA)
Z2 = pca2.fit_transform(X)
ax.scatter(Z2[:, 0], Z2[:, 1],
           c=grupo, cmap="tab10")
```

68,7 %

de la información en 2 componentes: lo que ves es una **sombra**

CARGAS · EJERCICIO 3 (CASA)

¿Qué significa cada componente?

Variable	PC1	PC2
edad	0,45	0,37
gasto_medio_dia	0,33	0,55
noches_medias	0,42	−0,16
reservas_anio	**−0,29**	0,30
antelacion_media	0,44	−0,34
pct_gasto_actividades	**−0,44**	−0,14
viaja_con_ninos	0,20	−0,55

Un componente es una receta

PC1 = 0,45·edad + 0,33·gasto − 0,44·%actividades … Los pesos son las **cargas**.

Opuestas a la edad en PC1

reservas_anio y **pct_gasto_actividades**: el PC1 opone «mayor, planificador, estancias largas» a «activo y viajero frecuente».

El signo de un componente es arbitrario: importa qué variables van juntas.

PCA Y CLUSTERING · EJERCICIO 4 (CASA)

Agrupar sobre menos columnas

k-means con 4 grupos sobre los primeros **n** componentes. **ARI** mide cuánto coinciden los grupos con los del clustering original: 1 = idénticos, 0 = al azar.

Componentes	Varianza acumulada	ARI con el clustering original
2	68,7 %	0,94
3	81,3 %	0,97
5 (el 90 %)	93,8 %	**1,00**
7 (todos)	100 %	**1,00**

```
Z90 = PCA(n_components=n_comp_90)
    .fit_transform(X)
```

Aviso

La silueta en espacios de distinta dimensión **no es comparable**: aquí solo se comprueba si los grupos son estables.

UNA MENCIÓN · T-SNE

t-SNE: para explorar, no para demostrar

	PCA	t-SNE (y su primo UMAP)
Tipo de transformación	Lineal	**No lineal**: muy buena mostrando grupos
Distancias entre grupos	Significan algo	**No significan nada**
Resultado	Mismo cada vez (salvo el signo)	Cambia con los parámetros y la semilla
Interpretación	Cargas: qué variables componen cada eje	Sin cargas que interpretar

```
tsne = TSNE(n_components=2, perplexity=30,
            random_state=SEMILLA,
            init="pca").fit_transform(X)
```

Para explorar

Úsalo para **ver** si hay grupos, no para sacar conclusiones cuantitativas sobre ellos.

MINI-RETO · CUADERNO (CASA)

¿Con 2 componentes ya vale?

Componentes	Información conservada	Información que se pierde
2	68,7 %	31,3 %
3	81,3 %	18,7 %
5	93,8 %	6,2 %
7	100 %	0 %

Tu mini-reto (3 o 4 líneas)

Un compañero dice: «con 2 componentes ya vale, quita los demás». ¿Estás de acuerdo para **(a)** dibujar los huéspedes y **(b)** entrenar un modelo que necesite precisión? Apóyate en **varianza_acum**.

Para pensar

PCA no mira ninguna etiqueta: es **no supervisada**. ¿Puede ayudar a un modelo de cancelaciones? ¿Qué se pierde en interpretabilidad?

HOY HAS APRENDIDO

Siete variables, dos ejes, un mapa

Ejes nuevos

PCA ordena los ejes por la **información** que conservan; se **escala** antes

Cuántos y qué son

La varianza acumulada dice cuántos (aquí **5** para el 90 %); las **cargas** dicen qué mezclan

Mapa y límites

Dos componentes dan un mapa útil (**68,7 %**); t-SNE solo para explorar

Siguiente: S09_03 · recomendadores