Sprint 9 · Segmentar, recomendar y aprender por refuerzo

¿qué tipos de cliente tenemos y qué les ofrecemos?

FECHAS
12 y 13 de noviembre
MÓDULO
M3, unidades 3.9 a 3.12
HORAS
12 h (3 h teoría · 5 h práctica · 4 h PBL)
EVALUACIÓN
test de M3 (segunda parte)

Qué aprenderás

1. Agrupar clientes sin etiquetas con **k-means, clustering jerárquico y DBSCAN**, y elegir cuántos grupos con el **coeficiente de silueta**.
2. Reducir dimensiones con **PCA** para ver los datos en 2D e interpretar qué variables pesan.
3. Construir recomendadores por **popularidad, contenido y filtrado colaborativo** (incluida la factorización de matrices) y evaluarlos con **RMSE** y **precision@k**.
4. Entender el **aprendizaje por refuerzo** implementando **Q-learning** en un entorno pequeño con numpy.
5. **Interpretar** un resultado no supervisado para el negocio: poner nombre, tamaño y una acción comercial a cada segmento.

Requisitos previos

- Pipelines y validación de scikit-learn (Sprints 7 y 8), y numpy/pandas (Sprints 4-5).
- Saber leer un mapa de calor y un diagrama de dispersión.
- Datos: `huespedes.csv`, `valoraciones_experiencias.csv` y `experiencias.csv` (los notebooks los descargan solos).

Prácticas

Notebook	Tema	Tiempo
`S09_01_clustering`	Segmentar huéspedes: escalado, k-means, silueta, jerárquico, DBSCAN	80 min
`S09_02_pca`	PCA: varianza explicada, mapa 2D, cargas, mención a t-SNE	55 min
`S09_03_recomendadores`	Popularidad, contenido, colaborativo, factorización; RMSE y precision@k	80 min
`S09_04_q_learning`	Q-learning en el hotel (numpy): recompensas, epsilon-greedy, política	55 min

Cada notebook tiene ejercicios con comprobaciones automáticas (cuando salen bien). Trabaja en orden y no pases al siguiente hasta que los `assert` pasen.

RETO Reto PBL · «Conocer al huésped» (unas 3 h 20 min)

En pocas palabras (léelo primero)

Qué os pide el cliente. Lucía, la directora comercial de TurisData, envía **la misma newsletter a sus 1.200 huéspedes** y vende las **25 experiencias** con los mismos banners. Sospecha que hay «tipos» de cliente muy distintos y que cada uno querría cosas diferentes. Os pide: *«Decidme quiénes son mis clientes, cómo los llamo y qué le enseño a cada uno.»*

Aquí la IA «aprende sin respuestas». No hay una columna que diga «este cliente es de tipo A». Tenéis que **descubrir los grupos** que se esconden en los datos y luego **ponerles nombre y significado de negocio**. Además, construiréis un **recomendador** sencillo: dado un huésped, sugerir experiencias que probablemente le gusten.

Qué vais a hacer, en cinco pasos:

1. **Agrupar a los huéspedes** (segmentación) con la técnica de clustering, eligiendo cuántos grupos (k) con un criterio técnico **y** de negocio.
2. **Dibujar un mapa 2D** de los grupos con PCA.
3. **Interpretar cada segmento**: ponerle nombre, tamaño, perfil y una acción comercial.
4. **Construir un recomendador** de experiencias (comparando al menos dos métodos) y una función `recomendar(id_usuario, n)`.
5. **Escribir una nota de IA responsable** (5 líneas).

Qué vais a entregar: un cuaderno, una ficha de segmentos de 1 página y una nota de IA responsable (dentro de la ficha).

Qué vais a aprender haciéndolo: a **segmentar sin etiquetas**, a **traducir grupos matemáticos a clientes con nombre**, a **comparar recomendadores** y a ver los riesgos de personalizar (discriminación, sesgo de popularidad, privacidad).

Cuánto tiempo: unas 3 horas y 20 minutos (12 y 13/11) entre el planning, el reto y la entrega, intercaladas con las prácticas.

Palabras que van a aparecer en este reto

Palabra	Qué significa, en sencillo
Segmentación	Dividir a los clientes en grupos parecidos entre sí
Clustering	La técnica que agrupa automáticamente los datos parecidos. Ejemplo: k-means
k	El número de grupos que se piden al algoritmo
Silueta	Un número entre −1 y 1 que dice si los grupos están bien separados (más alto, mejor)
Escalar	Poner las variables en una escala comparable (si no, la «edad» y el «gasto en euros» no pesan igual)
PCA	Técnica para «aplastar» muchas columnas en 2 dibujables, conservando lo más importante
Varianza explicada	Qué parte de la información conserva el dibujo 2D (el % que aparece en los ejes)
Recomendador	Un sistema que sugiere elementos (experiencias) a cada usuario
RMSE	Error medio entre la nota que predice el recomendador y la nota real
Precision@3	De las 3 experiencias que se recomiendan, cuántas le interesaban realmente
Sesgo de popularidad	El sistema recomienda siempre lo más popular y los demás nunca tienen oportunidad
Arranque en frío	No saber qué recomendar a un cliente nuevo que aún no ha valorado nada

El cliente

Lucía, directora comercial de **TurisData Canarias**, envía la misma newsletter a los 1 200 huéspedes de su base y vende las 25 experiencias con los mismos banners. Sospecha que hay «tipos» de cliente muy distintos y que cada uno querría cosas diferentes. Nos pide: *«Decidme quiénes son mis clientes, cómo los llamo y qué le enseño a cada uno»*.

Qué se entrega y en qué formato

1. **Notebook** `reto_S09_conocer_al_huesped.ipynb` (versión ejecutable de arriba abajo, con semillas fijas) con: - Segmentación de `huespedes.csv` (método justificado, k elegido con silueta y con criterio de negocio) y un **mapa 2D con PCA**. - Prototipo de **recomendador de experiencias** (mínimo dos métodos comparados con RMSE y precision@3) y la función `recomendar(id_usuario, n)`.
2. **Ficha de segmentos (1 página, Markdown o PDF)** usando `plantilla_ficha_segmentos.md`: por cada segmento, nombre, tamaño, perfil en una frase, **una acción comercial** y **una experiencia estrella** de las que recomienda tu prototipo.
3. **Nota de IA responsable (5 líneas)** dentro de la ficha: qué riesgos tiene segmentar y recomendar (discriminación, sesgo de popularidad, privacidad).

Restricciones

- Solo numpy, pandas, matplotlib/seaborn y scikit-learn (sin librerías de recomendación especializadas).
- Trabajo en equipos de 3-4; **todas las personas** deben poder explicar cualquier parte.
- Los ficheros de solución del docente no están disponibles: los segmentos se validan con **sentido de negocio** y con métricas internas.

Criterios de evaluación (rúbrica de retos, de 1 a 4)

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
Corrección técnica	Datos sin escalar o k al azar; métricas mal calculadas	Segmenta y recomienda con fallos menores	Escalado, k justificado y recomendador evaluado con una división de prueba	Además compara varios métodos de clustering y de recomendación con resultados razonados
Reproducibilidad	No se puede volver a ejecutar	Se ejecuta con ayuda del equipo	Se ejecuta de arriba abajo con semillas fijas	Además incluye README corto, datos o script de descarga y versiones
Análisis y comunicación al cliente	Solo cifras o gráficos sin interpretar	Nombres de segmentos sin acciones	Segmentos con nombre, tamaño y una acción cada uno	Además recomendación accionable, priorizada por valor y con límites explicados

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
IA responsable	No se considera	Menciones genéricas («hay que cuidar la privacidad»)	Riesgos específicos: sesgo de popularidad, discriminación por edad o niños	Además propone medidas (p. ej. no segmentar por edad para precios) y comprueba alguna

Pasos sugeridos

Día	Qué hacer
Jueves 12/11 (1 h de PBL tras las prácticas 01 y 02)	Ya tenéis los segmentos en borrador: elegid método y k con silueta **y** con criterio de negocio; haced el mapa PCA.
Viernes 13/11, por la mañana	Prácticas 03 y 04. Con lo aprendido, arrancad el prototipo de `recomendar` y comparad al menos dos métodos.
Viernes 13/11 (1 h 25 min de PBL)	1) Comparad recomendadores y probad `recomendar` con 3 usuarios (40 min). 2) Rellenad la ficha de segmentos, nota de IA responsable, repaso de la Definition of Done y ensayo de la review (45 min).

Guía paso a paso para principiantes

Paso 1 · Preparación y datos (jueves 12/11, tras las prácticas 01 y 02, 15 minutos)

1. Abrid un cuaderno nuevo (o el `reto_S09_conocer_al_huesped`) con `huespedes.csv` y `valoraciones_experiencias.csv`.
2. **Revisad las columnas** de `huespedes.csv` (edad, gasto, antelación, etc.). ¿Cuáles son números y cuáles categorías?
3. **Escalad** las variables numéricas. Si no, el algoritmo dará más peso a las columnas con números grandes.

Paso 2 · Segmentar y elegir k (jueves 12/11, 25 minutos)

1. Probad k-means con varios valores de k (por ejemplo, de 2 a 8).
2. Calculad la **silueta** para cada k y dibujad la curva.
3. **No elijáis k solo por la silueta.** Preguntaos también: *¿puede la directora actuar con ese número de grupos?* Entre 3 y 5 segmentos suele ser manejable; 12 serían inmanejables.
4. Anotad la razón de vuestra elección en **una frase con las dos justificaciones** (técnica y de negocio).

Paso 3 · Mapa PCA e interpretación (jueves 12/11, 20 minutos)

1. Aplicad **PCA** a 2 componentes y dibujad los huéspedes coloreados por segmento. Poned en los ejes el **% de varianza**.
2. Para cada segmento, calculad el **perfil medio**: edad, gasto, antelación, composición del grupo, etc. Comparadlo con la media general.
3. **Ponedle un nombre comercial y una frase** con cifras concretas. Ejemplo (inventado): *«Familias de larga estancia: 410 huéspedes (34 %); 9 de cada 10 viajan con niños, reservan con 110 días de antelación y gastan poco en actividades»*.
4. Proponed **una acción comercial** para cada segmento (qué enseñar, cuándo, por qué canal).

Paso 4 · Recomendador (viernes 13/11, tras las prácticas 03 y 04, 40 minutos)

1. Montad al menos **dos métodos** (por ejemplo, popularidad y filtrado colaborativo por similitud).
2. **Evaluad con una división de prueba:** esconded algunas valoraciones, dejad que el recomendador las prediga y comparad. Medid **RMSE** y **precision@3**.
3. Programad `recomendar(id_usuario, n)` que devuelva las `n` mejores experiencias que **el usuario aún no ha valorado**.
4. Probadla con **3 usuarios distintos** y comprobad que tiene sentido (¿le sugiere cosas parecidas a las que ya le gustaron?).

Paso 5 · Ficha, IA responsable y ensayo (viernes 13/11, 45 minutos)

1. Completad la ficha de segmentos: por segmento, nombre, tamaño, perfil, **una acción** y **una experiencia estrella** (la que recomienda vuestro prototipo para ese grupo).
2. Nota de IA responsable (5 líneas, al menos **2 riesgos específicos**), por ejemplo: - *Discriminar:* si se usa la edad o «viaja con niños» para fijar precios, se puede discriminar. Medida: usar la segmentación para comunicar, no para variar precios. - *Sesgo de popularidad:* las experiencias poco conocidas casi no se recomiendan. Medida: reservar un hueco de la recomendación a opciones menos populares. - *Privacidad:* se combinan datos de reserva y valoraciones. Medida: usar identificadores y no mostrar datos personales.
3. Repasad la Definition of Done y ensayad 3 minutos de review.

Cómo usar la IA en este reto

Para qué	Ejemplo de petición	Qué tenéis que comprobar
Entender un concepto	«Explícame k-means y la silueta con una analogía de personas en una fiesta»	Que podáis explicarlo con vuestras palabras
Entender PCA	«¿Qué significa que PCA conserve el 60 % de la varianza? Dame un ejemplo sin fórmulas»	Que vuestro gráfico dice lo mismo
Poner nombres a los segmentos	«Dado este perfil medio: *[tabla]*, dame 5 nombres comerciales cortos y evocadores»	Que el nombre refleja las **cifras** del segmento, no una invención
Pensar en riesgos	«¿Qué riesgos tiene recomendar experiencias según la edad?»	Elegid los que aplican a **vuestro** caso y dad una medida real

Reglas del reto:

- Solo `numpy`, `pandas`, `matplotlib/seaborn` y `scikit-learn`: nada de librerías de recomendación especializadas.
- **Todas las personas deben poder explicar cualquier parte.** En la review el docente puede preguntar a cualquiera.
- No hay soluciones del docente: los segmentos se validan con **sentido de negocio** y con **métricas internas** (silueta, RMSE).
- Declarad en el cuaderno dónde habéis usado IA y qué habéis comprobado.

Errores frecuentes (y cómo evitarlos)

Error	Por qué ocurre	Cómo evitarlo
Agrupar sin escalar	Se olvida	Escalad **antes** del clustering
Elegir k solo con la silueta	«Es lo que dice el número»	Añadid el criterio de negocio
Poner nombres sin mirar los datos	Suena bien	Cada nombre debe justificarse con **dos cifras** del perfil
Recomendar lo que el usuario ya ha valorado	No se filtra	La función debe excluirlas
Evaluar el recomendador con los mismos datos que usó	«Es lo más fácil»	Probad con valoraciones **escondidas**
Nota de IA responsable genérica	Prisa	Dos riesgos **concretos** de este caso, con medida

Un buen resultado se parece a...

- **Ficha de segmentos** con 3–5 filas, cada una con nombre, tamaño, perfil con cifras, acción y experiencia estrella.
- **Mapa PCA** con título que enuncia una conclusión («Cuatro tipos de huésped claramente separados») y ejes con el % de varianza.
- **Recomendador:** una tabla *método · RMSE · precision@3* y una frase de elección («Elegimos filtrado colaborativo porque mejora un 15 % la precision@3 de la popularidad»). Las cifras son un ejemplo.

Antes de entregar: autoevaluación rápida

Pregunta	Sí / No
¿El cuaderno se ejecuta de arriba abajo, con semillas fijas?	
¿Hemos escalado antes de agrupar y justificado k con silueta **y** con negocio?	
¿El mapa PCA tiene segmentos coloreados y el % de varianza en los ejes?	
¿La ficha tiene nombre, tamaño, perfil y acción por segmento?	
¿El recomendador está evaluado con RMSE y precision@3 y comparado con la popularidad?	
¿`recomendar` no propone experiencias ya valoradas?	
¿Hay al menos dos riesgos específicos de IA responsable?	
¿Cada persona ha hecho *commit* de su parte?	

Si os atascáis

- **Todos los segmentos se parecen:** revisad que habéis escalado y probad otras columnas; quizá algunas no aportan.

- **PCA nos da un mapa en el que todo está mezclado:** es posible; decidlo en la ficha. Los grupos pueden estar separados en dimensiones que el 2D no recoge.
- **El recomendador recomienda siempre lo mismo:** probablemente es un sesgo de popularidad; comentadlo como riesgo.
- Más ayuda: Cómo se trabaja un reto.

Qué se enseña en la review

Cada equipo presenta en 3 minutos: **sus segmentos (nombre + acción)** y **una recomendación concreta para un usuario**. Se comparan los k elegidos y se discute *¿es el mismo cliente aunque le pongamos otro nombre?*

Definition of Done

- [ ] El notebook se ejecuta de arriba abajo sin errores y con semillas fijas.
- [ ] Variables escaladas antes de agrupar; k justificado con silueta **y** con criterio de negocio.
- [ ] Mapa 2D (PCA) con los segmentos coloreados y ejes con el % de varianza.
- [ ] Ficha de segmentos con nombre, tamaño, perfil y acción por segmento.
- [ ] Recomendador evaluado con RMSE y precision@3, comparado con la popularidad.
- [ ] `recomendar(id_usuario, n)` no propone experiencias ya valoradas.
- [ ] Nota de IA responsable con al menos dos riesgos específicos.
- [ ] Cada persona del equipo ha hecho *commit* de su parte.

Recursos

- Documentación de scikit-learn: *Clustering* y *Decomposition* (guía de usuario, en inglés).
- Vídeo o artículo introductorio sobre el **coeficiente de silueta** y el método del codo (busca material propio del centro o de tu elección).
- Explicación visual de la **factorización de matrices** para recomendación.
- «Sutton y Barto: *Reinforcement Learning: An Introduction*» (capítulo 1, gratuito online) para ir más allá de Q-learning.
- Ampliación: Gymnasium (`pip install gymnasium`), la librería estándar que replica la interfaz `reset/step` del notebook 04.