

Sprint 9 · Segmentar, recomendar y aprender por refuerzo

MÓDULO M3 · UNIDADES 3.9 A 3.12

11 Y 12 DE NOVIEMBRE

11 H TOTALES (EVALUACIÓN: TEST M3)

Pregunta guía: **¿qué tipos de cliente tenemos y qué les ofrecemos?** Bienvenidos al **Sprint 9**, donde aplicamos técnicas de clustering, reducción de dimensionalidad, recomendación y aprendizaje por refuerzo a los datos del hotel de **TurisData Canarias**. Once horas organizadas en teoría, práctica y reto PBL para aprender a extraer patrones sin etiquetas y personalizar la experiencia del cliente.

3 h Teoría

Clustering (k-means, jerárquico, DBSCAN), PCA, recomendadores y Q-learning

5 h Práctica

4 laboratorios guiados con ejercicios prácticos y asserts automáticos en Colab

3 h Reto PBL

«Conocer al huésped»: segmentación, recomendador de experiencias y ficha con IA responsable

¿Qué aprenderás?

- 1 Agrupar clientes sin etiquetas**
Agruparás huéspedes con k-means, clustering jerárquico y DBSCAN, y elegirás cuántos grupos formar mediante el coeficiente de silueta.
- 2 Reducir dimensiones con PCA**
Reducirás dimensiones con PCA para proyectar y visualizar los datos en 2D e interpretarás qué variables tienen mayor peso.
- 3 Construir y evaluar recomendadores**
Construirás recomendadores por popularidad, contenido y filtrado colaborativo (incluida factorización de matrices) evaluados con RMSE y precision@k.
- 4 Q-learning en un entorno hotelero**
Entenderás los fundamentos del aprendizaje por refuerzo implementando un agente de Q-learning en un entorno pequeño con numpy.
- 5 Interpretar resultados para el negocio**
Traducirás un resultado no supervisado a impacto de negocio: nombre, tamaño, perfil resumido y acción comercial por segmento.

⚠ **Requisitos previos:** Pipelines y validación de scikit-learn (Sprints 7 y 8), numpy/pandas (Sprints 4-5). Saber leer un mapa de calor y un diagrama de dispersión. **Datos:** [huespedes.csv](#), [valoraciones_experiencias.csv](#) y [experiencias.csv](#) (los notebooks los descargan solos).

Prácticas del sprint (notebooks Colab ✓)

Notebook	Tema y contenidos clave	Tiempo
S09_01_clustering	Segmentar huéspedes: escalado, k-means, silueta, jerárquico, DBSCAN	1 h 30
S09_02_pca	PCA: varianza explicada, mapa 2D, cargas, mención a t-SNE	1 h 00
S09_03_recomendadores	Popularidad, contenido, colaborativo, factorización; RMSE y precision@k	1 h 30
S09_04_q_learning	Q-learning en el hotel (numpy): recompensas, epsilon-greedy, política	1 h 00

Ficha del reto · "Conocer al huésped"

TURISDATA CANARIAS · RETO PBL

3 H DE RETO

EQUIPOS DE 3-4 PERSONAS

Cliente: Lucía, directora comercial de **TurisData Canarias**, envía la misma newsletter a los 1 200 huéspedes y vende las 25 experiencias turísticas con los mismos banners. Sospecha que existen «tipos» de cliente claramente distintos y os pide: «*Decidme quiénes son mis clientes, cómo los llamo y qué le enseño a cada uno*».

Qué tenéis que entregar

Un paquete de entrega por equipo antes de la review final (3 minutos de presentación por equipo):

1 · Notebook reto_SO9_conocer_al_huesped.ipynb

Ejecutable de arriba abajo con semillas fijas. Incluye segmentación de `huespedes.csv` (método justificado, `k` con silueta y criterio de negocio), mapa 2D con PCA, prototipo de recomendador (al menos 2 métodos comparados con RMSE y `precision@3`) y función `recomendar(id_usuario, n)`.

2 · Ficha de segmentos (1 página, Markdown o PDF)

Usando `plantilla_ficha_segmentos.md`: por cada segmento, incluir nombre, tamaño, perfil en una frase, una acción comercial y una experiencia estrella.

3 · Nota de IA responsable (5 líneas)

Dentro de la ficha: análisis de riesgos éticos y operativos de segmentar y recomendar (discriminación, sesgo de popularidad, privacidad).

Restricciones del reto

• Librerías permitidas

Solo `numpy`, `pandas`, `matplotlib/seaborn` y `scikit-learn` (sin librerías especializadas de recomendación).

• Validación sin soluciones

Sin ficheros de solución del docente: los segmentos se validan con métricas internas y sentido de negocio.

• Equipos y autoría

Equipos de 3-4 personas; todas deben poder explicar cualquier parte del análisis técnico y comercial.

• Tiempo

3 h de reto en clase (1 h el 11/11 y 2 h el 12/11). Review de 3 min por equipo.

Pasos sugeridos (3 h de reto)



Recordad fijar las semillas aleatorias (`random_state`) desde el inicio para garantizar la reproducibilidad completa del notebook.

Qué se enseña en la review

- Cada equipo presenta en **3 minutos** sus segmentos definidos (**nombre comercial + acción concreta**).
- Una **recomendación personalizada** concreta para un usuario específico demostrada en directo.
- Comparación de los **valores de `k`** elegidos entre los distintos equipos.
- Debate guiado: *¿es el mismo cliente aunque le pongamos otro nombre?*

Criterios de evaluación

RÚBRICA DE EQUIPO

0 A 4 POR CRITERIO

Cada entregable se evalúa de **0 a 4 puntos** en los cuatro criterios de la rúbrica de retos del curso. La evaluación es de equipo: los roles, el tablero y el acuerdo cuentan tanto como los artefactos entregados. A continuación encontraréis la descripción completa de cada nivel para que podáis autoevaluaros antes de la review.

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
Corrección técnica	Datos sin escalar o k al azar; métricas mal calculadas	Segmenta y recomienda con fallos menores	Escalado, k justificado y recomendador evaluado con división de prueba	Además compara varios métodos de clustering y recomendación con resultados razonados
Reproducibilidad	No se puede volver a ejecutar	Se ejecuta con ayuda del equipo	Se ejecuta de arriba abajo con semillas fijas	Además README corto, datos o script de descarga y versiones
Análisis y comunicación al cliente	Solo cifras o gráficos sin interpretar	Nombres de segmentos sin acciones	Segmentos con nombre, tamaño y una acción cada uno	Además recomendación accionable, priorizada por valor y con límites explicados
IA responsable	No se considera	Menciones genéricas	Riesgos específicos: sesgo de popularidad, discriminación por edad o niños	Además propone medidas (p. ej. no segmentar por edad para precios) y comprueba alguna

¿Cómo llegar al nivel Excelente?

No se trata de acumular código, sino de justificar cada decisión técnica y comercial. Un clustering excelente no solo calcula k-means, sino que compara algoritmos y argumenta el valor de k con silueta y lógica de negocio. Un recomendador excelente evalúa con métricas rigurosas frente a la popularidad base. Y una ficha excelente ofrece al cliente acciones comerciales viables con conciencia de los sesgos éticos y de privacidad.



Rigor técnico y comparación

Escala siempre las variables, justifica k con silueta y evalúa los recomendadores comparando al menos dos métodos con RMSE y precision@3.



IA responsable proactiva

Aborda riesgos concretos (sesgo de popularidad, filtrado burbuja, discriminación por edad o perfil) y propone medidas verificables de mitigación.



Reproducibilidad total

El notebook debe ejecutarse de arriba abajo sin errores con semillas fijas, dependencias documentadas y commits de cada integrante del equipo.



Valor directo para el cliente

Presenta segmentos accionables con nombre descriptivo, tamaño, perfil claro y una acción comercial específica para Lucía en TurisData.

Definition of Done y cierre del sprint

CHECKLIST FINAL

RETROSPECTIVA

RECURSOS

Antes de presentar en la review del Sprint 9, cada equipo debe verificar el siguiente checklist. Si algún punto no se cumple, aún estás a tiempo de corregirlo en el notebook o en la ficha. Recordad que la Definition of Done garantiza el rigor analítico, la reproducibilidad técnica y la entrega de valor real a TurisData Canarias.

Checklist Definition of Done

- ☐ Notebook se ejecuta de arriba abajo sin errores y con semillas fijas
- ☐ Variables numéricas escaladas adecuadamente antes de agrupar
- ☐ Número de clusters (k) justificado con coeficiente de silueta y criterio de negocio
- ☐ Mapa 2D generado con PCA con segmentos coloreados y % de varianza en los ejes
- ☐ Ficha de segmentos completa: nombre, tamaño, perfil en 1 frase y acción comercial
- ☐ Recomendador evaluado con RMSE y precision@3, y comparado frente a la popularidad base
- ☐ Función recomendar(id_usuario, n) implementada y no propone experiencias ya valoradas
- ☐ Nota de IA responsable redactada con al menos dos riesgos específicos analizados
- ☐ Cada persona del equipo ha realizado commit de su parte en el repositorio

Preguntas de retrospectiva

Dedicad los últimos minutos del sprint a reflexionar en equipo sobre el trabajo con modelos no supervisados y recomendaciones:

- ¿Cómo influyó el escalado previo de datos en la coherencia de los clusters obtenidos?
- ¿Coincidieron las métricas matemáticas (silueta, RMSE) con el sentido de negocio de TurisData?
- ¿Qué sesgos potenciales de recomendación detectamos y cómo podemos mitigarlos?

Recursos recomendados

Documentación técnica, lecturas de referencia y recursos ampliados para profundizar en clustering, descomposición dimensional y aprendizaje por refuerzo:

- 1** Documentación scikit-learn
Guías oficiales de *Clustering* (k-means, DBSCAN, jerárquico) y *Decomposition* (PCA, análisis de componentes y varianza explicada).
- 2** Coeficiente de silueta y método del codo
Vídeo y artículo técnico sobre cómo diagnosticar la cohesión y separación entre clusters para elegir el valor óptimo de k.
- 3** Factorización de matrices en recomendadores
Explicación visual de descomposición matricial (SVD / embeddings latentes) para filtrado colaborativo entre usuarios y experiencias.
- 4** Sutton y Barto · Reinforcement Learning
«*Reinforcement Learning: An Introduction*» (capítulo 1, gratuito online) · La obra canónica para comprender el marco formal de RL y Q-learning.
- 5** Ampliación: Gymnasium
Entorno estándar de RL (pip install gymnasium), que replica la interfaz reset() y step() trabajada en el notebook 04.

⚠ Recordad tener listos el notebook ejecutable y la ficha de segmentos para la review: 3 minutos de presentación directa con recomendación en vivo.