Sprint 9 · Reto «Conocer al huésped»

Ficha completa del reto, para consultar. Para trabajar, el reto en una página. Qué se sube y cómo se evalúa: entrega y rúbrica.

- Volver al README del sprint.
- Si es vuestro primer reto: Cómo se trabaja un reto.

RETO Ficha del reto

1 Qué os pide el cliente

Qué os pide el cliente. Lucía, la directora comercial de TurisData Canarias, envía **la misma newsletter a sus 1.200 huéspedes** y vende sus **25 experiencias** con los mismos banners. Sospecha que hay «tipos» de cliente muy distintos y que cada uno querría cosas diferentes. Os pide: *«Decidme quiénes son mis clientes, cómo los llamo y qué le enseño a cada uno.»* Ninguna columna dice a qué tipo pertenece cada huésped: vosotros tenéis que **descubrir los grupos** con *clustering* (agrupar datos parecidos sin respuestas previas), **dibujarlos** en un mapa 2D, **ponerles nombre** y proponer **una acción comercial por grupo**. Además, construiréis un **recomendador** sencillo: dado un huésped, sugerirle experiencias que probablemente le gusten.

Cómo se trabaja. No hace falta experiencia previa: los cuadernos del sprint (`S09_01` , `S09_02` y `S09_03`) ya os hacen practicar cada pieza, y el reto consiste en **reutilizarlas con vuestras propias decisiones** y, sobre todo, en **explicar** qué habéis encontrado. No hay pruebas automáticas ni solución del docente: los grupos se validan con **sentido de negocio** y con **métricas internas** (silueta, RMSE). En clase tenéis 10 minutos de planning y 45 de reto el día 1, y 50 de reto más 40 de entrega, review y retrospectiva el día 2; lo que no quepa va a casa. El equipo decide hasta dónde llega: mínimo, estándar o extra.

2 · Recursos del reto

Recurso	Para qué lo usaréis	Dónde está
Python con `numpy` , `pandas` , `matplotlib` / `seaborn` y `scikit-learn` (solo esas bibliotecas: nada de librerías de recomendación especializadas)	Escribir el cuaderno del reto	Ya instaladas en Google Colab
Google Colab	Crear y ejecutar `reto_S09_conocer_al_huesped.ipynb`	En colab.research.google.com: *Archivo → Cuaderno nuevo*
Los datos de huéspedes `huespedes.csv`	1.200 huéspedes con 7 variables (`edad` , `gasto_medio_dia` , `noches_medias` , `reservas_anio` , `antelacion_media` , `pct_gasto_actividades` , `viaja_con_ninos`). Son **sintéticos**	No hace falta descargarlos: la celda «Preparación» de los cuadernos `S09_01` – `S09_03` los baja sola
Las valoraciones `valoraciones_experiencias.csv` y `experiencias.csv`	2.232 valoraciones (de 1 a 5 estrellas) de 300 usuarios sobre 25 experiencias, y el catálogo con nombre, categoría e isla	Igual: los baja la celda «Preparación»
Cuadernos del sprint: `S09_01` , `S09_02` y `S09_03`	El código de cada paso: escalar, k-means y silueta, PCA, recomendadores, RMSE y precision@3	Colab; su código explicado

Recurso	Para qué lo usaréis	Dónde está
Presentaciones Clustering y PCA y Sistemas de recomendación	Repasar los conceptos	En el repositorio del curso
La plantilla de la ficha `plantilla_ficha_segmentos.md`	Ficha de segmentos con huecos, nota de IA responsable y sección «Revisión con la rúbrica»	En GitHub: abrid el archivo y copiad el texto con el botón *Raw*
Cómo entregar en GitHub	Subir el cuaderno y la ficha a `sprint-09/`	Guía de entrega
Autoevaluación y coevaluación	Cada persona rellena su hoja	Hoja del sprint
Un asistente de IA (opcional)	Entender conceptos, pedir nombres y pensar riesgos	Con las reglas de la «Ayuda 1» del paso a paso

3 · Guía paso a paso

Son cinco pasos, de **105 minutos en total** (unos 45 el día 1 y unos 60 el día 2; el aula da 45 y 50, así que lo que no quepa va a casa). Cada uno dice **qué hacéis** (la lista corta), **cómo se hace** con el detalle, **qué deberíais ver** y **cuándo está hecho**. Las ayudas (IA, errores, atascos) están al final. Si el tiempo aprieta, completad el nivel mínimo y dejad lo demás para casa.

Paso 1 · Preparar el cuaderno y los datos (día 1, 10 minutos)

1. Crear en Colab el cuaderno `reto_S09_conocer_al_huesped.ipynb`.
2. Cargar `huespedes.csv` y mirar sus columnas.
3. Escalar las variables numéricas.
4. Repartir el trabajo de los pasos 2 y 3.

Cómo se hace

- **Crear el cuaderno.** En Colab: *Archivo → Cuaderno nuevo* y cambiadle el nombre a `reto_S09_conocer_al_huesped`. Trabajad en una sola pantalla compartida o compartid el cuaderno con el botón *Compartir* de Colab.
- **Cargar los datos.** Copiad al principio la celda «Preparación» de `S09_01` (la que define `dato(...)` y descarga los datos) y las importaciones. Fijad una semilla una sola vez, `SEMILLA = 42`, y usadla siempre que pidan `random_state`.
- **Mirar las columnas.** Con `head()` y `describe()`: `id_huesped` es solo un identificador y las otras 7 son números (`viaja_con_ninos` solo vale 0 o 1). Fijaos en las escalas: la edad va de 18 a 75 y el gasto diario, de 35 a 340.
- **Escalar.** Quitad `id_huesped` y pasad las 7 columnas por `StandardScaler().fit_transform(...)`: así todas pesan lo mismo. Guardad el resultado como `X`. Sin escalar, el gasto en euros mandaría sobre las demás.

Qué deberíais ver. Una tabla de 1200 filas y 8 columnas (el identificador y las 7 variables) y una matriz `X` de 1200 filas y 7 columnas, con la media de cada columna cerca de 0.

Hecho cuando: `X` existe y está escalada, y cada persona sabe qué parte del paso 2 o del 3 le toca.

Paso 2 · Segmentar y elegir k (día 1, 20 minutos)

1. Probar k-means con `k` de 2 a 8.
2. Calcular la silueta de cada `k` y dibujar la curva.
3. Elegir `k` con una razón técnica **y** una de negocio.
4. Escribir esa razón en una frase.

Cómo se hace. Es el mismo trabajo del ejercicio 2 de `S09_01`: podéis copiar de ahí la idea y adaptarla a vuestro cuaderno.

Orden	Qué hacéis	Pista
1	Para cada `k` de 2 a 8, entrenar k-means sobre `X`	`KMeans(n_clusters=k, n_init=10, random_state=SEMILLA)`

Orden	Qué hacéis	Pista
2	Guardar la silueta media de cada `k` en un diccionario	`silhouette_score(X, etiquetas)`; va de −1 a 1 y **más alto es mejor**
3	Dibujar la curva: `k` en el eje horizontal y silueta en el vertical	Título y nombres de ejes, como en `S09_01`
4	Preguntaos si Lucía puede actuar con ese número de grupos	Entre 3 y 5 segmentos suele ser manejable; 12 no lo serían
5	Escribir **una frase con las dos razones** y ponerla en el cuaderno y en la cabecera de la ficha	«Elegimos k = … porque la silueta es … y, para el negocio, … grupos se pueden gestionar»

Qué deberíais ver. Una curva con siluetas para `k` = 2, 3, …, 8 y un `k` elegido entre 3 y 5 (en `S09_01` el de mejor silueta cae en ese rango). No elijáis `k` **solo** por el número más alto de la silueta.

Hecho cuando: hay curva de silueta, un `k` elegido y la frase con las dos razones.

Paso 3 · Mapa PCA e interpretación de los segmentos (día 1, 15 minutos)

1. Dibujar el mapa 2D con PCA, con los segmentos coloreados.
2. Calcular el perfil medio de cada segmento y su tamaño.
3. Ponerle nombre a cada segmento, con cifras.
4. Proponer una acción comercial por segmento.

Cómo se hace

- **El mapa.** Entrenad `k-means` con el `k` elegido y guardad el grupo de cada huésped. Aplicad `PCA(n_components=2)` sobre `X` y dibujad un diagrama de dispersión coloreado por grupo (es el ejercicio 2 de `S09_02`). Los ejes llevan el **% de varianza** de cada componente (`explained_variance_ratio_`) y el título dice una **conclusión** («Cuatro tipos de huésped bastante separados»). Con 2 componentes se conserva solo una parte de la información (en `S09_02` salía cerca del 69 %): si el mapa sale mezclado, decidlo en la ficha.
- **El perfil.** Con `groupby` calculad la media de cada variable por grupo y el número de huéspedes. Comparad cada media con la media general; el mapa de calor de `S09_01` ayuda.
- **El nombre.** Cada nombre se apoya en **dos cifras** del perfil. Ejemplo de la plantilla: «Familias de larga estancia · 410 (34 %) · 9 de cada 10 viajan con niños, reservan con 110 días de antelación y gastan poco en actividades». Los tamaños de todos los segmentos suman 1.200.
- **La acción comercial.** Una por segmento: qué enseñar, cuándo y por qué canal. La IA puede sugerir nombres, pero el nombre tiene que reflejar vuestras cifras.

Qué deberíais ver. Un mapa con un color por segmento y el % de varianza en los ejes, y una tabla con el perfil medio de cada segmento: nombre, tamaño, dos o tres cifras y una acción.

Hecho cuando: el mapa está dibujado y cada segmento tiene nombre, tamaño, perfil con cifras y una acción.

Paso 4 · Recomendador de experiencias (día 2, 30 minutos)

1. Separar valoraciones de entrenamiento y de prueba.
2. Montar al menos dos métodos y evaluarlos con RMSE y precision@3.
3. Programar `recomendar(id_usuario, n)`.
4. Probarla con 3 usuarios.

Cómo se hace. Es el trabajo de `S09_03`: reutilizad su código y comprobad que lo entendéis.

Orden	Qué hacéis	Pista
1	Esconder el 20 % de las valoraciones como prueba y construir la matriz usuario × experiencia solo con el 80 % restante	`valoraciones.sample(frac=0.2, random_state=SEMILLA)`; las casillas vacías son `NaN`

Orden	Qué hacéis	Pista
2	Primer método: **popularidad** (la nota media de cada experiencia, igual para todos)	Es la referencia que hay que batir y la única opción para un huésped nuevo (*arranque en frío*)
3	Segundo método: **contenido** (se hace en clase en `S09_03`) o, si lo habéis hecho en casa, filtrado colaborativo o factorización	Cualquiera sirve, pero tiene que ser distinto de la popularidad
4	Medir los dos con **RMSE** (error de la nota, menos es mejor) y **precision@3** (de las 3 recomendadas, cuántas le gustaban, más es mejor)	Con pocos usuarios evaluables, una diferencia de 0,01 es ruido: no la vendáis como mejora
5	Una tabla *método · RMSE · precision@3* y una frase que explica cuál elegís	«Elegimos … porque su precision@3 es …»
6	Programar `recomendar(id_usuario, n)`: las `n` mejores experiencias **que el usuario no ha valorado**, con nombre, categoría, isla y nota prevista	Poned `-inf` en lo ya valorado antes de ordenar; es el mini-reto de `S09_03`

Probad `recomendar` con **3 usuarios distintos** y comprobad dos cosas: que ninguna experiencia recomendada estaba ya valorada y que las recomendaciones cambian de una persona a otra. Solo los usuarios 1 a 300 tienen valoraciones.

Qué deberíais ver. La tabla comparativa de los dos métodos, la frase de elección y tres listas de `n` experiencias, distintas entre sí.

Hecho cuando: el recomendador está evaluado con valoraciones escondidas, `recomendar` funciona con 3 usuarios y no propone nada ya valorado.

Paso 5 · Ficha, IA responsable, revisión y entrega (día 2, 30 minutos)

1. Rellenar la ficha de segmentos y la nota de IA responsable.
2. Pedir a alguien que no escribió esa parte que revise con la rúbrica y anote el resultado en la ficha.
3. Dejar el cuaderno ejecutable y subir los ficheros a `sprint-09/`.
4. Ensayar 3 minutos de review.

Cómo se hace

- **La ficha.** Copiad el texto de `plantilla_ficha_segmentos.md` en un archivo nuevo `ficha_segmentos.md` y rellenad cada sección:

Sección de la plantilla	Qué escribís
Cabecera	Equipo, método, `k`, silueta y la frase de las dos razones del paso 2
Mapa de segmentos	La imagen del mapa (`mapa_pca.png`, subida junto a la ficha) o dónde está en el cuaderno
Segmentos	Una fila por segmento: nombre, tamaño, perfil con cifras, acción y **experiencia estrella** (la que recomienda vuestro prototipo a ese grupo; **ojo:** los datos son sintéticos y las 300 personas de las valoraciones **no son** las de `huespedes.csv`, así que no hay un cruce real entre ambos ficheros: elegid la experiencia razonando con el perfil del segmento y apoyadla en lo que recomienda vuestro prototipo, y anotad esa decisión como supuesto)
Recomendador	Los dos métodos con su RMSE y precision@3, el elegido y un ejemplo con un usuario; qué haría el sistema con un huésped nuevo sin valoraciones
IA responsable	Cinco líneas con **al menos 2 riesgos específicos** de este caso, cada uno con su medida (ejemplos justo debajo de la tabla)
Limitaciones	Datos sintéticos, comportamiento de un año, pocas valoraciones por persona, y las vuestras

- **Nota de IA responsable.** Ejemplos, para que elijáis los que valen para **vuestro** caso: *discriminar* (si se usan la edad o «viaja con niños» para fijar precios; medida: usar la segmentación para comunicar, no para variar precios); *sesgo de popularidad* (las experiencias poco conocidas casi no se recomiendan; medida: reservar un hueco a opciones menos populares); *privacidad* (se combinan datos de reserva y valoraciones; medida: usar identificadores y no mostrar datos personales).
- **Declarar la IA.** En el cuaderno, una celda de texto que diga dónde la habéis usado y qué habéis comprobado a mano.
- **La revisión con la rúbrica (10 minutos).** Quien revisa sigue los cinco pasos de «Cómo se revisa» de entrega y rúbrica y rellena la sección «Revisión con la rúbrica» del final de `ficha_segmentos.md`: un nivel de 1 a 4 por criterio y **una frase de prueba**. Si hay tiempo, arreglad lo más fácil; lo demás queda como «lo primero que mejoraríamos». Si sobran minutos, empezad algún extra.
- **Subir los ficheros (la vía del curso, desde el navegador).** Seguid Cómo entregar en GitHub. (1) En Colab, *Entorno de ejecución → Reiniciar y ejecutar todo* y después *Archivo → Descargar → Descargar .ipynb*. (2) Abrid el repositorio del equipo y **entrad primero en la carpeta `sprint-09`**. (3) *Add file → Upload files*, arrastrad los ficheros, escribid un mensaje corto y pulsad **Commit changes**. Cada subida es un *commit* con el nombre de quien la hace. Un reparto posible: la persona A sube el cuaderno («Añado segmentación y recomendador»), la B sube la ficha y el mapa («Añado ficha de segmentos»), y cada persona sube su autoevaluación. Nombres de archivo **sin espacios ni tildes**.

Qué deberíais ver. En la carpeta `sprint-09` del repositorio, el cuaderno y la ficha del equipo (y el mapa, si lo habéis puesto) y una hoja de autoevaluación por persona (**2 + N**); y en el historial (el icono del reloj), *commits* de todas las personas del equipo.

Hecho cuando: otra persona podría repetir el cuaderno de arriba abajo, la sección «Revisión con la rúbrica» está rellena y cada persona ha subido algo con su cuenta.

Después, 40 minutos de entrega, review y retrospectiva: cada persona rellena y sube su autoevaluación y coevaluación a `sprint-09/`, y el equipo presenta en 3 minutos **sus segmentos (nombre y acción)** y **una recomendación concreta para un usuario**. Se comparan los `k` elegidos y se discute: *¿es el mismo cliente aunque le pongamos otro nombre?*

Ayuda 1 · Cómo usar la IA en este reto

La IA puede ahorrar tiempo, pero **inventa con mucha seguridad**: un nombre de segmento que suena bien pero no refleja las cifras es un error. Reglas:

- **Todo lo que dé, lo comprobáis y lo entendéis.** Si el docente pregunta por una celda, tenéis que saber explicarla; en la review puede preguntar a cualquiera.
- **Los datos mandan:** si un nombre o una conclusión de la IA no cuadra con vuestras cifras, no vale.
- **Declaradlo** en el cuaderno: dónde la habéis usado y qué habéis comprobado.
- **Nada de datos personales ni claves** en una IA.

Para qué	Ejemplo de petición	Qué comprobáis
Entender un concepto	«Explícame k-means y la silueta con una analogía de personas en una fiesta»	Que podéis explicarlo con vuestras palabras
Entender PCA	«¿Qué significa que PCA conserve el 60 % de la varianza? Dame un ejemplo sin fórmulas»	Que vuestro gráfico dice lo mismo
Poner nombres a los segmentos	«Dado este perfil medio: *[tabla]*, dame 5 nombres comerciales cortos y evocadores»	Que el nombre refleja las **cifras** del segmento, no una invención
Pensar en riesgos	«¿Qué riesgos tiene recomendar experiencias según la edad?»	Elegid los que aplican a **vuestro** caso y dad una medida real

Ayuda 2 · Errores frecuentes (y cómo evitarlos)

Error	Por qué ocurre	Cómo evitarlo
Agrupar sin escalar	Se olvida	Escalad **antes** del clustering
Elegir `k` solo con la silueta	«Es lo que dice el número»	Añadid el criterio de negocio
Poner nombres sin mirar los datos	Suena bien	Cada nombre debe justificarse con **dos cifras** del perfil
Recomendar lo que el usuario ya ha valorado	No se filtra	La función debe excluirlas
Evaluar el recomendador con los mismos datos que usó	«Es lo más fácil»	Probad con valoraciones **escondidas**
Nota de IA responsable genérica	Prisa	Dos riesgos **concretos** de este caso, con medida
El cuaderno falla al ejecutarlo de nuevo	Celdas ejecutadas en desorden o semillas sin fijar	*Reiniciar y ejecutar todo* antes de subirlo y usar siempre la misma `SEMILLA`

Ayuda 3 · Si os atascáis

1. **Todos los segmentos se parecen:** revisad que habéis escalado y probad otras columnas; quizá algunas no aportan.
2. **El mapa PCA sale con todo mezclado:** es posible; decidlo en la ficha. Los grupos pueden estar separados en dimensiones que el 2D no recoge.
3. **El recomendador recomienda siempre lo mismo:** probablemente es un sesgo de popularidad; comentadlo como riesgo.
4. Repasad el cuaderno de ese paso y su código explicado; preguntad al equipo y, después, al docente. Más ayuda: Cómo se trabaja un reto.