

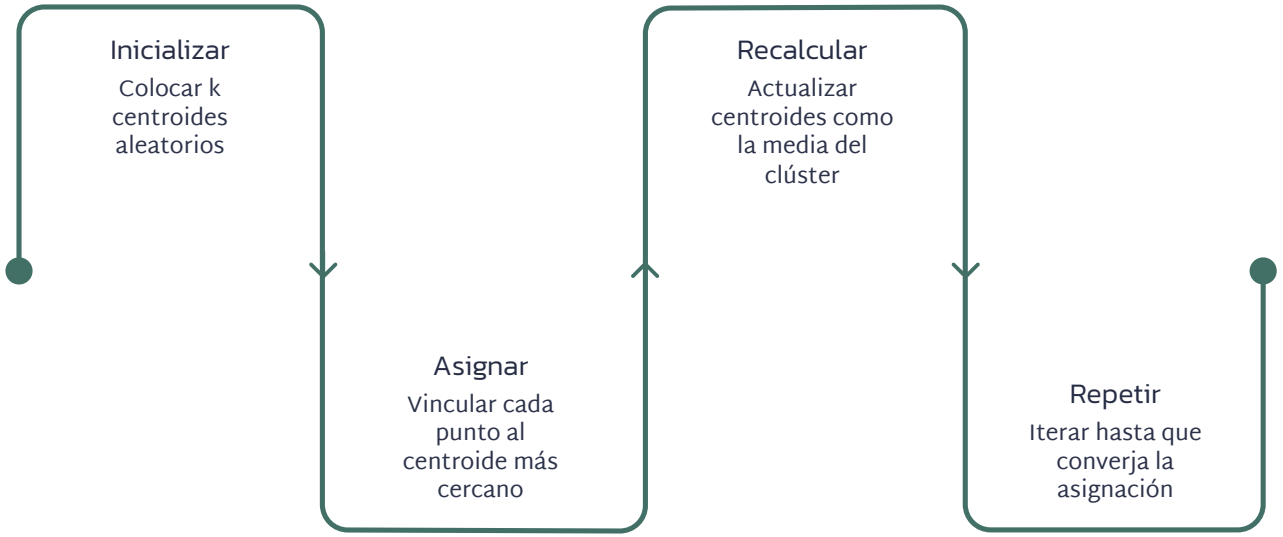
Sprint 9 · Segmentar, recomendar y aprender por refuerzo

S9.1 · Clustering y PCA

Un recorrido por las técnicas esenciales del aprendizaje no supervisado: desde agrupar datos sin etiquetas hasta reducir dimensiones para visualizar y comprender estructuras ocultas en los datos.



k-means: agrupación por centroides



k-means minimiza la suma de distancias cuadradas dentro de cada clúster (inercia). Es rápido y escalable, pero asume clústeres esféricos y de tamaño similar. La inicialización con **k-means++** mejora la estabilidad del resultado.

Elegir k: método del codo y silueta

Método del codo (Elbow)

Se grafica la inercia en función de k. Cuando la reducción de inercia se ralentiza bruscamente, aparece un "codo": ese punto sugiere el número óptimo de clústeres. Es heurístico y no siempre produce un codo claro.

Coeficiente de silueta

Mide qué tan bien encaja cada punto en su clúster frente a los demás. Valores cercanos a **+1** indican clústeres bien separados; valores negativos señalan asignaciones incorrectas. Se puede calcular para distintas k y elegir el máximo.

Inercia

Suma de distancias al centroide. Siempre baja al aumentar k.

Silueta

Rango [−1, +1]. Penaliza clústeres solapados o muy pequeños.

Consejo

Combina ambos métodos para una decisión más robusta.



Clustering jerárquico

El clustering jerárquico construye un árbol de fusiones (dendrograma) sin necesidad de especificar k de antemano. Existen dos enfoques principales:

Aglomerativo (bottom-up)

Parte de cada punto como su propio clúster y los va fusionando iterativamente según un criterio de enlace: **single** (mínima distancia), **complete** (máxima) o **ward** (mínima varianza interna). Es el más habitual en la práctica.

Divisivo (top-down)

Parte de un único clúster con todos los datos y lo divide sucesivamente. Computacionalmente más costoso y menos frecuente, pero útil cuando se conoce la estructura global del problema.

Cortar el dendrograma a una altura determinada equivale a elegir k clústeres.

DBSCAN: densidad frente a geometría

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) agrupa puntos que están densamente conectados, identificando automáticamente el número de clústeres y detectando **outliers** como ruido.

Parámetros clave

- **ε (epsilon)**: radio de vecindad de cada punto
- **min_samples**: mínimo de vecinos para ser punto núcleo

Ventajas frente a k-means

- Detecta clústeres de forma arbitraria (no solo esféricos)
- No requiere especificar k
- Robusto ante ruido y anomalías

Punto núcleo

Tiene ≥ min_samples vecinos en radio ε

Punto frontera

En el vecindario de un núcleo, pero con pocos vecinos propios

Ruido

No pertenece a ningún clúster; es un outlier

Evaluar clustering sin etiquetas

Sin una verdad de referencia, evaluar la calidad del clustering requiere métricas **internas** que solo utilizan los propios datos:



Coeficiente de silueta

Compara la cohesión interna del clúster con la separación respecto al más cercano. Valor óptimo: próximo a +1.



Índice Davies-Bouldin

Ratio de dispersión interna sobre separación entre clústeres. Cuanto más bajo, mejor. Penaliza clústeres solapados.



Índice Calinski-Harabasz

Cociente entre la dispersión entre clústeres y la interna. Valores más altos indican clústeres más compactos y separados.

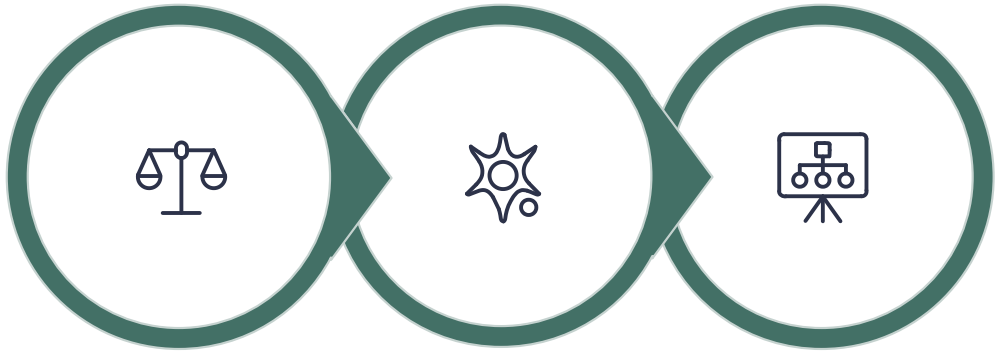


Métricas externas (si hay etiquetas)

Adjusted Rand Index o Normalized Mutual Information permiten comparar con etiquetas de referencia cuando están disponibles.

PCA: la idea detrás de la reducción de dimensionalidad

Principal Component Analysis (PCA) busca las direcciones del espacio de características que maximizan la varianza de los datos. Estas direcciones, llamadas **componentes principales**, son ortogonales entre sí y se ordenan de mayor a menor varianza explicada.



Escalar datos

Calcular covarianza

Proyectar componentes



Varianza explicada y selección de componentes

¿Cuántos componentes usar?

Cada componente principal captura una fracción de la varianza total. La **varianza explicada acumulada** indica cuánta información se retiene al quedarse con k componentes. Un criterio habitual es elegir el mínimo k que supere el **85-95 %** de varianza acumulada.

El **scree plot** representa la varianza explicada por cada componente en orden decreciente, ayudando a identificar visualmente el punto de corte óptimo (similar al método del codo en k-means).

PC1

Mayor varianza

Primer eje de máxima dispersión en los datos

⊥

Ortogonalidad

Cada componente es perpendicular a los anteriores

λ

Valor propio

Magnitud de varianza capturada por cada componente

PCA + Clustering: el dúo perfecto

En la práctica, **PCA y clustering se combinan con frecuencia**. Reducir la dimensionalidad antes de aplicar k-means o DBSCAN tiene múltiples beneficios:

1 Elimina ruido y colinealidad

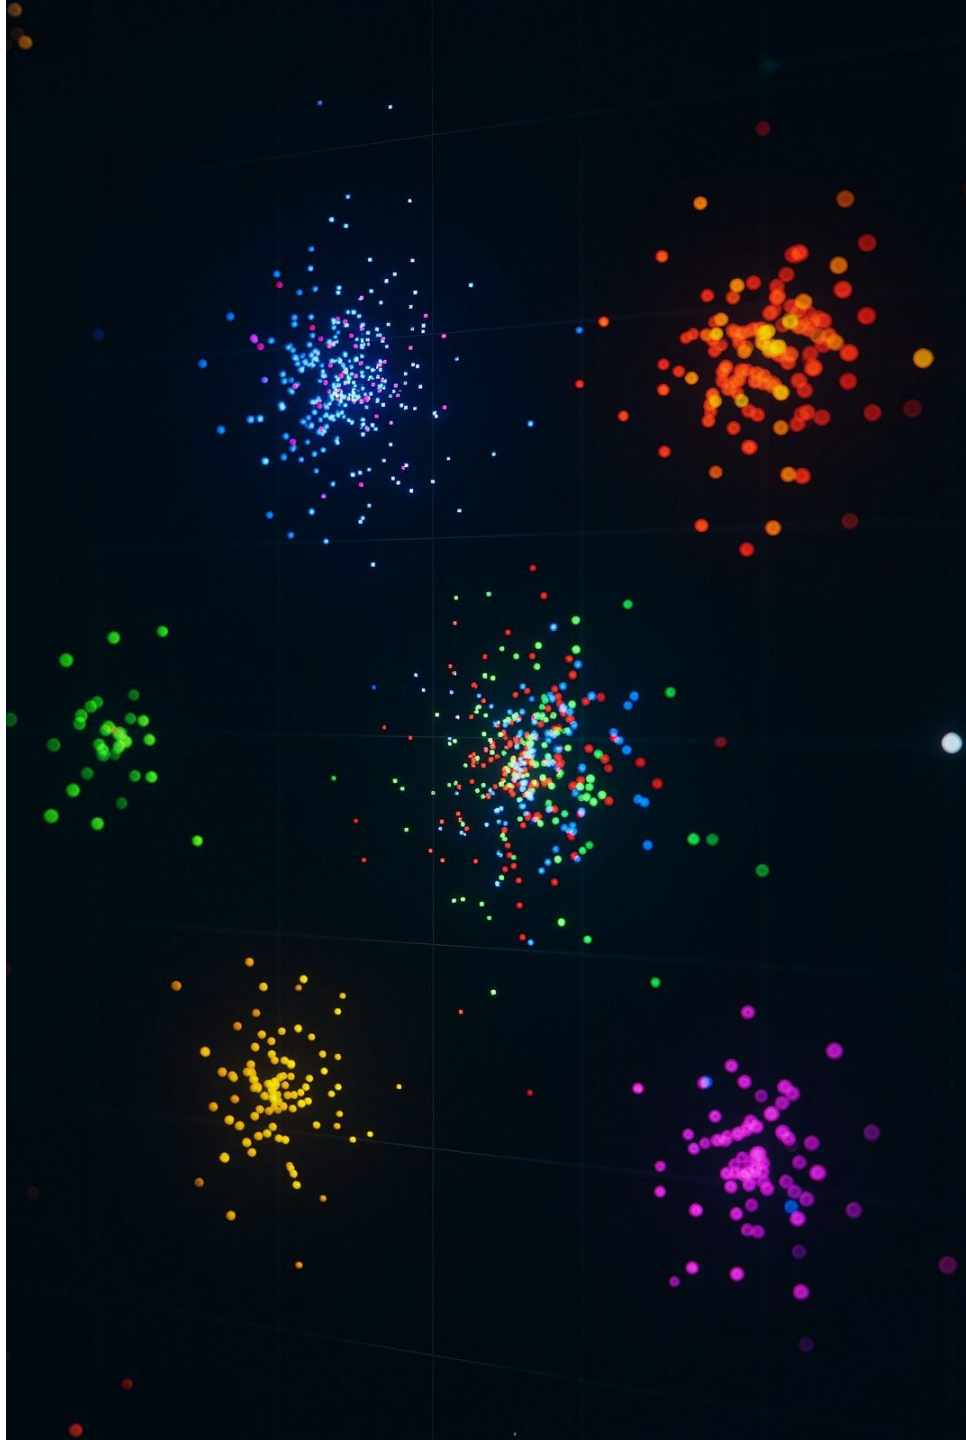
Las componentes principales descartan varianza espuria, haciendo que las distancias entre puntos sean más significativas.

2 Acelera el cómputo

Con menos dimensiones, los algoritmos de clustering convergen más rápido y consumen menos memoria.

3 Facilita la visualización

Proyectar en 2D con PCA permite pintar los clústeres resultantes y validarlos visualmente de forma inmediata.



S09 · EN EL REPOSITORIO DEL CURSO

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

S09_01_clustering

55 min

Segmentar huéspedes: k-means, silueta, jerárquico y DBSCAN

sprints/S09/notebooks/S09_01_clustering.ipynb

CUADERNO

S09_02_pca

40 min

PCA: varianza explicada y mapa en 2D

sprints/S09/notebooks/S09_02_pca.ipynb

RETO

Reto del sprint

50 min

Arrancar el reto: preparar datos, segmentar y elegir k, mapa PCA (pasos 1–3)

sprints/S09/guia/Reto_Sprint_09.md