Clustering y PCA

Lucía, la directora comercial, envía la misma newsletter a sus 1.200 huéspedes. Sospecha que hay «tipos» de cliente muy distintos. **No hay una columna que diga el tipo:** hay que descubrirlo.

Aprender sin respuestas

Supervisado

Hay una columna objetivo (`cancelada`). El modelo aprende a predecirla.

No supervisado

No hay objetivo. El algoritmo **descubre estructura**: grupos (clustering) o ejes de variación (PCA).

Tu trabajo no termina con el algoritmo: tienes que **ponerle nombre y significado de negocio** a cada grupo y proponer una acción comercial.

Escalar primero

Clustering agrupa por **distancia**. Si el gasto va en euros y `viaja_con_ninos` es 0/1, el gasto manda y el 0/1 no cuenta.

```
X = StandardScaler().fit_transform(huespedes.drop(columns="id_huesped"))   # Ejercicio 1
variables = list(huespedes.drop(columns="id_huesped").columns)             # X: 1200 × 7
```

Pregunta de reflexión del cuaderno: prueba **sin escalar** y compara la silueta.

k-means y la silueta (cuaderno S09_01)

1. Elige `k` centros, asigna cada huésped al más cercano, recalcula los centros y repite.
2. Rápido y fácil de explicar; **tú decides `k`** y prefiere grupos «redondos» y de tamaño parecido.

```
siluetas = {k: silhouette_score(X, KMeans(k, n_init=10, random_state=SEMILLA).fit_predict(X))
            for k in range(2, 9)}                                          # Ejercicio 2
mejor_k = max(siluetas, key=siluetas.get)
```

Silueta (−1 a 1): > 0,5 estructura buena; 0,25–0,5 aceptable. La silueta más alta **no siempre** da el mejor número de segmentos para el negocio.

Interpretar: ¿quién es cada grupo?

```
perfil = huespedes.assign(grupo=etiquetas).groupby("grupo").mean()        # media por grupo
grupo_familias = perfil["viaja_con_ninos"].idxmax()                        # Ejercicio 3
grupo_aventura = perfil["pct_gasto_actividades"].idxmax()
```

- Un grupo sin nombre no sirve al negocio: léelo como un **cliente típico** (edad, gasto, niños, % de gasto en actividades).
- El mapa de calor de las medias por grupo te da la pista para el nombre.

Jerárquico y DBSCAN

Jerárquico (Ward)

Cada huésped empieza solo y se fusionan los más parecidos. Resultado: un **dendrograma**; se «corta» a la altura que da `k` grupos. `AgglomerativeClustering(n_clusters=4, linkage="ward")` (Ejercicio 4).

DBSCAN

Grupos = zonas **densas**. No hay que decir cuántos. `eps` (radio) y `min_samples`. Lo demás es **ruido (−1)**: clientes raros. `DBSCAN(eps=1.0, min_samples=10)` (Ejercicio 5).

Mini-reto: elige método, **justifícalo en una frase** y escribe para cada grupo un nombre, una descripción de una línea y una acción comercial (`nombres_segmentos`).

PCA: ver los datos en 2D (cuaderno S09_02)

Como una nube con forma de puro: el **componente 1** es la dirección con más variación; el **componente 2**, la siguiente, perpendicular.

```
varianza_acum = np.cumsum(pca.explained_variance_ratio_)                # Ejercicio 1
n_comp_90 = int(np.argmax(varianza_acum >= 0.90)) + 1
Z2 = PCA(n_components=2).fit_transform(X)                               # mapa 2D
ax.scatter(Z2[:, 0], Z2[:, 1], c=grupo)                                 # Ejercicio 2
```

Pon en los ejes el **% de varianza** de cada componente.

Leer los componentes y usar PCA con cuidado

- Un componente es una **receta**: `0,45·edad + 0,33·gasto − 0,44·%actividades…`. Esos pesos son las **cargas** (Ejercicio 3: variables con signo contrario al de `edad` en PC1). El signo global es arbitrario.
- Ejercicio 4: `PCA(n_components=n_comp_90)` antes de k-means; `adjusted_rand_score` mide si los grupos son estables.
- **t-SNE / UMAP**: bonitos para ver grupos, pero las distancias entre grupos **no significan nada** y cambian con la semilla.

Mini-reto: un compañero dice «con 2 componentes ya vale». ¿Para **dibujar**? Sí. ¿Para un modelo que necesita precisión? Mira `varianza_acum`.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO **S09_01_clustering** — 55 min
Segmentar huéspedes: k-means, silueta, jerárquico y DBSCAN
sprints/S09/notebooks/S09_01_clustering.ipynb

CUADERNO **S09_02_pca** — 40 min
PCA: varianza explicada y mapa en 2D
sprints/S09/notebooks/S09_02_pca.ipynb

RETO **Reto del sprint** — 50 min
Arrancar el reto: preparar datos, segmentar y elegir k, mapa PCA (pasos 1–3)
sprints/S09/guia/Reto_Sprint_09.md