

Clustering y PCA

Sprint 9 · Aprendizaje no supervisado y por refuerzo · S09.1

Lucía, la directora comercial, envía la misma newsletter a sus 1.200 huéspedes. Sospecha que hay «tipos» de cliente muy distintos. No hay una columna que diga el tipo: hay que descubrirlo.

Aprender sin respuestas

Supervisado

Hay una columna objetivo (cancelada). El modelo aprende a predecirla.

No supervisado

No hay objetivo. El algoritmo descubre estructura: grupos (clustering) o ejes de variación (PCA).

Tu trabajo no termina con el algoritmo: tienes que ponerle nombre y significado de negocio a cada grupo y proponer una acción comercial.

Escalar primero

Clustering agrupa por distancia. Si el gasto va en euros y viaja_con_ninos es 0/1, el gasto manda y el 0/1 no cuenta.

```
X = StandardScaler().fit_transform(huespedes.drop(columns="id_huesped"))   # Ejercicio 1
variables = list(huespedes.drop(columns="id_huesped").columns)             # X: 1200 × 7
```

Pregunta de reflexión del cuaderno: prueba sin escalar y compara la silueta.

k-means y la silueta (cuaderno S09_01)

1. Elige k centros, asigna cada huésped al más cercano, recalcula los centros y repite.
2. Rápido y fácil de explicar; tú decides k y prefiere grupos «redondos» y de tamaño parecido.

```
siluetas = {k: silhouette_score(X, KMeans(k, n_init=10, random_state=SEMILLA).fit_predict(X))
            for k in range(2, 9)}                                  # Ejercicio 2
mejor_k = max(siluetas, key=siluetas.get)
```

Silueta (–1 a 1): > 0,5 estructura buena; 0,25–0,5 aceptable. La silueta más alta no siempre da el mejor número de segmentos para el negocio.

Interpretar: ¿quién es cada grupo?

```
perfil = huespedes.assign(grupo=etiquetas).groupby("grupo").mean()       # media por grupo
grupo_familias = perfil["viaja_con_ninos"].idxmax()                      # Ejercicio 3
grupo_aventura = perfil["pct_gasto_actividades"].idxmax()
```

- Un grupo sin nombre no sirve al negocio: léelo como un cliente típico (edad, gasto, niños, % de gasto en actividades).
- El mapa de calor de las medias por grupo te da la pista para el nombre.

Jerárquico y DBSCAN

Jerárquico (Ward)

Cada huésped empieza solo y se fusionan los más parecidos. Resultado: un dendrograma; se «corta» a la altura que da k grupos.

`AgglomerativeClustering(n_clusters=4, linkage="ward")`

(Ejercicio 4)

DBSCAN

Grupos = zonas densas. No hay que decir cuántos. eps (radio) y min_samples. Lo demás es ruido (–1): clientes raros.

`DBSCAN(eps=1.0, min_samples=10)`

(Ejercicio 5)

Mini-reto: elige método, justifícalo en una frase y escribe para cada grupo un nombre, una descripción de una línea y una acción comercial (nombres_segmentos).

PCA: ver los datos en 2D (cuaderno S09_02)

Como una nube con forma de puro: el componente 1 es la dirección con más variación; el componente 2, la siguiente, perpendicular.

```
varianza_acum = np.cumsum(pca.explained_variance_ratio_)          # Ejercicio 1
n_comp_90 = int(np.argmax(varianza_acum >= 0.90)) + 1
Z2 = PCA(n_components=2).fit_transform(X)                  # mapa 2D
ax.scatter(Z2[:, 0], Z2[:, 1], c=grupo)                    # Ejercicio 2
```

Pon en los ejes el % de varianza de cada componente.

Leer los componentes y usar PCA con cuidado

- Un componente es una receta: 0,45·edad + 0,33·gasto – 0,44·%actividades…. Esos pesos son las cargas (Ejercicio 3: variables con signo contrario al de edad en PC1). El signo global es arbitrario.
- Ejercicio 4: PCA(n_components=n_comp_90) antes de k-means; adjusted_rand_score mide si los grupos son estables.
- t-SNE / UMAP: bonitos para ver grupos, pero las distancias entre grupos no significan nada y cambian con la semilla.

Mini-reto: un compañero dice «con 2 componentes ya vale». ¿Para dibujar? Sí. ¿Para un modelo que necesita precisión? Mira varianza_acum.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio.

- CUADERNO · Segmentar huéspedes: k-means, silueta, jerárquico y DBSCAN (sprints/S09/notebooks/S09_01_clustering) — 55 min.
- CUADERNO · PCA: varianza explicada y mapa en 2D (sprints/S09/notebooks/S09_02_pca) — 40 min.
- RETO · Arrancar el reto: preparar datos, segmentar y elegir k, mapa PCA (pasos 1–3) (sprints/S09/Reto_S09/Reto_Sprint_09.md) — 50 min.