



Sprint 9 · Segmentar, recomendar y aprender por refuerzo

S9.1 · Clustering y PCA

Un recorrido por las técnicas esenciales del aprendizaje no supervisado: desde agrupar datos sin etiquetas hasta reducir dimensiones para visualizar y comprender estructuras ocultas en los datos.

¿Para qué sirve el aprendizaje no supervisado?

Sin etiquetas, sin problema


A diferencia del aprendizaje supervisado, aquí no disponemos de una variable objetivo. El algoritmo **descubre estructura por sí solo**: grupos naturales, patrones ocultos o representaciones compactas de los datos.

Casos de uso habituales

- Segmentación de clientes en marketing
- Detección de anomalías en ciberseguridad
- Compresión y visualización de datos de alta dimensión
- Sistemas de recomendación y análisis exploratorio

Es especialmente valioso cuando etiquetar datos es costoso o imposible.

k-means: agrupación por centroides



k-means minimiza la suma de distancias cuadradas dentro de cada clúster (inercia). Es rápido y escalable, pero asume clústeres esféricos y de tamaño similar. La inicialización con **k-means++** mejora la estabilidad del resultado.

Elegir k: método del codo y silueta

Método del codo (Elbow)

Se grafica la inercia en función de k. Cuando la reducción de inercia se ralentiza bruscamente, aparece un "codo": ese punto sugiere el número óptimo de clústeres. Es heurístico y no siempre produce un codo claro.

Coeficiente de silueta

Mide qué tan bien encaja cada punto en su clúster frente a los demás. Valores cercanos a **+1** indican clústeres bien separados; valores negativos señalan asignaciones incorrectas. Se puede calcular para distintas k y elegir el máximo.

Inercia

Suma de distancias al centroide. Siempre baja al aumentar k.

Silueta

Rango $[-1, +1]$. Penaliza clústeres solapados o muy pequeños.

Consejo

Combina ambos métodos para una decisión más robusta.



Clustering jerárquico

El clustering jerárquico construye un árbol de fusiones (dendrograma) sin necesidad de especificar k de antemano. Existen dos enfoques principales:

Aglomerativo (bottom-up)

Parte de cada punto como su propio clúster y los va fusionando iterativamente según un criterio de enlace: **single** (mínima distancia), **complete** (máxima) o **ward** (mínima varianza interna). Es el más habitual en la práctica.

Divisivo (top-down)

Parte de un único clúster con todos los datos y lo divide sucesivamente. Computacionalmente más costoso y menos frecuente, pero útil cuando se conoce la estructura global del problema.

- ❏ Cortar el dendrograma a una altura determinada equivale a elegir k clústeres.

DBSCAN: densidad frente a geometría

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) agrupa puntos que están densamente conectados, identificando automáticamente el número de clústeres y detectando **outliers** como ruido.

Parámetros clave

- **ϵ (epsilon):** radio de vecindad de cada punto
- **min_samples:** mínimo de vecinos para ser punto núcleo

Ventajas frente a k-means

- Detecta clústeres de forma arbitraria (no solo esféricos)
- No requiere especificar k
- Robusto ante ruido y anomalías

Punto núcleo

Tiene $\geq$ min_samples
vecinos en radio ϵ

Punto frontera

En el vecindario de un
núcleo, pero con pocos
vecinos propios

Ruido

No pertenece a ningún clúster; es un outlier

Evaluar clustering sin etiquetas

Sin una verdad de referencia, evaluar la calidad del clustering requiere métricas **internas** que solo utilizan los propios datos:



Coeficiente de silueta

Compara la cohesión interna del clúster con la separación respecto al más cercano. Valor óptimo: próximo a +1.



Índice Davies–Bouldin

Ratio de dispersión interna sobre separación entre clústeres. Cuanto más bajo, mejor. Penaliza clústeres solapados.



Índice Calinski–Harabasz

Cociente entre la dispersión entre clústeres y la interna. Valores más altos indican clústeres más compactos y separados.




Métricas externas (si hay etiquetas)

Adjusted Rand Index o Normalized Mutual Information permiten comparar con etiquetas de referencia cuando están disponibles.

PCA: la idea detrás de la reducción de dimensionalidad

Principal Component Analysis (PCA) busca las direcciones del espacio de características que maximizan la varianza de los datos. Estas direcciones, llamadas **componentes principales**, son ortogonales entre sí y se ordenan de mayor a menor varianza explicada.



Varianza explicada y selección de componentes

¿Cuántos componentes usar?

Cada componente principal captura una fracción de la varianza total.

La **varianza explicada acumulada** indica cuánta información se retiene al quedarse con k componentes. Un criterio habitual es elegir el mínimo k que supere el **85-95 %** de varianza acumulada.

El **scree plot** representa la varianza explicada por cada componente en orden decreciente, ayudando a identificar visualmente el punto de corte óptimo (similar al método del codo en k-means).

PC1

Mayor varianza

Primer eje de máxima dispersión en los datos



Ortogonalidad

Cada componente es perpendicular a los anteriores

λ

Valor propio

Magnitud de varianza capturada por cada componente

Visualización en 2D con PCA y t-SNE

PCA en 2D

Proyectar sobre los dos primeros componentes principales permite visualizar datos de alta dimensión en un plano. La proyección es **lineal**, rápida y reproducible, ideal como primer paso exploratorio. Sin embargo, puede perder estructuras no lineales presentes en los datos.

t-SNE: más allá de lo lineal

t-SNE (t-Distributed Stochastic Neighbor Embedding) es una técnica no lineal que conserva la estructura local de los datos: puntos cercanos en alta dimensión quedan cerca en 2D. Muy popular para visualizar embeddings y datos complejos como imágenes o texto.

❏ t-SNE no es apto para reducción de dimensionalidad previa al modelado; úsalo solo para visualización.

PCA

Lineal · Rápido · Reproducible · Interpretable

t-SNE

No lineal · Lento · Estocástico · Solo visualización

PCA + Clustering: el dúo perfecto

En la práctica, **PCA y clustering se combinan con frecuencia**. Reducir la dimensionalidad antes de aplicar k-means o DBSCAN tiene múltiples beneficios:

1 Elimina ruido y colinealidad


Las componentes principales descartan varianza espuria, haciendo que las distancias entre puntos sean más significativas.

2 Acelera el cómputo

Con menos dimensiones, los algoritmos de clustering convergen más rápido y consumen menos memoria.

3 Facilita la visualización

Proyectar en 2D con PCA permite pintar los clústeres resultantes y validarlos visualmente de forma inmediata.



Comparativa de algoritmos de clustering

Algoritmo	Especifica k	Forma clústeres	Outliers	Escalabilidad
k-means	Sí	Esférica	Sensible	Alta
Jerárquico	No (post-corte)	Cualquiera	Sensible	Baja
DBSCAN	No	Arbitraria	Robusto	Media

La elección del algoritmo depende de la geometría esperada de los datos, la presencia de ruido y el volumen del conjunto. No existe un ganador universal: experimenta y valida con las métricas internas.

Resumen y próximos pasos

01

Aprendizaje no supervisado

Descubre estructura sin etiquetas: agrupaciones, jerarquías y representaciones compactas.

02

k-means, jerárquico y DBSCAN

Tres paradigmas complementarios para segmentar datos según geometría, jerarquía o densidad.

03

Selección de k y evaluación

Codo, silueta y Davies-Bouldin permiten elegir y validar modelos sin etiquetas de referencia.

04

PCA y visualización

Reducción lineal de dimensionalidad para comprimir, acelerar y visualizar datos en 2D. t-SNE para exploración no lineal.

📅 Próximo sprint: sistemas de recomendación y aprendizaje por refuerzo.

