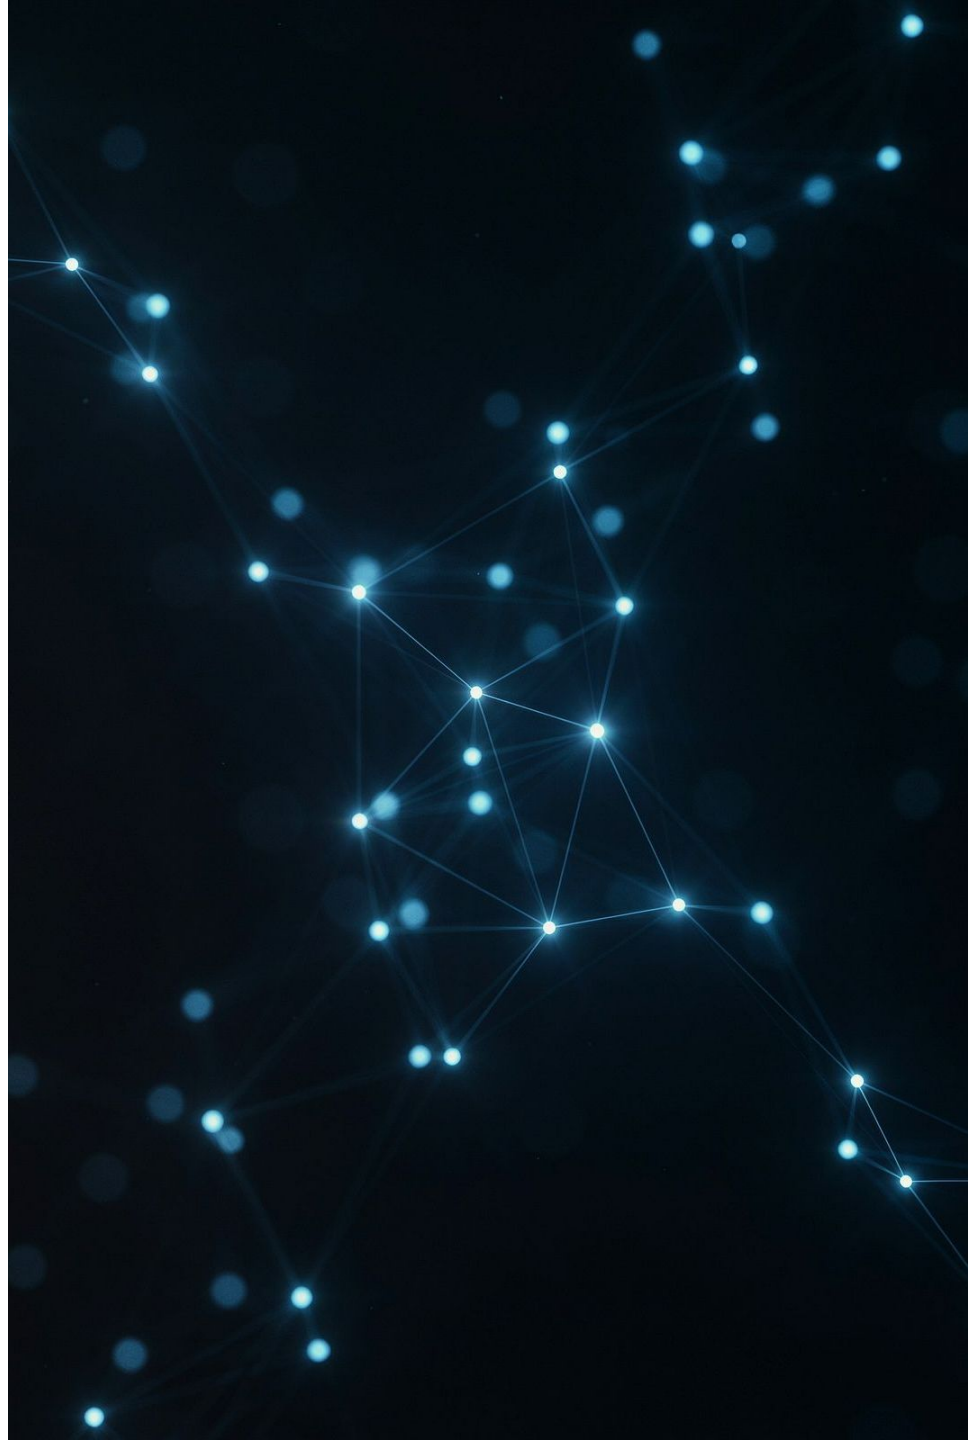
Sistemas de Recomendación

TEMA 9.2 · APRENDIZAJE AUTOMÁTICO

Los sistemas de recomendación son uno de los casos de uso más impactantes del aprendizaje automático. Desde Netflix hasta Spotify, estos algoritmos moldean qué consumimos, cómo lo descubrimos y qué queda invisible para nosotros. En esta lección exploraremos los fundamentos técnicos, los modelos clave y los retos éticos que plantean.



Las tres grandes familias

🎯 Basado en contenido

Analiza las características intrínsecas de los ítems (género, descripción, metadatos) y las compara con el perfil histórico del usuario. Recomienda lo que es **similar a lo que ya le gustó**.

👥 Filtrado colaborativo

Explota patrones de comportamiento entre usuarios. Si dos usuarios tienen gustos similares, lo que le gusta a uno puede gustarle al otro. No necesita conocer el contenido del ítem.

🔀 Sistemas híbridos

Combinan ambos enfoques para aprovechar sus fortalezas y mitigar sus debilidades. Son los más usados en producción (Netflix, Spotify, Amazon).

PARTE 2

Recomendación Basada en Contenido

En este enfoque, cada ítem se representa como un **vector de características**: palabras clave, género, director, precio, etc. El perfil de usuario se construye agregando los vectores de los ítems con los que ha interactuado.

La recomendación se calcula midiendo la **similitud coseno** entre el perfil del usuario y los ítems candidatos:

$$\text{sim}(\mathbf{u}, \mathbf{i}) = \frac{\mathbf{u} \cdot \mathbf{i}}{|\mathbf{u}||\mathbf{i}|}$$

Se recomiendan los ítems con mayor puntuación de similitud que el usuario aún no haya visto.

Ventaja clave: no requiere datos de otros usuarios; puede funcionar desde el primer ítem.

Ejemplo: recomendador de películas

Representa cada película como vector de géneros:

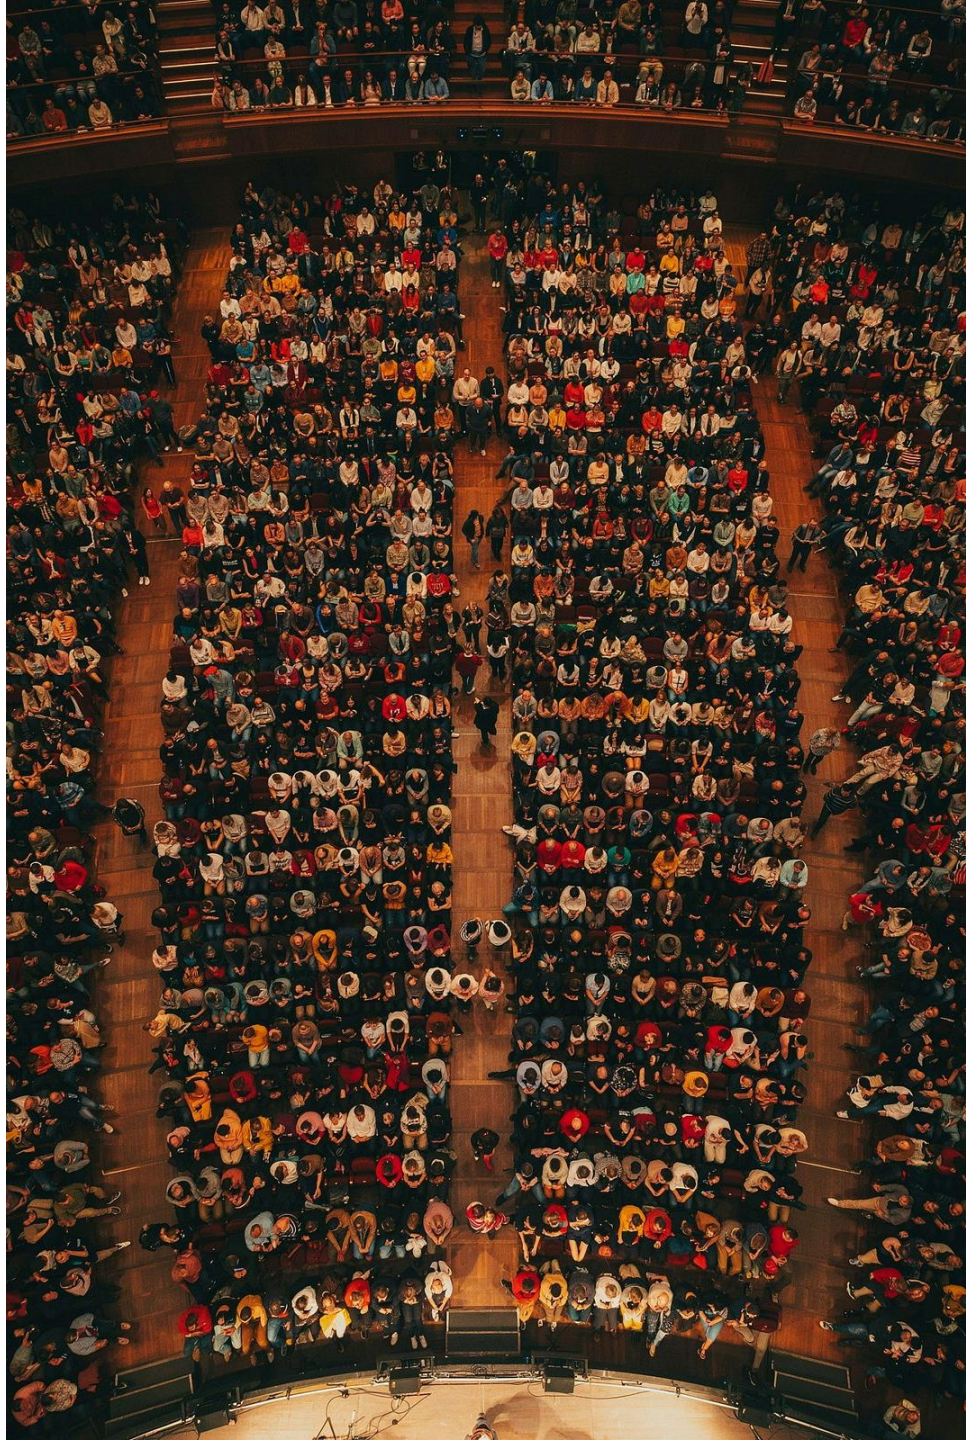
Película	Acción	Drama	Sci-Fi
Película A	1	0	1
Película B	0	1	0
Película C	1	0	1

Si el usuario vio A, se le recomienda C por alta similitud coseno.

PARTE 3

Filtrado Colaborativo

El filtrado colaborativo es el enfoque dominante en la industria. Su premisa: **usuarios con comportamientos similares en el pasado tendrán preferencias similares en el futuro**. No es necesario conocer el contenido de los ítems.



PARTE 4

Matriz Usuario–Ítem y Factorización

La matriz de valoraciones

El punto de partida es una matriz **R** de dimensión *m* × *n* (usuarios × ítems). La mayoría de sus celdas están vacías: los usuarios solo han interactuado con una fracción mínima del catálogo.

El objetivo es **completar esa matriz**, prediciendo las valoraciones desconocidas para hacer recomendaciones.

Matrices con 99 % o más de datos ausentes son habituales en plataformas reales.

Factorización matricial (MF)

Descompone **R ≈ P · Q**ᵀ, donde:

- **P** (m × k): matriz de factores latentes de usuarios
- **Q** (n × k): matriz de factores latentes de ítems
- **k**: dimensión del espacio latente (hiperparámetro)

Se minimiza el error cuadrático con regularización:

$$\min_{P,Q} \sum_{(u,i)\in\Omega} \left(r_{ui} - \mathbf{p}_u^\top \mathbf{q}_i\right)^2 + \lambda\left(\|\mathbf{p}_u\|^2 + \|\mathbf{q}_i\|^2\right)$$



PARTE 5

El Problema del Arranque en Frío

Uno de los retos más conocidos en sistemas de recomendación: ¿qué recomendar cuando no hay datos históricos suficientes?

PARTE 6

Evaluación: Precision@k

Evaluar un sistema de recomendación no es trivial. La métrica más utilizada en contextos de ranking es **Precision@k**: ¿cuántos de los k ítems recomendados son realmente relevantes para el usuario?

$$\text{Precision@}k = \frac{|\{\text{ítems relevantes}\} \cap \{\text{top-}k \text{ recomendados}\}|}{k}$$

Otras métricas complementarias:

- **Recall@k**: fracción de ítems relevantes que aparecen en el top-k
- **NDCG@k**: tiene en cuenta la posición del ítem relevante
- **MAP**: promedia la precisión a lo largo de múltiples consultas
- **RMSE / MAE**: para predicción explícita de valoraciones

Ejemplo práctico

El sistema recomienda 5 ítems al usuario (k = 5). De esos 5, 3 son relevantes según el historial del usuario.

$$\text{Precision@5} = \frac{3}{5} = 0.60$$

El sistema recomienda con un 60 % de precisión en el top-5.

En producción, la relevancia se mide con datos de interacción offline (clics, compras, reproducciones) o estudios de usuario.

PARTE 7

Sesgos y «Burbujas de Filtro»

Los sistemas de recomendación optimizan el engagement, pero este objetivo puede tener consecuencias sociales no deseadas que van más allá de la precisión técnica.

Burbuja de filtro

El sistema refuerza continuamente los intereses ya conocidos del usuario, reduciendo la exposición a contenido diverso o contrario a sus creencias previas.

Sesgo de popularidad

Los ítems muy populares reciben más recomendaciones, lo que los hace aún más populares. Los ítems de nicho quedan sistemáticamente infra-recomendados (long tail problem).

Sesgo de retroalimentación

El modelo se entrena con datos generados por sus propias recomendaciones pasadas, creando un bucle que amplifica errores y sesga la distribución de entrenamiento.

Mitigaciones

Introducir diversidad forzada (serendipia), regularizar por equidad entre grupos, auditar regularmente la distribución de recomendaciones y usar exploración activa.