Aprendizaje por Refuerzo

Una rama del aprendizaje automático en la que un **agente** aprende a tomar decisiones óptimas interactuando con su entorno, guiado únicamente por señales de recompensa. Descubre los fundamentos, algoritmos clave y aplicaciones reales de esta poderosa técnica.

TEMA 9.3 MACHINE LEARNING



¿Qué es el Aprendizaje por Refuerzo?

El **aprendizaje por refuerzo** (RL, del inglés *Reinforcement Learning*) es un paradigma en el que un agente aprende a actuar en un entorno de forma autónoma. A diferencia del aprendizaje supervisado, **no existen ejemplos etiquetados**: el agente descubre por sí mismo qué acciones producen mejores resultados, guiado únicamente por una señal de recompensa.

> Analogía clave: es como entrenar a un animal con premios y castigos, sin explicarle jamás las reglas del juego.



Los Cinco Componentes Fundamentales

Todo problema de aprendizaje por refuerzo queda definido por cinco elementos que forman el marco **MDP** (Proceso de Decisión de Markov).

🤖 Agente

El sistema que aprende y toma decisiones. Observa el entorno y selecciona acciones para maximizar la recompensa acumulada.

🌍 Entorno

Todo aquello externo al agente. Recibe las acciones, actualiza su estado interno y devuelve una nueva observación y recompensa.

📍 Estado

Representación del entorno en un instante dado. Condensa toda la información relevante para tomar la siguiente decisión.

⚡ Acción

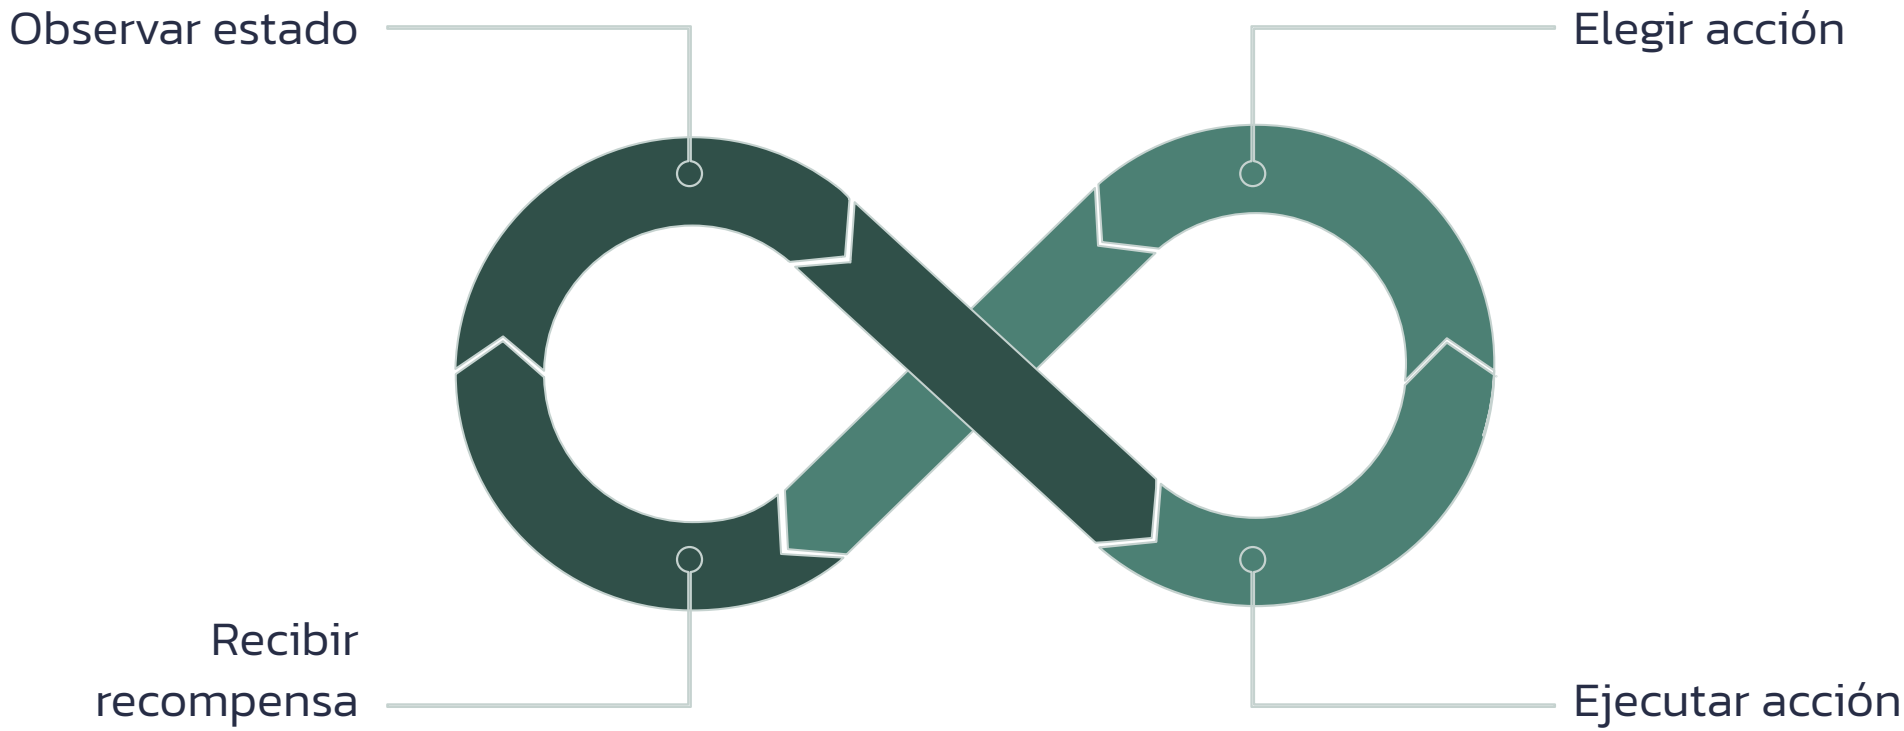
Elección que realiza el agente en cada paso. Puede ser discreta (izquierda/derecha) o continua (ángulo de un volante).

🏆 Recompensa

Señal escalar que indica cuán buena fue la acción tomada. El objetivo del agente es **maximizar la recompensa total** a largo plazo.

El Ciclo Agente–Entorno

La interacción entre el agente y el entorno sigue un bucle continuo: el agente observa el estado, elige una acción, y el entorno responde con un nuevo estado y una recompensa.



Este proceso se repite en cada **paso de tiempo** (*timestep*) hasta alcanzar un estado terminal o agotar el horizonte del episodio.

Exploración frente a Explotación

Este es el **dilema central** del aprendizaje por refuerzo. El agente debe decidir en cada paso si **explota** el conocimiento ya adquirido para obtener la mayor recompensa posible, o si **explora** acciones nuevas que podrían descubrir estrategias mejores. Un agente puramente explotador queda atrapado en óptimos locales; uno puramente explorador nunca converge.



Q-learning: El Algoritmo Fundamental

El **Q-learning** es un algoritmo de diferencia temporal que aprende la función de valor de acción **Q(s, a)** — la recompensa futura esperada al tomar la acción *a* en el estado *s* — sin necesidad de conocer el modelo del entorno.

Regla de actualización

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[r + \gamma \max_{a'} Q(s',a') - Q(s,a) \right]$$

- **α** (alpha): tasa de aprendizaje — velocidad de actualización
- **γ** (gamma): factor de descuento — importancia del futuro
- **r**: recompensa inmediata recibida
- **s'**: estado siguiente tras ejecutar *a*

La Q-Table

Para entornos discretos, los valores Q se almacenan en una tabla de estados × acciones. El agente la consulta para elegir la acción con mayor Q en el estado actual.

Q-learning converge al óptimo global si α decrece adecuadamente y todos los pares (s,a) se visitan suficientes veces.

Aplicaciones Reales del RL

El aprendizaje por refuerzo ha dejado de ser un ejercicio académico para convertirse en una tecnología con impacto directo en industrias clave.



Juegos de estrategia

AlphaGo / AlphaZero de DeepMind venció a los mejores jugadores humanos de Go y Ajedrez, aprendiendo únicamente jugando contra sí mismo.



Vehículos autónomos

El RL se usa para entrenar políticas de conducción en simulación antes de desplegarlas en coches reales, optimizando seguridad y eficiencia.



Gestión de energía

Google DeepMind redujo el consumo de refrigeración de sus centros de datos en un **40%** usando RL para controlar los sistemas de climatización.

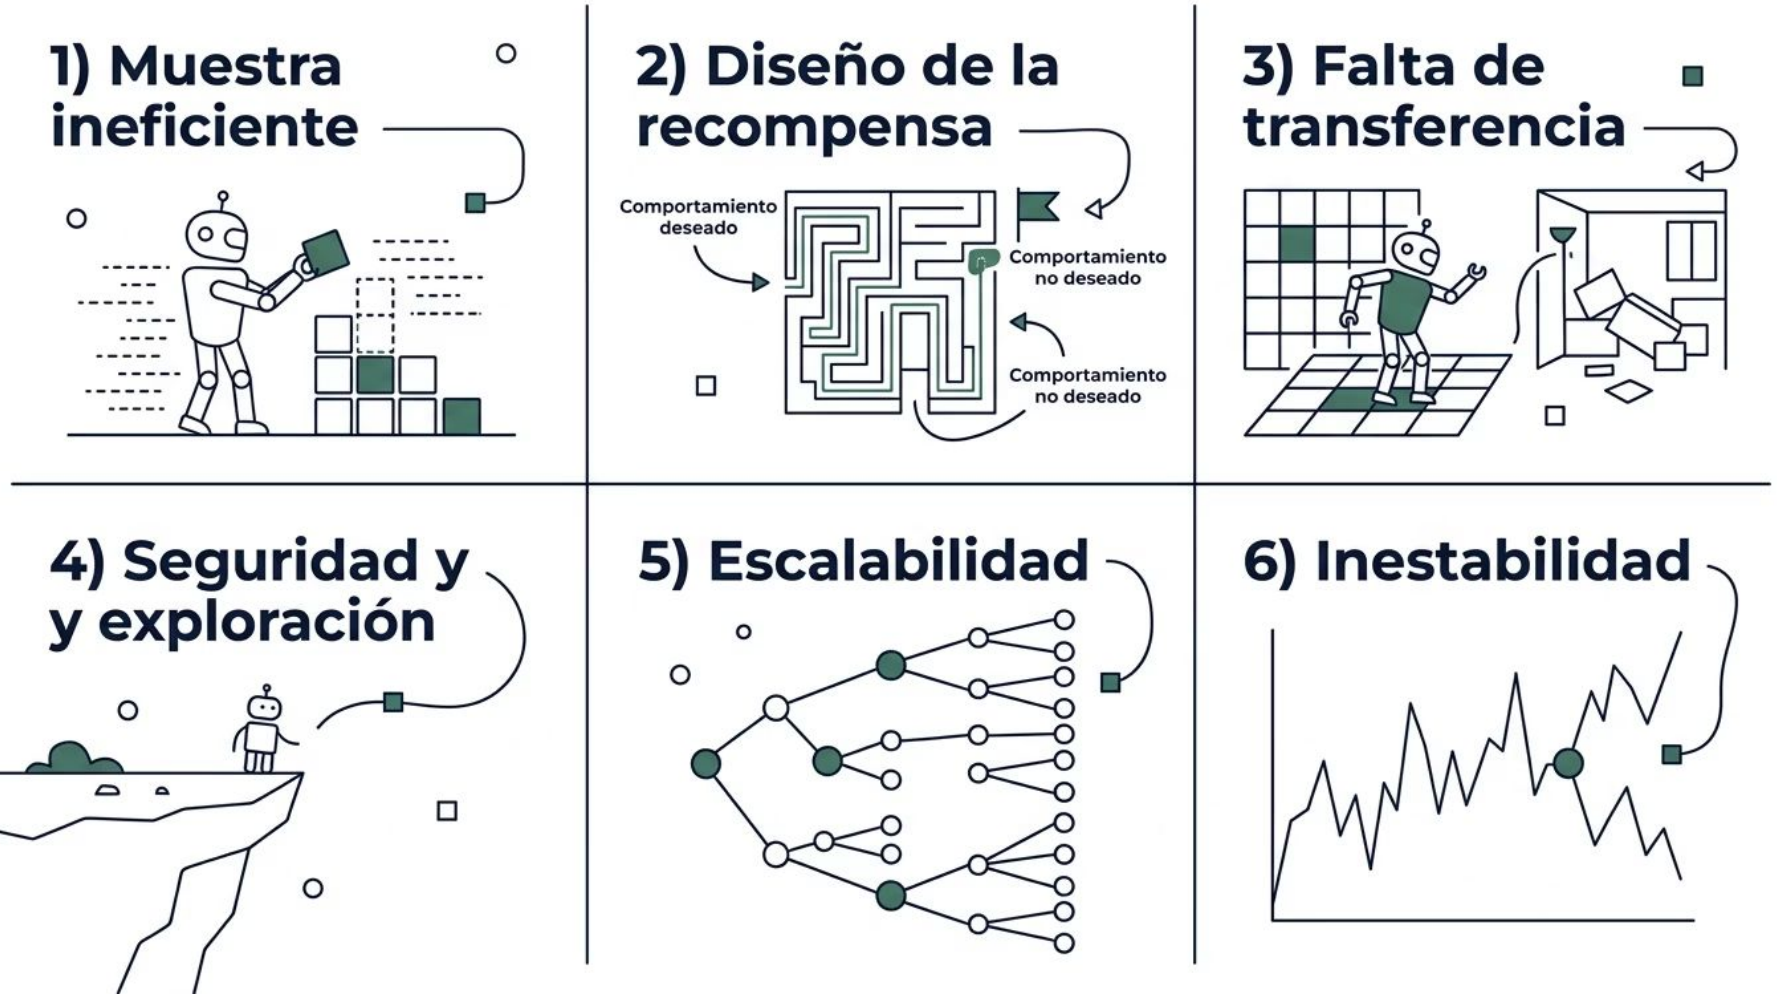


Trading algorítmico

Agentes de RL aprenden estrategias de compraventa en mercados financieros simulados, adaptándose dinámicamente a condiciones cambiantes.

Límites y Desafíos del Aprendizaje por Refuerzo

A pesar de sus éxitos, el RL presenta **limitaciones importantes** que restringen su aplicabilidad directa en muchos problemas del mundo real.



S09 · EN EL REPOSITORIO DEL CURSO

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

S09_03_recomendadores — 60 min

Recomendadores: popularidad, contenido, colaborativo y factorización

sprints/S09/notebooks/S09_03_recomendadores.ipynb

CUADERNO

S09_04_q_learning — 30 min

Q-learning en el hotel (demostración guiada)

sprints/S09/notebooks/S09_04_q_learning.ipynb

RETO

Reto del sprint — 40 min

Recomendador, ficha de segmentos, IA responsable y ensayo (pasos 4–5)

sprints/S09/guia/Reto_Sprint_09.md