Aprendizaje por refuerzo

Tercera gran familia: un **agente** aprende probando, con recompensas y castigos. Lo vemos con una demostración guiada en el hotel.

SPRINT 9 · APRENDIZAJE NO SUPERVISADO Y POR REFUERZO · S09.3



El bucle del refuerzo

Agente

Quien decide (aquí, un empleado que quiere llegar a una habitación).

Entorno

El pasillo del hotel: estados (casillas) y acciones (arriba, abajo, izquierda, derecha).

Recompensa

+ si llega a la habitación con vistas; – por zona en obras (–5) y por cada paso (coste).

No hay respuestas correctas dadas: el agente aprende qué acciones llevan a más recompensa total.

El pasillo del hotel (cuaderno S09_04)

```
S . . . .    S = recepción (inicio)
. # # . X    # = pared
. . . . .    X = zona en obras (−5, se puede pisar)
. # . . G    G = habitación con vistas al mar (meta)
```

Cuadrícula de 4 × 5 = 20 estados. La clase EntornoHotel y la función entrenar ya están escritas; tú programas actualizar_q y elegir_accion.

La tabla Q y su regla de actualización

Q[estado, acción] = recompensa total esperada si estoy aquí, hago esta acción y luego sigo lo mejor posible. Empieza en ceros.

```
def actualizar_q(Q, s, a, r, s2, alpha, gamma):          # Ejercicio 1
    objetivo = r + gamma * Q[s2].max()     # lo que ahora crees que vale la acción
    Q[s, a] += alpha * (objetivo - Q[s, a])  # mueve Q una fracción alpha hacia ese valor
```

- **alpha** (0–1): cuánto corrige cada experiencia.
- **gamma** (0–1): cuánto pesa el futuro frente al presente.

Explorar o explotar: epsilon-greedy

```
def elegir_accion(Q, s, epsilon, rng):                # Ejercicio 2
    if rng.random() < epsilon:
        return int(rng.integers(4))                   # explorar: al azar
    return int(np.argmax(Q[s]))                       # explotar: la mejor
```

Si siempre explota, nunca descubre caminos mejores. Si siempre experimenta, nunca aprovecha lo aprendido.

Política aprendida y experimento

```
politica = Q.argmax(axis=1)          # Ejercicio 3: mejor acción en cada estado (20 acciones)
```

- **Camino:** estados que visita el agente sin explorar desde recepción hasta la meta.
- **Experimento:** con coste_paso=0 la única recompensa llega al final; sin exploración el agente no aprende. La exploración importa.
- **Mini-reto:** pasar por la zona en obras cuesta –20 (reclamaciones). Copia EntornoHotel, reentrena con clase_entorno y comprueba si el camino cambia.

Ahora, a practicar

Lo que viene a continuación está en tu repositorio.

CUADERNO · Q-learning en el hotel (demostración guiada)

sprints/S09/notebooks/S09_04_q_learning — 30 min

RETO · Recomendador, ficha de segmentos, IA responsable y ensayo (pasos 4–5)

sprints/S09/guia/Reto_Sprint_09.md — 40 min