IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

ETAPA B · CONSTRUIR · SPRINT 10 DE 17

# Sprint 10 · Redes neuronales bien entrenadas

*¿una red neuronal mejora al aprendizaje automático clásico y a qué precio?*

**FECHAS**
13–17 de noviembre

**HORAS**
15 h (5 h teoría · 6 h práctica · 4 h PBL) · **Módulo 4, UD 4.1–4.3**

## Qué aprenderás

1. Cómo funciona por dentro una red neuronal: neurona, capas, activación, propagación hacia delante y hacia atrás.
2. Construir y entrenar un MLP con Keras para clasificar cancelaciones y predecir el precio por noche.
3. Reconocer el **sobreajuste** en las curvas de aprendizaje y combatirlo (L2, *dropout*, parada temprana, *batch norm*).
4. Ajustar tasa de aprendizaje y tamaño de lote, usar *callbacks* y guardar/cargar modelos.
5. Decidir con datos si una red "vale la pena" frente a un modelo de boosting.

## Requisitos previos

- Sprints 7 y 8: partición entrenamiento/validación/prueba, métricas (AUC, F1, MAE) y modelos de árboles/boosting.
- Python y pandas del Bloque B. No hace falta saber matemáticas avanzadas: se explican con ejemplos.
- Datos: `reservas_turisdata.csv` (se descarga solo desde el notebook). Todo funciona **sin internet** y en Colab.

## Prácticas

| Notebook | Tema | Tiempo | Colab |
|---|---|---|---|
| `S10_01_red_desde_cero` | Una red neuronal con solo NumPy: neurona, activación, *backprop*, entrenamiento | 1 h 15 | Abrir en Colab |
| `S10_02_mlp_keras` | MLP en Keras: cancelaciones (clasificación) y `precio_noche` (regresión) | 1 h 30 | Abrir en Colab |
| `S10_03_regularizacion` | Curvas, sobreajuste, L2, *dropout*, parada temprana, lote, tasa, *callbacks*, guardar modelo | 1 h 45 | Abrir en Colab |
| `S10_04_reto_vale_la_pena` | Esqueleto del reto: MLP frente a boosting con incertidumbre y diagnóstico | 1 h 30 (+ trabajo PBL) | Abrir en Colab |

Cada notebook tiene ejercicios con comprobaciones automáticas (`assert`): si saltan, el mensaje te dice qué revisar.

## RETO Reto PBL · «¿Vale la pena la red?»

### En pocas palabras (léelo primero)

**Qué os pide el cliente.** La dirección de TurisData oye hablar de **redes neuronales** en todas partes y pregunta si debe **sustituir su modelo de cancelaciones por una red**. No quiere una opinión: quiere **evidencias, con el coste incluido**, para decidir si merece la pena el cambio.

**La pregunta guía del reto:** *¿una red neuronal mejora al aprendizaje automático clásico, y a qué precio?* Y la respuesta puede ser **«no»**. Un resultado honesto de «no compensa» es tan válido y útil como un «sí».

**Qué vais a hacer, en seis pasos:**

1. **Elegir un problema** (cancelaciones o precio) y reproducir vuestro modelo de referencia (el campeón del Sprint 8 o el boosting del cuaderno).
2. **Entrenar una red neuronal sencilla** (un MLP) con el mismo conjunto de datos.
3. **Probar 2 o 3 variantes** (tamaño, *dropout*, regularización L2, tasa de aprendizaje), mirando **solo la validación**.
4. **Diagnosticar el sobreajuste** con curvas de aprendizaje.
5. **Comparar de forma justa** con el modelo clásico (varias semillas, con incertidumbre).
6. **Escribir un informe** de 1–2 páginas con una recomendación: «Recomendamos… porque…».

**Qué vais a entregar:** un cuaderno ejecutable (basado en `S10_04`) y un informe comparativo *ML clásico frente a MLP*.

**Qué vais a aprender haciéndolo:** a **entrenar una red sin que memorice**, a leer **curvas de aprendizaje**, y a **comparar con honestidad** (que un número sea mayor no basta).

**Cuánto tiempo:** 4 horas de proyecto (13 al 17/11).

### Palabras que van a aparecer en este reto

| Palabra | Qué significa, en sencillo |
|---|---|
| **Red neuronal / MLP** | Modelo formado por capas de «neuronas» artificiales que combinan los datos. MLP = red de capas totalmente conectadas |
| **Capa** | Un nivel de neuronas. Una red tiene una capa de entrada, capas ocultas y una de salida |
| **Época** | Una pasada completa de la red por todos los datos de entrenamiento |
| **Sobreajuste** | La red «memoriza» los ejemplos de entrenamiento y falla con datos nuevos |
| **Curva de aprendizaje** | Gráfico del error en entrenamiento y en validación a lo largo de las épocas |
| **Dropout** | Truco que «apaga» neuronas al azar al entrenar para que la red no memorice |
| **Regularización L2** | Penalización para que los números internos de la red no crezcan demasiado y no memorice |
| **Tasa de aprendizaje** | Tamaño de cada paso al ajustar la red |
| **Early stopping** | Parar el entrenamiento cuando la validación deja de mejorar |
| **Validación** | Datos usados para **decidir** cosas (variantes, parada). No son el test |
| **Test** | Datos guardados que se miran **una sola vez** al final |
| **Semilla** | Número que fija el azar. Las redes dan resultados distintos con semillas distintas, por eso se prueban varias |

**Contexto del cliente.** La dirección de TurisData Canarias oye hablar de redes neuronales en todas partes y pregunta si debe sustituir su modelo de cancelaciones por una. No quiere una opinión: quiere evidencias, coste incluido, para decidir si merece la pena el cambio.

**Qué se entrega y en qué formato**

1. **Notebook** ejecutable de principio a fin (basado en `S10_04`), con semillas fijas.
2. **Informe comparativo** de 1–2 páginas (PDF o Markdown) *ML clásico frente a MLP*: tabla de resultados, curvas de aprendizaje y recomendación.

**Restricciones**

- Un solo problema a elegir: cancelaciones (`cancelada`) **o** precio (`precio_noche`). El otro es opcional.
- Misma partición para todos los modelos; la prueba se usa **una sola vez**.
- Modelo de referencia: tu campeón del Sprint 8 (o el boosting que trae el notebook).
- Máximo 40 épocas por entrenamiento y modelos pequeños (se ejecuta en CPU en pocos minutos).

- Sin fugas de datos: el escalador se ajusta solo con el entrenamiento.

**Criterios de evaluación** (0–4, la media alimenta "ejercicios y entregas")

| Criterio | Qué buscamos aquí |
|---|---|
| **Corrección técnica** | Partición correcta, preprocesado sin fuga, MLP regularizado, comparación justa (varias semillas o intervalo), curvas bien interpretadas. |
| **Reproducibilidad** | Se ejecuta desde el README; semillas y versiones fijadas; datos y script incluidos. |
| **Análisis y comunicación al cliente** | Respuesta clara a "¿vale la pena?": métricas con incertidumbre, coste (tiempo, complejidad, explicabilidad) y recomendación accionable con sus límites. |
| **IA responsable** | Riesgos concretos: datos sintéticos, umbral y coste de errores (overbooking), posibles sesgos por país o canal; medidas aplicadas y evaluadas. |

**Pasos sugeridos**

- **Día 1:** ejecuta `S10_04`, entiende cada bloque y elige el problema. Reproduce tu modelo de referencia.
- **Día 2:** entrena el MLP, prueba 2–3 variantes (tamaño, *dropout*, L2, tasa) mirando **solo la validación**.
- **Día 3:** diagnostica el sobreajuste con curvas y compara con la referencia (varias semillas, intervalo de confianza).
- **Día 4:** redacta el informe y prepara la presentación de 5 minutos.

## Guía paso a paso para principiantes

### Paso 1 · Elegir el problema y reproducir la referencia (día 1)

1. Elegid **un problema**: cancelaciones ( `cancelada` ) **o** precio ( `precio_noche` ). El otro es opcional.
2. Abrid `S10_04_reto_vale_la_pena` y ejecutadlo bloque a bloque, **entendiendo cada uno** (si no lo entendéis, preguntad antes de seguir).
3. **Reproducid el modelo de referencia** (vuestro campeón del Sprint 8 o el boosting que trae el cuaderno) y anotad su métrica.
4. **Fijad la partición** entrenamiento / validación / prueba y no la cambiéis nunca más. **La prueba se usa una sola vez.**

### Paso 2 · Primera red (día 2, mañana)

1. Escalad los datos **ajustando el escalador solo con el entrenamiento** (si no, hay fuga).
2. Entrenad un MLP pequeño (por ejemplo, 2 capas ocultas de 32 neuronas), **máximo 40 épocas**. Se ejecuta en CPU en pocos minutos.
3. Dibujad la **curva de aprendizaje**: error en entrenamiento y en validación.

### Paso 3 · Variantes (día 2, tarde)

1. Probad **2 o 3 variantes**: más o menos neuronas, *dropout*, L2, otra tasa de aprendizaje, *early stopping*.
2. **Compararlas mirando solo la validación.** El test no se toca.
3. Anotad qué ha mejorado y qué no. Una tabla pequeña basta: *variante · error en entrenamiento · error en validación*.

### Paso 4 · Diagnosticar el sobreajuste (día 3)

Mirad vuestras curvas:

- **Entrenamiento baja y validación sube:** la red memoriza (sobreajuste). Soluciones: más regularización, menos neuronas, parar antes.
- **Las dos curvas están altas y juntas:** la red es demasiado simple (subajuste).
- **Las dos bajan y se estabilizan juntas:** buen ajuste.

Escribid **una frase de diagnóstico** para vuestra mejor red.

### Paso 5 · Comparación justa (día 3)

1. **Repetid el entrenamiento con varias semillas** (por ejemplo, 5) para el MLP y para el modelo clásico.

2. Calculad **media ± desviación** (o un intervalo) de la métrica.
3. Comparad: **si los intervalos se solapan, no podéis decir que uno sea mejor**.
4. Evaluad en el test **una sola vez**, con el MLP elegido y con el modelo clásico, y registrad ambos.
5. Añadid el **coste**: tiempo de entrenamiento, complejidad, explicabilidad. Una red puede mejorar un 1 % pero tardar 20 veces más y ser opaca.

### Paso 6 · Informe y presentación (día 4)

Informe de 1–2 páginas:

1. **Pregunta y respuesta en una frase** («Recomendamos mantener el boosting porque…»).
2. **Tabla de resultados** (media ± desviación) de ambos enfoques.
3. **Curva de aprendizaje comentada.**
4. **Coste** (tiempo, complejidad, explicabilidad).
5. **Riesgos de IA responsable** (al menos dos específicos) con medidas.
6. **Límites.**

## Cómo usar la IA en este reto

| Para qué | Ejemplo de petición | Qué tenéis que comprobar |
|---|---|---|
| Entender conceptos | «Explícame qué es el sobreajuste en una red neuronal con una analogía de estudiar para un examen memorizando» | Que lo explicáis con vuestras palabras |
| Interpretar una curva | «Mi pérdida de entrenamiento baja pero la de validación sube a partir de la época 12. ¿Qué significa y qué puedo probar?» | Que probáis lo que sugiere y compruebas el efecto |
| Entender un error de Keras | «Me da este error: *[mensaje]* con este código: *[código]*» | Que entendéis la causa |
| Revisar el informe | «Léelo como un directivo y dime qué no se entiende» | Que no cambie cifras |

**Reglas del reto:**

- **Solo se compara con las mismas métricas y la misma partición.** No vale cambiar la referencia para que la red gane.
- **Las variantes se eligen con la validación**, nunca con el test.
- Declarad dónde habéis usado IA y qué habéis comprobado.

**Pista de IA responsable:** datos sintéticos; qué pasa con el umbral y el coste de los errores (*overbooking*); posibles sesgos por país o canal. Elegid dos y proponed medidas.

## Errores frecuentes (y cómo evitarlos)

| Error | Por qué ocurre | Cómo evitarlo |
|---|---|---|
| Escalar con todos los datos | Se olvida la fuga | `fit` del escalador solo con entrenamiento |
| Mirar el test para elegir la variante | «Para saber cuál va mejor» | Solo validación; el test, una sola vez |
| Comparar con una sola semilla | «Ya ha salido mejor» | Varias semillas y media ± desviación |
| Entrenar 500 épocas | «Cuanto más, mejor» | Máximo 40 épocas y *early stopping* |
| Concluir «la red es mejor» por 0,3 puntos | Se mira solo el número | Comparad los intervalos y añadid el coste |
| Informe sin recomendación | Se queda en los números | Terminad con «Recomendamos… porque…» |

### Un buen resultado se parece a...

> *«Recomendamos mantener el boosting. El MLP alcanza un AUC de 0,77 ± 0,02 frente a 0,78 ± 0,01 del boosting: la diferencia no es significativa. Además, la red tarda 12 veces más en entrenar y es más difícil de explicar. Solo compensaría con muchos más datos o con imágenes o texto. Riesgos: …»* (Cifras de ejemplo.)

### Antes de entregar: autoevaluación rápida

| Pregunta | Sí / No |
|---|---|
| ¿El cuaderno se ejecuta de arriba abajo, con semillas fijas? | |
| ¿La partición es única y la prueba se usa una sola vez? | |
| ¿Hay al menos un MLP y un modelo de árboles/boosting comparados con las mismas métricas? | |
| ¿Hay curvas de aprendizaje y un diagnóstico explícito de sobreajuste? | |
| ¿La comparación tiene incertidumbre (varias semillas o bootstrap)? | |
| ¿El informe recomienda algo concreto, con coste y límites? | |
| ¿Hay al menos dos riesgos de IA responsable específicos? | |

### Si os atascáis

- **La red no aprende (la pérdida no baja):** revisad que los datos estén escalados y probad una tasa de aprendizaje menor.
- **Las curvas son ruidosas:** es normal en datos pequeños; usad varias semillas y promediad.
- **No entendemos las curvas:** repasad `S10_03_regularizacion`, que tiene un ejemplo comentado.
- Más ayuda: Cómo se trabaja un reto.

**Qué se enseña en la *review*.** La tabla comparativa, una curva de aprendizaje comentada y la recomendación en una frase ("Recomendamos… porque…"), con el coste y los riesgos.

## Definition of Done

- [ ] El notebook se ejecuta de arriba abajo sin errores y con semillas fijas.
- [ ] La partición entrenamiento/validación/prueba es única y la prueba se usa una sola vez.
- [ ] Hay al menos un MLP y un modelo de árboles/boosting comparados con las mismas métricas.
- [ ] Incluye curvas de aprendizaje y un diagnóstico explícito de sobreajuste.
- [ ] La comparación tiene en cuenta la incertidumbre (varias semillas o bootstrap).
- [ ] El informe recomienda algo concreto, con coste y límites.
- [ ] Se mencionan al menos dos riesgos de IA responsable específicos de este caso.

## Recursos

- Documentación de Keras: guía «Sequential model» y «Training & evaluation with the built-in methods» (keras.io).
- Documentación de scikit-learn: `HistGradientBoostingClassifier` y métricas (`roc_auc_score`, `average_precision_score`).
- Vídeos/artículos sobre curvas de aprendizaje y sobreajuste (busca «learning curves overfitting» y elige uno con ejemplos).
- Guía de callbacks de Keras: `EarlyStopping`, `ReduceLROnPlateau`, `ModelCheckpoint`.

- Apuntes del curso: UD 4.1–4.3 (teoría de este sprint).