

Sprint 10 · Redes neuronales bien entrenadas

MÓDULO 4 · UD 4.1–4.3

13–17 NOV

15 H TOTALES

Pregunta guía: ¿una red neuronal mejora al aprendizaje automático clásico y a qué precio? En este sprint exploraréis el funcionamiento interno del deep learning y construiréis modelos con Keras para **TurisData Canarias**. Compararéis de forma rigurosa si un perceptrón multicapa (MLP) compensa frente a modelos de boosting, considerando rendimiento, sobreajuste, coste de cómputo y explicabilidad.

5 h Teoría

Neurona, activación, propagación hacia delante y atrás, regularización, optimizadores e IA responsable

6 h Práctica

Cuatro notebooks: red NumPy desde cero, MLP en Keras, técnicas anti-sobreajuste y esqueleto del reto

4 h Reto PBL

«¿Vale la pena la red?»: MLP vs. boosting con incertidumbre, informe ejecutivo y presentación

¿Qué aprenderás?

- 1** Funcionamiento interno de una red
Comprenderás cómo funciona por dentro una red neuronal: neurona, capas, activación, propagación hacia delante y hacia atrás.
- 2** Construir y entrenar un MLP con Keras
Construirás y entrenarás un MLP con Keras para clasificar cancelaciones y predecir el precio por noche.
- 3** Reconocer y combatir el sobreajuste
Reconocerás el sobreajuste en las curvas de aprendizaje y lo combatirás (L2, dropout, parada temprana, batch norm).
- 4** Ajuste fino, callbacks y persistencia
Ajustarás tasa de aprendizaje y tamaño de lote, usarás callbacks y guardarás/cargarás modelos entrenados.
- 5** Decisión informada con datos
Decidirás con datos si una red "vale la pena" frente a un modelo clásico de boosting.

⚠ **Requisitos previos:** Sprints 7 y 8 (partición train/val/test, métricas AUC, F1, MAE y modelos de árboles/boosting). Python y pandas del Bloque B. No hace falta matemáticas avanzadas: se explican con ejemplos. Datos: `reservas_turisdata.csv` (se descarga solo desde el notebook). Todo funciona **sin internet** y en Colab.

Prácticas del sprint

Notebook	Tema	Tiempo	Colab
S10_01_red_desde_cero	Una red neuronal con solo NumPy: neurona, activación, <i>backprop</i> , entrenamiento	1 h 15	Colab
S10_02_mlp_keras	MLP en Keras: cancelaciones (clasificación) y precio_noche (regresión)	1 h 30	Colab
S10_03_regularizacion	Curvas, sobreajuste, L2, <i>dropout</i> , parada temprana, lote, tasa, <i>callbacks</i> , guardar modelo	1 h 45	Colab
S10_04_reto_vale_la_pena	Esqueleto del reto: MLP frente a boosting con incertidumbre y diagnóstico	1 h 30 (+ PBL)	Colab

Ficha del reto · «¿Vale la pena la red?»

RETO PBL · SPRINT 10

TURISDATA CANARIAS

Contexto del cliente: La dirección de TurisData Canarias oye hablar de redes neuronales en todas partes y pregunta si debe sustituir su modelo de cancelaciones por una. No quiere una opinión: quiere evidencias, coste incluido, para decidir si merece la pena el cambio.

Qué se entrega y en qué formato

Dos entregables principales por equipo para responder a la dirección de TurisData:

1 · Notebook ejecutable

Basado en S10_04, ejecutable de principio a fin y con semillas fijas.


2 · Informe comparativo (1–2 págs.)

En PDF o Markdown (*ML clásico frente a MLP*): tabla de resultados, curvas de aprendizaje y recomendación final.

Restricciones del reto

- **Un solo problema**
Elegir cancelaciones (cancelada) o precio (precio_noche). El otro es opcional.
- **Partición y prueba**
Misma partición para todos los modelos; la prueba se usa **una sola vez**.
- **Modelo de referencia**
Tu campeón del Sprint 8 (o el boosting que trae el notebook).
- **Límites y fuga de datos**
Máximo 40 épocas por entrenamiento (CPU en minutos). Escalador ajustado solo con entrenamiento.

Pasos sugeridos por día



4 h de trabajo PBL repartidas en el sprint para modelar, diagnosticar y documentar con rigor.

Qué se enseña en la review

- La **tabla comparativa** de resultados entre el modelo clásico y el MLP con métricas e incertidumbre.
- Una **curva de aprendizaje comentada** mostrando la evolución y diagnóstico del sobreajuste.
- La **recomendación en una frase**: «Recomendamos... porque...», integrando coste, complejidad y riesgos detectados.

Criterios de evaluación

RÚBRICA DE EQUIPO

0 A 4 POR CRITERIO

Cada entregable se evalúa de **0 a 4 puntos** en los cuatro criterios de la rúbrica del curso (la media alimenta "ejercicios y entregas"). A continuación se detallan las expectativas por criterio y las claves para alcanzar el nivel de excelencia técnica y analítica.

Criterio	Qué buscamos aquí (0–4 puntos)
Corrección técnica	Partición correcta, preprocesado sin fuga de datos, MLP regularizado, comparación justa (varias semillas o intervalo de confianza) y curvas de aprendizaje bien interpretadas.
Reproducibilidad	Se ejecuta de principio a fin desde el README; semillas y versiones fijadas; datos y script incluidos para su replicabilidad exacta.
Análisis y comunicación	Respuesta clara a "¿vale la pena?": métricas con incertidumbre, coste (tiempo, complejidad, explicabilidad) y recomendación accionable con sus límites.
IA responsable	Riesgos concretos identificados: datos sintéticos, umbral y coste de errores (overbooking), posibles sesgos por país o canal; medidas aplicadas y evaluadas.

¿Cómo llegar al nivel Excelente?

Un proyecto excelente en redes neuronales no consiste en entrenar el modelo más complejo ni en batir el AUC por una centésima a costa de sobreajuste. Demuestra excelencia un análisis que previene fugas de datos, evalúa la incertidumbre con múltiples semillas, diagnostica con curvas reales y sabe decir con honestidad a negocio si la red merece la pena o si el boosting sigue siendo la mejor opción.



Sin fuga de datos

El escalador se ajusta únicamente sobre el conjunto de entrenamiento. La partición de prueba se evalúa una sola vez al final.



Comparación justa

Usa métricas con incertidumbre (varias semillas o intervalos de confianza) enfrentadas bajo exactamente la misma partición.



IA responsable y sesgos

Evalúa el impacto de falsos positivos en cancelaciones (overbooking) y audita posibles sesgos según país de origen o canal.



Recomendación accionable

Responde con claridad a negocio: balance entre ganancia métrica, tiempo de entrenamiento, coste de inferencia y explicabilidad.

Definition of Done y cierre del sprint

CHECKLIST FINAL

RETROSPECTIVA

RECURSOS

Antes de dar por cerrado el Sprint 10, cada equipo debe repasar el siguiente checklist de Definition of Done. Recordad que la comparación debe ser reproducible y honesta: evidenciar con datos si el MLP aporta valor real sobre el boosting y garantizar que el cliente reciba conclusiones claras.

Checklist Definition of Done

- ☐ El notebook se ejecuta de arriba abajo sin errores y con semillas fijas
- ☐ La partición entrenamiento/validación/prueba es única y la prueba se usa una sola vez
- ☐ Hay al menos un MLP y un modelo de árboles/boosting comparados con las mismas métricas
- ☐ Incluye curvas de aprendizaje y un diagnóstico explícito de sobreajuste
- ☐ La comparación tiene en cuenta la incertidumbre (varias semillas o bootstrap)
- ☐ El informe recomienda algo concreto, con coste y límites
- ☐ Se mencionan al menos dos riesgos de IA responsable específicos de este caso

Preguntas de retrospectiva

Dedicad los últimos minutos del sprint a responder estas reflexiones en equipo para consolidar el aprendizaje del bloque de deep learning.

- ¿Compensa la complejidad de ajustar hiperparámetros en el MLP frente a la rapidez del boosting?
- ¿Nuestras curvas de aprendizaje muestran sobreajuste o supimos frenarlo a tiempo con regularización?
- ¿Cómo explicamos a la dirección de TurisData las predicciones de una red neuronal respecto a un árbol?

Recursos recomendados

Documentación oficial, guías y materiales del curso para profundizar en Keras, regularización y diagnóstico de modelos tabulares.

1	Documentación de Keras keras.io · Guías «Sequential model» y «Training & evaluation with the built-in methods». Referencia clave para definir y compilar modelos.
2	Documentación de scikit-learn scikit-learn.org · HistGradientBoostingClassifier y métricas de evaluación (roc_auc_score, average_precision_score).
3	Curvas de aprendizaje y sobreajuste Búsqueda recomendada: «learning curves overfitting». Materiales y tutoriales con ejemplos visuales para detectar sesgo y varianza.
4	Guía de callbacks de Keras keras.io/api/callbacks · Documentación técnica de EarlyStopping, ReduceLROnPlateau y ModelCheckpoint.
5	Apuntes del curso Unidades Didácticas UD 4.1–4.3 del Bloque de Deep Learning · Toda la teoría del sprint disponible en el repositorio de la asignatura.

 **Preparación de la review:** Traed la tabla comparativa lista, la curva de aprendizaje comentada y la recomendación en una sola frase justificando coste y riesgos.