Sprint 11 · Resultados de los cuadernos (sin código)

IFCD107 · Especialista en Inteligencia Artificial

- **Para explicar a clase** qué pide cada ejercicio y qué se obtiene, sin enseñar código.
- **Clase** = ejercicio del cuaderno «en clase» · **Casa** = solo en el cuaderno completo (`para_casa/`).
- Los números son los que salen al ejecutar los cuadernos con los datos del curso (turisdata).

S11_01 · Redes convolucionales (CNN)

Ej.	Qué pide	Qué obtenemos
1 · clase	Preparar los dígitos: valores entre 0 y 1, forma (n, 8, 8, 1), y separar prueba	**1 797** imágenes de 8×8; **1 347** para entrenar y **450** para probar
2 · clase	Calcular cuánto «encoge» la imagen un filtro de 3×3	Una imagen de 14×14 pasa a **12×12** (14 − 3 + 1); los filtros detectan bordes verticales y horizontales
3 · casa	Escribir el max pooling: quedarse con el máximo de cada bloque 2×2	El mapa de **12×12** pasa a **6×6**, conservando lo más fuerte
4 · casa	Construir una CNN y compararla con un MLP	CNN **97.6 %** (6 090 parámetros) frente a MLP **96.4 %** (4 810 parámetros)
Mini-reto · casa	Dígitos desplazados: ¿ayuda el *data augmentation*?	CNN normal **26.4 %** · CNN con aumento **65.1 %** · MLP **14.4 %**

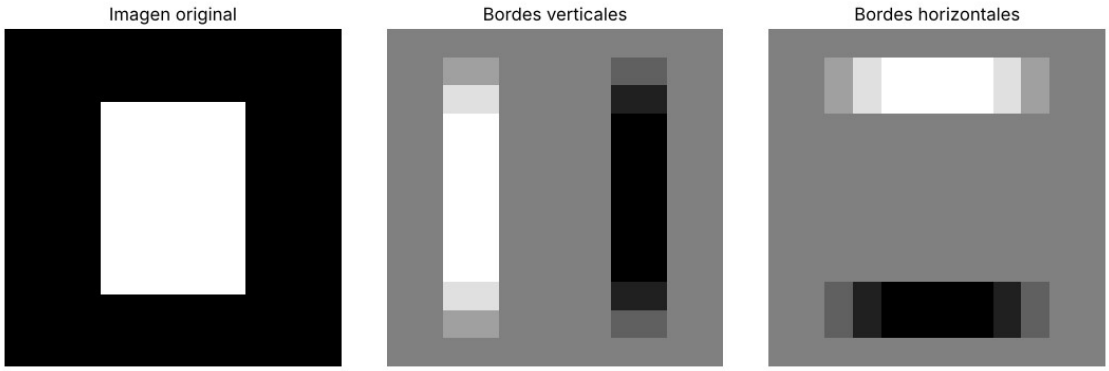


Figura 1. *Ejercicio 2 · Imagen original y resultado de un filtro de bordes verticales y de otro de bordes horizontales.*

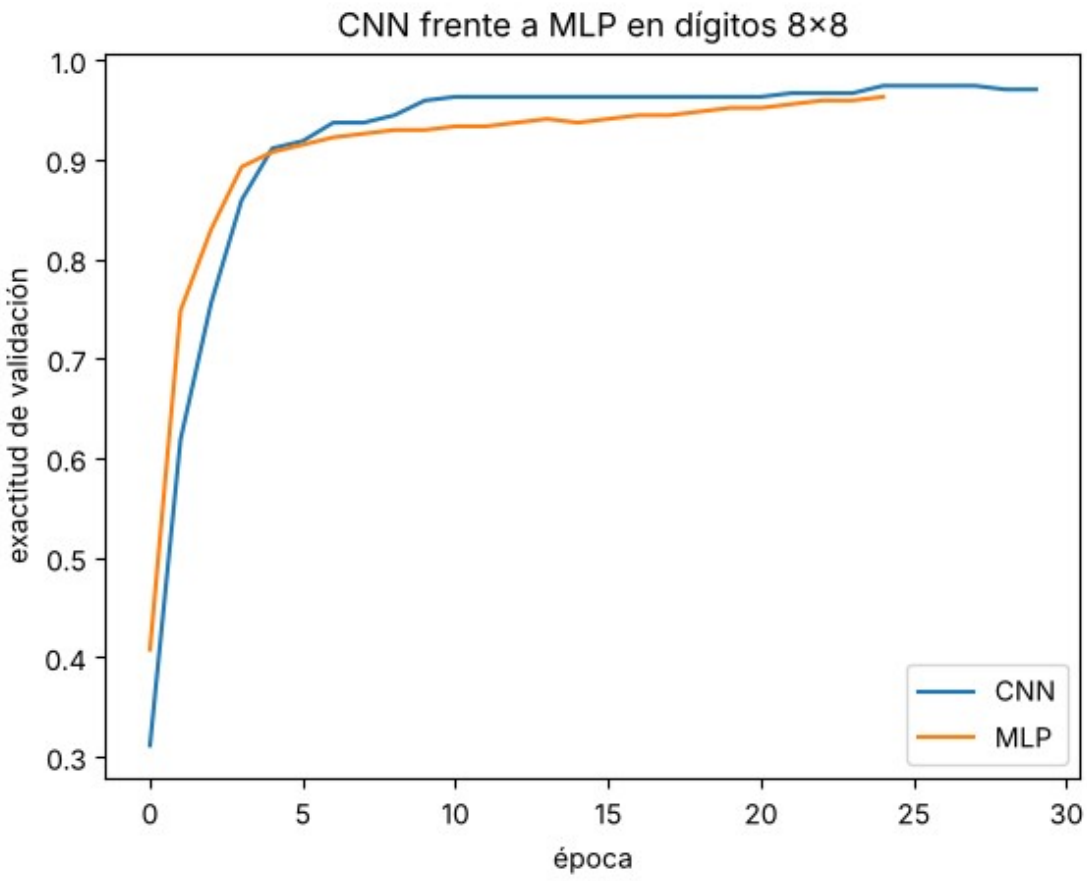


Figura 2. *Ejercicio 4 · Exactitud de validación por época: la CNN (azul) acaba por encima del MLP (naranja).*

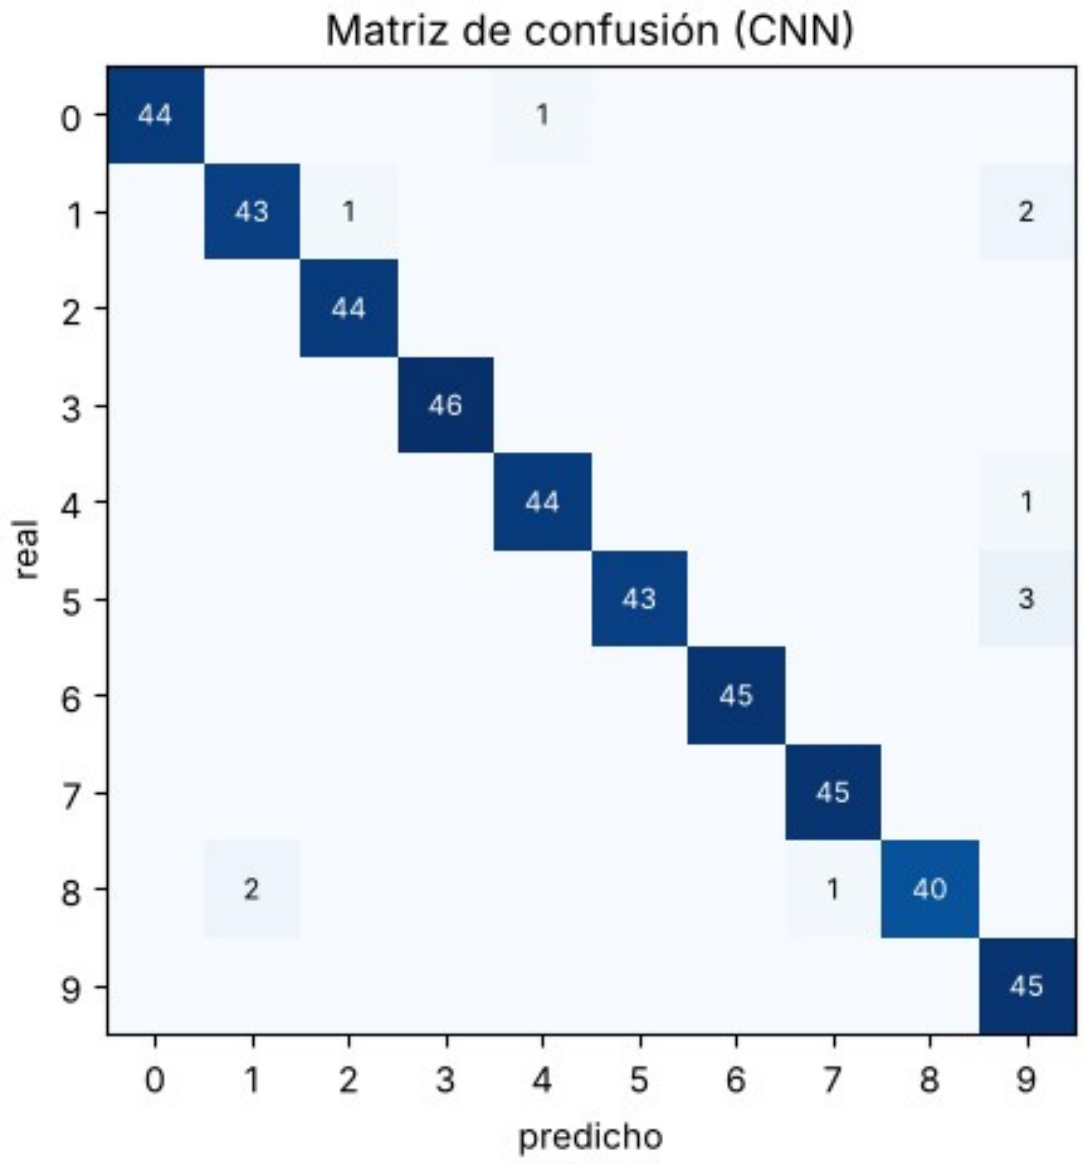


Figura 3. *Matriz de confusión de la CNN: casi todo en la diagonal; los pocos errores van sobre todo hacia el 9.*

S11_02 · Transfer learning

Ej.	Qué pide	Qué obtenemos
1 · clase	Congelar la base preentrenada y entrenar solo la cabeza nueva	De **35 109** parámetros solo se entrenan **11 525** (la cabeza); exactitud en prueba **83.3 %**
2 · casa	Descongelar un bloque (fine-tuning)	Se entrenan solo los pesos del bloque 3 (**2** tensores de pesos); exactitud en prueba **83.0 %**

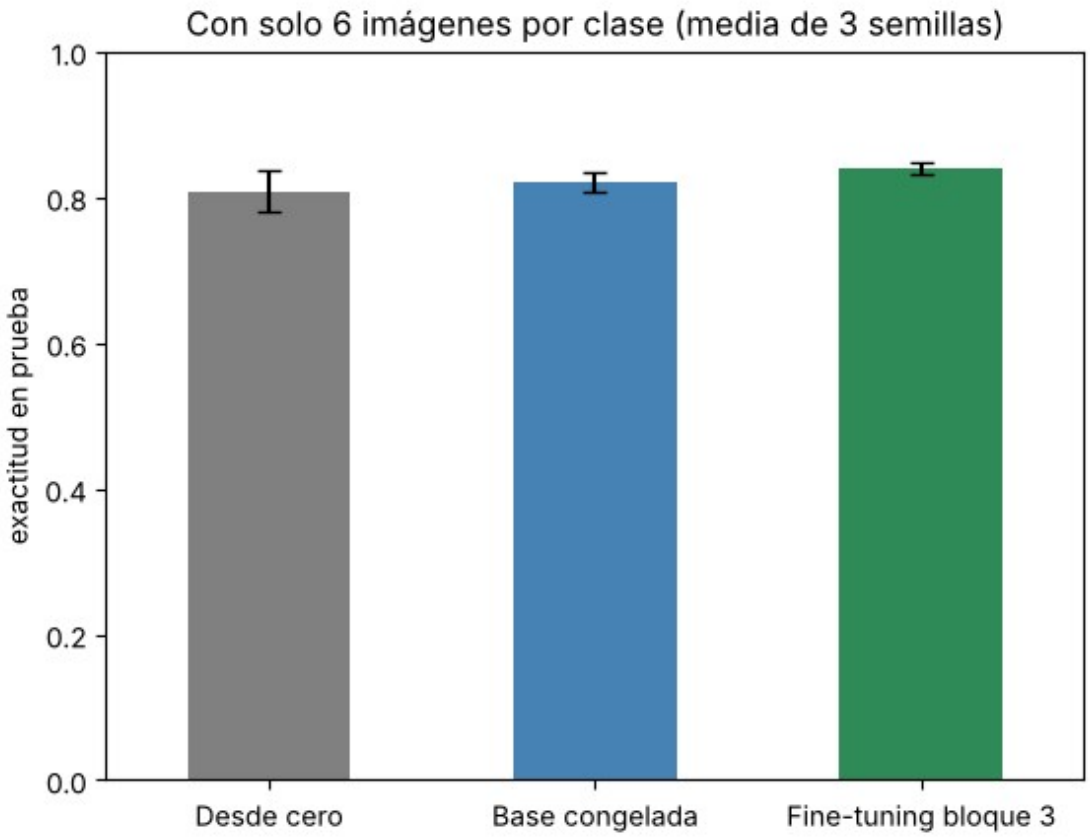


Figura 4. *Con solo 6 imágenes por clase (media de 3 semillas): desde cero (gris), base congelada (azul) y fine-tuning del bloque 3 (verde). Las barras de error son más cortas con transfer learning.*

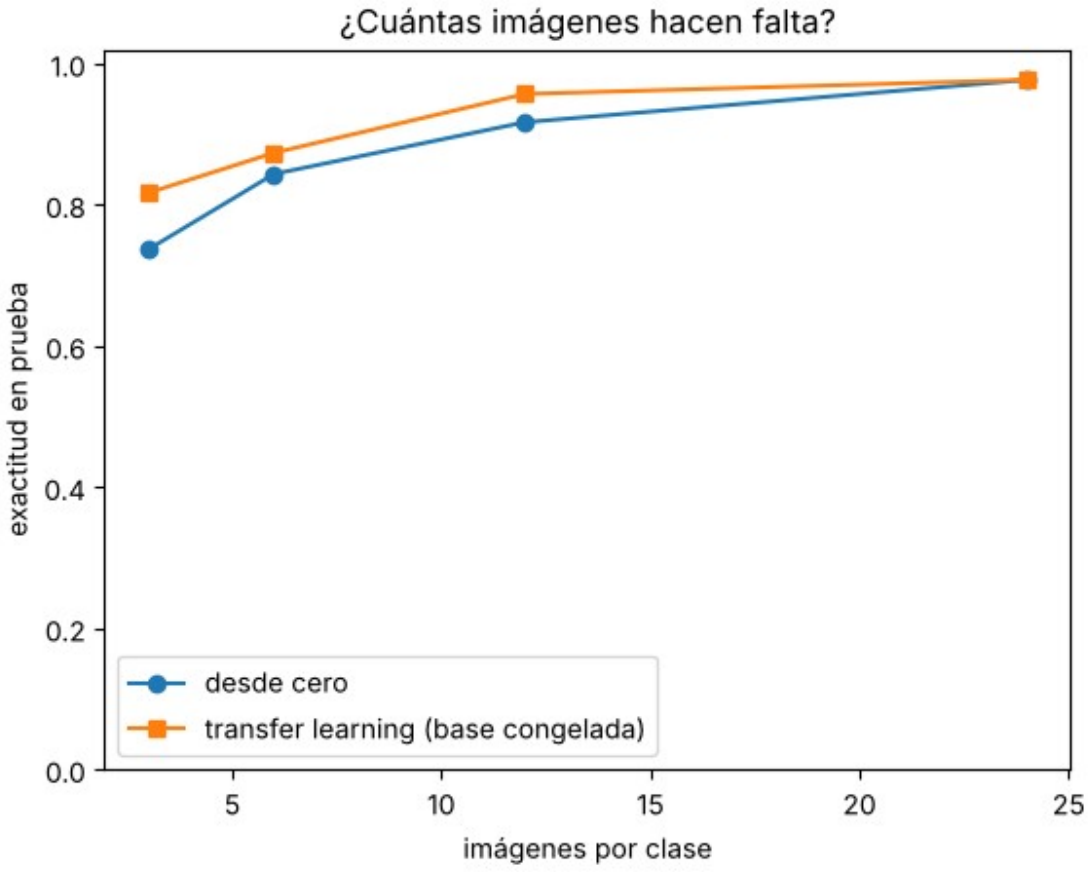


Figura 5. *Mini-reto · ¿Cuántas imágenes hacen falta? Con pocas imágenes por clase el transfer learning (naranja) gana a entrenar desde cero (azul); con 24 por clase se igualan.*

S11_03 · Detección y segmentación

Ej.	Qué pide	Qué obtenemos
1 · clase	Calcular el IoU (solapamiento) de dos cajas	Un número entre 0 y 1; **0** si las cajas no se tocan
2 · clase	NMS: quedarse con la mejor caja cuando hay varias encima	Sobre la imagen de la playa pasa de **47 cajas** a **6**
3 · casa	Calcular la *average precision* (AP) de las detecciones ordenadas por confianza	Un número entre 0 y 1: mejor cuanto antes aparecen los aciertos
4 · casa	mAP del detector de color con IoU de 0.5 a 0.9	AP por umbral: **0.54, 0.51, 0.48, 0.29 y 0.00** · media **0.36**
5 · casa	IoU y Dice de máscaras de segmentación	Segmentación por color: IoU medio **0.63** y Dice medio **0.76**

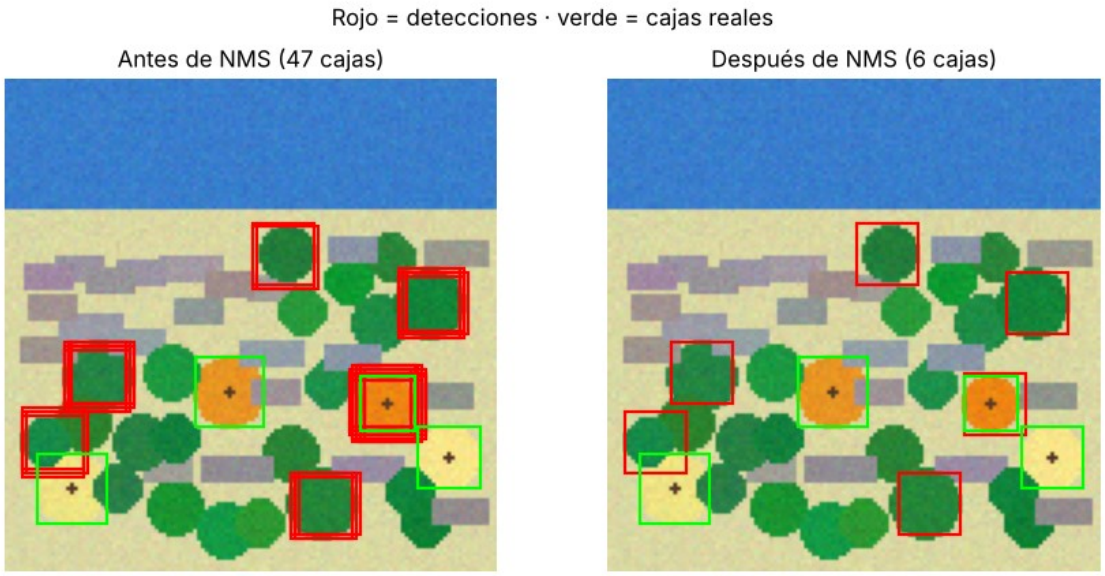


Figura 6. *Ejercicio 2 · Antes de NMS (47 cajas, izquierda) y después (6 cajas, derecha).*

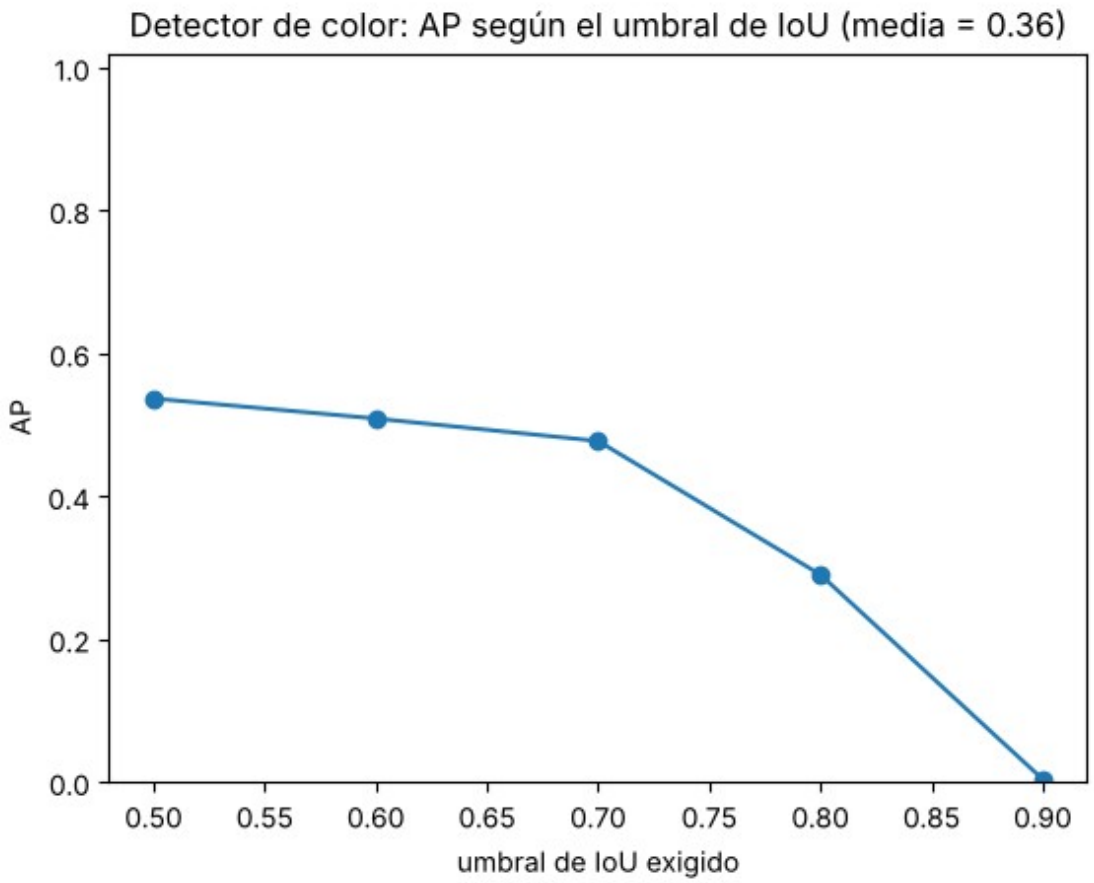


Figura 7. *Ejercicio 4 · AP del detector de color según el IoU exigido: cuanto más exigimos, peor; con 0.9 no acierta ninguna.*

S11_04 · Reto: visión para un cliente

Ej.	Qué pide	Qué obtenemos
1 · reto	Contar las imágenes de cada clase del conjunto	**60 imágenes** en cada una de las 5 clases (apartamentos, camping, casa rural, hotel, piscina)
2 · reto	Transfer learning con la base congelada y con fine-tuning	Validación: base congelada **86.7 %** · fine-tuning **88.3 %** · desde cero **88.3 %**
3 · reto	Precisión y recall por clase	La clase más difícil es **camping** (recall **0.60**, precisión **0.46**); piscina tiene precisión **1.00**
4 · reto	Mirar los errores más seguros del modelo	**15 de 60** imágenes mal clasificadas; **14 de 15** son etiquetas ambiguas (casa rural ↔ camping, sobre todo)
5 · reto	Aceptar solo las fotos con confianza alta	Con umbral **0.7** decide el **78 %** de las fotos y acierta el **77 %** de esas

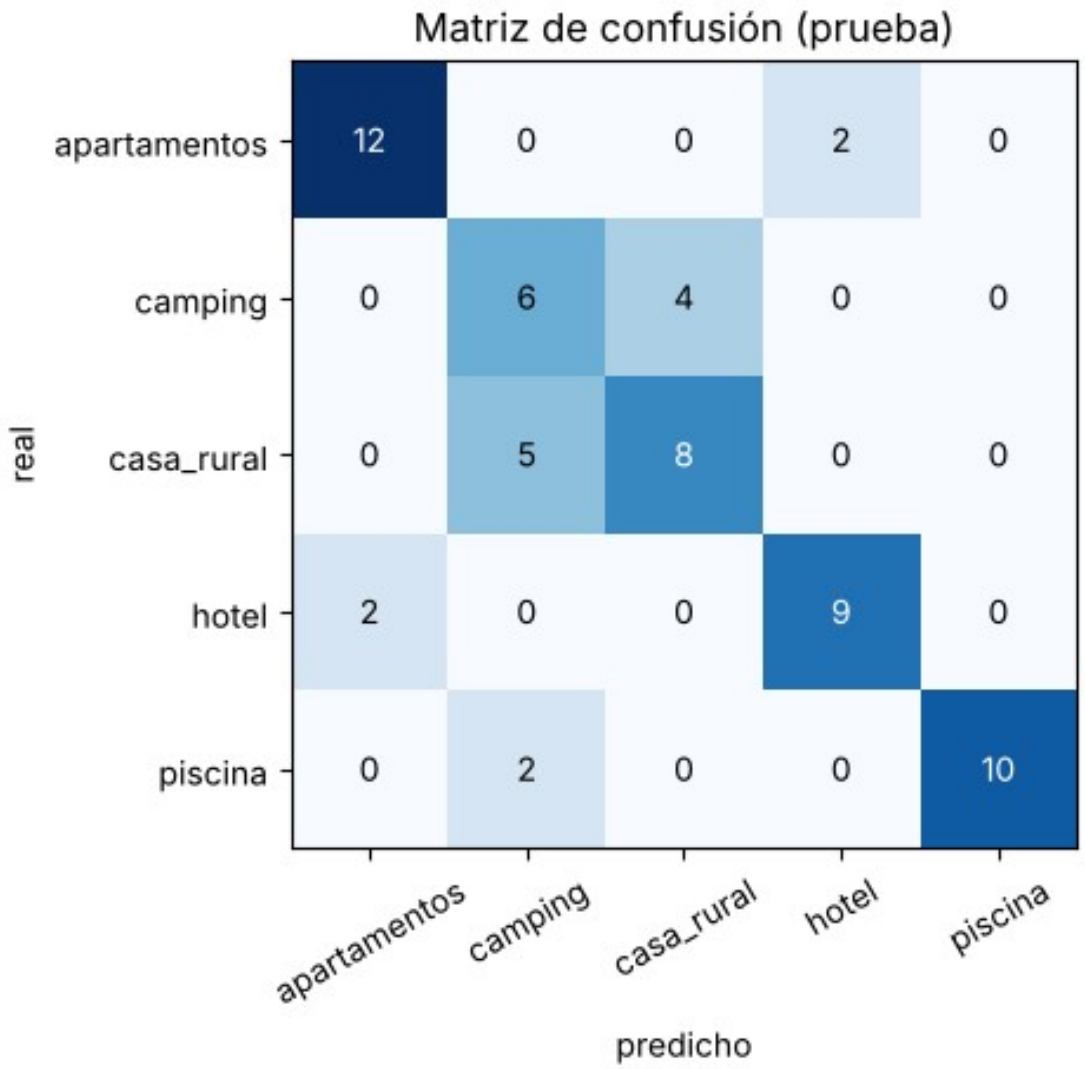


Figura 8. *Ejercicio 3 · Matriz de confusión en prueba: camping y casa rural se confunden entre sí.*

La historia del sprint

- **97.6 %** · Una **CNN** reconoce dígitos mejor que un MLP, y con aumento de datos aguanta los desplazados.
- **47 → 6** · El **NMS** quita las cajas repetidas: de 47 a 6 cajas.
- **6 por clase** · Con pocas imágenes, el **transfer learning** es más estable que entrenar desde cero.
- **14 de 15** · En el reto, casi todos los errores son **etiquetas ambiguas**: el problema está en los datos.