

Sprint 11 · Visión por computador

MÓDULO 4 · UD 4.4-4.6

17-20 DE NOVIEMBRE

17 H TOTALES

Pregunta guía: ¿podemos aprovechar las imágenes del cliente?

Bienvenidos al **Sprint 11**. En este sprint nos adentraremos en el procesamiento y análisis de imagen con redes neuronales convolucionales (CNN) y transfer learning para dar respuesta a necesidades reales de negocio de nuestro cliente **TurisData Canarias**. Diecisiete horas distribuidas entre fundamentos teóricos, laboratorios prácticos en notebooks y el reto PBL.

5 h Teoría

Convolución, pooling, arquitecturas CNN, transfer learning, fine-tuning y detección de objetos

7 h Práctica

Cuatro notebooks: CNN básica, transfer learning, detección/segmentación y esqueleto del reto

5 h Reto PBL

Visión artificial para TurisData: clasificador con transfer learning, demostrador y análisis de errores

¿Qué aprenderás?

- 1** Cómo "ve" una red
Imágenes como matrices, operaciones de convolución, pooling y arquitectura global de una CNN.
- 2** Entrenamiento y data augmentation
Entrenar una CNN pequeña y mejorar notablemente su generalización mediante data augmentation.
- 3** Transfer learning y fine-tuning
Reutilizar redes preentrenadas adaptando cabezas de clasificación y realizando fine-tuning con tasa baja.
- 4** Detección y segmentación
Fundamentos de localización: IoU, NMS, AP/mAP y construcción de un detector clásico mediante OpenCV.
- 5** Evaluación y análisis de errores
Evaluar clasificadores con métricas por clase, matrices de confusión y análisis exhaustivo de fallos.

⚠️ Requisitos previos: Sprint 10 (redes neuronales, Keras, curvas de aprendizaje, regularización). Todo funciona **sin internet** con imágenes sintéticas generadas por código. Las celdas opcionales para Colab requieren internet (en el taller llevan `USAR_INTERNET = False`).

Prácticas del sprint

Notebook / Material	Tema y contenido	Tiempo
S11_01_cnn	Convolución, pooling y CNN en Keras (dígitos 8×8); <i>data augmentation</i>	1 h 45
S11_02_transfer_learning	Transfer learning y fine-tuning (con preentrenamiento propio y MobileNetV2 en Colab)	1 h 45
S11_03_deteccion_segmentacion	IoU, NMS, mAP, detector con OpenCV, segmentación (y YOLO opcional)	1 h 45
S11_04_reto_vision_cliente	Esqueleto del reto: dataset por carpetas, transfer learning y análisis de errores	1 h 45 (+ trabajo PBL)
generar_dataset_sintetico.py	Crea el mini dataset sintético de tipos de alojamiento (una carpeta por clase) para probar el flujo	Material extra

Ficha del reto · «Visión artificial para el cliente»

TURISDATA CANARIAS

EQUIPOS DE 3-4 PERSONAS

TurisData Canarias recibe cientos de fotos de alojamientos y zonas cada semana y las clasifica una persona a mano (hotel, apartamentos, casa rural, camping, piscina). Quiere saber si un modelo puede pre-clasificarlas y, sobre todo, **en qué se equivoca**, para decidir cuánto puede fiarse de él y qué fotos debe revisar una persona.

Qué tenéis que entregar

Tres entregables por equipo en formato digital, revisados y defendidos en la **review** (presentación de 5 minutos).

1 · Modelo transfer learning

Archivo .keras o notebook reproducible entrenado con transfer learning.

2 · Demostrador funcional

Función o interfaz en Colab que recibe foto y devuelve clase, confianza y «revisar a mano» si es baja.

3 · Análisis de errores (1-2 pág.)

PDF o Markdown: métricas por clase, matriz de confusión y ≥ 6 ejemplos mal clasificados con hipótesis.

Restricciones del reto

• Dataset y licencias

Sintético o propio con licencia clara y sin personas reconocibles (≥ 30 imágenes/clase).

• Estructura de carpetas

Una carpeta por clase; partición entrenamiento/validación/prueba fija (prueba usada 1 sola vez).


• Ejecución y entorno

Ejecución en CPU en pocos minutos; en Colab opcional MobileNetV2 con ImageNet.

• Equipos y review

Equipos de 3-4 personas; presentación final de 5 minutos por equipo.

Pasos sugeridos (5 h de trabajo PBL)



Las actividades del reto forman parte de las 5 horas de trabajo PBL planificadas para el sprint.

Qué se enseña en la review

- El **demostrador funcionando** en vivo con 2-3 fotos de prueba.
- La **matriz de confusión** y las principales métricas de rendimiento por clase.
- **Tres errores comentados** en detalle: "el modelo confunde X con Y porque... y propondríamos...".
- Recomendación de **umbral de confianza** justificado: qué se automatiza y qué se envía a revisión manual.

Criterios de evaluación

RÚBRICA DE EQUIPO

0 A 4 POR CRITERIO

Cada entregable se evalúa de **0 a 4 puntos** en los cuatro criterios de la rúbrica de retos del curso (la media alimenta «ejercicios y entregas»). La evaluación contempla tanto el rigor técnico en modelado y datos como el análisis reflexivo y la comunicación orientada al cliente. A continuación encontraréis la descripción completa de cada criterio y los aspectos clave para alcanzar el nivel de excelencia.

Criterio	1 · Insuficiente	2 · Suficiente	3 · Bueno	4 · Excelente
Corrección técnica Modelado, partición y transfer learning	Fugas en datos o modelo sin entrenar adecuadamente	Modelo básico sin comparación ni ajuste fino	Transfer learning bien aplicado con métricas completas	Carga sin fugas, transfer learning y fine-tuning óptimos, y comparación con baseline
Reproducibilidad Ejecución clara y reproducible	No se puede ejecutar de forma autónoma	Requiere ajustes manuales no documentados	Ejecución guiada con dependencias especificadas	Se ejecuta desde el README; semillas y versiones fijadas; instrucciones de dataset
Análisis y comunicación Evaluación de fallos y recomendación	Sin análisis cualitativo ni estudio de fallos	Métricas globales sin detalle por clase	Matriz interpretada y ejemplos descritos	Errores con hipótesis y propuesta; umbral de confianza justificado para el cliente
IA responsable Privacidad, sesgos y licencias	No se consideran aspectos éticos ni legales	Mención genérica sin medidas prácticas	Riesgos identificados en datos y licencias	Medidas aplicadas: representatividad, clases raras, privacidad y licencias de fotos

¿Cómo llegar al nivel Excelente?

No se trata únicamente de maximizar la precisión global, sino de entender en profundidad el comportamiento del sistema. Un proyecto excelente no oculta los fallos, sino que los categoriza, establece hipótesis sólidas y diseña mecanismos para que el cliente pueda operar con seguridad delegando en personas las predicciones dudosas.



Rigor metodológico

Partición fija de entrenamiento/validación/prueba sin fugas. Compara siempre el modelo preentrenado con una referencia entrenada desde cero.



Reproducibilidad total

Fija todas las semillas y versiones en el notebook para que cualquier persona pueda reproducir idénticos resultados de arriba abajo.



IA responsable y datos

Asegura licencias claras, ausencia de personas reconocibles, y documenta medidas ante clases poco frecuentes o etiquetas dudosas.



Valor para el negocio

Define un umbral de confianza justificado (cobertura vs. precisión) para guiar a TurisData sobre qué automatizar y qué revisar a mano.

Definition of Done y cierre del sprint

CHECKLIST FINAL

RETROSPECTIVA

RECURSOS

Antes de dar por cerrado el Sprint 11, cada equipo debe repasar el siguiente checklist. Si algún punto no está marcado, aún estáis a tiempo de completarlo antes de la review. Recordad que la Definition of Done no es burocracia: es la garantía de que el trabajo entregado es reproducible y aporta valor real a TurisData Canarias.

Checklist Definition of Done

- ☐ El notebook se ejecuta de arriba abajo con semillas fijas
- ☐ El dataset tiene estructura por carpetas y se ha comprobado su contenido por clase
- ☐ Entrenamiento/validación/prueba separados; la prueba se usa una sola vez
- ☐ Hay modelo con transfer learning y una referencia para compararlo
- ☐ Métricas por clase y matriz de confusión interpretadas
- ☐ Al menos 6 ejemplos mal clasificados analizados, con hipótesis y mejora propuesta
- ☐ Demostrador con umbral de confianza y opción «revisar a mano»
- ☐ Se documentan origen y licencia de los datos y al menos dos riesgos de IA responsable

Preguntas de retrospectiva

Dedicad los últimos minutos del sprint a responder estas tres preguntas en equipo para evaluar el proceso técnico y analítico desarrollado.

- ¿Qué decisiones en el preprocesamiento o la arquitectura han mejorado más las métricas?
- ¿Cómo de fiable resulta la opción de «revisar a mano» según el umbral elegido?
- ¿Qué aspectos de calidad de imagen o sesgo de datos solucionaríamos en una siguiente iteración?

Recursos recomendados

Todos los recursos siguientes son referencias oficiales y documentación abierta para apoyar la implementación y resolver dudas técnicas.

1

Keras · Transfer Learning y Fine-Tuning

keras.io · Guías oficiales «Transfer learning & fine-tuning» e «Image classification from scratch».

2

Keras · Carga de imágenes por directorios

keras.io · Documentación oficial de `keras.utils.image_dataset_from_directory`.

3

OpenCV para Python

docs.opencv.org · Referencia de funciones clásicas de visión: `cv2.findContours` y `cv2.matchTemplate`.

4

Ultralytics YOLO

docs.ultralytics.com · Guía de uso y modelos YOLO (aplicable a la celda opcional de Colab).

5

Creative Commons · Licencias de imágenes

creativecommons.org · Guía sobre cómo reconocer, verificar y citar licencias abiertas en datasets de imágenes.



Llegad a la review con el demostrador listo para probar 2–3 fotos en vivo y la matriz de confusión analizada.