IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Series, texto y generación: predecir, leer y crear

Series temporales, redes recurrentes, NLP, transformers, RAG y autoencoders · un recorrido por S12_01 a S12_07

Sprint 12 · recorrido global de los cuadernos S12_01 a S12_07

DÓNDE ESTAMOS

Del dato suelto al tiempo y al lenguaje

Hasta S11: filas e imágenes

Cada ejemplo era **independiente**: una fila o una foto.

El **orden** no importaba.

S12: orden y significado

En una **serie** importa el **orden** del tiempo.

En un **texto** importa qué palabras hay… y qué **significan**.

Dos finales

Leer: clasificar, buscar, responder con fuentes.

Crear y vigilar: generar y detectar anomalías.

Hilo común: **primero una línea base sencilla**; el modelo complejo solo se justifica si la **mejora se mide.**

Datos: ocupación diaria 2023-2025 y 1 500 reseñas de TurisData.

LOS TEMAS DE HOY

Siete cuadernos, seis ideas

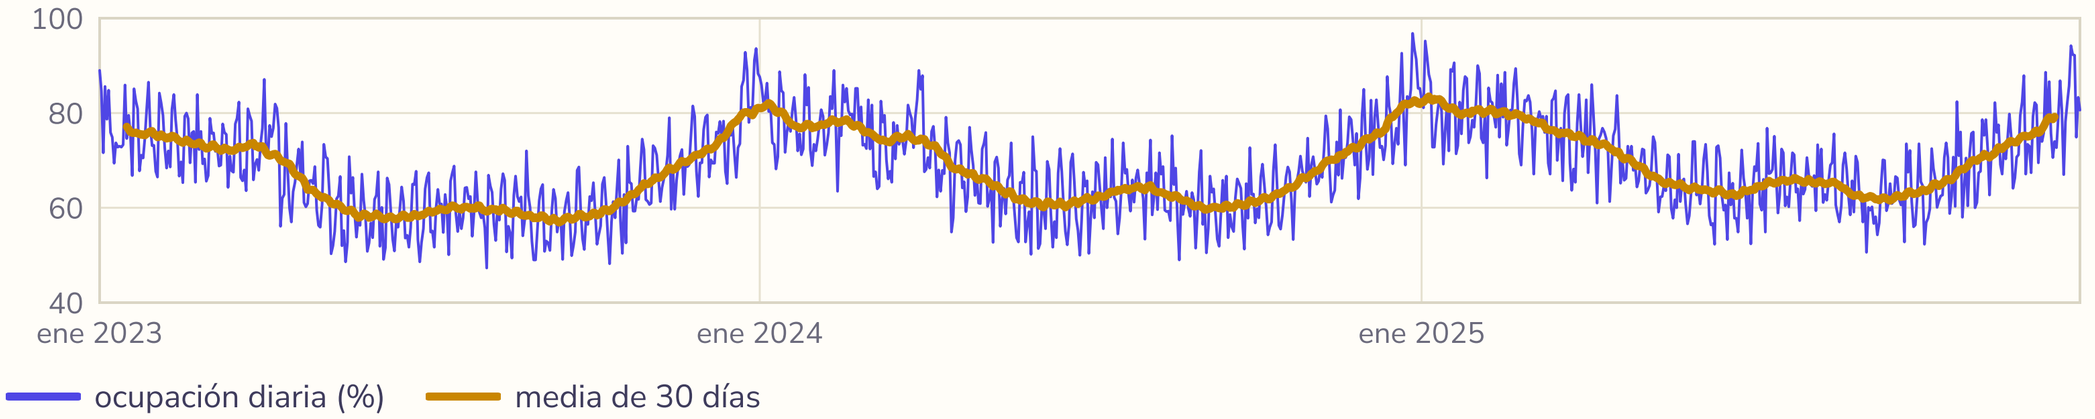
Tema	La pregunta que responde	Cuaderno
Series temporales	¿Cuánta ocupación habrá **la semana que viene**?	S12_01
Redes recurrentes	¿Puede una red **recordar** los últimos 28 días?	S12_02
NLP clásico	¿Qué **opinan** y de qué **hablan** 1 500 reseñas?	S12_03
Embeddings	¿Cómo se mide que dos textos **se parecen**?	S12_04
Transformers	¿Cómo **lee** y **escribe** un modelo de lenguaje?	S12_05
Mini-RAG	¿Cómo **responde con fuentes** y sin inventar?	S12_06
Autoencoders	¿Qué es **raro**? ¿Cómo se **genera**?	S12_07

Recorrido: 1 · Series → 2 · Redes recurrentes → 3 · Texto y embeddings → 4 · Transformers → 5 · RAG → 6 · Autoencoders.

1 · SERIES TEMPORALES

Una serie tiene orden: no se baraja

Ocupación diaria del alojamiento, 2023-2025 (1 096 días)



Tendencia

¿Sube a largo plazo? Media de enero: **77,0 %**, **78,6 %** y **81,0 %**.

Estacionalidad

Lo que se repite. Ene-feb 2025: **80,6 %**; jun-sep: **64,0 %**.

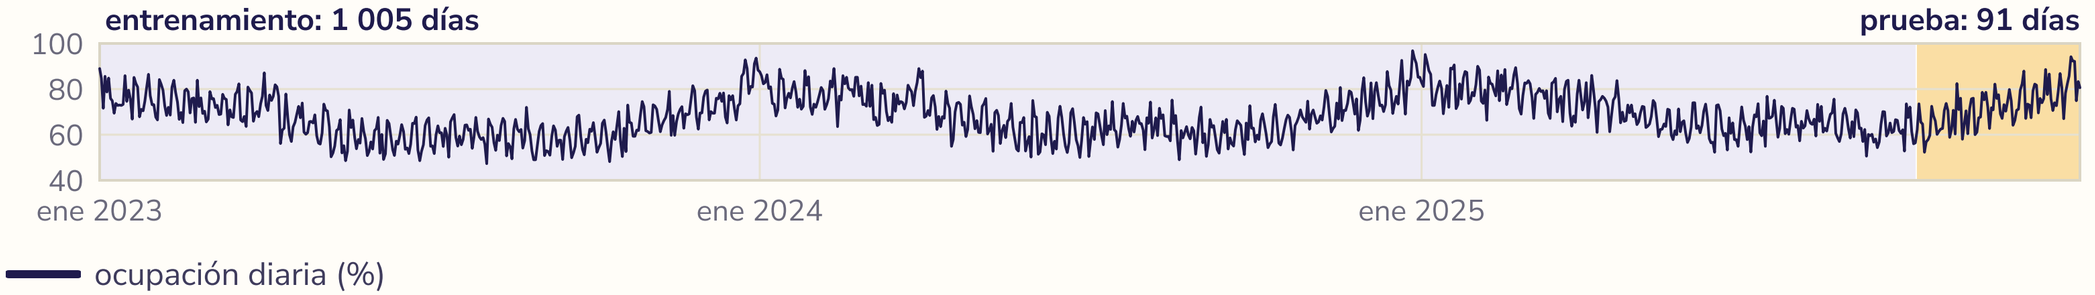
Ruido

Lo que ningún patrón explica: un día suelto puede salirse de la línea.

1 · PARTIR POR FECHA

Se entrena con el pasado y se prueba al final

La partición respeta el calendario



Por qué no se baraja

Si mezclas días, el modelo **ve el futuro**: una **fuga de datos**.

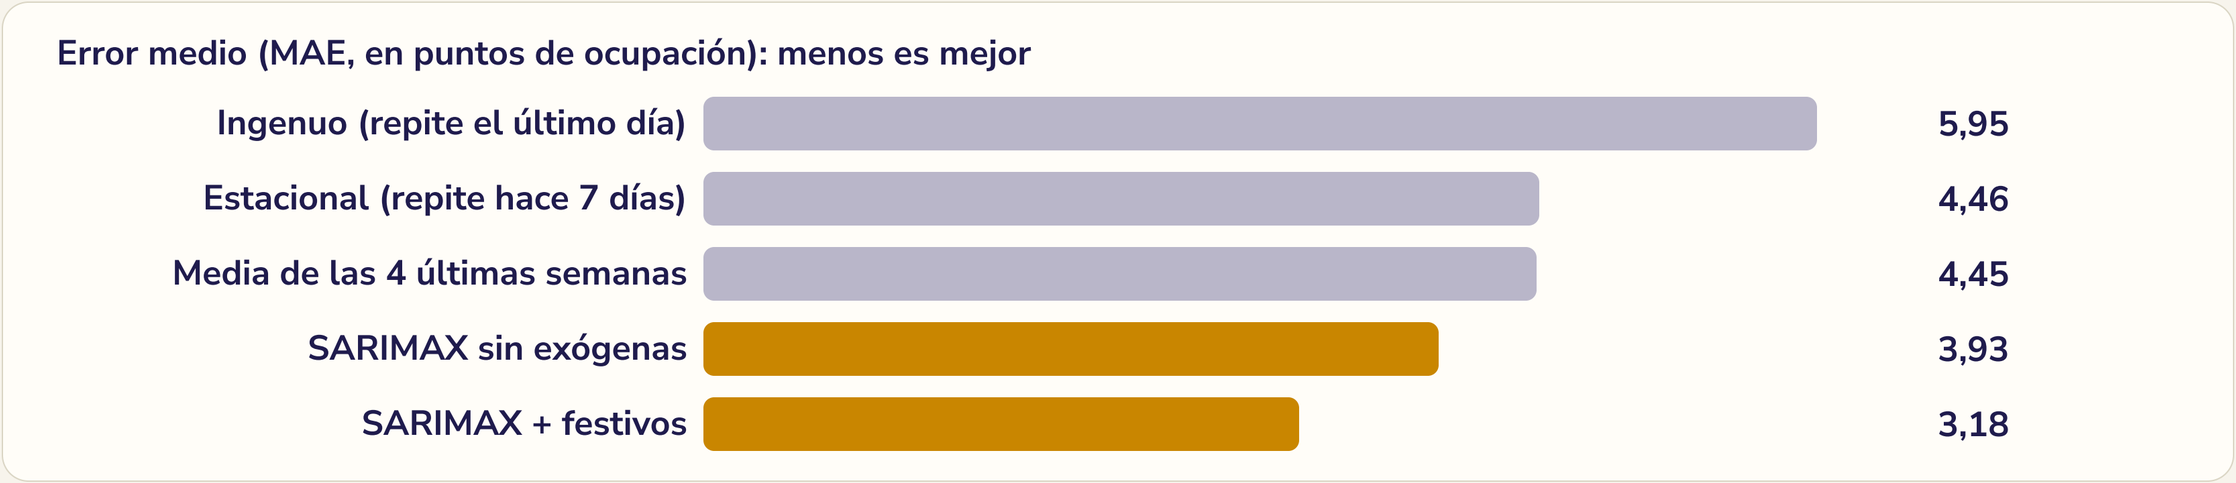
Qué se reserva

Entrenamiento hasta el **1/10/2025**; prueba: **13 semanas** (91 días).

Regla de oro de las series: el examen siempre es posterior al estudio.

1 · EL BASELINE

Antes de un modelo, una vara de medir



SARIMAX mejora un 28,5 % al mejor baseline (3,18 frente a 4,45). Sin el baseline, esa cifra no significaría nada.

Ejemplo de juguete: repetir la semana pasada falla 1,43 puntos; repetir solo el último día, 8,43.

SARIMAX: lo que se repite y lo que ya sabes

Lo que se repite

Memoria de días anteriores y del **mismo día de otras semanas** (ciclo de 7).

Lo que ya sabes

Variables **conocidas de antemano**: festivos y ondas del calendario anual.

+9,2

puntos más de ocupación en un **festivo**

IC: 7,7 a 10,7

Dos ritmos

Entre el mejor y el peor día de la semana hay **9,4 puntos**: el ciclo semanal es real.

La temperatura no entra

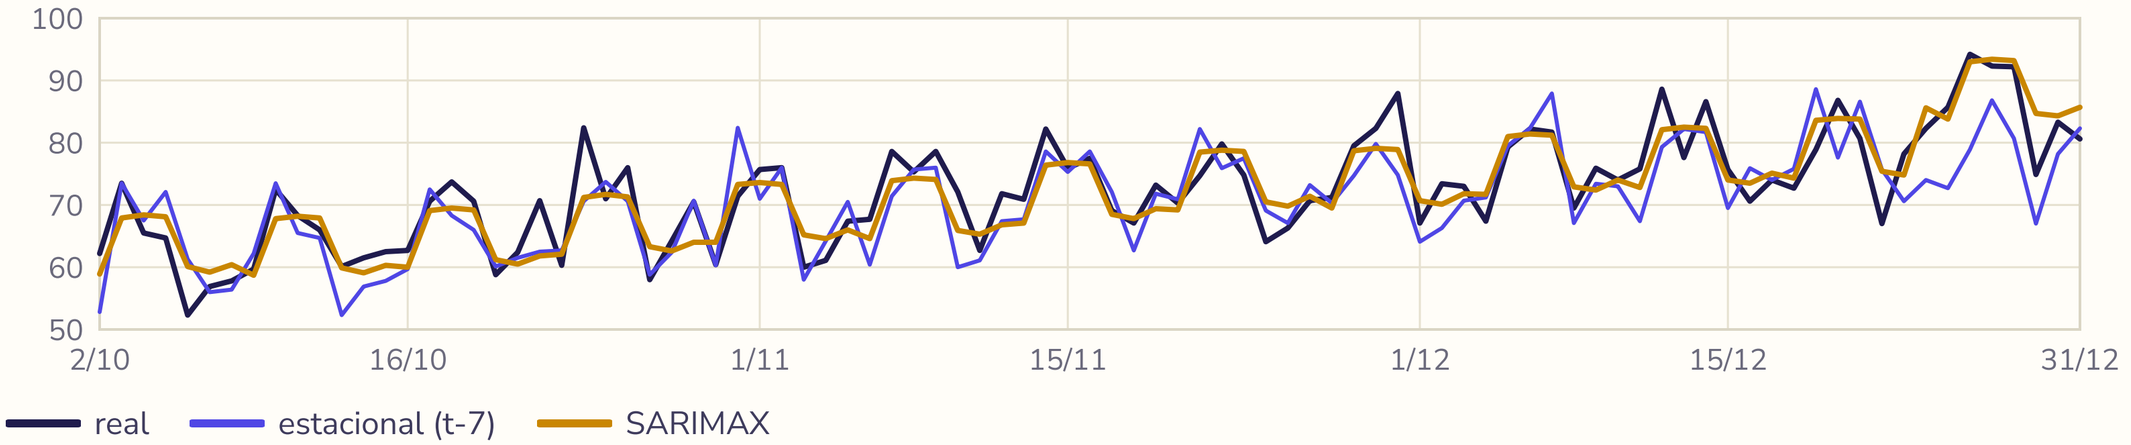
De la semana que viene **aún no se conoce**: usarla sería **fuga de datos**.

Una ecuación lenta y explicable que se bate con redes: ese es el listón del sprint.

1 · EN LA PRUEBA

Real frente a previsión: las últimas 13 semanas

Previsión a 7 días en las últimas 13 semanas (ocupación %)



Cómo se lee

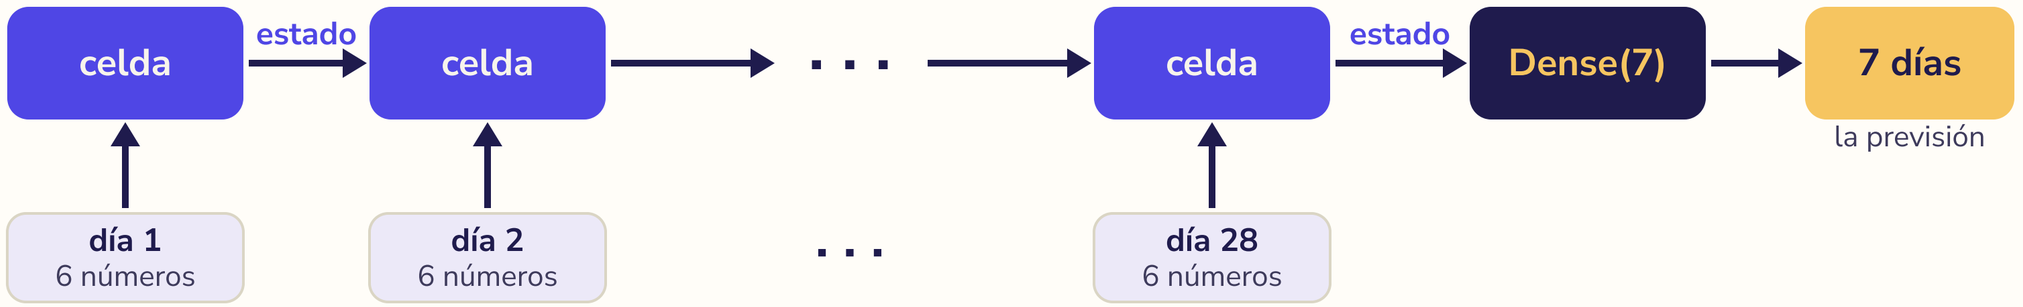
Línea **oscura** = lo que pasó. Las de color, previsiones a **7 días** desde 13 orígenes.

Qué mirar

Cuanto más **pegada a la oscura**, mejor. SARIMAX sigue la semana mejor que repetir la anterior.

Una red que lee el calendario día a día

La misma celda lee un día tras otro y pasa su resumen (el estado) al siguiente



Estado

Un **resumen** de lo leído hasta hoy.

LSTM y GRU

Puertas: qué **olvidar** y qué **guardar**.

Salida

Tras **28 días**, una capa densa da los **7** siguientes.

Misma idea que SARIMAX, usar el pasado, pero aprendida por la red.

2 · PREPARAR LOS DATOS

Ventanas de 28 días para prever 7

6 variables
ocupación, festivo, semana (sen, cos), año (sen, cos)

→

Escalar
con mínimo y máximo del **entrenamiento**

→

Ventanas
28 días de entrada → 7 de salida

→

Red
32 unidades: SimpleRNN, LSTM o GRU

Escalar sin mirar la prueba

Mínimo y máximo (entrenamiento)	`40 · 90`
Valor nuevo, en la prueba	`95`
(95 – 40) ÷ (90 – 40)	**`1,10`**

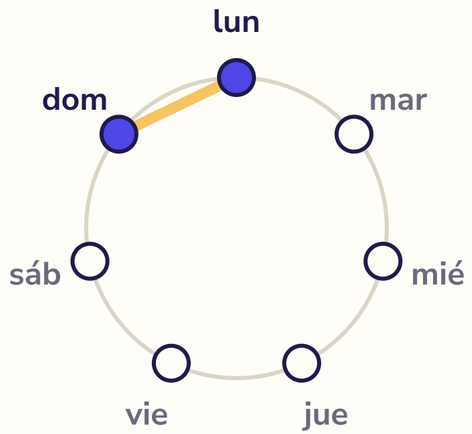
Cuántas ventanas salen

Serie de 8 días, entrada 3, salida 2	
n – entrada – salida + 1	`8 - 3 - 2 + 1`
Ventanas posibles	**`4`**

Escalar con todo el conjunto sería otra fuga: la prueba habría influido en el entrenamiento.

Lunes está cerca de domingo

El día de la semana, en un círculo



Distancia lunes–domingo: **0,87**. Lunes–jueves: **1,95**. Como números de 0 a 6, lunes y domingo estarían a **6**.

Dos números por día

Seno y coseno colocan los 7 días en un **círculo**: el domingo enlaza con el lunes.

Distancias

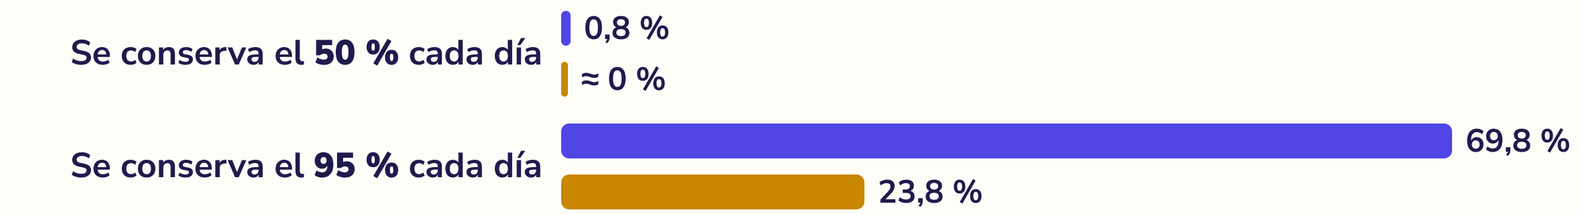
Lunes–domingo: **0,87**. Lunes–jueves: **1,95**. Los días vecinos quedan cerca.

Con un número del 1 al 7, lunes y domingo parecerían lejísimos. Con seno y coseno, no.

2 · POR QUÉ LSTM Y GRU

Una red simple se olvida del pasado

Cuánta señal queda de lo que se vio al principio



El problema

Cada día la señal se **multiplica** por un factor menor que 1. A los **28 días** casi no queda nada.

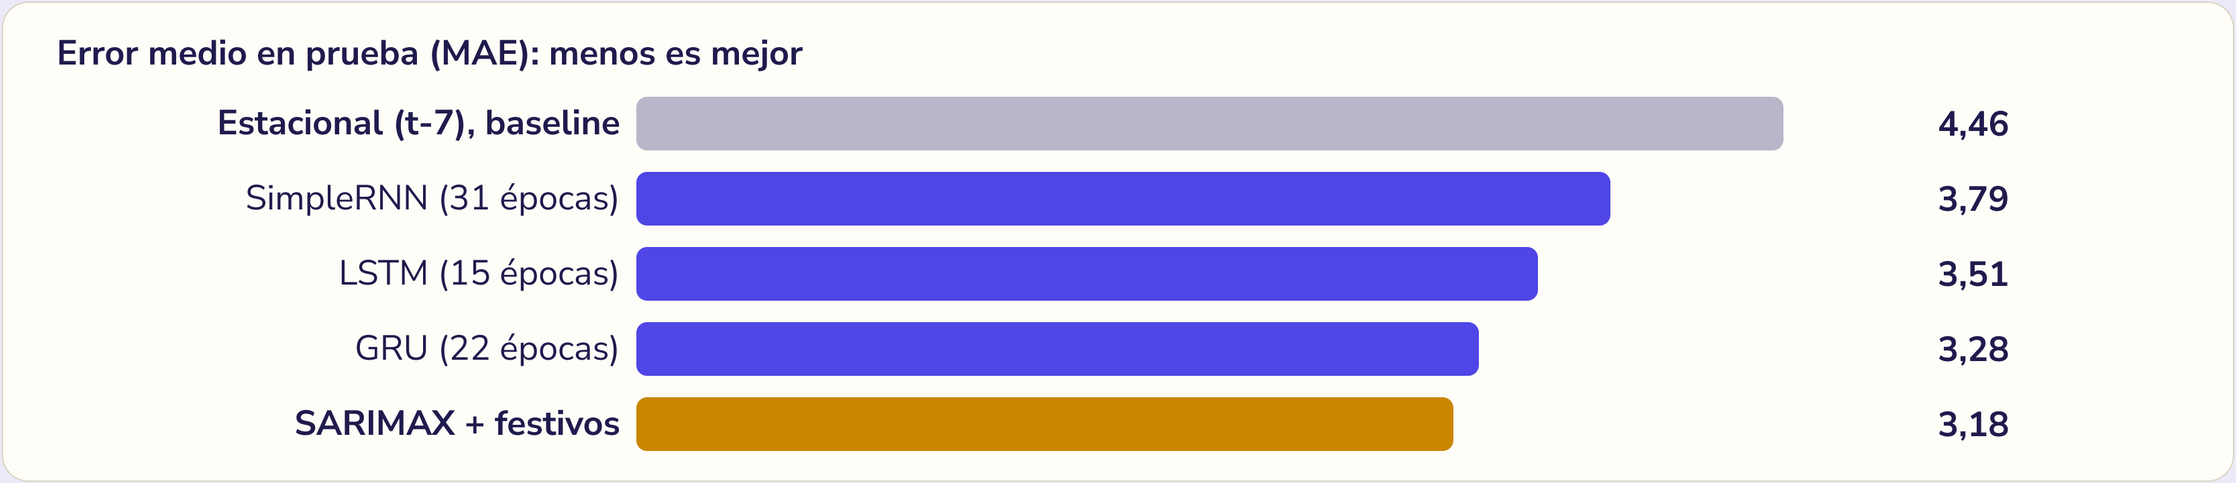
La solución

Las **puertas** de LSTM y GRU dejan pasar lo útil casi **sin multiplicar**.

Por eso con 28 días de ventana conviene LSTM o GRU, no una red simple.

2 · RESULTADOS

¿Gana una red a la ecuación?

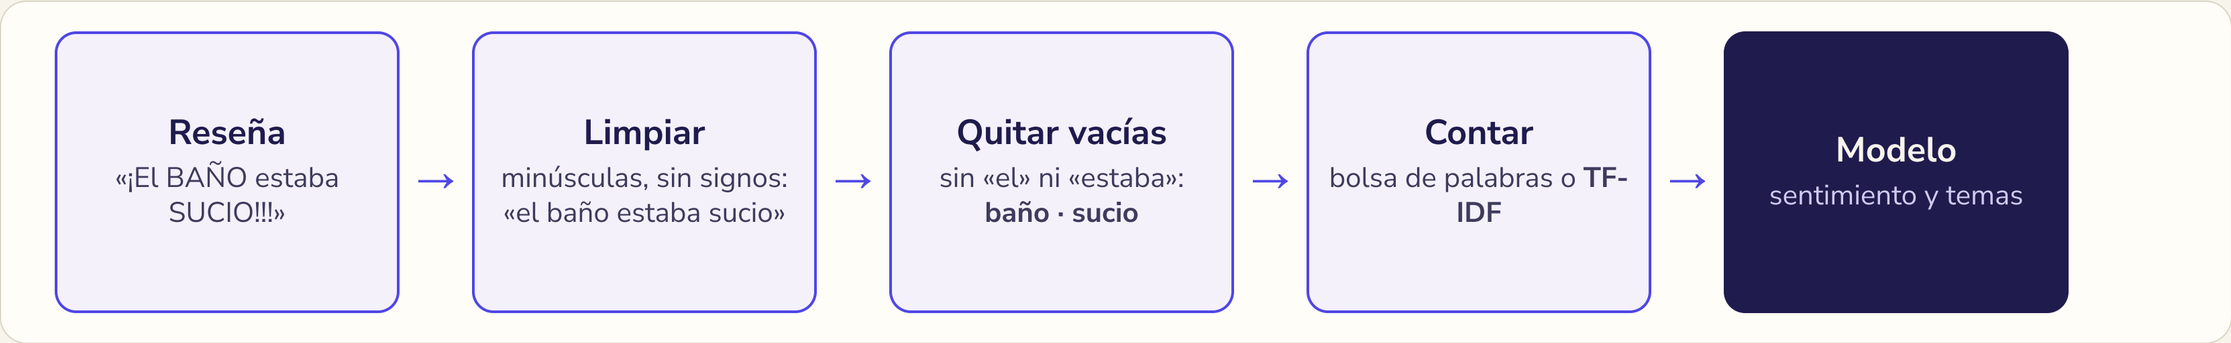


La GRU mejora un 26 % al baseline (3,28 frente a 4,46), pero ninguna red bate a SARIMAX (3,18).

Con pocos datos y un patrón claro, la ecuación sencilla compite. Una red no es siempre mejor.

3 · TEXTO A NÚMEROS

El modelo solo entiende números



Se conservan

La **ñ** y las **tildes**. Y también el **«no»**: cambia el sentido.

Se quitan

Palabras **vacías** (el, la, de, es…) y los **signos** de puntuación.

Cada paso decide qué información se queda: limpiar mal es perder datos antes de empezar.

TF-IDF: no todas las palabras pesan igual

«la cama es cómoda»: peso TF-IDF de cada palabra



Bolsa de palabras

Cuenta cuántas veces sale cada palabra.

TF-IDF

Da más peso a lo **raro** (cómoda) y menos a lo que está en **todas** (es).

No ve el orden: «Está limpio, no está caro» y «No está limpio, está caro» dan **la misma bolsa.**

3 · SENTIMIENTO

Un modelo casi perfecto… ¿es sospechoso?

Exactitud en 375 reseñas de prueba



Qué falla

Solo **3** de 375 se equivocan: 3 reseñas **neutras** leídas como negativas.

Por qué desconfiar

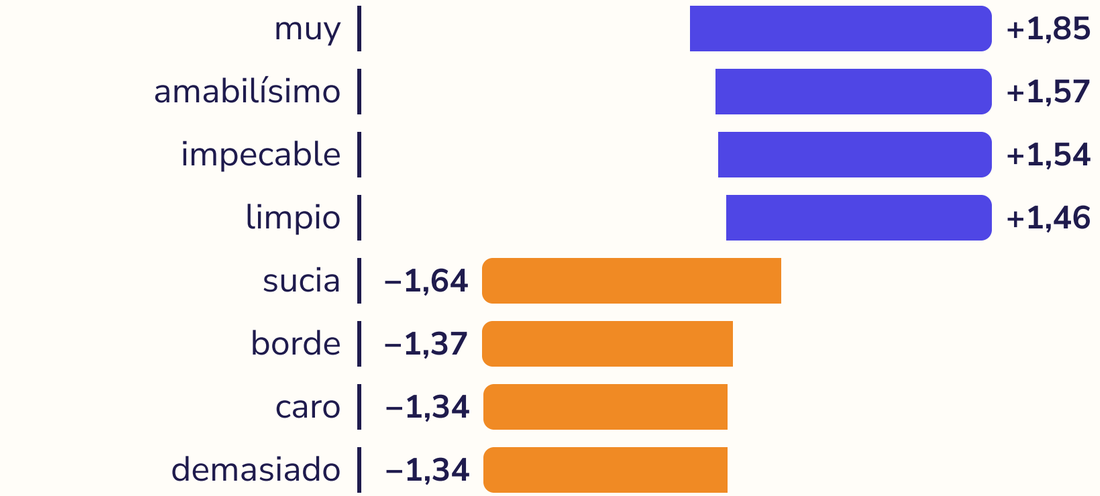
Las reseñas son **sintéticas** y repetitivas: en datos reales el techo sería **más bajo**.

Un resultado demasiado bueno pide una pregunta: ¿de dónde salen los datos?

3 · QUÉ MIRA EL MODELO

Las palabras que más pesan

Peso de la palabra en la regresión logística



Cómo se lee

Derecha: empuja a **positivo**. **Izquierda**: empuja a **negativo**.

Peso no es causa

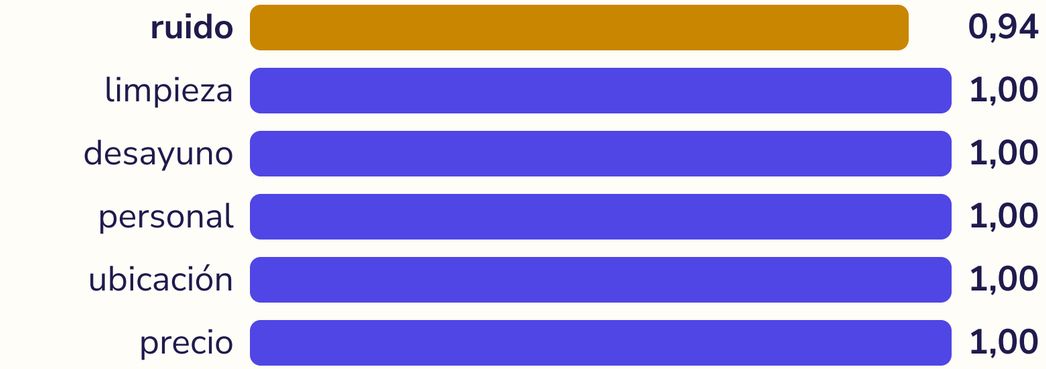
«muy» sale primero porque aparece en el **73,9 %** de las reseñas positivas, no porque sea alegre.

Mirar los **pesos** ayuda a **entender** y a **sospechar** del modelo.

3 · TEMAS POR PALABRAS CLAVE

Un diccionario también falla

F1 de cada tema



El método

Una **lista de claves** por tema. Barato y **transparente**.

Dónde falla

La clave **«ruid»** también encaja con **«ruidosa»**: encuentra de más.

F1 equilibra **precisión y recall**: sirve cuando buscar de menos y de más cuestan.

Significado en pocos números

TF-IDF

105 columnas, casi todas a cero. Cada palabra es una columna distinta: «ruido» y «bullicio» **no se parecen**.

LSA (embedding)

12 ejes densos. Palabras que viajan juntas caen en el **mismo eje**: «ruido», «dormir», «noche».

Precio

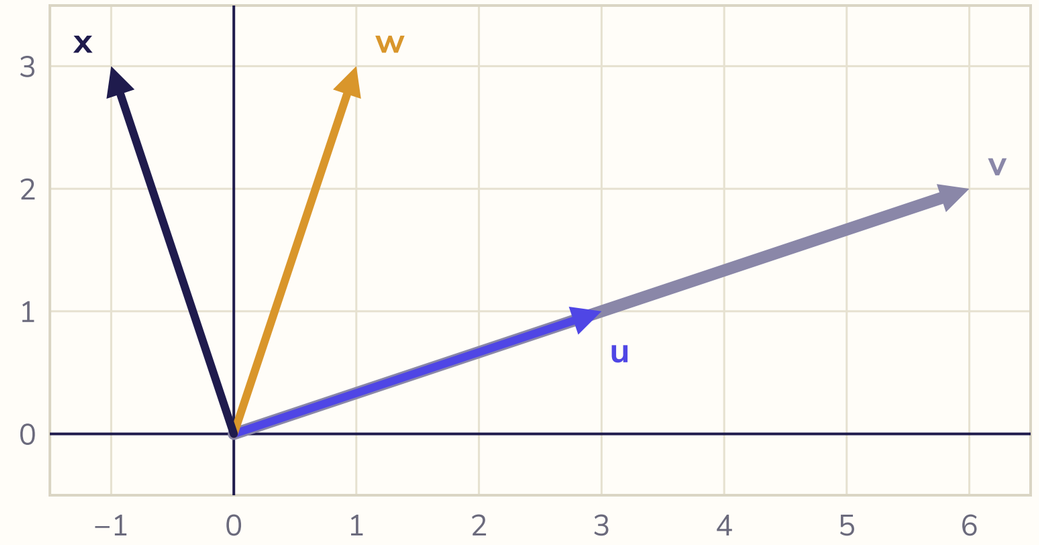
12 ejes conservan el **44 %** de la información; se **pierde un 56 %**.



Un buscador por significado: compara ángulos, no letras.

3 · MEDIR EL PARECIDO

El coseno mide el ángulo entre textos



u y v: 0°

Misma dirección: coseno **1,00**. Mismo tema, aunque uno sea más largo.

u y w: 53°

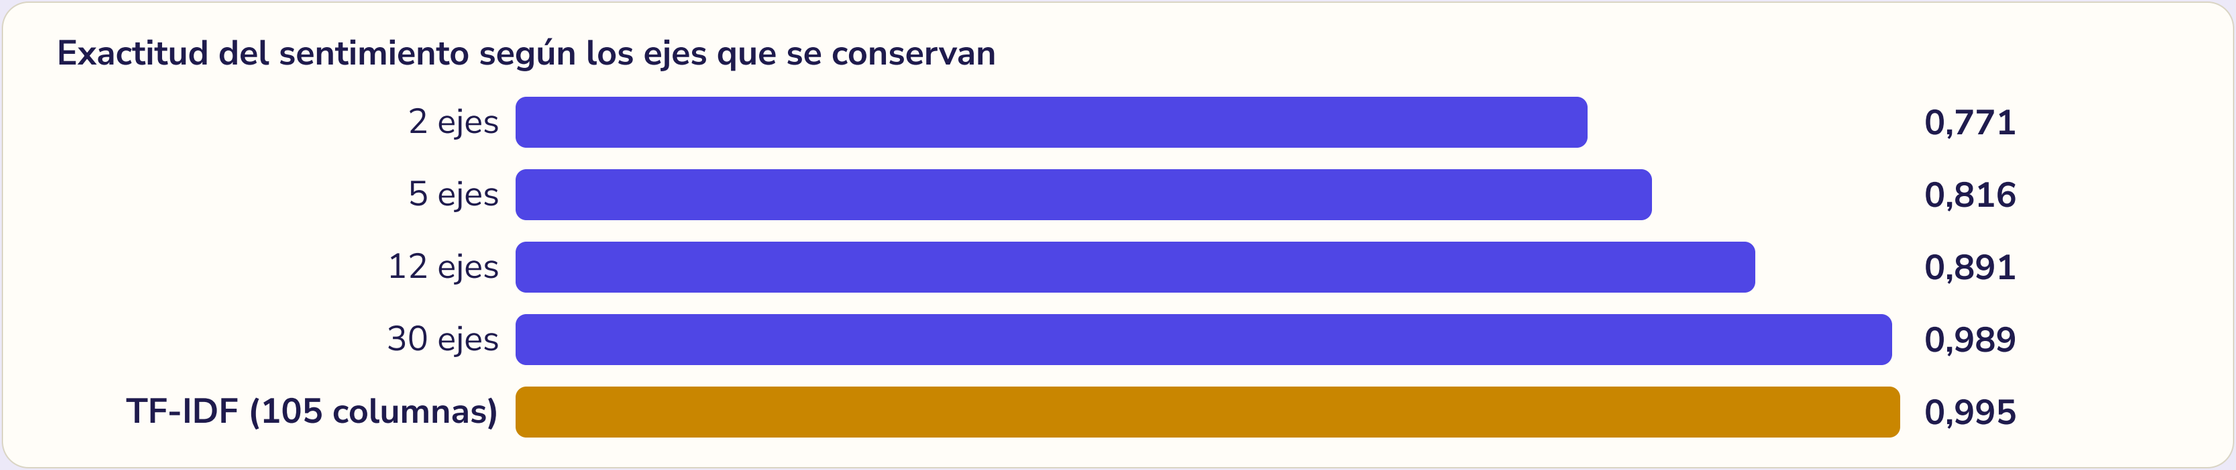
Se parecen **algo**: coseno **0,60**.

u y x: 90°

Sin relación: coseno **0,00**.

3 · ¿CUÁNTOS EJES?

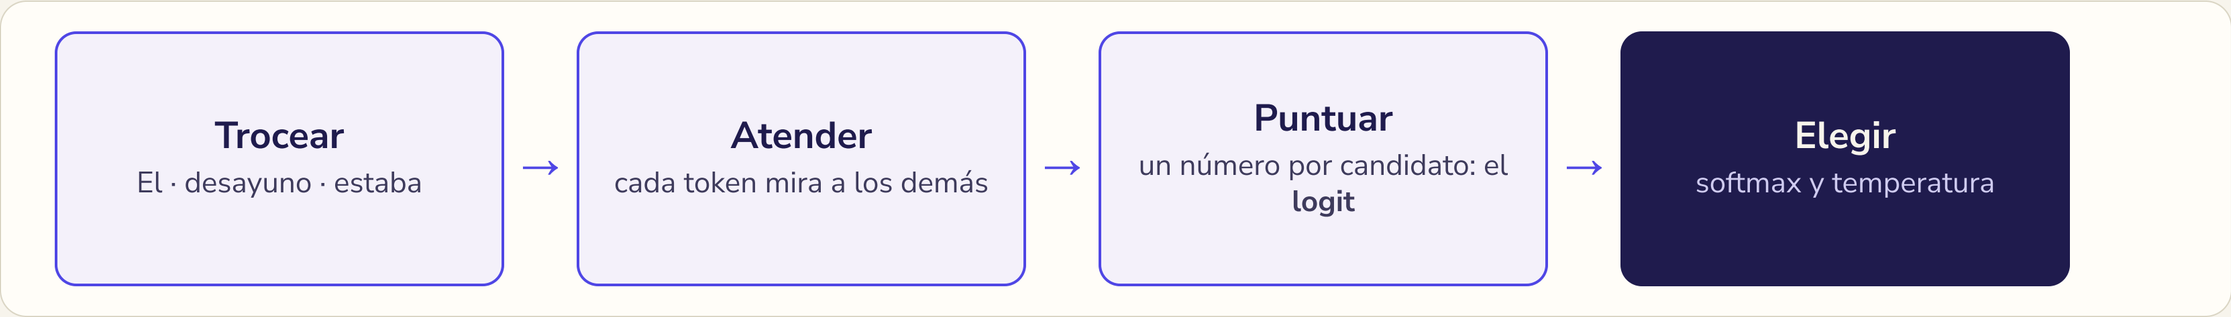
Más ejes, más información… con límite



Con 2 ejes se ve la forma de los datos pero se pierde el sentimiento; con 30, casi como el original.

Los embeddings de redes neuronales captan más significado, pero traen dependencia y privacidad.

Un LLM solo sabe elegir el siguiente token



Elegido el token, se añade al texto y todo se repite: así escribe un LLM, token a token.

Un Transformer apila muchas capas de atención, con varias «cabezas» a la vez. Hoy calculamos una, a mano.

Los tokens son trozos de palabra

Palabra	Tras 5 fusiones	Letras → tokens
playa	play · a	5 → 2
playas	play · a · s	6 → 3
playero	play · e · r · o	7 → 4
jugar	jug · a · r	5 → 3
jugamos	jug · a · m · o · s	7 → 5
jugaba	jug · a · b · a	6 → 4
jugando (nueva)	jug · a · n · d · o	7 → 5

BPE fusiona los pares más frecuentes. Una palabra **nueva** se escribe con **trozos conocidos**.

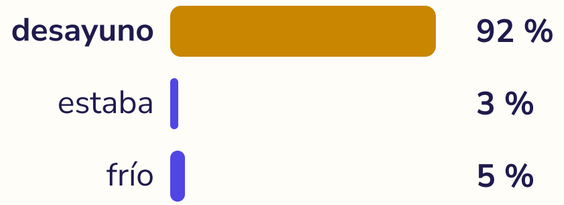
Ejemplo de juguete: 36 letras del corpus se quedan en 21 tokens.

Cada token pregunta, compara y mezcla

Token «frío»: a quién mira

Q·K con cada token	7 · 2 · 3
÷ √2	4,95 · 1,41 · 2,12
softmax = reparto	0,919 · 0,027 · 0,054
Mezcla de los V	**(2,784 ; 0,135)**

Atención de «frío»



Q (pregunta)

Qué busca este token.

K (clave)

Qué ofrece cada token.

V (valor)

Qué información aporta.

«frío» mira sobre todo a «desayuno»: le dice **qué** estaba frío.

4 · MÁSCARA CAUSAL

Al escribir, no se puede mirar el futuro

Sin máscara

mira a →	desayuno	estaba	frío
desayuno	0,47	0,47	0,06
estaba	0,58	0,14	0,28
frío	0,92	0,03	0,05

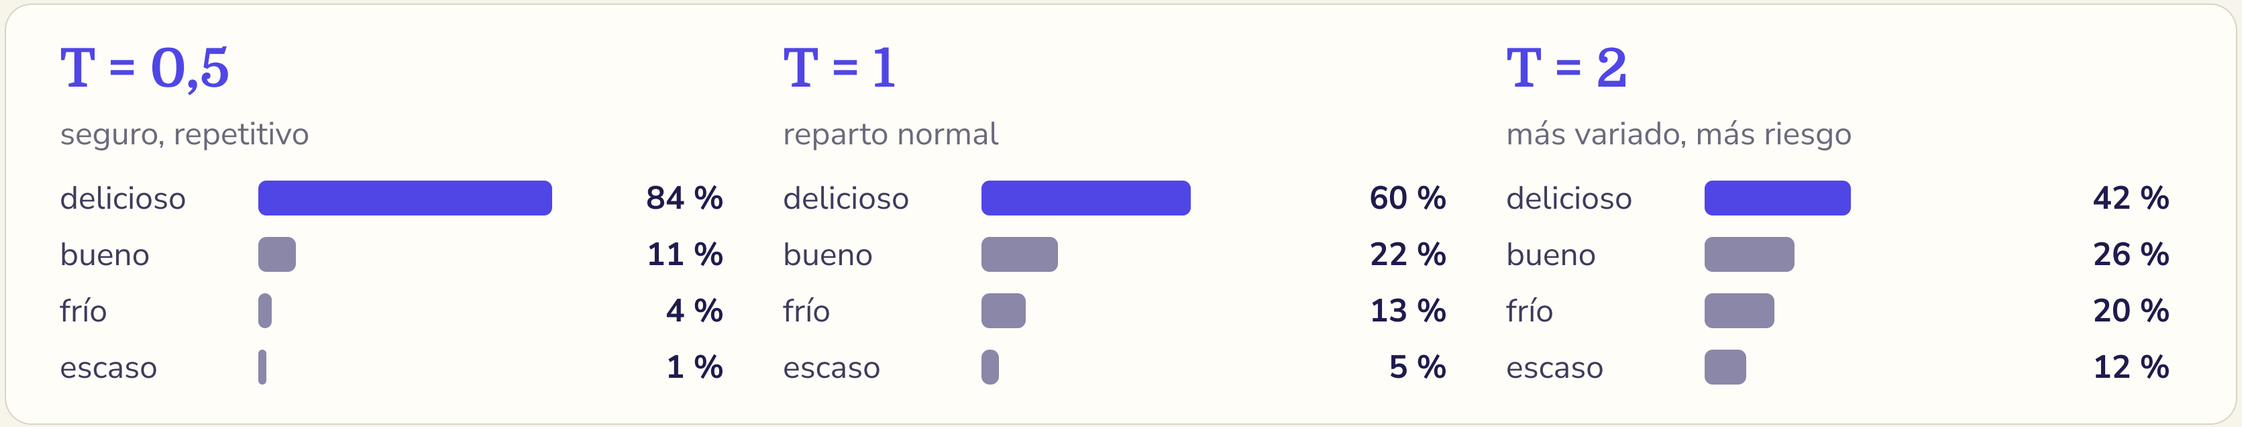
Con máscara causal

mira a →	desayuno	estaba	frío
desayuno	1,00	0,00	0,00
estaba	0,80	0,20	0,00
frío	0,92	0,03	0,05

La máscara causal tapa los tokens de después: al generar, el siguiente aún no existe.

Filas: quién pregunta. Columnas: a quién mira. Más oscuro = más atención.

La temperatura reparte la elección



T baja = respuestas seguras y repetidas. **T alta** = más variedad y más **riesgo** de decir tonterías.

5 · MINI-RAG

RAG: buscar, aumentar, generar y citar

Trocear
el documento en **fragmentos** con sección

→

Buscar
TF-IDF y coseno: los **mejores** fragmentos

→

Aumentar
reglas + **contexto** etiquetado + pregunta

→

Generar
responder **citando** la fuente

Por qué

El modelo **no sabe** los datos del centro. Se le da el texto **en el momento**.

Ojo: prompt injection

El documento puede traer **órdenes ocultas**. Se defiende con **capas**: filtro, reglas y revisión.

Sin defensa prosperan 3 de 3 ataques de prueba; con filtro, 0 de 3.

5 · EL UMBRAL DE «NO CONSTA»

Si nada se parece, mejor no inventar



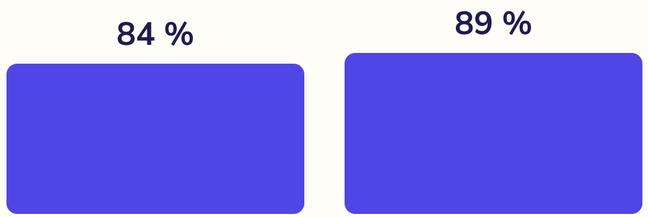
Si el mejor fragmento **no llega a 0,15**, la respuesta es **«no consta»**: nada de inventar.

Las dos últimas preguntas no están en el documento: la respuesta correcta es admitirlo.

5 · EVALUAR EL RAG

Buscar bien y responder bien se miden aparte

¿Aparece el fragmento correcto?



Respuestas correctas



Con umbral

0 sin fuente y **0** alucinaciones.

Sin umbral

1 alucinación: respondió lo que no consta.

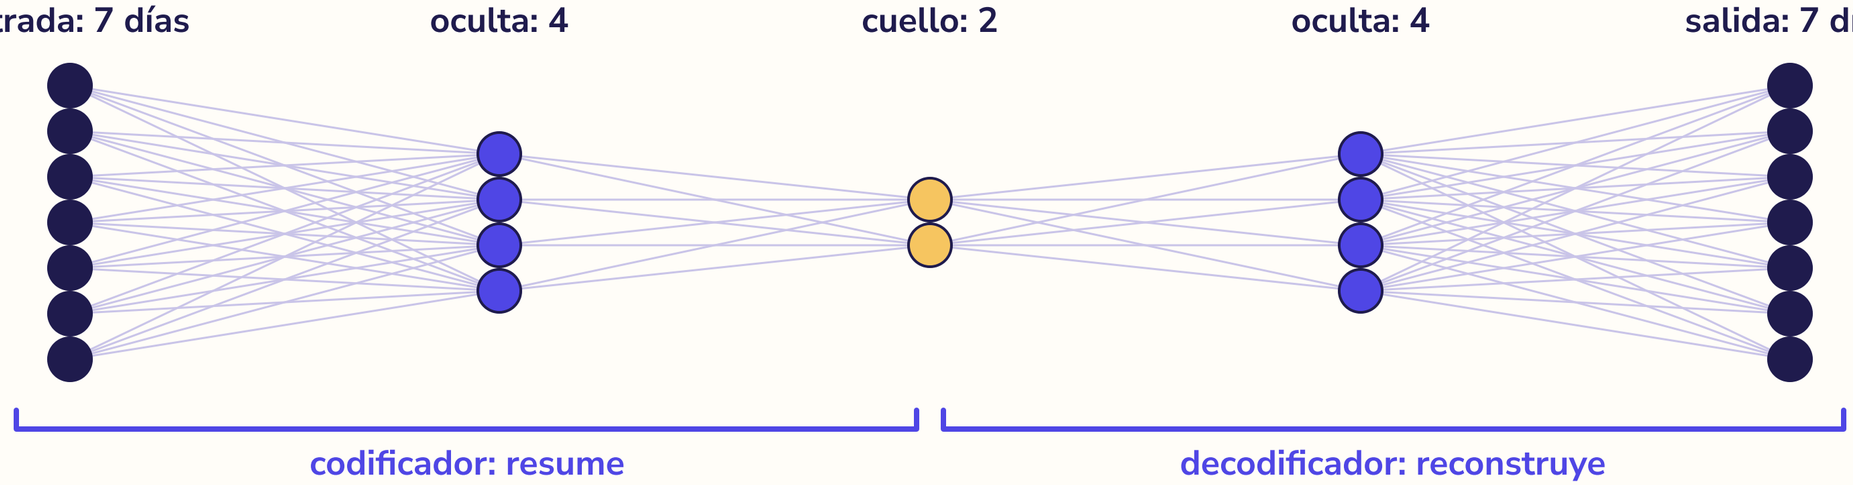
Generador que inventa

19 alucinaciones: casi todo inventado.

Los fallos de recuperación vienen del **vocabulario** («check-out», «bebés») y de frases **parecidas.**

6 · AUTOENCODER

Una red que aprende a copiarse con un cuello



La idea

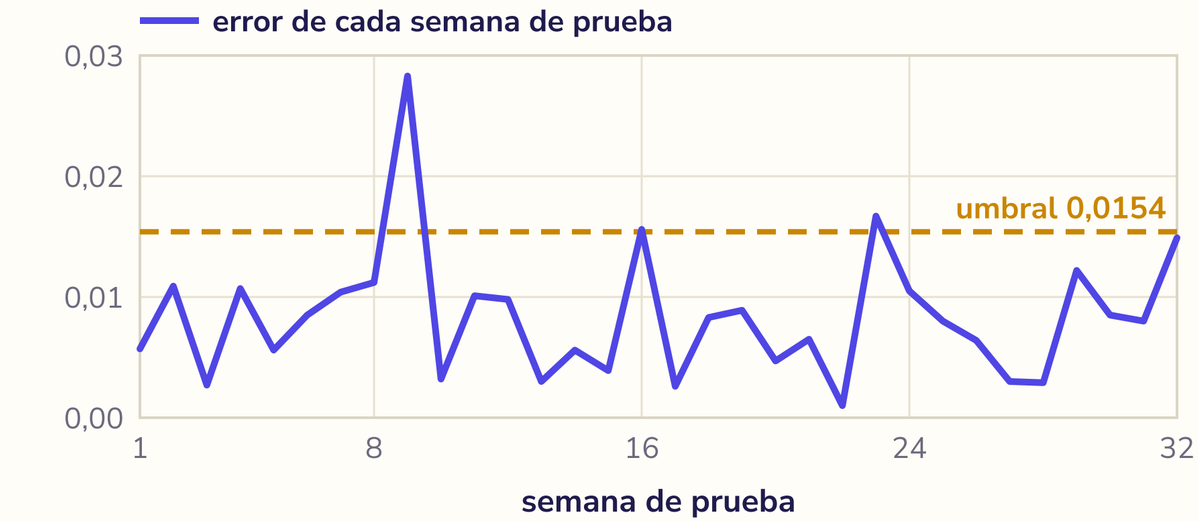
Entra una **semana de 7 días** y debe **reconstruirla** pasando por **solo 2 números**.

Pequeña y probada

89 parámetros, **156 semanas** (124 + 32). Error: **0,0076** (entrenar) y **0,0095** (validar).

6 · DETECTAR LO RARO

Lo que no se reconstruye bien, es raro



Umbral

Percentil 95 de los errores de entrenamiento: **0,0154**.

Semanas a revisar

13/07/2025 (0,0284), **19/10/2025** (0,0168) y **31/08/2025** (0,0157).

Con semanas **inyectadas** el error se dispara: apagón de reservas **1,44**, día roto **0,27**, pico irreal **0,24**.

6 · MODELOS QUE GENERAN

Tres formas de crear datos nuevos

Modelo	Cómo aprende	Riesgo típico
Autoencoder	Comprime y **reconstruye**; con un espacio de 2 números se puede **generar** moviéndose por él	Salidas **borrosas** o poco variadas
GAN	Un **falsificador** engaña a un **policía** que distingue lo real de lo falso	**Mode collapse**: el falsificador repite lo mismo
Difusión	Aprende a **quitar un poco de ruido** y genera quitándolo paso a paso, guiado por un texto	Es **lenta** y puede copiar estilos o rostros

Las tres crean parecido a lo que vieron: no entienden ni verifican lo que hacen.

6 · GENERAR CON CABEZA

IA generativa responsable

Riesgo	Qué hago
Veracidad: puede inventar con aplomo	**Contrastar** con fuentes y con un RAG; marcar lo generado
Derechos: imitar obras o estilos ajenos	Revisar **licencias** y no pasar lo generado por propio
Sesgos: repite los de sus datos	**Probar** con casos distintos y registrar los fallos
Datos personales: lo que escribes viaja	**No pegar** datos sensibles; preferir modelos en local
Supervisión: nadie revisa	Una **persona** decide en lo importante

Un modelo generativo ayuda a escribir; responder de lo escrito sigue siendo de la persona.

QUÉ TÉCNICA USO

Según el problema que tengas

Tengo…	Empiezo por…	Ojo con…
Una **serie** con calendario	**Baseline** y luego **SARIMAX**	Partir **por fecha**; no usar el futuro
Una serie con **mucho historial**	**LSTM o GRU** con ventanas	Escalar solo con el **entrenamiento**; compararla con SARIMAX
Reseñas que clasificar	**TF-IDF + regresión logística**	Un resultado **demasiado bueno**; el orden y el «no»
Textos que **comparar o buscar**	**Embeddings** y coseno	Qué información se **pierde** al reducir
Que un asistente **responda con datos propios**	**RAG** con umbral	**Alucinación** y prompt **injection**
Anomalías o datos nuevos	**Autoencoder**; GAN o difusión para generar	Umbral fijado con el **entrenamiento**; uso responsable

Primero una línea base sencilla; el modelo complejo debe ganarle midiendo.

MAPA FINAL

Idea, cómo sabes si funciona y la trampa típica

Idea	Cómo sabes si funciona	La trampa típica
Series	**MAE** frente al baseline, en prueba posterior	Barajar los días; usar datos del **futuro**
Redes recurrentes	MAE frente al baseline **y a SARIMAX**	Creer que la red **siempre** gana; escalar con la prueba
NLP clásico	Exactitud y **F1** frente a «siempre la clase más común»	Datos **sintéticos**; ignorar la **negación**
Embeddings	Exactitud según los **ejes** y buscar casos reales	Reducir **demasiado** y perder el sentimiento
Transformers	Se **calcula a mano** con números pequeños	Olvidar la **máscara causal** o la **temperatura**
RAG	Recuperación, aciertos, **sin fuente** y alucinaciones	Sin **umbral** ni defensa ante inyecciones
Autoencoder	Error de reconstrucción **frente al umbral**	Fijar el umbral con la **prueba**

Medir **contra algo** y **mirar los datos** vale más que un modelo grande.

PARA LLEVARSE

Lo que tienes que poder decir

Series

Baseline primero, partir **por fecha** y comparar con SARIMAX.

Texto

TF-IDF para leer, **embeddings** para comparar, **transformers** para escribir.

RAG

Buscar, aumentar, generar y citar; con **umbral** para no inventar.

Generar y vigilar

Autoencoder: lo mal reconstruido es raro. Generar con **responsabilidad**.

Los detalles, en las presentaciones S12_01 a S12_07 y en los cuadernos.