IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

De texto a números: qué opinan los clientes

NLP clásico con reseñas de TurisData: limpiar, TF-IDF, sentimiento y temas

Sprint 12 · S12_03 · cuaderno: 55 min en clase (ejercicios 1 a 4)

LA IDEA · DEL TEXTO AL NÚMERO

Un modelo no lee: calcula con números

1 · Reseña

```
¡El BAÑO estaba SUCIO!!!
```

El texto, tal cual lo escribe el cliente.

→

2 · Limpiar

```
el baño estaba sucio
```

Minúsculas y sin signos: una sola forma por palabra.

→

3 · Trocear

```
['baño', 'sucio']
```

Tokens (palabras), sin las palabras vacías.

→

4 · Contar

```
baño 1 · sucio 1
```

Un número por cada palabra del vocabulario.

→

5 · Clasificar

```
negativo
```

Un modelo, entrenado con reseñas, elige la etiqueta.

1 500

reseñas de TurisData: **704** positivas, **318** neutras y **478** negativas.

Dos preguntas del cliente

¿Qué opina la gente? → **sentimiento**.

¿De qué habla? → **temas** (limpieza, ruido, desayuno…).

Ojo: son reseñas sintéticas

Inventadas para el curso: más repetitivas y fáciles que las reales.

SECCIÓN 2 · EJERCICIO 1 · CUADERNO (CLASE)

Limpiar: que «Bueno» y «BUENO» sean la misma palabra

Reseña tal cual	Después de **limpiar**
¡El BAÑO estaba SUCIO!!!	el baño estaba sucio
Wifi: 0 estrellas... ¿en serio?	wifi estrellas en serio
Desayuno 10/10, ¡volveremos!	desayuno volveremos

Las tres reglas del ejercicio

1. Todo a minúsculas.
2. Lo que no sea letra ni espacio, por un espacio.
3. Un solo espacio entre palabras.

Dos trampas

La **ñ** y las **tildes** son letras: «baño» y «ubicación» se quedan como están.

Un número o un símbolo (**0**, **10/10**) no es una letra: desaparece.

Cómo sabes que va bien

Cada ejercicio lleva su **assert**: si tu función no cumple, el cuaderno te dice qué revisar.

SECCIÓN 2 · EJERCICIO 2 · CUADERNO (CLASE)

Contar palabras: lo más frecuente no es lo más útil

```
tokenizar("El baño estaba sucio, no me gustó")
# ['baño', 'sucio', 'no', 'gustó']
Counter(["wifi", "cama", "wifi"]).most_common(1)
# [('wifi', 2)]
```

Mini-corpus de 4 reseñas

Wifi lento y cama dura

Cama cómoda y wifi gratis

Wifi caído otra vez

Piscina limpia y cama cómoda

Las 3 palabras más frecuentes	Resultado
Con todas las palabras	**wifi** 3 · **y** 3 · **cama** 3
Sin palabras vacías (PALABRAS_VACIAS)	**wifi** 3 · **cama** 3 · **cómoda** 2

«y» se repite tanto como «wifi»; y «wifi» sale en 3 de 4 reseñas: frecuente no es lo mismo que informativo.

Bolsa de palabras y TF-IDF

reseña	cama	cómoda	dura	el	es	la	lento	wifi
r1 · la cama es cómoda	1	1	0	0	1	1	0	0
r2 · la cama es dura	1	0	1	0	1	1	0	0
r3 · el wifi es lento	0	0	0	1	1	0	1	1

Palabras de r1	Está en…	Bolsa	TF-IDF
es	3 de 3 reseñas	1	0,37
la, cama	2 de 3	1	0,48
cómoda	1 de 3	1	**0,63**

Bolsa de palabras

Un recuento por palabra del vocabulario. Se pierde el orden.

TF-IDF

Recuento × rareza: lo que está en **todas** las reseñas pesa menos.

SECCIÓN 4 · EJERCICIO 3 · CUADERNO (CLASE)

Dos modelos con el mismo pipeline

75 %
Entrenamiento
1 125 reseñas: aquí se aprende, vocabulario incluido

25 %
Prueba
375: solo para medir

```
modelo = make_pipeline(vectorizador, clasificador)
modelo.fit(X_ent, y_ent)   # aprende solo con el entrenamiento
modelo.predict(X_test)     # a la prueba solo se le aplica
```

Sin fuga de datos

El vectorizador va **dentro** del pipeline: no «espía» la prueba.

Regresión logística + TF-IDF

Un peso por palabra y clase: suma los pesos de la reseña y elige la clase con más puntos.

Naive Bayes + bolsa de palabras

Cuenta cuánto aparece cada palabra en cada clase y elige la clase más probable.

Una referencia

Siempre «positivo» acierta **0,469**: tus modelos deben superarla.

SECCIÓN 4 · TRAS EL EJERCICIO 3 · CUADERNO (CLASE)

Casi el 99 %: demasiado bonito para ser verdad

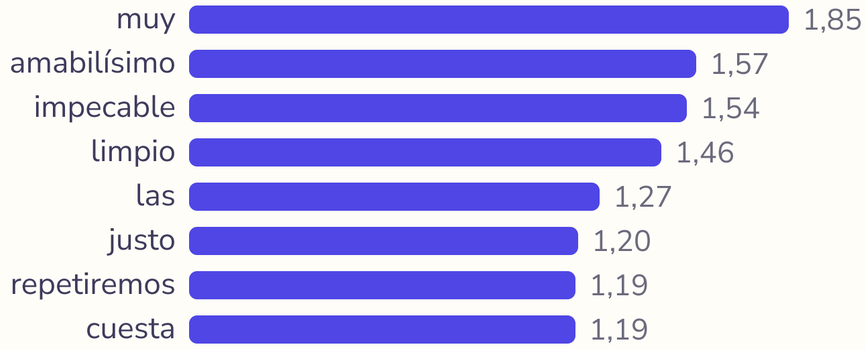
Modelo (375 reseñas de prueba)	Exactitud
Siempre «positivo»	0,469
Regresión logística + TF-IDF	≈ **0,99**
Naive Bayes + bolsa de palabras	≈ 0,99

Sospecha

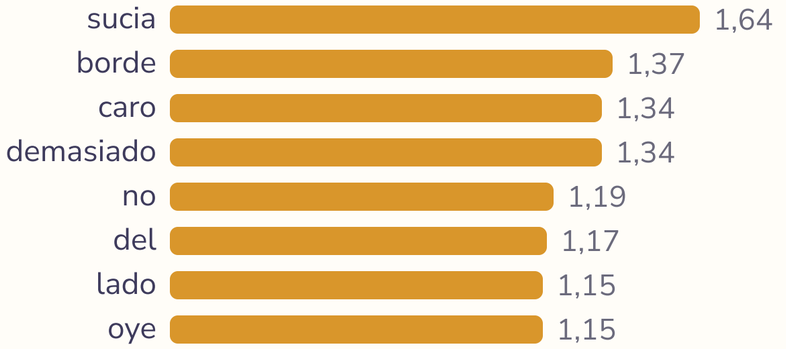
Fallan muy pocas reseñas, y las que fallan son neutras.

Con reseñas sintéticas no te fíes de este número.

Empujan a «positivo»



Empujan a «negativo»



SECCIÓN 5 · EJERCICIO 4 · CUADERNO (CLASE)

La bolsa de palabras no ve el orden

Dos frases con sentidos opuestos	Su bolsa de palabras
Está limpio, no está caro	**caro** 1 · **está** 2 · **limpio** 1 · **no** 1
No está limpio, está caro	**caro** 1 · **está** 2 · **limpio** 1 · **no** 1

Frase nueva para el modelo	¿Qué predice?
El personal fue amabilísimo	?
El personal **no** fue amabilísimo	?
El desayuno es caro	?
El desayuno **no** es caro	?

Pregunta para el grupo

Las dos bolsas son **idénticas**. ¿Qué información de la frase se ha perdido?

¿Cómo la guardarías? Y, con y sin «no», ¿qué etiqueta crees que dará el modelo?

SECCIÓN 6 · CUADERNO (CLASE)

Temas por palabras clave: transparente y barato

```
TEMAS = {"wifi": ["wifi", "internet", "conexión"]}
t = limpiar(texto)
any(c in t for c in claves)   # ¿aparece alguna clave?
```

F1 = 0,67

Mezcla dos medidas: de lo que **detecta**, cuánto es real (**2 de 3**); de lo real, cuánto encuentra (**2 de 3**).

Reseña	¿Habla de wifi?	¿Lo detecta?	Resultado
El wifi no funciona	sí	sí	acierto
Internet va muy lento	sí	sí	acierto
La conexión con el aeropuerto es buena	no	sí	**falso positivo**: clave demasiado amplia
Cobran por conectarse a la red	sí	no	**falso negativo**: falta una clave
La piscina es enorme	no	no	acierto

PARA CASA · EJERCICIO 5 Y SECCIÓN 7

Temas que fallan y expresiones que se repiten

Ejercicio 5 (casa)

¿Qué tema detecta peor el diccionario? ¿Cuántas reseñas mencionan **de verdad** «precio»?

Mira los fallos: ¿quitas una clave demasiado amplia o añades otra?

n-grama = n palabras seguidas

«no compensa el precio» tiene 3 **bigramas** (**no compensa**, **compensa el**, **el precio**) y 2 **trigramas**.

n-grama en reseñas negativas	veces
constante noche	69
ruido constante	69
ruido constante noche	69
ruidosa poco	61
ruidosa poco segura	61
poco segura	61
poco segura noche	61
zona ruidosa	61

Ocho filas, solo dos quejas repetidas en trozos de distinta longitud: el ruido por la noche y la zona poco segura.

PARA CASA · SECCIÓN 8 · MINI-RETO Y REFLEXIÓN

Un panel solo vale lo que valga su diccionario

Paso	Qué haces	Con qué
1	Te quedas con las reseñas **negativas**	`sentimiento == "negativo"`
2	Un tema por fila	`explode()` sobre `temas_detectados`
3	Cuentas y ordenas de mayor a menor	`value_counts()`
4	**Validas** con las etiquetas reales	`temas_reales`

Antes de enseñar el panel al cliente, compáralo con las etiquetas reales: un diccionario sin validar engaña.

1 · El 99 %

¿Por qué no fiarte con reseñas sintéticas?

2 · Explicar

¿Qué gana un modelo con pesos que se leen?

3 · Ironía

«¡Qué gran idea poner música a las 3 de la mañana!»

4 · Privacidad

¿Qué haces con nombres y datos personales antes de guardar?

HOY HAS APRENDIDO

De texto a números, y sus límites

Texto a números

Limpiar, trocear y contar: bolsa de palabras y TF-IDF. El vectorizador se ajusta **solo con el entrenamiento**

Clasificar y explicar

Regresión logística y Naive Bayes dan casi el 99 %, y se **leen** con sus pesos. Con reseñas sintéticas, no te fíes

Límites

La bolsa no ve el orden (negaciones) y un diccionario de palabras clave **hay que validar**

Siguiente: el martes 24/11, Transformers y atención (S12_05)