IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

# De texto a números: qué opinan los clientes

NLP clásico con reseñas de TurisData: limpiar, TF-IDF, sentimiento y temas

Sprint 12 · S12_03 · cuaderno: 55 min en clase (ejercicios 1 a 4)

LA IDEA · DEL TEXTO AL NÚMERO

# Un modelo no lee: calcula con números

### 1 · Reseña

```
¡El BAÑO estaba SUCIO!!!
```

El texto, tal cual lo escribe el cliente.

→

### 2 · Limpiar

```
el baño estaba sucio
```

Minúsculas y sin signos: una sola forma por palabra.

→

### 3 · Trocear

```
['baño', 'sucio']
```

**Tokens** (palabras), sin las palabras vacías.

→

### 4 · Contar

```
baño 1 · sucio 1
```

Un número por cada palabra del vocabulario.

→

### 5 · Clasificar

```
negativo
```

Un modelo, entrenado con reseñas, elige la etiqueta.

**1 500**

reseñas de TurisData: **704** positivas, **318** neutras y **478** negativas.

### Dos preguntas del cliente

¿Qué opina la gente? → **sentimiento**.

¿De qué habla? → **temas** (limpieza, ruido, desayuno…).

### Ojo: son reseñas sintéticas

Inventadas para el curso: más repetitivas y fáciles que las reales.

SECCIÓN 2 · EJERCICIO 1 · CUADERNO (CLASE)

# Limpiar: que «Bueno» y «BUENO» sean la misma palabra

| Reseña tal cual | Después de **limpiar** |
|---|---|
| ¡El BAÑO estaba SUCIO!!! | el baño estaba sucio |
| Wifi: 0 estrellas... ¿en serio? | wifi estrellas en serio |
| Desayuno 10/10, ¡volveremos! | desayuno volveremos |

### Las tres reglas del ejercicio

1. Todo a minúsculas.
2. Lo que no sea letra ni espacio, por un espacio.
3. Un solo espacio entre palabras.

### Dos trampas

La **ñ** y las **tildes** son letras: «baño» y «ubicación» se quedan como están.

Un número o un símbolo (**0**, **10/10**) no es una letra: desaparece.

### Cómo sabes que va bien

Cada ejercicio lleva su **assert**: si tu función no cumple, el cuaderno te dice qué revisar.

SECCIÓN 2 · EJERCICIO 2 · CUADERNO (CLASE)

# Contar palabras: lo más frecuente no es lo más útil

```
tokenizar("El baño estaba sucio, no me gustó")
# ['baño', 'sucio', 'no', 'gustó']
Counter(["wifi", "cama", "wifi"]).most_common(1)
# [('wifi', 2)]
```

**Mini-corpus de 4 reseñas**

Wifi lento y cama dura

Cama cómoda y wifi gratis

Wifi caído otra vez

Piscina limpia y cama cómoda

| Las 3 palabras más frecuentes | Resultado |
|---|---|
| Con todas las palabras | **wifi** 3 · **y** 3 · **cama** 3 |
| Sin palabras vacías (PALABRAS_VACIAS) | **wifi** 3 · **cama** 3 · **cómoda** 2 |

**«y» se repite tanto como «wifi»; y «wifi» sale en 3 de 4 reseñas: frecuente no es lo mismo que informativo.**

# Bolsa de palabras y TF-IDF

| reseña | cama | cómoda | dura | el | es | la | lento | wifi |
|---|---|---|---|---|---|---|---|---|
| r1 · la cama es cómoda | 1 | 1 | 0 | 0 | 1 | 1 | 0 | 0 |
| r2 · la cama es dura | 1 | 0 | 1 | 0 | 1 | 1 | 0 | 0 |
| r3 · el wifi es lento | 0 | 0 | 0 | 1 | 1 | 0 | 1 | 1 |

| Palabras de r1 | Está en… | Bolsa | TF-IDF |
|---|---|---|---|
| es | 3 de 3 reseñas | 1 | 0,37 |
| la, cama | 2 de 3 | 1 | 0,48 |
| cómoda | 1 de 3 | 1 | **0,63** |

### Bolsa de palabras

Un recuento por palabra del vocabulario. Se pierde el orden.

### TF-IDF

Recuento × rareza: lo que está en **todas** las reseñas pesa menos.

SECCIÓN 4 · EJERCICIO 3 · CUADERNO (CLASE)

# Dos modelos con el mismo pipeline

**75 %**
**Entrenamiento**
1 125 reseñas: aquí se aprende, vocabulario incluido

**25 %**
**Prueba**
375: solo para medir

```
modelo = make_pipeline(vectorizador, clasificador)
modelo.fit(X_ent, y_ent)   # aprende solo con el entrenamiento
modelo.predict(X_test)     # a la prueba solo se le aplica
```

### Sin fuga de datos

El vectorizador va **dentro** del pipeline: no «espía» la prueba.

### Regresión logística + TF-IDF

Un peso por palabra y clase: suma los pesos de la reseña y elige la clase con más puntos.

### Naive Bayes + bolsa de palabras

Cuenta cuánto aparece cada palabra en cada clase y elige la clase más probable.

### Una referencia

Siempre «positivo» acierta **0,469**: tus modelos deben superarla.

SECCIÓN 4 · TRAS EL EJERCICIO 3 · CUADERNO (CLASE)

# Casi el 99 %: demasiado bonito para ser verdad

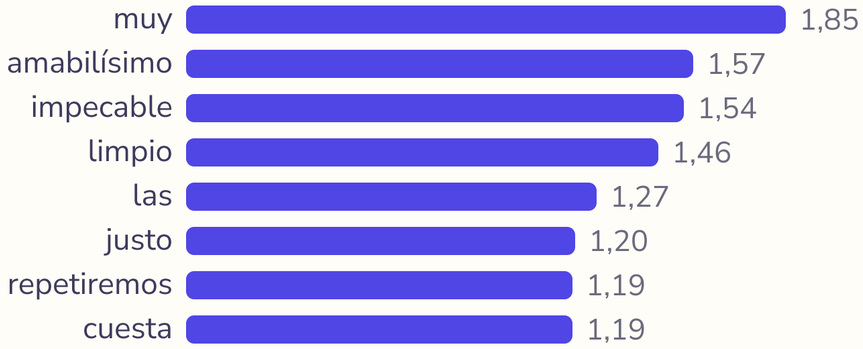
| Modelo (375 reseñas de prueba) | Exactitud |
|---|---|
| Siempre «positivo» | 0,469 |
| Regresión logística + TF-IDF | **0,992** |
| Naive Bayes + bolsa de palabras | 0,989 |

**Sospecha**

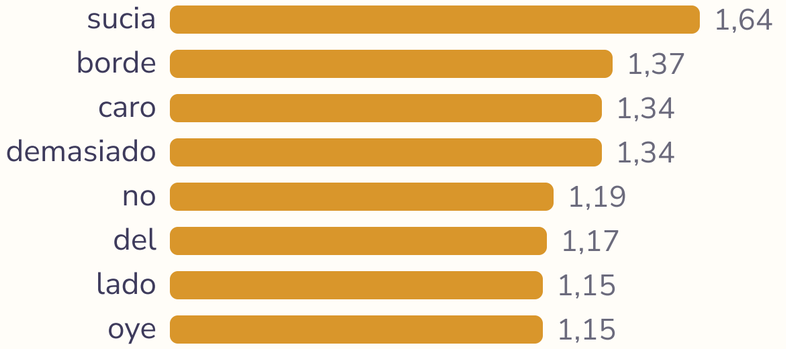
Solo **3 de 375** reseñas fallan: 3 neutras que se toman por negativas.

Con reseñas sintéticas no te fíes de este número.

**Empujan a «positivo»**




**Empujan a «negativo»**



SECCIÓN 5 · EJERCICIO 4 · CUADERNO (CLASE)

# La bolsa de palabras no ve el orden

| Dos frases con sentidos opuestos | Su bolsa de palabras |
|---|---|
| Está limpio, no está caro | **caro** 1 · **está** 2 · **limpio** 1 · **no** 1 |
| No está limpio, está caro | **caro** 1 · **está** 2 · **limpio** 1 · **no** 1 |

| Frase nueva para el modelo | Predicción |
|---|---|
| El personal fue amabilísimo | positivo |
| El personal **no** fue amabilísimo | positivo |
| El desayuno es caro | negativo |
| El desayuno **no** es caro | negativo |

### Pregunta para el grupo

Las dos bolsas son **idénticas**. ¿Qué información de la frase se ha perdido?

¿Cómo la guardarías?

SECCIÓN 6 · CUADERNO (CLASE)

# Temas por palabras clave: transparente y barato

```
TEMAS = {"wifi": ["wifi", "internet", "conexión"]}
t = limpiar(texto)
any(c in t for c in claves)   # ¿aparece alguna clave?
```

**F1 = 0,67**

Mezcla dos medidas: de lo que **detecta**, cuánto es real (**2 de 3**); de lo real, cuánto encuentra (**2 de 3**).

| Reseña | ¿Habla de wifi? | ¿Lo detecta? | Resultado |
|---|---|---|---|
| El wifi no funciona | sí | sí | acierto |
| Internet va muy lento | sí | sí | acierto |
| La conexión con el aeropuerto es buena | no | sí | **falso positivo**: clave demasiado amplia |
| Cobran por conectarse a la red | sí | no | **falso negativo**: falta una clave |
| La piscina es enorme | no | no | acierto |

PARA CASA · EJERCICIO 5 Y SECCIÓN 7

# Temas que fallan y expresiones que se repiten

### Ejercicio 5 (casa)

¿Qué tema detecta peor el diccionario? ¿Cuántas reseñas mencionan **de verdad** «precio»?

Mira los fallos: ¿quitas una clave demasiado amplia o añades otra?

### n-grama = n palabras seguidas

«no compensa el precio» tiene 3 **bigramas** (**no compensa**, **compensa el**, **el precio**) y 2 **trigramas**.

| n-grama en reseñas negativas | veces |
|---|---|
| constante noche | 69 |
| ruido constante | 69 |
| ruido constante noche | 69 |
| ruidosa poco | 61 |
| ruidosa poco segura | 61 |
| poco segura | 61 |
| poco segura noche | 61 |
| zona ruidosa | 61 |

**Ocho filas, solo dos quejas repetidas en trozos de distinta longitud: el ruido por la noche y la zona poco segura.**

PARA CASA · SECCIÓN 8 · MINI-RETO Y REFLEXIÓN

# Un panel solo vale lo que valga su diccionario

| Paso | Qué haces | Con qué |
|---|---|---|
| 1 | Te quedas con las reseñas **negativas** | `sentimiento == "negativo"` |
| 2 | Un tema por fila | `explode()` sobre `temas_detectados` |
| 3 | Cuentas y ordenas de mayor a menor | `value_counts()` |
| 4 | **Validas** con las etiquetas reales | `temas_reales` |

**Antes de enseñar el panel al cliente, compáralo con las etiquetas reales: un diccionario sin validar engaña.**

### 1 · El 99 %

¿Por qué no fiarte con reseñas sintéticas?

### 2 · Explicar

¿Qué gana un modelo con pesos que se leen?

### 3 · Ironía

«¡Qué gran idea poner música a las 3 de la mañana!»

### 4 · Privacidad

¿Qué haces con nombres y datos personales antes de guardar?

HOY HAS APRENDIDO

# De texto a números, y sus límites

### Texto a números

Limpiar, trocear y contar: bolsa de palabras y TF-IDF. El vectorizador se ajusta **solo con el entrenamiento**

### Clasificar y explicar

Regresión logística y Naive Bayes dan casi el 99 %, y se **leen** con sus pesos. Con reseñas sintéticas, no te fíes

### Límites

La bolsa no ve el orden (negaciones) y un diccionario de palabras clave **hay que validar**

**Siguiente: el martes 24/11, Transformers y atención (S12_05)**