IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Embeddings: el significado en vectores

LSA, similitud del coseno, reseñas parecidas y un buscador, sin internet

Sprint 12 · S12_04 · cuaderno de ampliación: 50 min en casa (no se hace en clase)

Un vector corto donde «cerca» es «parecido»

TF-IDF: largo y casi vacío

105 columnas por reseña y un **94 %** de ceros.

Embedding: corto y denso

12 números por reseña, sin ceros: cada dimensión es un «eje de conversación».

Mini-corpus propio de 8 reseñas

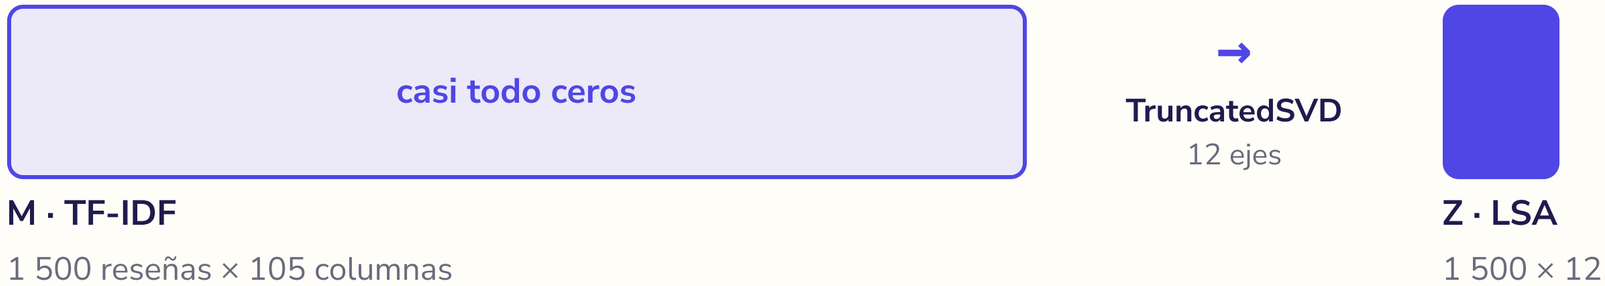
ruido de bar por la noche
ruidosa y sin dormir de noche
no pude dormir por el ruido
ruido del bar sin dormir
desayuno buffet variado
café y desayuno buffet
buffet variado con café
desayuno con café variado

Dos frases sin ninguna palabra en común	TF-IDF	LSA (2 ejes)
«habitación ruidosa de bar» y «no pude dormir»	0,00	**1,00**
«habitación ruidosa de bar» y «café variado»	0,00	0,00

LSA junta las frases del ruido porque **aparecen en reseñas que hablan de lo mismo**, aunque no compartan palabras.

SECCIÓN 1 · EJERCICIO 1 · CUADERNO (CASA)

Reducir a 12 ejes: se gana tamaño y se pierde algo



44 %
se conserva
de la varianza con 12 ejes

56 %
se pierde
al comprimir de 105 a 12

Qué pide el ejercicio

TruncatedSVD con 12 componentes y **random_state=SEMILLA**.

Z (1 500 × 12) y **var_explicada**: lo que conservan los 12 ejes.

Varianza explicada

Qué parte de lo que **distingue** unas reseñas de otras conservan los ejes. Con 12 ejes, el **44 %**.

SECCIÓN 2 · CUADERNO (CASA)

¿Qué «significa» cada eje? Palabras que van juntas

Eje	Las 6 palabras con más peso
1	desayuno, limpio, precio, tranquilo, duerme, maravilla
2	habitación, limpieza, noche, sencilla, correcta, impecable
3	total, noches, silencio, cinco, ubicación, perfecta
4	ubicación, playa, perfecta, cinco, minutos, precio
5	habitación, correcta, sencilla, impecable, limpieza, tranquilo

Nadie le ha dicho nada

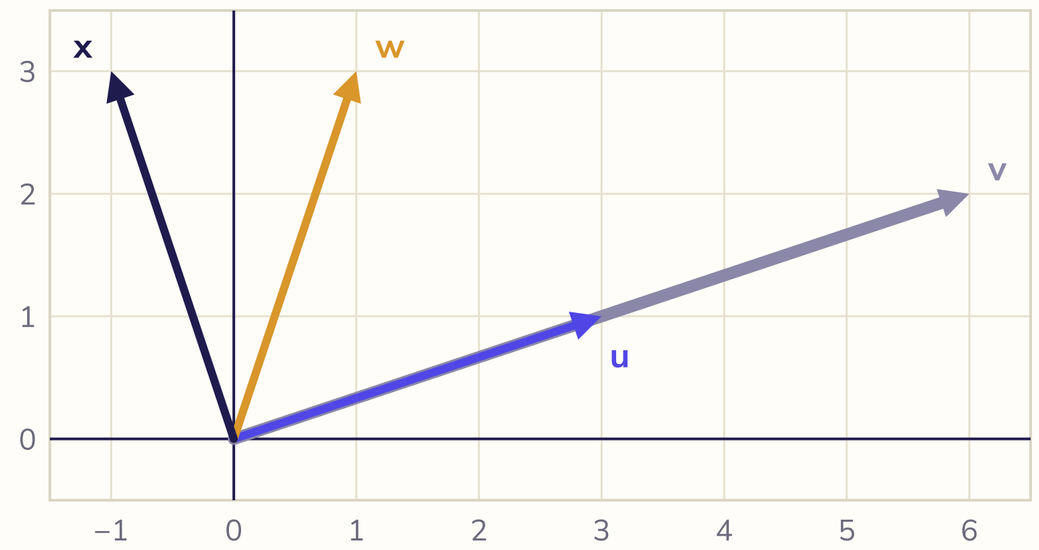
LSA descubre solo qué palabras **aparecen juntas** en las reseñas.

Un eje no es una etiqueta

Es una mezcla de palabras: el nombre se lo pones tú. En el eje 4 se lee «ubicación a cinco minutos de la playa».

SECCIÓN 3 · CUADERNO (CASA)

Similitud del coseno: cuenta el ángulo, no la longitud



Pareja	Coseno	Ángulo
u y v	1,00	0°
u y w	0,60	53°
u y x	0,00	90°

1 = misma dirección

v es el doble de largo que u pero apunta igual: **mismo parecido**. 0 = sin relación.

Una reseña de 5 palabras y otra de 50, con las mismas proporciones de temas: coseno 1. Por eso sirve para textos de cualquier longitud.

SECCIÓN 3 · EJERCICIO 2 · CUADERNO (CASA)

Las 3 reseñas más parecidas a una dada

Reseña 5

Pasamos una semana aquí. Está muy bien situado, cerca de todo. Se duerme de maravilla, muy tranquilo. Las sábanas y toallas olían a limpio.

Reseñas más parecidas (coseno en Z)	Coseno
Pasamos una semana aquí. Está muy bien situado, cerca de todo. Todo estaba muy limpio. Se duerme de maravilla, muy tranquilo!	0,90
En general, Todo estaba muy limpio. Está muy bien situado, cerca de todo. Se duerme de maravilla, muy tranquilo.	0,90
Fuimos por trabajo. Está muy bien situado, cerca de todo. Las sábanas y toallas olían a limpio.	0,87

Tres pasos

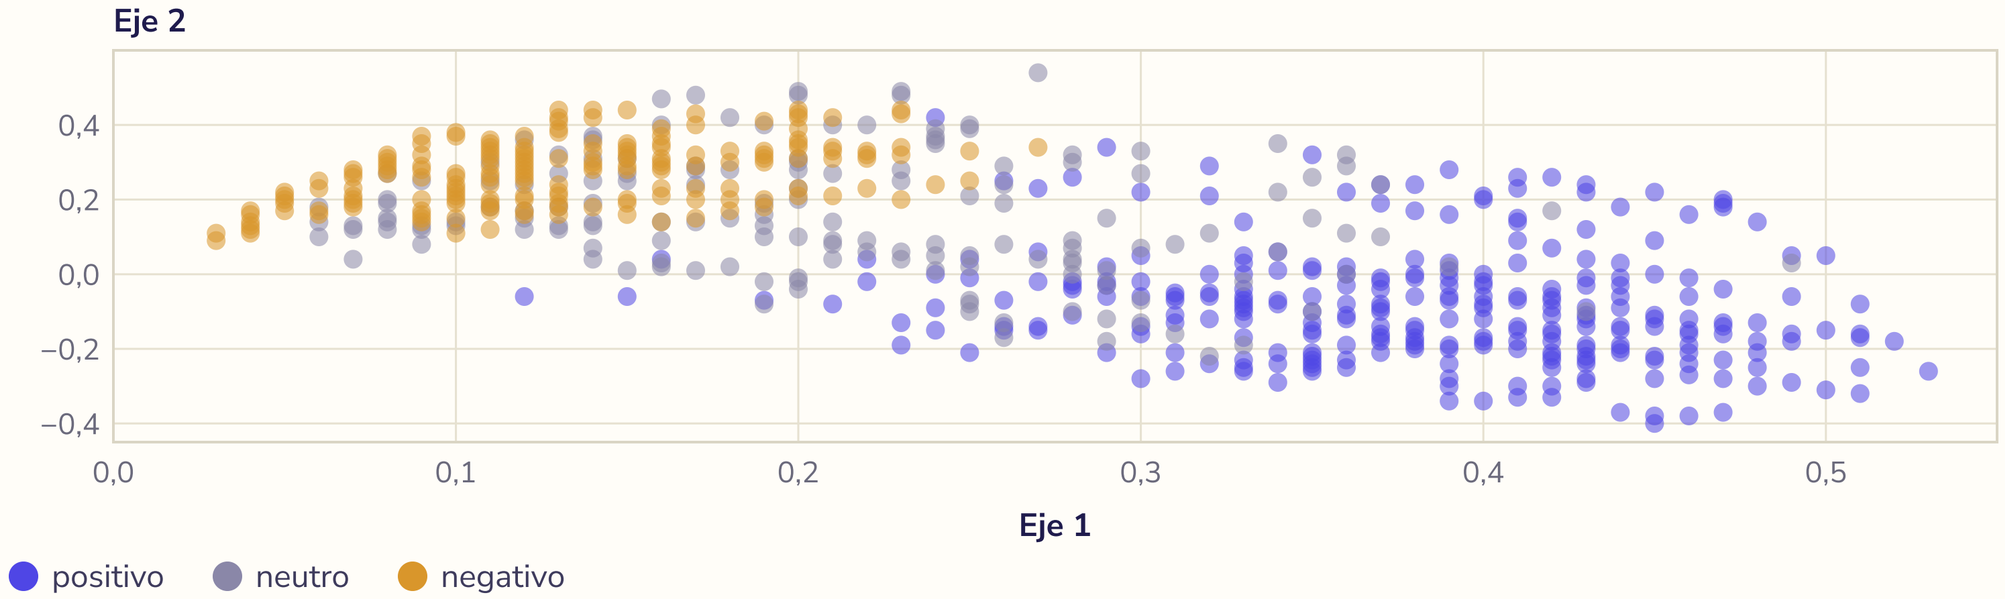
Coseno de **Z[i]** con todas las reseñas · dejar fuera la propia **i** · ordenar de más a menos parecida.

Una trampa

La reseña más parecida a **i** es **ella misma** (coseno 1): hay que excluirla.

SECCIÓN 4 · CUADERNO (CASA)

Un mapa de 1 500 reseñas con solo 2 ejes



LSA no ha visto el sentimiento, y aun así los negativos quedan arriba a la izquierda y los positivos abajo a la derecha.

SECCIÓN 5 · EJERCICIO 3 · CUADERNO (CASA)

12 números frente a 105 columnas

Entrada del clasificador (regresión logística)	Columnas	Exactitud en prueba
TF-IDF completo	105	**0,995**
LSA con 12 ejes	12	0,891

Comprimir tiene precio

Con 12 ejes se conserva el 44 % de la varianza y el clasificador acierta menos. Es lo normal.

LSA también se ajusta con datos

Si los ejes se calculan con **todas** las reseñas, la prueba se filtra. Se ajusta **solo con X_ent**.

Un clasificador con 12 números por reseña acierta el 89 %: el embedding conserva mucho de lo importante.

SECCIÓN 6 · MINI-RETO · CUADERNO (CASA)

Un buscador de reseñas por significado

1 · Consulta

```
colas enormes para desayunar
```

Texto libre, como lo escribiría el cliente.

→

2 · Mismo espacio

```
tfidf → lsa
```

Con **el mismo** tfidf y lsa que las reseñas.

→

3 · Coseno

```
contra todas las filas de Z
```

Una similitud por cada reseña.

→

4 · Los k mejores

```
k = 3
```

Los textos con mayor coseno.

Resultado de la consulta de ejemplo

Las 3 primeras reseñas, con coseno **0,985**, contienen «Colas enormes en el desayuno».

Se encuentra por el **significado de los ejes**, no solo por la palabra exacta.

El límite de LSA

«bullicio» no está en el corpus: su vector es todo ceros y el coseno con **todas** las reseñas es **0**. LSA solo conoce **tu** corpus.

SECCIÓN 7 · OPCIONAL · CUADERNO (CASA, CON INTERNET)

Neuronales: más significado, más dependencia

	LSA (este cuaderno)	Modelo neuronal preentrenado
Qué conoce	Solo **tu** corpus	Español general, entrenado con millones de frases
Qué necesita	scikit-learn, sin internet	Descargar un modelo e instalar una librería
Se explica	Sí: palabras de cada eje	Mucho menos
Riesgo	No entiende lo que no ha visto	Depende de un tercero; privacidad si usas un servicio externo

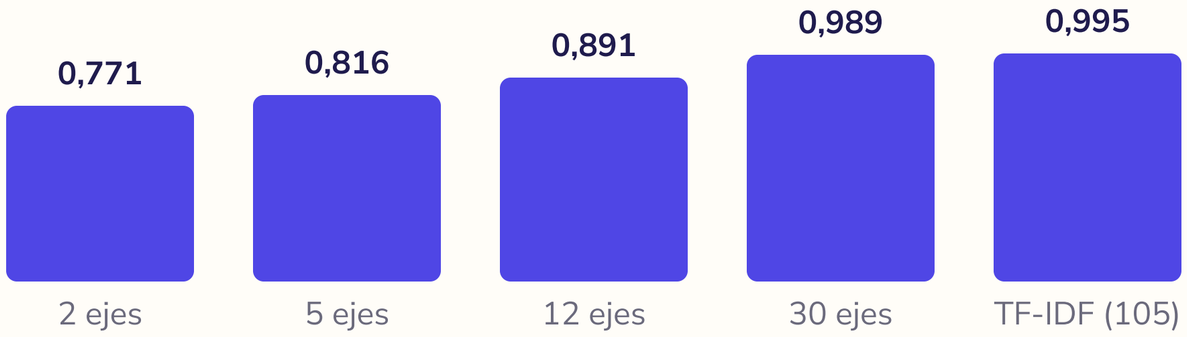
No verificado en el taller: ejecútalo en Colab o en casa con conexión. Sin internet, sáltalo: el resto del cuaderno funciona sin él.

En el cuaderno

USAR_SENTENCE_TRANSFORMERS = False por defecto: cámbialo a **True** solo con internet. Usa **sentence-transformers** y el modelo **paraphrase-multilingual-MiniLM-L12-v2**.

PARA CASA · AMPLIACIÓN Y REFLEXIÓN

¿Cuántos ejes hacen falta?



Repite el ejercicio 3

Cambia **n_components** y mira la exactitud en prueba. **No está en el cuaderno**: es una ampliación.

Con 30 ejes casi igualas al TF-IDF.

1 · Densos y dispersos

¿Qué ganas y qué pierdes al comprimir?

2 · Ajustar con todo

¿Qué error cometes si ajustas LSA antes de partir?

3 · Preentrenado

¿Qué ventaja y qué riesgo frente a LSA?

4 · Privacidad

¿Qué problemas hay al enviar reseñas a un servicio externo?

LO QUE TE LLEVAS

El significado, en un vector

Embedding

Un texto como un vector **corto y denso**: «cerca» (coseno alto) quiere decir «parecido»

LSA

TF-IDF + **TruncatedSVD**: embeddings **sin internet**, rápidos y explicables. Se ajusta solo con el entrenamiento

Usos y límites

Reseñas parecidas, mapa, clasificador y buscador. Comprimir pierde señal y LSA solo conoce **tu** corpus

Siguiente en clase: Transformers y atención (S12_05, martes 24/11)