IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Embeddings: el significado en vectores

Teoría, práctica (en casa) y, al final, material de consulta

Sprint 12 · S12_04 · cuaderno de ampliación: 50 min en casa (no se hace en clase)

LA IDEA · UN VECTOR CORTO Y DENSO

Un vector corto donde «cerca» es «parecido»

TF-IDF: largo y casi vacío

Una columna por palabra del vocabulario: **miles** de columnas y casi todo **ceros**.

Embedding: corto y denso

Pocas decenas de números por reseña, sin ceros: cada dimensión es un «eje de conversación».

Mini-corpus propio de 8 reseñas

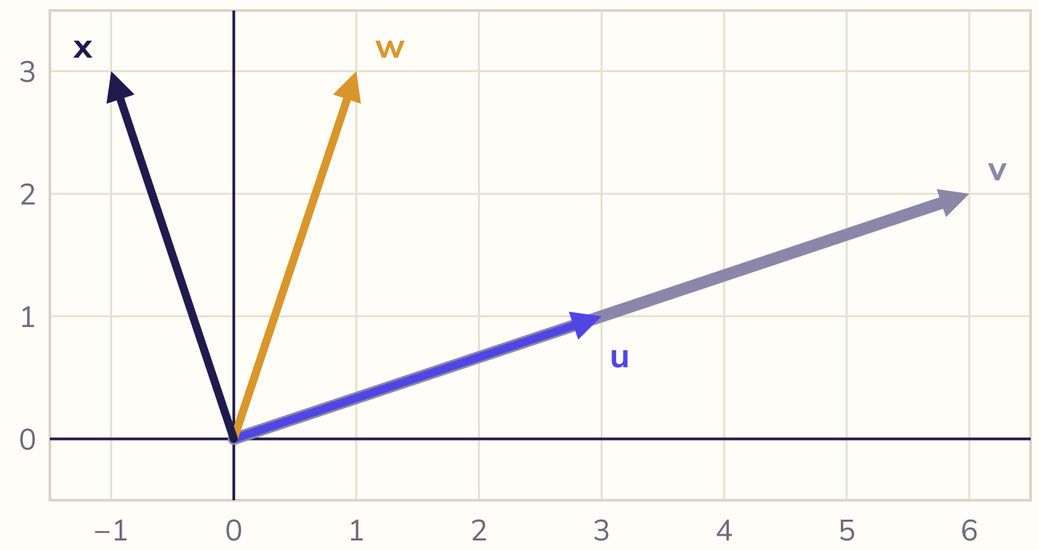
ruido de bar por la noche
ruidosa y sin dormir de noche
no pude dormir por el ruido
ruido del bar sin dormir
desayuno buffet variado
café y desayuno buffet
buffet variado con café
desayuno con café variado

Dos frases sin ninguna palabra en común	TF-IDF	LSA (2 ejes)
«habitación ruidosa de bar» y «no pude dormir»	0,00	**1,00**
«habitación ruidosa de bar» y «café variado»	0,00	0,00

LSA junta las frases del ruido porque aparecen en reseñas que hablan de lo mismo, aunque no compartan palabras.

LA IDEA · MEDIR EL PARECIDO

Similitud del coseno: cuenta el ángulo, no la longitud



Pareja	Coseno	Ángulo
u y v	1,00	0°
u y w	0,60	53°
u y x	0,00	90°

1 = misma dirección

v es el doble de largo que u pero apunta igual: **mismo parecido**. 0 = sin relación.

Una reseña de 5 palabras y otra de 50, con las mismas proporciones de temas: coseno 1. Por eso sirve para textos de cualquier longitud.

LA IDEA · BUSCAR POR SIGNIFICADO

Un buscador de reseñas por significado

1 · Consulta

```
colas enormes para desayunar
```

Texto libre, como lo escribiría el cliente.

→

2 · Mismo espacio

```
tfidf → lsa
```

Con **el mismo** tfidf y lsa que las reseñas.

→

3 · Coseno

```
contra todas las filas de Z
```

Una similitud por cada reseña.

→

4 · Los k mejores

```
k = 3
```

Los textos con mayor coseno.

Mismo espacio

La consulta se pasa por el **mismo** vectorizador y los **mismos** ejes que las reseñas, o no se pueden comparar.

Se encuentra por el **significado de los ejes**, no solo por la palabra exacta.

El límite de LSA

«bullicio» no está en el corpus: su vector es todo ceros y el coseno con **todas** las reseñas es **0**. LSA solo conoce **tu** corpus.

LA IDEA · MÁS ALLÁ DE LSA

Neuronales: más significado, más dependencia

	LSA (este cuaderno)	Modelo neuronal preentrenado
Qué conoce	Solo **tu** corpus	Español general, entrenado con millones de frases
Qué necesita	scikit-learn, sin internet	Descargar un modelo e instalar una librería
Se explica	Sí: palabras de cada eje	Mucho menos
Riesgo	No entiende lo que no ha visto	Depende de un tercero; privacidad si usas un servicio externo

Un modelo preentrenado entiende más, pero depende de un tercero: ojo con la privacidad de las reseñas.

Qué elegir

Con un corpus pequeño y sin internet, **LSA basta**. Si hay que entender expresiones que no están en tu corpus, un modelo preentrenado.

PRÁCTICA · CUADERNO S12_04 (AMPLIACIÓN)

Lo que haremos en el cuaderno

Parte	Qué haremos	Dónde
Preparación	Cargar las reseñas y la limpieza	Casa
Ejemplo	TF-IDF: un vector largo y casi vacío	Casa
Ejercicio 1	Reducir a 12 dimensiones con LSA	Casa
Ejemplo	Palabras de cada eje y coseno	Casa
Ejercicio 2	Las reseñas más parecidas a una dada	Casa
Ejemplo	Mapa de reseñas en 2 dimensiones	Casa
Ejercicio 3	LSA de 12 columnas frente a TF-IDF	Casa
Mini-reto	Buscador semántico de reseñas	Casa
Opcional	Embeddings neuronales (con internet)	Casa

Cada ejercicio: **lee** → **escribe** → **ejecuta** → **comprueba el** ✔. La solución está plegada: ábrela tras intentarlo.

CONSULTA

Material de consulta: código y aclaraciones

Cuándo abrirlo

Después de intentar el ejercicio, o cuando algo no te salga. En clase no se proyecta.

Cómo está ordenado

En el **mismo orden que el cuaderno**, cada ejercicio con su código y sus aclaraciones.

Ejercicio	Tema	Diapositivas
1	Reducir a 12 ejes con LSA	8, 9 y 10
Ejemplo	Palabras de cada eje	11
2	Reseñas más parecidas	12 y 13
Ejemplo	Mapa de reseñas	14
3	LSA frente a TF-IDF	15 y 16
Ejemplo	¿Cuántos ejes hacen falta?	17
Mini-reto	Buscador semántico	18 y 19

CONSULTA · EJERCICIO 1

Reducir a 12 dimensiones con LSA

```
lsa = TruncatedSVD(n_components=12, random_state=SEMILLA)
Z = lsa.fit_transform(M)
var_explicada = float(lsa.explained_variance_ratio_.sum())
```

(1 500, 12)
Forma de **Z**

0,438
Varianza explicada

Antes: **105** columnas con un **94,1 %** de ceros. Ahora: **12** números por reseña, sin ceros.

CONSULTA · ACLARACIONES · EJERCICIO 1

Leer la reducción (ejercicio 1)

TruncatedSVD(n_components=12)

Reduce a **12 ejes**; **random_state** fija la semilla para que el resultado se repita.

fit_transform(M)

Aprende los ejes y convierte las reseñas: **Z**, no el modelo, es lo que se guarda.

Resultado

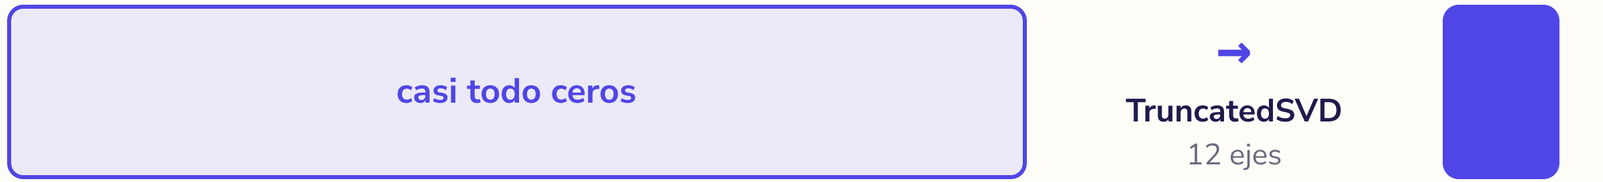
Z de **1 500 × 12** y **var_explicada** = **0,438** (43,8 %).

Qué se paga

Se gana un vector **corto y denso**; se pierde **información** (más de la mitad de la variación).

CONSULTA · SECCIÓN 1 · QUÉ SE CONSERVA Y QUÉ SE PIERDE

Reducir a 12 ejes: se gana tamaño y se pierde algo



M · TF-IDF

1 500 reseñas × 105 columnas

→

TruncatedSVD

12 ejes

Z · LSA

1 500 × 12

44 %
se conserva
de la varianza con 12 ejes

56 %
se pierde
al comprimir de 105 a 12

Qué muestra

La matriz **ancha y casi vacía** (105 columnas) pasa a una **estrecha y llena** (12 ejes).

Varianza explicada

Qué parte de lo que **distingue** unas reseñas de otras conservan los ejes. Con 12 ejes, el **44 %**.

CONSULTA · SECCIÓN 2 · PALABRAS DE CADA EJE

¿Qué «significa» cada eje? Palabras que van juntas

Eje	Las 6 palabras con más peso
1	desayuno, limpio, precio, tranquilo, duerme, maravilla
2	habitación, limpieza, noche, sencilla, correcta, impecable
3	total, noches, silencio, cinco, ubicación, perfecta
4	ubicación, playa, perfecta, cinco, minutos, precio
5	habitación, correcta, sencilla, impecable, limpieza, tranquilo

Nadie le ha dicho nada

LSA descubre solo qué palabras **aparecen juntas** en las reseñas.

Un eje no es una etiqueta

Es una mezcla de palabras: el nombre se lo pones tú. En el eje 4 se lee «ubicación a cinco minutos de la playa».

CONSULTA · EJERCICIO 2

Las reseñas más parecidas a una dada

```
def parecidas(i, k=3):
    sim = cosine_similarity([Z[i]], Z)[0]
    sim[i] = -1
    return list(np.argsort(sim)[::-1][:k])
```

3 parecidas

Reseña 0

«Vistas al mar increíbles»

Frase común

Ninguna de las tres menciona la música del bar: con 12 ejes se pierde el detalle raro.

CONSULTA · ACLARACIONES · EJERCICIO 2

Leer las parecidas (ejercicio 2)

cosine_similarity([Z[i]], Z)[0]

El coseno de la reseña **i** con **todas** las filas de **Z**.

sim[i] = -1

Evita que la reseña se devuelva a **sí misma** (su coseno consigo misma es 1).

Resultado

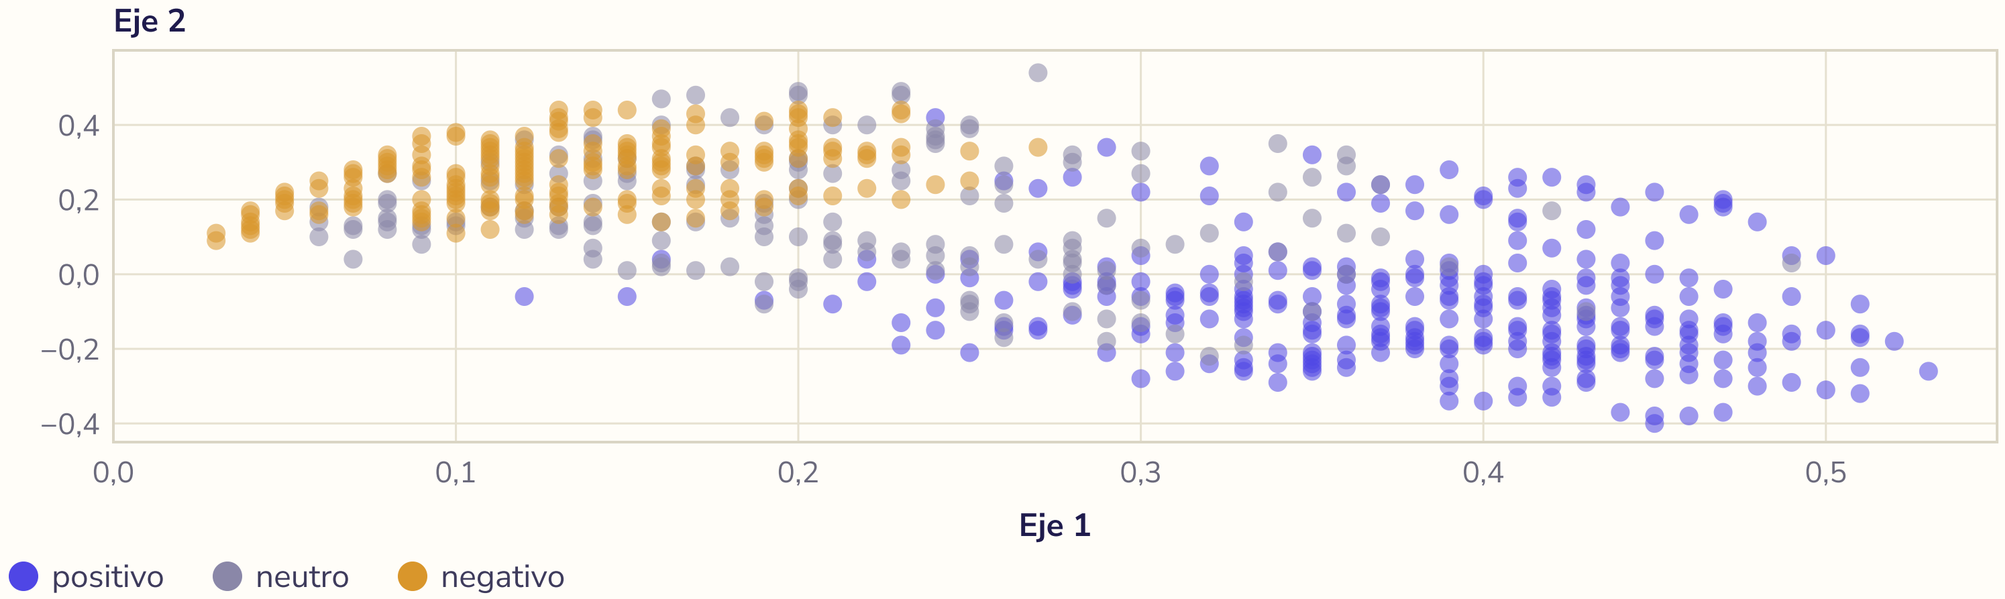
Las tres parecidas a la reseña 0 comparten **«Vistas al mar increíbles»**.

Cuidado

Ninguna recoge **la música del bar**: lo raro se pierde con solo 12 ejes.

CONSULTA · SECCIÓN 4 · RESEÑAS EN 2 DIMENSIONES

Un mapa de 1 500 reseñas con solo 2 ejes



LSA no ha visto el sentimiento, y aun así los negativos quedan arriba a la izquierda y los positivos abajo a la derecha.

CONSULTA · EJERCICIO 3

LSA de 12 columnas frente a TF-IDF

```
Me_ent = tfidf_e.fit_transform(X_ent)
Me_test = tfidf_e.transform(X_test)
lsa_e = TruncatedSVD(n_components=12, random_state=SEMILLA)
Ze_ent = lsa_e.fit_transform(Me_ent)
Ze_test = lsa_e.transform(Me_test)
clf_lsa = LogisticRegression(max_iter=1000).fit(Ze_ent, y_ent)
acc_lsa = accuracy_score(y_test, clf_lsa.predict(Ze_test))
```

0,995

TF-IDF completo · 105 columnas

0,891

LSA · 12 columnas

Comprimir cuesta unos 10 puntos. Ajustar LSA con todas las reseñas sería fuga de datos.

CONSULTA · ACLARACIONES · EJERCICIO 3

Leer la comparación (ejercicio 3)

fit_transform solo con **X_ent**

El vectorizador y los ejes se **ajustan con el entrenamiento**; a la prueba, solo **transform**.

tfidf_e nuevo

Un vectorizador **nuevo**, ajustado solo con el entrenamiento: así no se filtra la prueba.

Resultado

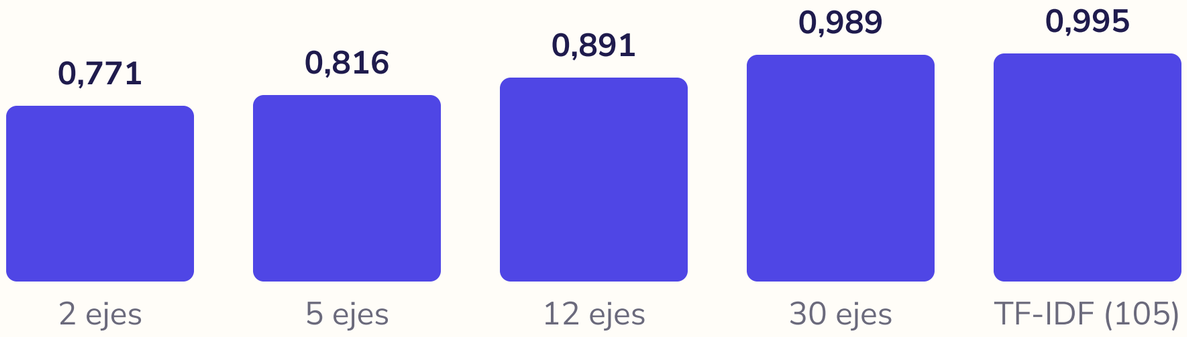
0,995 con las 105 columnas y **0,891** con 12 ejes.

Qué se paga

Unos **10 puntos** de exactitud a cambio de un vector 9 veces más corto.

CONSULTA · AMPLIACIÓN · NO ESTÁ EN EL CUADERNO

¿Cuántos ejes hacen falta?



Repite el ejercicio 3

Cambia **n_components** y mira la exactitud en prueba. **No está en el cuaderno**: es una ampliación.

Con 30 ejes casi igualas al TF-IDF.

Con 30 ejes casi igualas al TF-IDF completo: comprimir cuesta menos de lo que parece, pero hay que elegir cuántos.

CONSULTA · MINI-RETO

Buscador semántico de reseñas

```
def buscar(consulta, k=3):
    q = lsa.transform(tfidf.transform([consulta]))
    sim = cosine_similarity(q, Z)[0]
    return [resenas.loc[i, "texto"] for i in np.argsort(sim)[::-1][:k]]
hallazgos = buscar("no me dejó dormir el ruido")
```

«no me dejó dormir el ruido»

Consulta

3 reseñas de ruido nocturno

Resultado

La consulta no aparece tal cual en ninguna reseña: se busca por **parecido de significado**.

CONSULTA · ACLARACIONES · MINI-RETO

Leer el buscador

lsa.transform(tfidf.transform([consulta]))

Pasa la consulta por el **mismo** tfidf y el **mismo** lsa: queda en el espacio de las reseñas.

np.argsort(sim)[::-1][:k]

Ordena de **mayor a menor** parecido y se queda con los k primeros.

Resultado

Tres reseñas que mencionan **«Ruido constante por la noche»**.

Límite

LSA solo conoce **tu corpus**: una consulta con palabras que no aparecen no se entiende.