IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Transformers y atención: cómo lee un LLM

Tokens, autoatención y temperatura, calculados a mano con numpy y números pequeños

Sprint 12 · S12_05 · cuaderno: 40 min en clase (secciones 1 a 3: ejercicios 3, 4 y 5)

LA IDEA · ANTES DEL CUADERNO

Un LLM solo sabe elegir el siguiente token

1 · Trocear

```
El|desayuno|estaba
```

El texto se parte en **tokens** y cada token es un número.

→

2 · Atender

```
cada token mira a
los demás
```

La **atención** mezcla en cada token lo que dicen los otros.

→

3 · Puntuar

```
un número por
candidato
```

Cada token posible recibe una puntuación: el **logit**.

→

4 · Elegir

```
softmax y
temperatura
```

Se pasan a probabilidades y se elige un token.

Elegido el token, se añade al texto y todo se repite: así escribe un LLM, token a token.

Un Transformer

Apila **muchas capas** de atención, con varias «cabezas» a la vez. Hoy calculamos una, a mano.

No es magia

Son **matrices y probabilidades**: por eso se puede calcular con **numpy**.

SECCIÓN 1 · TOKENS

Tokens: ni palabras enteras ni letras sueltas

Por palabras

Un vocabulario **enorme**, y ninguna respuesta ante una palabra nueva.

Por letras

Vocabulario diminuto, pero «habitaciones» son **12 símbolos**: secuencias larguísimas.

BPE: el punto medio

Parte de letras y **fusiona los pares más frecuentes** hasta formar trozos útiles.

Qué es un token

Un trozo frecuente de texto: a veces una palabra, a veces una raíz o una terminación.

Por qué importa

Los LLM cobran y se limitan **por tokens**. El español suele gastar más tokens que el inglés.

Un token no es una palabra: es un trozo de texto, y cada trozo es un número.

BPE: cada fusión junta el par más frecuente

Paso	Par más frecuente	Veces	Símbolo nuevo
1	p + l	3	pl
2	pl + a	3	pla
3	pla + y	3	play
4	j + u	3	ju
5	ju + g	3	jug

Palabra	Tras 5 fusiones	Letras → tokens
playa	play · a	5 → 2
playas	play · a · s	6 → 3
playero	play · e · r · o	7 → 4
jugar	jug · a · r	5 → 3
jugamos	jug · a · m · o · s	7 → 5
jugaba	jug · a · b · a	6 → 4
jugando (nueva)	jug · a · n · d · o	7 → 5

36 letras → 21 tokens, sin saber español: han aparecido las raíces **play** y **jug**. Una palabra nueva se trocea con los mismos trozos.

SECCIÓN 2 · AUTOATENCIÓN

Atención: cada palabra decide a quién mirar

Q · query («pregunta»)

Lo que esta palabra **busca**.

K · key («etiqueta»)

Lo que cada palabra **ofrece**.

V · value («contenido»)

La información que **se pasa**.

«El desayuno estaba frío»

Para entender «frío» conviene mirar a «desayuno»: la atención deja que cada palabra decida **cuánto mira** a las demás.

Palabra	Q	K	V
desayuno	(2, 1)	(1, 2)	(3, 0)
estaba	(0, 1)	(2, 0)	(1, 1)
frío	(1, 3)	(0, 1)	(0, 2)

La Q de «frío», (1, 3), y la K de «desayuno», (1, 2), son las que mejor encajan.

Cuatro pasos para una palabra: «frío»

Paso	desayuno	estaba	frío
1 · Puntuaciones $Q \cdot K^T$	7	2	3
2 · Escalar ÷ √2	4,95	1,41	2,12
3 · Softmax (pesos)	**0,919**	0,027	0,054

4 · Mezclar

salida de «frío» = **0,919**·V(desayuno) + 0,027·V(estaba) + 0,054·V(frío)

= **(2,784 ; 0,135)**

¿Por qué ÷ √d?

Aquí d = 2, y √2 ≈ 1,41. Se divide para que los números **no crezcan demasiado** antes del softmax.

«frío» mira sobre todo a «desayuno» y su vector ya lleva información de él.

SECCIÓN 2 · EJERCICIO 3 · CUADERNO (CLASE)

Softmax: de puntuaciones a probabilidades

Opción	Puntuación **x**	**exp(x)**	Probabilidad
a	4	54,6	0,867
b	2	7,4	0,117
c	0	1,0	0,016
Suma		63,0	**1,000**

Truco: restar el máximo

x – máximo: (4, 2, 0) pasa a (0, −2, −4) y las probabilidades salen **iguales**.

Por qué hace falta

Con (1 000, 998, 996), **exp(1000)** desborda: sale **inf** y el resultado es **nan**. Restando el máximo, salen las mismas 0,867 · 0,117 · 0,016.

Por filas: cada fila de la matriz de atención suma 1. El error típico es poner el eje al revés.

SECCIÓN 2 · EJERCICIO 4 · CUADERNO (CLASE)

La matriz de pesos: quién mira a quién

Pesos de atención (ejemplo propio)

mira a →	desayuno	estaba	frío
desayuno	0,47	0,47	0,06
estaba	0,58	0,14	0,28
frío	0,92	0,03	0,05

Cómo se lee

Fila: la palabra que pregunta. **Columna**: a quién mira. Cada fila suma **1**.

Palabra	Salida = pesos · V
desayuno	(1,89 ; 0,58)
estaba	(1,87 ; 0,71)
frío	(2,78 ; 0,14)

atencion(X, Wq, Wk, Wv) devuelve **(salida, pesos)**: una mezcla de contenidos por palabra.

SECCIÓN 3 · EJERCICIO 5 · CUADERNO (CLASE)

Máscara causal: no mirar al futuro

Sin máscara

mira a →	desayuno	estaba	frío
desayuno	0,47	0,47	0,06
estaba	0,58	0,14	0,28
frío	0,92	0,03	0,05

Con máscara causal

mira a →	desayuno	estaba	frío
desayuno	1,00	0,00	0,00
estaba	0,80	0,20	0,00
frío	0,92	0,03	0,05

Qué se hace

Antes del softmax, un número muy negativo (**−1e9**) por encima de la diagonal: el futuro. Su peso pasa a **0**.

Qué se ve

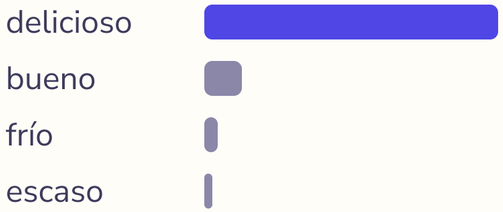
La primera palabra solo se mira a sí misma (**1,00**). La **última fila no cambia**: ya veía todo lo anterior.

SECCIÓN 4 · EJERCICIO 6 · CUADERNO (CASA)

Temperatura: cuánto arriesga el modelo al elegir

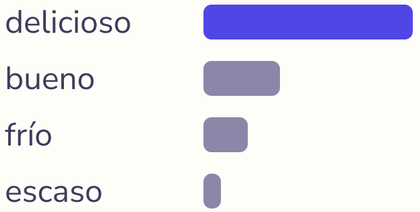
T = 0,5

seguro, repetitivo



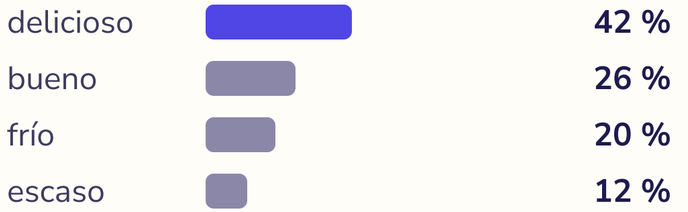
T = 1

reparto normal



T = 2

más variado, más riesgo



T baja

Casi siempre el token **más probable**: respuestas previsibles.

T alta

Más reparto: **más variedad** y más riesgo de errores o alucinaciones.

Siguiente token de «El desayuno estaba…». Mismo modelo, mismos logits: solo cambia el reparto.

PARA CASA · LO QUE QUEDA DEL CUADERNO

En casa: BPE, mini-reto, Hugging Face y reflexión

Ejercicios 1 y 2 · BPE

contar_pares y **par_mas_comun** sobre el corpus en letras.

Tokens tras 12 fusiones: **n_tokens_bpe**, **n_letras** y **compresion**.

Mini-reto · atención

Cambia el embedding de «limpio» en **X2** para que «hotel» le preste más atención y guarda la comparación en **subio**.

¿Qué vector decide cuánto le interesa «limpio» a «hotel»?

Opcional · Hugging Face

USAR_HUGGING_FACE = False por defecto.

No verificado: necesita internet y Colab; los nombres de modelo pueden haber cambiado.

Reflexión 1 y 2

¿Qué son las filas y las columnas de la matriz de pesos, y por qué cada fila suma 1?

¿Por qué una temperatura alta favorece que el modelo se invente datos?

Reflexión 3 y 4

Si el español gasta más tokens que el inglés, ¿cómo cambia el coste de un asistente?

¿Qué comprobarías antes de fiarte de un modelo zero-shot con reseñas reales?

LO QUE TE LLEVAS

Cómo lee y cómo escribe un LLM

Tokens

Un LLM lee **trozos de texto**, no palabras: BPE fusiona los pares más frecuentes

Atención

Q, K y V: puntuaciones, **÷ √d**, **softmax por filas** y mezcla de V. La máscara causal tapa el futuro

Generar

Un logit por token, softmax y **temperatura**: T baja es seguro, T alta es variado y arriesga

Siguiente, el mismo martes: RAG, un asistente que cita su fuente (S12_06)