Sprint 12 · Resultados de los cuadernos (sin código)

IFCD107 · Especialista en Inteligencia Artificial

- **Para explicar a clase** qué pide cada ejercicio y qué se obtiene, sin enseñar código.
- **Clase** = ejercicio del cuaderno «en clase» · **Casa** = solo en el cuaderno completo (`para_casa/`).
- Los números son los que salen al ejecutar los cuadernos con los datos del curso (turisdata).

S12_01 · Series temporales

Ej.	Qué pide	Qué obtenemos
1 · clase	¿Qué día de la semana tiene más ocupación y qué mes menos?	Más ocupación: el **sábado** · menos: **septiembre** (mes 9)
2 · clase	Un tercer baseline: la media de las últimas 4 semanas para cada día	Error medio (MAE) **4.45 puntos** de ocupación
3 · casa	Cuánta variación explica la estacionalidad semanal	Diferencia entre el mejor y el peor día: **9.4 puntos**; lo que queda sin explicar tiene desviación **3.67**
4 · clase	SARIMAX sin festivos ni Fourier, comparado con el modelo completo	MAE **3.93** sin variables extra frente a **3.18** con ellas

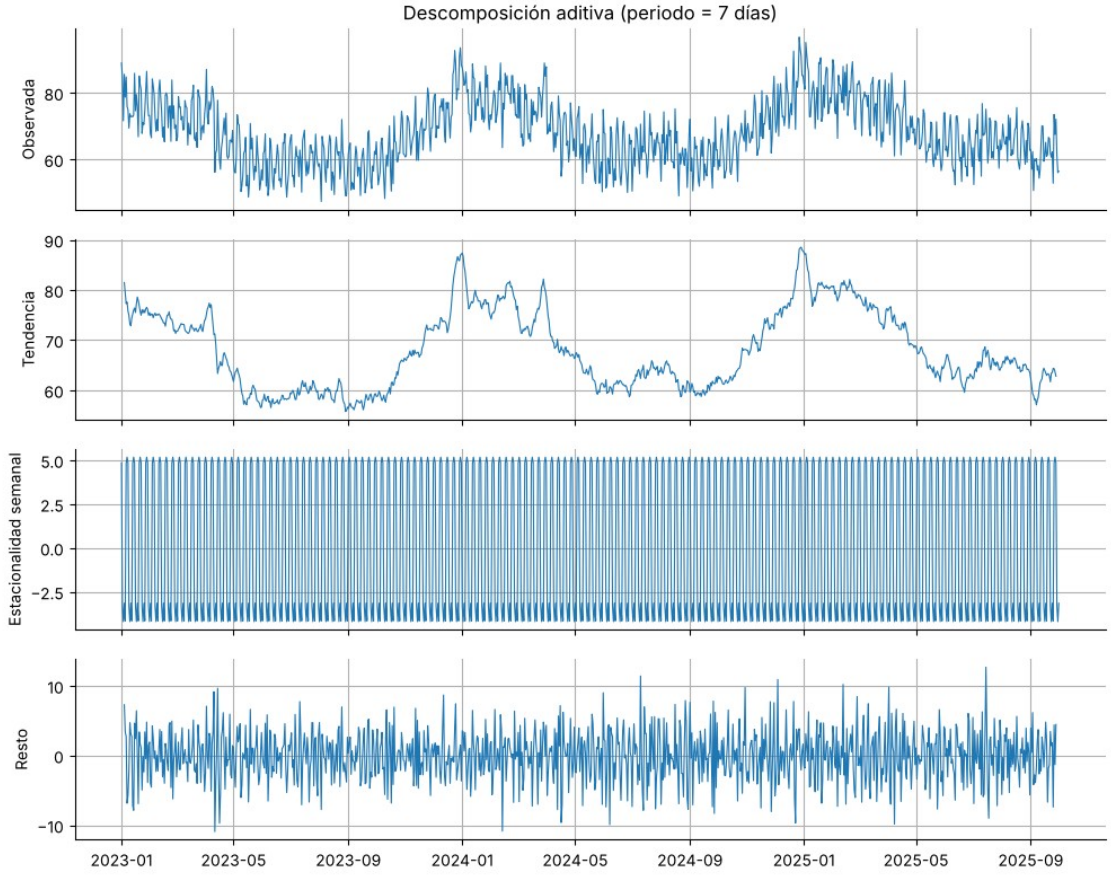


Figura 1. *Sección 4 · Descomposición: serie observada, tendencia (las temporadas), estacionalidad semanal (se repite cada 7 días) y resto.*

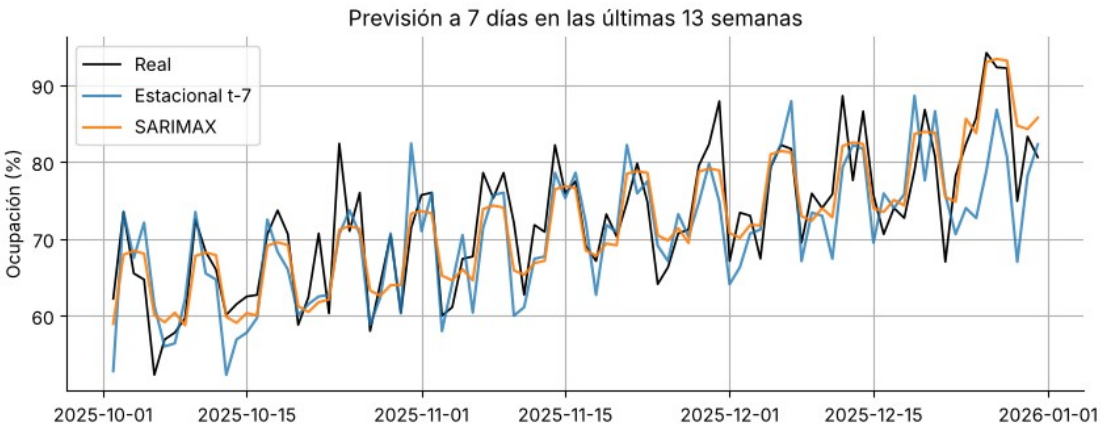


Figura 2. *Sección 6 · Real (negro) frente a copiar la semana anterior (azul) y SARIMAX (naranja): SARIMAX sigue mejor los picos.*

S12_02 · Redes recurrentes (RNN, LSTM, GRU)

Ej.	Qué pide	Qué obtenemos
1 · clase	Escalar la ocupación entre 0 y 1 usando solo el entrenamiento	Serie de **1 096 días** escalada, con 6 variables por día (ocupación, festivo y ciclos de semana y año)
2 · clase	Crear ventanas: 28 días de pasado para predecir los 7 siguientes	**971** ventanas de entrenamiento de forma (28, 6) y **13** de prueba
3 · clase	Entrenar SimpleRNN, LSTM y GRU y medir el error en prueba	SimpleRNN **3.79** · LSTM **3.51** · GRU **3.28** puntos; el baseline (copiar la semana) da **4.46**

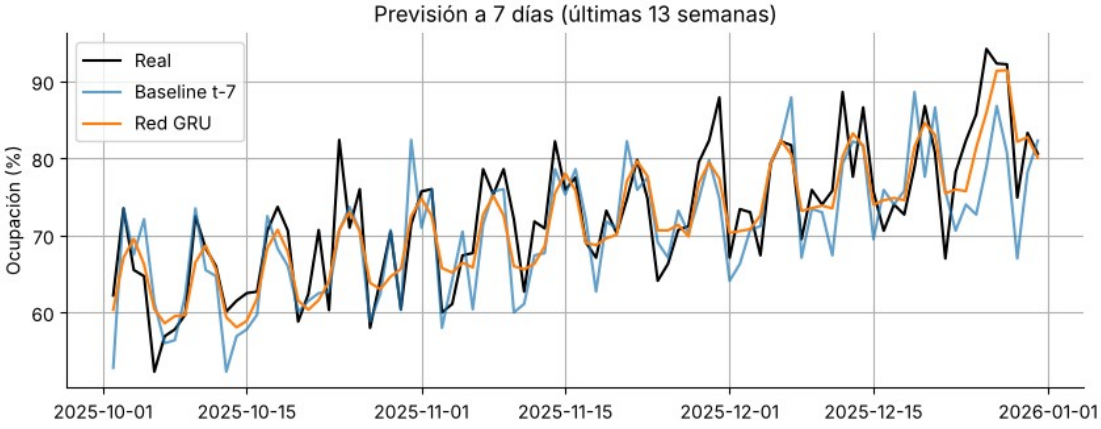


Figura 3. *Sección 7 · Previsión de la red GRU (naranja) frente a la realidad (negro) y al baseline de copiar la semana anterior (azul).*

S12_03 · NLP clásico con reseñas

Ej.	Qué pide	Qué obtenemos
1 · clase	Limpiar el texto: minúsculas, sin signos ni espacios repetidos	«¡Qué BUENO!... Sí» → **qué bueno sí**
2 · clase	Las 5 palabras más frecuentes del corpus	**semana** (504), **desayuno** (391), **todo** (382), **habitación** (284), **escapada** (256)
3 · clase	Clasificar el sentimiento con regresión logística + TF-IDF y con Naive Bayes	Exactitud **99.2 %** y **98.9 %** (siempre «la clase mayoritaria» acertaría 46.9 %)

Ej.	Qué pide	Qué obtenemos
4 · clase	¿Falla con las frases con negación?	**Sí**: «no es impecable» se trata como «impecable»; los **bigramas** («no es») conservan algo del orden
5 · casa	El tema con peor resultado y cuántas reseñas hablan de precio	Peor tema: **ruido** (55 reseñas donde falla) · **455** reseñas mencionan el precio

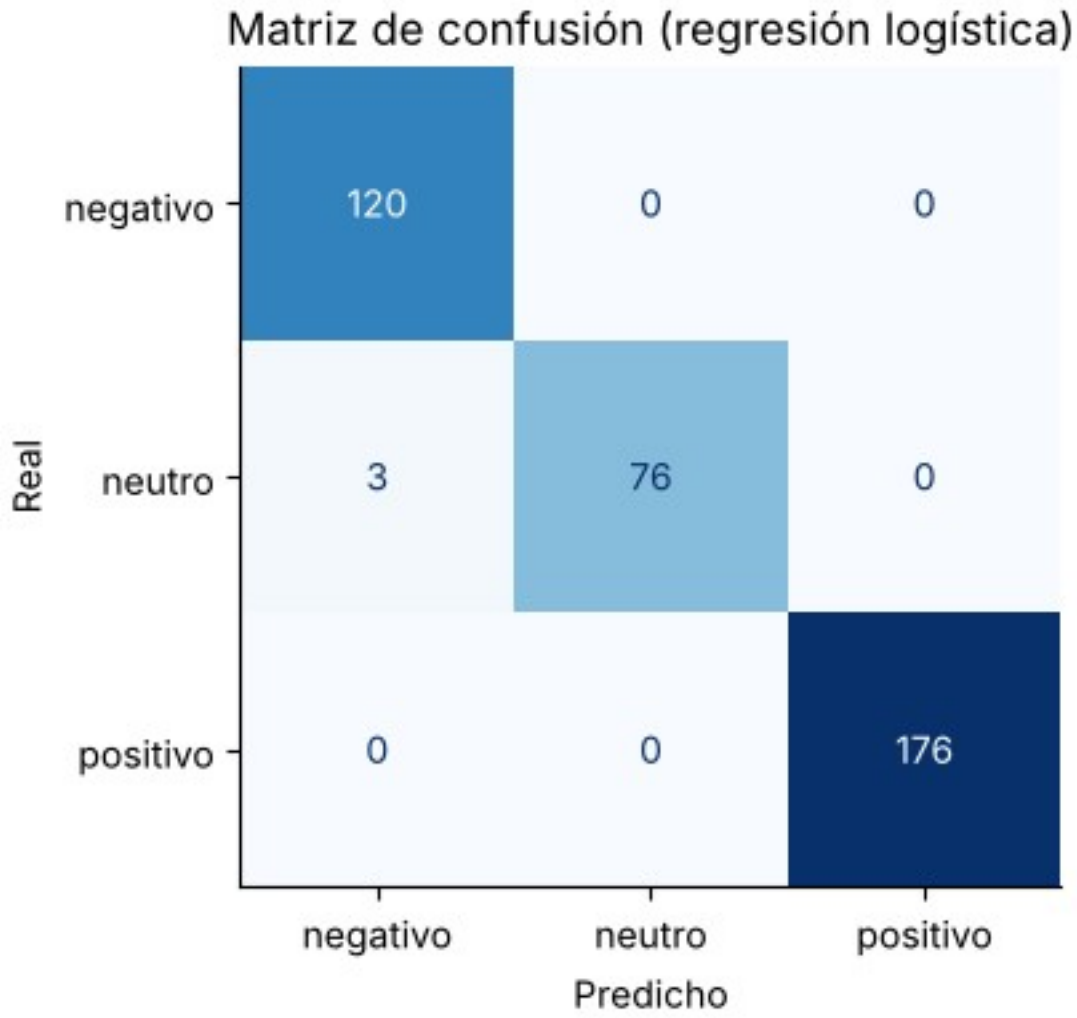


Figura 4. *Ejercicio 3 · Matriz de confusión: solo 3 reseñas neutras se confunden con negativas.*

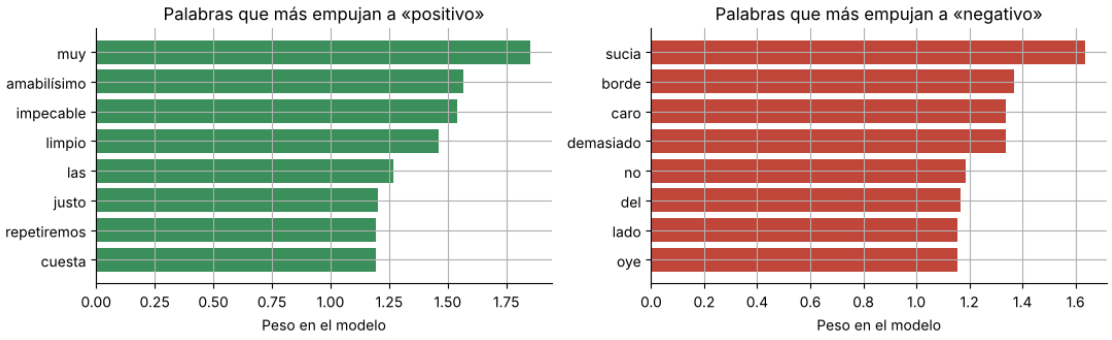


Figura 5. *Palabras que más pesan: verde empuja a «positivo» (amabilísimo, impecable, limpio) y rojo a «negativo» (sucia, borde, caro).*

S12_04 · Embeddings y LSA

Ej.	Qué pide	Qué obtenemos
1 · casa	Reducir las reseñas a 12 dimensiones con LSA	Cada reseña pasa a **12 números** (matriz 1 500 × 12) que conservan el **44 %** de la variación
2 · casa	Encontrar las reseñas más parecidas a una dada	Para «música del bar… vistas al mar increíbles», las más parecidas son otras reseñas con **«Vistas al mar increíbles»**
3 · casa	Clasificar con los vectores LSA (12 columnas) y comparar con TF-IDF completo	LSA **89.1 %** frente a **99.5 %** con las 105 columnas: se pierde precisión a cambio de comprimir

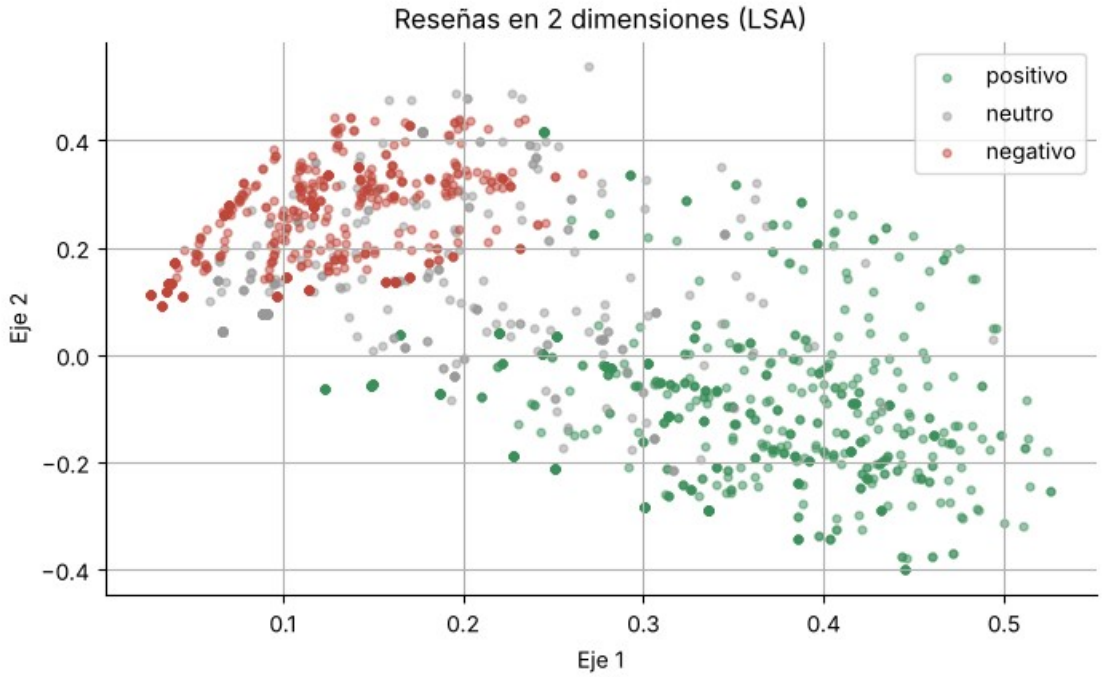


Figura 6. *Sección 4 · Mapa de reseñas en 2 dimensiones: las negativas (rojo) a un lado, las positivas (verde) al otro y las neutras (gris) en medio.*

S12_05 · Transformers y atención

Ej.	Qué pide	Qué obtenemos
1 · casa	Contar pares de letras para empezar a construir un tokenizador BPE	Par más común: **«d» + «e»**, 4 veces
2 · casa	Tokens tras 12 fusiones y razón de compresión	**67 letras → 22 tokens**: compresión **3.05×** («desayuno» → «desayun» + «o»)
3 · clase	Softmax por filas	Cada fila suma 1; por ejemplo **0.09 · 0.24 · 0.67**
4 · clase	Autoatención con 3 palabras (hotel, muy, limpio)	Pesos de atención: «limpio» mira sobre todo a «muy» (**0.73**) y «muy» a sí misma (**0.89**)
5 · clase	Atención causal: no se puede mirar al futuro	La parte de arriba de la matriz queda en **0**: la 1.ª palabra solo se mira a sí misma (1.00)
6 · casa	Temperatura al generar texto	Con T = 0.3 la palabra más probable tiene **0.82**; con T = 2.5 solo **0.30**: la temperatura baja es **más segura**

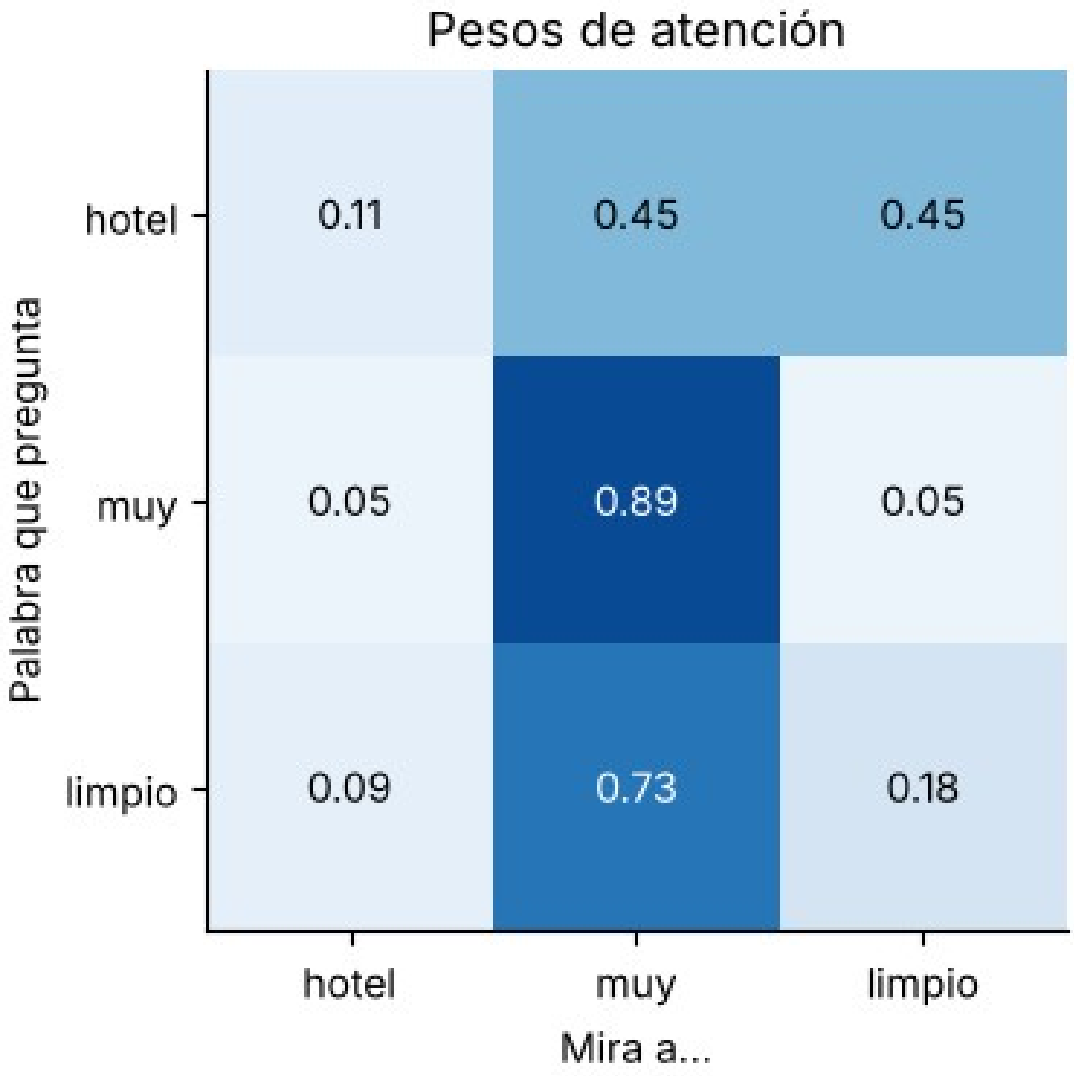


Figura 7. *Ejercicio 4 · Pesos de atención: cada fila es la palabra que pregunta y cada columna, la palabra a la que mira (suman 1 por fila).*

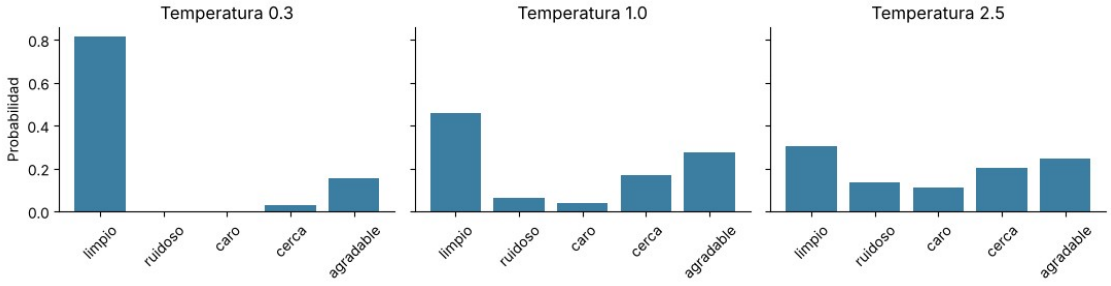


Figura 8. *Sección 4 · Probabilidad de cada palabra candidata con temperatura baja (izquierda), media y alta (derecha): al subir T se reparte más.*

S12_06 · Mini RAG

Ej.	Qué pide	Qué obtenemos
1 · clase	Trocear la política del alojamiento en fragmentos	**25 fragmentos**, cada uno con su sección
2 · clase	Recuperar los fragmentos más parecidos a una pregunta	Para «mascotas»: «perros y gatos de hasta 10 kg… 15 euros» (**0.41**) y «no se admiten mascotas en las suites» (**0.23**)

Ej.	Qué pide	Qué obtenemos
3 · casa	Ampliar la pregunta con sinónimos	El fragmento correcto en 1.ª posición pasa del **84 %** al **95 %**; entre los 3 primeros, **100 %**
4 · clase	Responder citando la fuente (y decir «no consta» si no hay nada parecido)	«No se admiten mascotas en las suites. [1] (Fuente: 3. Mascotas)» con puntuación **0.89**
5 · casa	Detectar alucinaciones en 20 preguntas de referencia	**19 de 20** correctas, **0** alucinaciones; falla «¿A qué hora es el desayuno?»
6 · casa	Filtro contra inyección de instrucciones	Ataques que prosperan con el filtro: **0 de 3**

S12_07 · Autoencoders y modelos generativos

Ej.	Qué pide	Qué obtenemos
1 · casa	Separar el último 20 % de las semanas para prueba y escalar solo con el entrenamiento	**124** semanas de entrenamiento y **32** de prueba, con 7 columnas (los 7 días)
2 · casa	Entrenar el autoencoder (la entrada es también el objetivo)	Error final **0.0076** en entrenamiento y **0.0095** en validación
3 · casa	Umbral de error de reconstrucción (percentil 95 del entrenamiento)	Umbral **0.0154**
4 · casa	Probar con 3 anomalías inyectadas	Detecta **3 de 3** anomalías y marca **3 de 32** semanas reales
5 · casa	Emparejar cada situación con su técnica	Semanas raras → **autoencoder** · foto desde texto → **difusión** · engañar a un discriminador → **GAN**

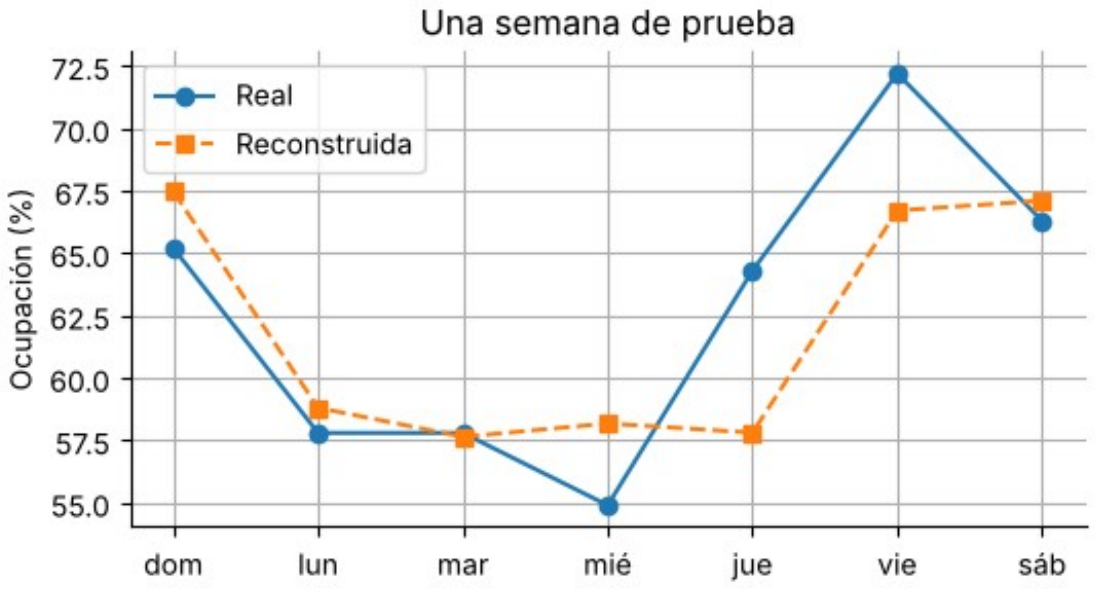


Figura 9. *Sección 3 · Una semana real (azul) y su reconstrucción (naranja): el autoencoder reproduce el patrón general pero suaviza los extremos.*

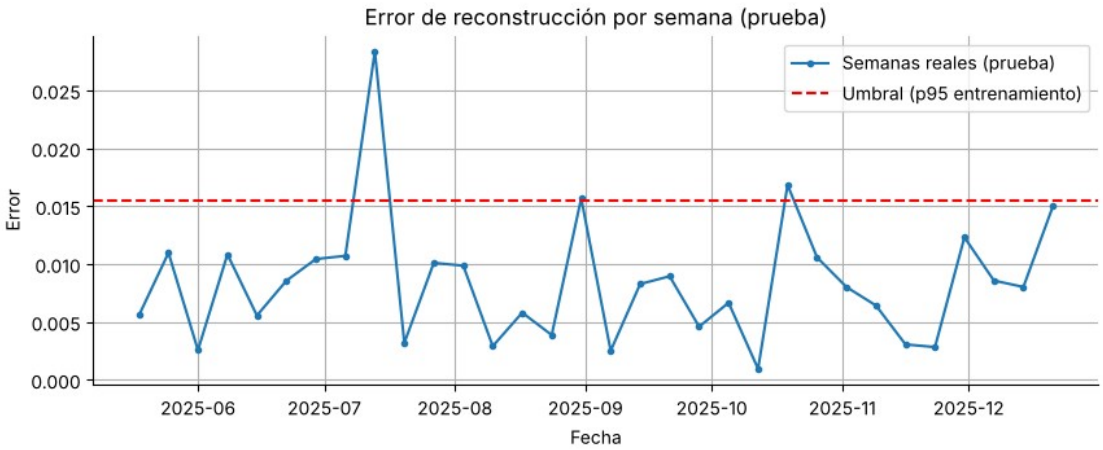


Figura 10. *Ejercicio 4 · Error de las semanas de prueba: las que superan el umbral (línea roja) son las candidatas a raras.*

La historia del sprint

- **3.28** · La red **GRU** es la que mejor prevé la ocupación (error 3.28), mejor que copiar la semana (4.46).
- **99 %** · Con **TF-IDF y regresión logística** se clasifica bien el sentimiento, pero la negación se le escapa.
- **19 / 20** · El **mini RAG** responde bien 19 de 20 preguntas, cita sus fuentes y no alucina.
- **3 de 3** · El **autoencoder** detecta las 3 semanas raras con solo 3 falsas alarmas.