Guía Sprint S12 · Lenguaje, secuencias y modelos generativos

¿qué dicen los clientes y qué pasará mañana?

FECHAS
23–25/11
HORAS
18 h (5 h teoría · 6 h práctica · 7 h PBL, con el Sprint 13 integrado en el último día)

Qué aprenderás

1. A **predecir una serie temporal** (la ocupación) y a comprobar si tu modelo gana de verdad a un método simple (*baseline*).
2. A **leer reseñas con Python**: limpiar texto, medir el sentimiento y descubrir de qué se queja o qué alaba la gente.
3. A representar texto con **vectores (embeddings)** y a entender, con números pequeños, cómo funciona la **atención** de un Transformer.
4. A montar un **mini asistente con RAG** que responde con la política del alojamiento, cita su fuente y sabe decir "no consta".
5. A **evaluar** un asistente (aciertos, alucinaciones) y a reconocer un ataque de *prompt injection*; y a entender la idea de autoencoders, GAN y difusión.

Temario

Los conceptos que entran en este sprint (temario oficial del curso):

Unidad	Conceptos que entran
UD 4.7	RNN, LSTM, GRU y series temporales
UD 4.8	NLP clásico y embeddings: tokenización, TF-IDF, word2vec; procesamiento léxico, sintáctico y semántico
UD 4.9	Transformers y LLM: atención, BERT/GPT, Hugging Face, fine-tuning ligero, introducción a RAG y APIs
UD 4.10	Autoencoders y modelos generativos (GAN, difusión: introducción)

Material del sprint

Presentaciones

Presentación	Tema	Tiempo
S12.1	RNN, LSTM, GRU y series temporales	20 min
S12.2	NLP clásico y embeddings	15 min
S12.3	Transformers y LLM	30 min
S12.4	Autoencoders y modelos generativos	10 min
S13.1	Visualizar y comunicar resultados (Sprint 13, integrado; versión rápida)	10 min

Actividades

Actividad	Tiempo
Series temporales: *baselines*, descomposición y SARIMAX	45 min
RNN, LSTM y GRU frente al *baseline*	45 min
Reseñas: limpieza, TF-IDF, sentimiento, temas y n-gramas	55 min
Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día	20 min
Tokens, atención paso a paso y temperatura	40 min
Mini RAG con la política, evaluación y seguridad	45 min
Matriz de confusión, ROC/PR, importancia, umbral y coste	35 min

RETO **Reto PBL · «Escuchar al cliente»**

Qué os pide el cliente. TurisData recibe cada semana **decenas de reseñas** y **decenas de mensajes** de huéspedes con las mismas preguntas («¿hasta cuándo puedo cancelar?», «¿admiten perros?»). La dirección no puede leerlo todo ni contestar a mano. Quiere **tres cosas**:

1. **Saber qué opinan y de qué se quejan** sus clientes (reseñas).
2. **Prever la ocupación de la próxima semana** para organizar personal y compras (serie temporal).
3. **Probar un asistente** que responda con la política del alojamiento **sin inventar nada** (RAG).

Qué vais a entregar: una carpeta (o zip) por equipo con (1) el informe de reseñas, (2) el cuaderno del modelo de ocupación, (3) el cuaderno de la demo del asistente con su tabla de evaluación y (4) la nota de IA responsable, más un `LEEME.md` de 5 líneas.

Cuánto tiempo: unas 2 horas y 40 minutos de reto (a lo largo de los tres días del sprint) además de lo que avancéis en las prácticas y del informe visual del Sprint 13, que va dentro del último día.

Núcleo y extra. Núcleo: dos de las tres partes técnicas (a elegir entre reseñas, ocupación y asistente) con su informe. Extra: la tercera parte y las prácticas de ampliación.

Ficha completa del reto (pasos, rúbrica, ayudas y errores frecuentes): Reto_Sprint_12.md · **Qué hacemos cada día:** Guía día a día

Conclusión del Sprint 12

Al acabar este sprint...

- Sé partir una serie temporal por fecha y calcular un *baseline*.
- Sé calcular el sentimiento de una reseña.
- Mi equipo tiene una tarjeta por entregable con responsable.
- Sé qué es RAG y por qué hace falta un umbral.
- Las cuatro entregas del Sprint 12 en `sprint-12/` y el informe visual de una página en `sprint-13/`.
- Test de M4 hecho.
- Autoevaluación y coevaluación rellenadas.

Y ahora: Sprint 13 · Contar lo que hace el modelo, dentro de esta misma última jornada (miércoles 25/11).