Sprint 12 · Lenguaje, secuencias y modelos generativos

¿qué dicen los clientes y qué pasará mañana?

FECHAS
23–25/11
HORAS
18 h (5 h teoría · 6 h práctica · 7 h PBL, con el Sprint 13 integrado en el último día)
CONTENIDOS (MÓDULO 4)
UD 4.7 redes recurrentes y series temporales · UD 4.8 NLP clásico y embeddings · UD 4.9 Transformers, LLM y RAG · UD 4.10 autoencoders y modelos generativos.
EVALUACIÓN
test de M4 + entrega del reto con la rúbrica de 4 criterios.

Qué aprenderás

1. A **predecir una serie temporal** (la ocupación) y a comprobar si tu modelo gana de verdad a un método simple (*baseline*).
2. A **leer reseñas con Python**: limpiar texto, medir el sentimiento y descubrir de qué se queja o qué alaba la gente.
3. A representar texto con **vectores (embeddings)** y a entender, con números pequeños, cómo funciona la **atención** de un Transformer.
4. A montar un **mini asistente con RAG** que responde con la política del alojamiento, cita su fuente y sabe decir "no consta".
5. A **evaluar** un asistente (aciertos, alucinaciones) y a reconocer un ataque de *prompt injection*; y a entender la idea de autoencoders, GAN y difusión.

Requisitos previos

- Sprints 9–11: aprendizaje automático con scikit-learn, redes neuronales y Keras básico (capas, `fit`, épocas).
- Saber cargar datos con pandas y hacer gráficos sencillos.
- No necesitas cuenta en ningún servicio de IA: **todo se ejecuta sin internet**. Hay partes opcionales (marcadas **NO VERIFICADO**) para Colab o para un LLM instalado en tu equipo.

Prácticas (≈ 3 h 50 min; las dos de ampliación, en casa)

Notebook	Tema	Tiempo
`S12_01_series_temporales`	Serie temporal: baselines, descomposición, ARIMA/SARIMAX	45 min
`S12_02_redes_recurrentes`	RNN, LSTM y GRU en Keras vs. baseline	45 min
`S12_03_nlp_clasico`	Reseñas: limpieza, TF-IDF, sentimiento, temas y n-gramas	55 min
`S12_04_embeddings_lsa`	Embeddings con LSA y buscador de reseñas parecidas	50 min (opcional, en casa)
`S12_05_transformers_atencion`	Tokens, atención paso a paso, temperatura (+ Hugging Face opcional)	40 min
`S12_06_mini_rag`	Mini RAG con la política, evaluación y seguridad	45 min
`S12_07_autoencoder_generativos`	Autoencoder para anomalías; idea de GAN y difusión	50 min (opcional, en casa)

Cómo trabajar: ejecuta las celdas en orden. Cada ejercicio tiene una pista y, justo debajo, una comprobación automática (`assert`): si falla, te dice qué revisar. Las celdas marcadas **OPCIONAL / NO VERIFICADO** usan internet o programas externos: puedes saltártelas sin perder nada.

Regla de oro del sprint: nunca escribas claves de API en el código. Si usas un servicio externo, la clave se lee de una variable de entorno o con `getpass`.

RETO **Reto PBL · «Escuchar al cliente»**

Qué os pide el cliente. TurisData recibe cada semana **decenas de reseñas** y **decenas de mensajes** de huéspedes con las mismas preguntas («¿hasta cuándo puedo cancelar?», «¿admiten perros?»). La dirección no puede leerlo todo ni contestar a mano. Quiere **tres cosas**:

1. **Saber qué opinan y de qué se quejan** sus clientes (reseñas).
2. **Prever la ocupación de la próxima semana** para organizar personal y compras (serie temporal).
3. **Probar un asistente** que responda con la política del alojamiento **sin inventar nada** (RAG).

Qué vais a entregar: una carpeta (o zip) por equipo con (1) el informe de reseñas, (2) el cuaderno del modelo de ocupación, (3) el cuaderno de la demo del asistente con su tabla de evaluación y (4) la nota de IA responsable, más un `LEEME.md` de 5 líneas.

Cuánto tiempo: unas 2 horas y 40 minutos de reto (23 al 25/11), repartidas entre el martes y el miércoles, además de lo que avancéis en las prácticas y del informe visual del Sprint 13, que va dentro del último día.

Núcleo y extra. Núcleo: dos de las tres partes técnicas (a elegir entre reseñas, ocupación y asistente) con su informe. Extra: la tercera parte y las prácticas de ampliación.

Ficha completa del reto (pasos, rúbrica, ayudas y errores frecuentes): Reto_Sprint_12.md · **Qué hacemos cada día:** Guía día a día