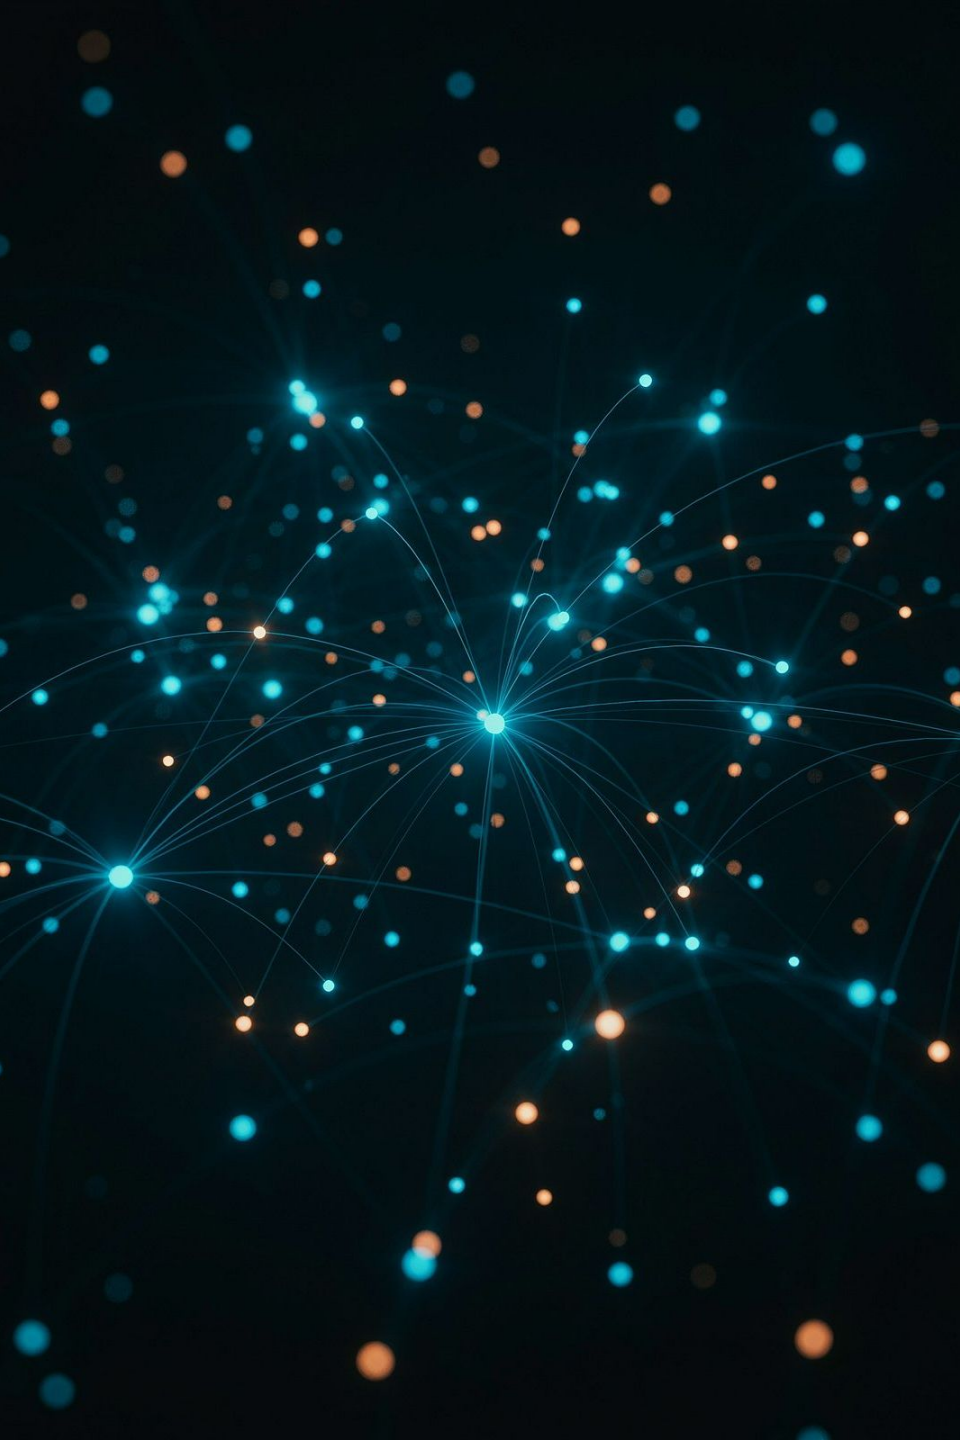


NLP Clásico y Embeddings

S12.2 · PROCESAMIENTO DE LENGUAJE NATURAL

Una introducción completa al procesamiento de lenguaje natural clásico: desde los primeros pasos del pipeline hasta representaciones vectoriales avanzadas como *word2vec*. Exploraremos cómo las máquinas comprenden, representan y clasifican el texto humano.

El Pipeline de NLP

El pipeline de NLP es la secuencia de transformaciones que convierte texto crudo en información estructurada y procesable. Cada etapa prepara la entrada para la siguiente, garantizando que el modelo reciba datos limpios y representados correctamente.



La calidad del resultado final depende críticamente de cada etapa: un error en la limpieza o la tokenización se propaga y amplifica a lo largo de todo el proceso.



Tokenización y limpieza

¿Qué es la tokenización?

Proceso de segmentar el texto en unidades mínimas significativas llamadas **tokens**. Un token puede ser una palabra, subpalabra, carácter o símbolo de puntuación, según el enfoque elegido.

Ejemplo: *"El gato duerme."* → `["El", "gato", "duerme", "."]`

Pasos de limpieza habituales

- **Lowercasing**: convertir todo a minúsculas
- **Eliminación de stopwords**: quitar palabras vacías de contenido (*de, la, y…*)
- **Stemming / Lematización**: reducir palabras a su raíz o forma canónica
- **Eliminación de puntuación y ruido**: URLs, HTML, caracteres especiales
- **Normalización de acentos**: gestión de tildes y diacríticos

Bolsa de Palabras (BoW)

El modelo de **Bolsa de Palabras** representa un documento como un vector de frecuencias de términos, ignorando el orden y la gramática. Es simple, interpretable y sorprendentemente efectivo para muchas tareas de clasificación.

Cómo funciona

Se construye un vocabulario global con todos los términos del corpus. Cada documento se representa como un vector de longitud igual al vocabulario, donde cada posición indica cuántas veces aparece ese término.

> Limitación clave: BoW no captura el orden ni el significado de las palabras. "El perro muerde al hombre" y "El hombre muerde al perro" producen el mismo vector.

Ejemplo ilustrativo

Término	Doc 1	Doc 2
gato	2	0
perro	0	3
animal	1	1

TF–IDF: Peso Inteligente de Términos

TF-IDF (Term Frequency–Inverse Document Frequency) mejora la Bolsa de Palabras ponderando la importancia real de cada término en un documento relativo a todo el corpus.

TF · Frecuencia de término

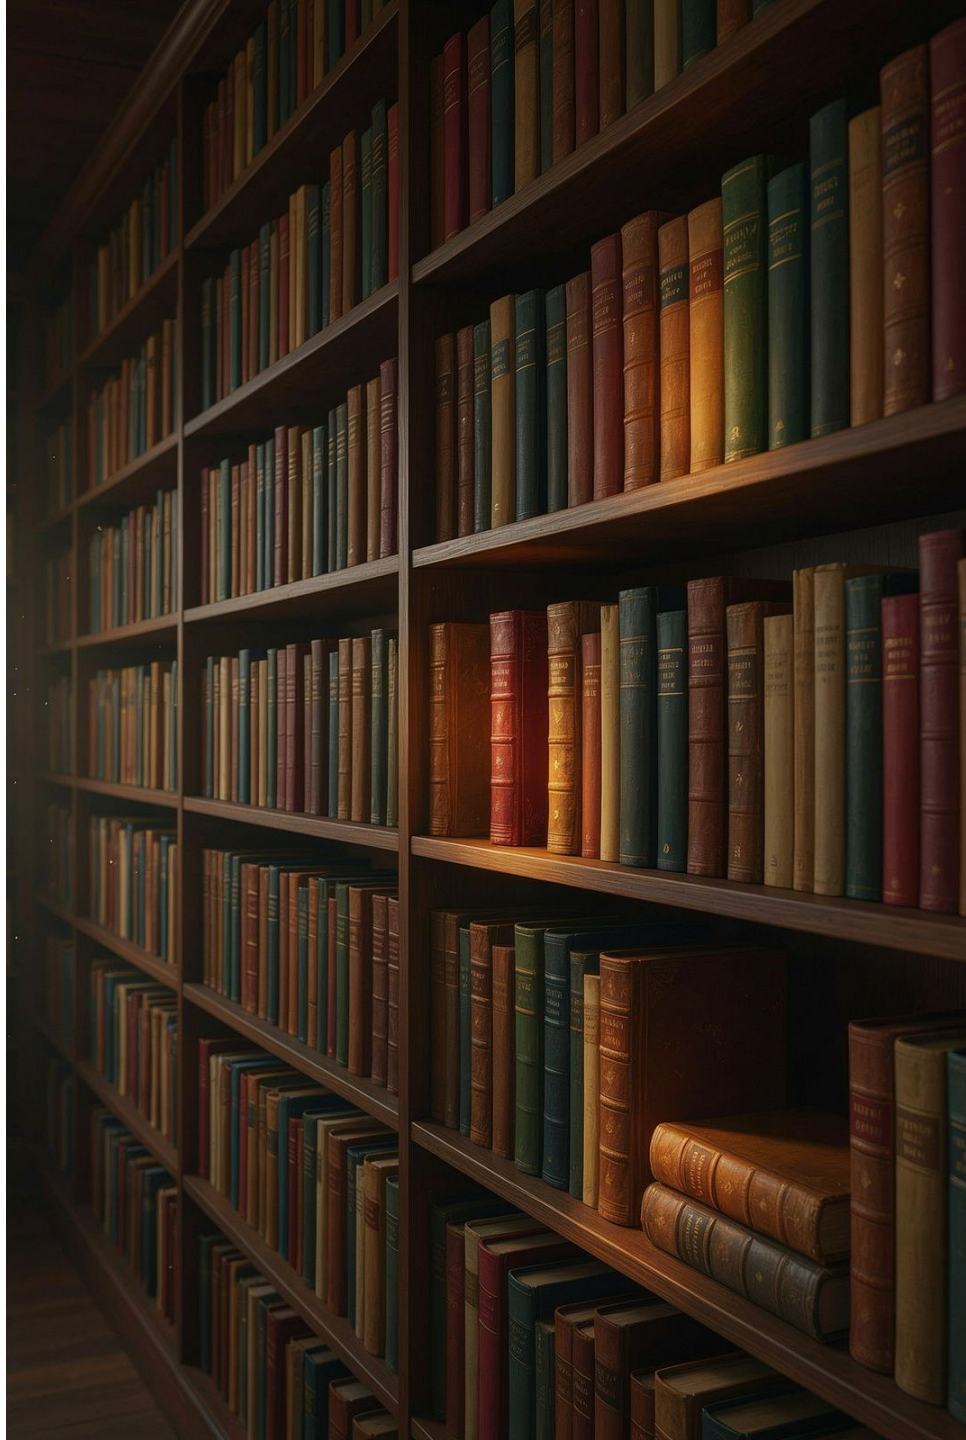
Mide con qué frecuencia aparece un término en un documento concreto. Un término muy repetido en un documento recibe mayor peso.

IDF · Frecuencia inversa

Penaliza los términos que aparecen en muchos documentos (como *"el"* o *"de"*), ya que aportan poca información discriminativa.

TF–IDF = TF × IDF

El producto final premia palabras frecuentes en un documento pero raras en el corpus: las más informativas y representativas del contenido.





Word Embeddings: Palabras en el Espacio Vectorial

Los **word embeddings** son representaciones densas y continuas de las palabras en un espacio vectorial de baja dimensión (típicamente 100–300 dimensiones). A diferencia de BoW, capturan relaciones semánticas y sintácticas de forma implícita.

Intuición clave

Palabras con significados similares aparecen en contextos similares. El modelo aprende a asignarles vectores cercanos en el espacio. Esto se resume en la famosa hipótesis distribucional:

> "Una palabra se conoce por la compañía que mantiene." — J.R. Firth

Ventajas sobre BoW

- Vectores densos (no dispersos)
- Capturan similitud semántica
- Permiten analogías algebraicas
- Transfieren conocimiento entre tareas

Word2Vec: Aprendiendo Significado del Contexto

Word2Vec (Mikolov et al., 2013) es el algoritmo de referencia para generar word embeddings. Entrena una red neuronal superficial con uno de dos objetivos:

CBOW · Continuous Bag of Words

Predice la palabra central a partir de su contexto (palabras vecinas). Funciona bien para vocabularios frecuentes y corpus grandes. El contexto actúa como entrada y la palabra objetivo como salida.

Skip-Gram

Predice las palabras de contexto a partir de la palabra central. Funciona mejor con palabras poco frecuentes y produce embeddings de mayor calidad en corpus pequeños.

La famosa analogía vectorial: **rey – hombre + mujer ≈ reina** emerge de forma natural del entrenamiento de Word2Vec, sin que sea programada explícitamente.

Similitud Semántica

¿Cómo medimos la similitud?

Una vez que las palabras están representadas como vectores, podemos calcular cuánto se parecen semánticamente usando métricas de distancia o ángulo en el espacio vectorial.

La métrica más utilizada es la **similitud coseno**, que mide el ángulo entre dos vectores con independencia de su magnitud:

$$\text{sim}(\vec{a}, \vec{b}) = \frac{\vec{a} \cdot \vec{b}}{|\vec{a}||\vec{b}|}$$

Aplicaciones prácticas

- **Búsqueda semántica**: encontrar documentos relevantes aunque no compartan términos exactos
- **Recomendación de contenido**: artículos, productos o canciones similares
- **Detección de paráfrasis**: identificar frases que dicen lo mismo de distinta forma
- **Clustering de textos**: agrupar documentos por temática
- **Traducción asistida**: alineamiento entre idiomas en espacios vectoriales

Análisis de Sentimiento

El **análisis de sentimiento** (o minería de opiniones) es un caso especial de clasificación de texto cuyo objetivo es identificar la polaridad emocional o actitudinal de un texto: positivo, negativo o neutro.

Enfoques principales

1 Léxico-basado

Usa diccionarios de sentimiento (SentiWordNet, AFINN). Rápido y sin necesidad de datos etiquetados, pero sensible a ironía y contexto.

2 Aprendizaje supervisado

Entrena un clasificador con textos etiquetados manualmente. Mayor precisión, pero requiere corpus anotado y puede no generalizar bien entre dominios.

Casos de uso reales

- 📊 Monitorización de marca en redes sociales
- ⭐ Análisis de reseñas de productos
- 🏛️ Análisis de opinión política en medios
- 💬 Evaluación de satisfacción del cliente (NPS)
- 📈 Análisis de sentimiento financiero en noticias

El análisis de sentimiento tiene limitaciones importantes: la ironía, el sarcasmo y el contexto cultural siguen siendo retos abiertos de investigación.

S12 · EN EL REPOSITORIO DEL CURSO

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

S12_03_nlp_clasico — 55 min

Reseñas: limpieza, TF-IDF, sentimiento, temas y n-gramas

sprints/S12/notebooks/S12_03_nlp_clasico.ipynb