

Autoencoders y Modelos Generativos

Sesión 12.4 · Una inmersión en las arquitecturas que permiten a las máquinas **comprender, comprimir y crear** contenido nuevo: desde autoencoders y espacios latentes hasta GANs, modelos de difusión y sus implicaciones éticas.

APRENDIZAJE AUTOMÁTICO | MODELOS GENERATIVOS | SESIÓN 12.4

Autoencoders y Espacio Latente

Un **autoencoder** es una red neuronal entrenada para aprender una representación comprimida de los datos de entrada y luego reconstruirlos con la mayor fidelidad posible. Su arquitectura consta de dos componentes fundamentales:

Codificador (Encoder)

Toma la entrada —por ejemplo, una imagen de 784 píxeles— y la proyecta sobre un **espacio latente** de dimensión mucho menor (p. ej., 32 dimensiones). Extrae las características más relevantes, descartando ruido e información redundante.

Decodificador (Decoder)

A partir del vector latente comprimido, reconstruye la salida original con la mayor fidelidad posible. El entrenamiento minimiza el **error de reconstrucción** entre entrada y salida, forzando al modelo a aprender representaciones útiles.

El espacio latente no es arbitrario: sus dimensiones capturan factores de variación semántica de los datos, como la forma, el color o el estilo en imágenes.

GANs: Redes Generativas Adversariales

Propuestas por Ian Goodfellow en 2014, las **GANs** revolucionaron la generación de datos sintéticos mediante un ingenioso esquema de competición entre dos redes neuronales entrenadas simultáneamente.



Generador

Recibe un vector de **ruido aleatorio** del espacio latente y lo transforma en una muestra sintética (imagen, audio, texto). Su objetivo es engañar al discriminador produciendo muestras indistinguibles de las reales.

Discriminador

Recibe muestras reales y falsas y aprende a **clasificarlas correctamente**. Actúa como árbitro: cuanto mejor discrimina, más presión ejerce sobre el generador para mejorar la calidad de sus síntesis.

Modelos de Difusión

Los **modelos de difusión** son la arquitectura dominante en generación de imágenes de alta calidad (Stable Diffusion, DALL·E, Midjourney). Su principio se basa en dos procesos opuestos:

1

Proceso de difusión directa

Se añade ruido gaussiano progresivo a una imagen real en **T pasos**, hasta obtener ruido puro. Este proceso es fijo y no se aprende.

2

Proceso de desnoise (reverse)

Una red neuronal aprende a **revertir el ruido** paso a paso, reconstruyendo o generando imágenes coherentes a partir del ruido puro.

3

Guía por texto (conditioning)

Los modelos modernos condicionan el proceso inverso con **embeddings de texto**, permitiendo generar imágenes a partir de descripciones en lenguaje natural.

Los modelos de difusión superan en calidad y diversidad a las GANs en muchos benchmarks, aunque son computacionalmente más costosos durante la inferencia.

Usos, Riesgos y Ética

La capacidad generativa de estos modelos abre posibilidades extraordinarias, pero también plantea desafíos éticos, legales y sociales que no pueden ignorarse.

🎨 Aplicaciones legítimas

Generación de imágenes artísticas, síntesis de datos de entrenamiento, compresión de señales, diseño asistido, avatares virtuales, restauración de fotografías antiguas y síntesis de voz accesible.

🎭 Deepfakes: una amenaza real

Los modelos generativos permiten crear vídeos y audios hiperrealistas de personas reales diciendo o haciendo cosas que nunca ocurrieron. Esto facilita la **desinformación, el fraude y el acoso**. La detección automatizada de deepfakes es un campo de investigación activo.

⚖️ Derechos de autor y propiedad intelectual

Los modelos se entrenan sobre datos masivos que incluyen obras protegidas sin consentimiento explícito. Surgen preguntas clave: ¿quién es el autor de una imagen generada por IA? ¿Puede el artista original reclamar derechos? La legislación europea y el debate académico están en plena evolución.

⚠ El uso irresponsable de modelos generativos puede causar daños reales. Como profesionales de IA, la dimensión ética es parte integral del trabajo técnico.

S12 · EN EL REPOSITORIO DEL CURSO

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

RETO

Reto del sprint — 65 min

Reparto y plan (paso 1) y datos y modelos de las partes A (reseñas) y C (asistente) (paso 2)

sprints/S12/guia/Reto_Sprint_12.md