



Autoencoders y Modelos Generativos

Sesión 12.4 · Una inmersión en las arquitecturas que permiten a las máquinas **comprender, comprimir y crear** contenido nuevo: desde autoencoders y espacios latentes hasta GANs, modelos de difusión y sus implicaciones éticas.

APRENDIZAJE AUTOMÁTICO

MODELOS GENERATIVOS

SESIÓN 12.4

Índice de contenidos

Esta sesión cubre cuatro grandes bloques que construyen progresivamente la comprensión de los modelos generativos modernos.

01

Autoencoders y espacio latente

Codificación, compresión y reconstrucción de datos mediante redes neuronales.

03

Modelos de difusión

Generación de imágenes mediante ruido progresivo y desnoise iterativo.

02

Redes Generativas Adversariales (GAN)

El juego entre generador y discriminador para sintetizar datos realistas.

04

Usos y riesgos

Deepfakes, derechos de autor y responsabilidad ética en IA generativa.

Autoencoders y Espacio Latente

Un **autoencoder** es una red neuronal entrenada para aprender una representación comprimida de los datos de entrada y luego reconstruirlos con la mayor fidelidad posible. Su arquitectura consta de dos componentes fundamentales:

Codificador (Encoder)

Toma la entrada —por ejemplo, una imagen de 784 píxeles— y la proyecta sobre un **espacio latente** de dimensión mucho menor (p. ej., 32 dimensiones). Extrae las características más relevantes, descartando ruido e información redundante.

Decodificador (Decoder)

A partir del vector latente comprimido, reconstruye la salida original con la mayor fidelidad posible. El entrenamiento minimiza el **error de reconstrucción** entre entrada y salida, forzando al modelo a aprender representaciones útiles.

- ❏ El espacio latente no es arbitrario: sus dimensiones capturan factores de variación semántica de los datos, como la forma, el color o el estilo en imágenes.


Variantes de Autoencoders

Más allá del autoencoder clásico, existen variantes que amplían su capacidad generativa y de representación.




Autoencoder Disperso (Sparse)

Impone una restricción de dispersión sobre las activaciones del espacio latente, fomentando representaciones más interpretables y especializadas.



Autoencoder Variacional (VAE)

El espacio latente sigue una distribución probabilística (normalmente gaussiana). Permite **muestrear puntos nuevos** para generar datos inéditos, siendo la base de muchos modelos generativos modernos.




Autoencoder Denoising

Se entrena añadiendo ruido artificial a la entrada y obligando al modelo a recuperar la versión limpia, aprendiendo representaciones más robustas.

GANs: Redes Generativas Adversariales

Propuestas por Ian Goodfellow en 2014, las **GANs** revolucionaron la generación de datos sintéticos mediante un ingenioso esquema de competición entre dos redes neuronales entrenadas simultáneamente.



Generador


Recibe un vector de **ruido aleatorio** del espacio latente y lo transforma en una muestra sintética (imagen, audio, texto). Su objetivo es engañar al discriminador produciendo muestras indistinguibles de las reales.

Discriminador

Recibe muestras reales y falsas y aprende a **clasificarlas correctamente**. Actúa como árbitro: cuanto mejor discrimina, más presión ejerce sobre el generador para mejorar la calidad de sus síntesis.

Modelos de Difusión

Los **modelos de difusión** son la arquitectura dominante en generación de imágenes de alta calidad (Stable Diffusion, DALL·E, Midjourney). Su principio se basa en dos procesos opuestos:



Los modelos de difusión superan en calidad y diversidad a las GANs en muchos benchmarks, aunque son computacionalmente más costosos durante la inferencia.

Usos, Riesgos y Ética

La capacidad generativa de estos modelos abre posibilidades extraordinarias, pero también plantea desafíos éticos, legales y sociales que no pueden ignorarse.

Aplicaciones legítimas

Generación de imágenes artísticas, síntesis de datos de entrenamiento, compresión de señales, diseño asistido, avatares virtuales, restauración de fotografías antiguas y síntesis de voz accesible.

Deepfakes: una amenaza real

Los modelos generativos permiten crear vídeos y audios hiperrealistas de personas reales diciendo o haciendo cosas que nunca ocurrieron. Esto facilita la **desinformación, el fraude y el acoso**. La detección automatizada de deepfakes es un campo de investigación activo.

Derechos de autor y propiedad intelectual

Los modelos se entrenan sobre datos masivos que incluyen obras protegidas sin consentimiento explícito. Surgen preguntas clave: ¿quién es el autor de una imagen generada por IA? ¿Puede el artista original reclamar derechos? La legislación europea y el debate académico están en plena evolución.

 El uso irresponsable de modelos generativos puede causar daños reales. Como profesionales de IA, la dimensión ética es parte integral del trabajo técnico.