Sprint 12 · Lenguaje, secuencias y modelos generativos

¿qué dicen los clientes y qué pasará mañana?

FECHAS
23–25/11

HORAS
18 h (5 h teoría · 6 h práctica · 7 h PBL, con el Sprint 13 integrado en el último día)

Reto de este sprint: «Escuchar al cliente». Ver el reto completo, explicado paso a paso · Reto en PDF (ecofriendly) · PDF de la guía · Cómo se trabaja un reto

Material del sprint

- **Guía del sprint (PDF):** `Guia_Sprint_12.pdf` · versión ecofriendly para imprimir
- **Reto completo, paso a paso:** `Reto_Sprint_12.md`
- **S12.1 · RNN LSTM GRU y series temporales:** `S12.1_RNN_LSTM_GRU_y_series_temporales.pdf`
- **S12.2 · NLP clasico y embeddings:** `S12.2_NLP_clasico_y_embeddings.pdf`
- **S12.3 · Transformers y LLM:** `S12.3_Transformers_y_LLM.pdf`
- **S12.4 · Autoencoders y modelos generativos:** `S12.4_Autoencoders_y_modelos_generativos.pdf`
- **¿Tu proyecto usará un modelo de lenguaje por internet?** Guía de acceso gratuito: `Acceso_modelos_de_lenguaje.md`

En esta carpeta: `guia/` PDF de la guía (normal y para imprimir) y el reto explicado paso a paso · `presentaciones/` diapositivas de cada sesión · `notebooks/` prácticas para abrir en Colab · `plantillas/` plantillas para el reto · `tests/` test de conocimientos

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Teoría = diapositivas · Práctica = cuaderno de Colab o actividad · Reto = trabajo en equipo · Ceremonia = momento de Scrum

Lunes 23/11

1. **Ceremonia**: Planning del reto «Escuchar al cliente» y reparto de las cinco áreas · *15 min*
2. **Teoría**: RNN, LSTM, GRU y series temporales · *1 h*
3. **Práctica**: Series temporales: *baselines*, descomposición y SARIMAX · *40 min*
4. **Práctica**: RNN, LSTM y GRU frente al *baseline* · *40 min*
5. **Teoría**: NLP clásico y embeddings · *40 min*
6. **Práctica**: Reseñas: limpieza, TF-IDF, sentimiento, temas y n-gramas · *55 min*

Martes 24/11

7. **Teoría**: Transformers y LLM · *55 min*
8. **Práctica**: Tokens, atención paso a paso y temperatura · *40 min*
9. **Práctica**: Mini RAG con la política, evaluación y seguridad · *55 min*
10. **Teoría**: Autoencoders y modelos generativos · *25 min*
11. **Reto**: Reparto y plan (paso 1) y datos y modelos de las partes A (reseñas) y C (asistente) (paso 2) · *1 h 15 min*

Miércoles 25/11

12. **Reto**: Parte B (ocupación), evaluación y seguridad del asistente y cierre (pasos 2–4) · *1 h 45 min*
13. **Test**: **Test de M4** (redes neuronales), solo se abre hoy · *30 min*

14. **Teoría**: Visualizar y comunicar resultados (Sprint 13, integrado; versión rápida) · *15 min*
15. **Práctica**: Matriz de confusión, ROC/PR, importancia, umbral y coste · *30 min*
16. **Reto**: Reto del Sprint 13: elegir el modelo y los costes → tres o cuatro gráficos → titular y viñetas. Usad el cuaderno plantilla y la plantilla del informe · *25 min*
17. **Ceremonia**: Entrega en `sprint-12/` (y el informe visual en `sprint-13/`), autoevaluación y coevaluación, review y retrospectiva · *45 min*

Qué aprenderás

- A **predecir una serie temporal** (la ocupación) y comprobar si gana a un método simple (*baseline*).
- A **leer reseñas con Python**: sentimiento y temas de queja o elogio.
- Qué son los **embeddings** y la **atención** de un Transformer.
- A montar un **mini asistente RAG** que cita su fuente y sabe decir «no consta», y a reconocer un *prompt injection*.

Prácticas

Todo se ejecuta sin internet (las partes **OPCIONAL / NO VERIFICADO** se pueden saltar). Nunca escribas claves de API en el código.

Notebook	Tema	Tiempo	Colab
`S12_01_series_temporales`	Serie temporal: baselines, descomposición, ARIMA/SARIMAX	50 min	Abrir en Colab
`S12_02_redes_recurrentes`	RNN, LSTM y GRU en Keras vs. baseline	50 min	Abrir en Colab
`S12_03_nlp_clasico`	Reseñas: limpieza, TF-IDF, sentimiento, temas y n-gramas	60 min	Abrir en Colab
`S12_04_embeddings_lsa`	Embeddings con LSA y buscador de reseñas parecidas	50 min (ampliación, en casa)	Abrir en Colab
`S12_05_transformers_atencion`	Tokens, atención paso a paso, temperatura (+ Hugging Face opcional)	50 min	Abrir en Colab
`S12_06_mini_rag`	Mini RAG con la política, evaluación y seguridad	70 min	Abrir en Colab
`S12_07_autoencoder_generativos`	Autoencoder para anomalías; idea de GAN y difusión	50 min (ampliación, en casa)	Abrir en Colab

Plantilla en esta carpeta: `plantilla_informe_cliente.md` (informe de reseñas).

Entrega / Reto · «Escuchar al cliente»

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData Canarias recibe decenas de reseñas y mensajes de huéspedes cada semana. Quiere saber qué opinan, prever la ocupación de la próxima semana y probar un asistente que responda con su política sin inventar nada. Los datos son sintéticos: dilo en el informe. **Entregáis** (carpeta `sprint-12/` del repositorio del equipo):

- `informe_resenas.md` (o PDF), 2 páginas: sentimiento, 3 temas criticados y 3 valorados, 5 citas, 3 recomendaciones y límites.
- Notebook de ocupación: partición temporal, baseline, modelo, tabla de MAE y previsión a 7 días.
- Notebook del asistente RAG con tabla de evaluación: 20 preguntas de referencia + 5 propias + 3 ataques.
- Nota de IA responsable (1 página `.md`): riesgos y medidas medidas.
- `LEEME.md` de 5 líneas para ejecutarlo todo. **Reglas:**

- Prohibido partir la serie al azar, o escalar/vectorizar antes de partir.
- Todo debe ejecutarse sin internet y sin claves; las cifras salen del código.
- Se presenta en la *review* (5 min por equipo). **Se valora:** corrección técnica, reproducibilidad (`SEMILLA = 42`), comunicación al cliente e IA responsable (0–4 cada uno).

Test de conocimientos · mié 25/11

Test de M4 · Redes neuronales · 12 preguntas · unos 20 min · individual, en el navegador, sin penalización por fallo. Cubre M4 (redes densas, CNN, series, lenguaje y Transformers).

Abrir el test (`https://ccoolboox.github.io/IFCD107-alumnado/sprints/S12/tests/test_M4.html`)

Solo se abre el día mié 25/11 (hora de Canarias). Al terminar, copia tu resultado y envíaselo al docente. Cuenta para el 30 % de «tests de conocimientos».

Definition of Done · antes de cerrar el sprint

- [ ] Test de conocimientos hecho el mié 25/11
- [ ] Serie partida **por fecha** y con **baseline** en la tabla.
- [ ] Escalado y vectorización ajustados solo con entrenamiento.
- [ ] El asistente cita la fuente y responde «No consta…» cuando no sabe.
- [ ] Probados 3 ataques de prompt injection.
- [ ] Ninguna clave en el código ni en el repositorio.
- [ ] Todo se ejecuta de arriba abajo, sin errores y sin internet.
- [ ] Entregable subido a la carpeta `sprint-12/` del repositorio del equipo.