# README Sprint S12 · Lenguaje, secuencias y modelos generativos

*¿qué dicen los clientes y qué pasará mañana?*

**FECHAS**
23–25/11

**HORAS**
18 h (5 h teoría · 6 h práctica · 7 h PBL, con el Sprint 13 integrado en el último día)

**ESTE README EN PDF**
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

## Qué aprenderás

1. A **predecir una serie temporal** (la ocupación) y a comprobar si tu modelo gana de verdad a un método simple (*baseline*).
2. A **leer reseñas con Python**: limpiar texto, medir el sentimiento y descubrir de qué se queja o qué alaba la gente.
3. A representar texto con **vectores (embeddings)** y a entender, con números pequeños, cómo funciona la **atención** de un Transformer.
4. A montar un **mini asistente con RAG** que responde con la política del alojamiento, cita su fuente y sabe decir "no consta".
5. A **evaluar** un asistente (aciertos, alucinaciones) y a reconocer un ataque de *prompt injection*; y a entender la idea de autoencoders, GAN y difusión.

## Requisitos previos

- Sprints 9–11: aprendizaje automático con scikit-learn, redes neuronales y Keras básico (capas, `fit`, épocas).
- Saber cargar datos con pandas y hacer gráficos sencillos.
- No necesitas cuenta en ningún servicio de IA: **todo se ejecuta sin internet**. Hay partes opcionales (marcadas **NO VERIFICADO**) para Colab o para un LLM instalado en tu equipo.

## Materiales del sprint

**Documentos del curso** (PDF y .md; las actividades van en la tabla siguiente)

| Material | Tema | Tiempo | Cuándo |
|---|---|---|---|
| Guía del sprint (PDF) · ecofriendly | Resumen del sprint: qué aprenderás, temario, material, reto y conclusión | 2 páginas | Antes de empezar |
| **Carpeta del reto: `Reto_S12/`** | Todo el material del reto junto: ficha (.md y PDF), plantillas y material de apoyo, hoja de autoevaluación y coevaluación y láminas del reto | — | Antes del planning y durante el reto |
| Reto completo, paso a paso (.md) · PDF · ecofriendly | Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes | — | Antes del planning y durante el reto |
| Resumen del sprint en una página | Lámina con la pregunta guía, qué aprenderás, cómo se reparte el sprint (teoría, práctica y reto) y dónde estás en el curso | — | Antes del planning |

| Material | Tema | Tiempo | Cuándo |
|---|---|---|---|
| El reto paso a paso · PDF con enlaces | Los pasos del reto con su día y minutos, el material de cada paso, los errores frecuentes y el uso de la IA | — | Durante el reto |
| Esquema del contenido y su relación con el reto | Qué presentación prepara cada pieza del entregable, con el material que se reutiliza después | — | Antes del planning y como guía durante el reto |
| Infografías del sprint | 3 láminas ilustradas | — | Antes del planning y durante el reto |
| Atlas de algoritmos | Atlas de algoritmos del sprint: series, RNN/LSTM/GRU, NLP, Transformers/LLM y autoencoders | — | Teoría y práctica; consulta cuando elijas modelo |
| Cómo se trabaja un reto | El método de trabajo de todos los retos | — | Antes del primer reto |
| `S12.1_RNN_LSTM_GRU_y_series_temporales.pdf` | RNN, LSTM, GRU y series temporales | 20 min | Teoría · día 1 del S12 |
| `S12.2_NLP_clasico_y_embeddings.pdf` | NLP clásico y embeddings | 15 min | Teoría · día 1 del S12 |
| `S12.3_Transformers_y_LLM.pdf` | Transformers y LLM | 30 min | Teoría · día 2 del S12 |
| `S12.4_Autoencoders_y_modelos_generativos.pdf` | Autoencoders y modelos generativos | 10 min | Teoría · día 2 del S12 |
| `S13.1_Visualizar_y_comunicar_resultados.pdf` | Visualizar y comunicar resultados (Sprint 13, integrado; versión rápida) | 10 min | Teoría · día 3 del S12 |
| `Acceso_modelos_de_lenguaje.md` | ¿Tu proyecto usará un modelo de lenguaje por internet? Guía de acceso gratuito | — | Si tu proyecto usa un modelo de lenguaje |
| Test de conocimientos | Test de M4 · Redes neuronales · 12 preguntas · individual, en el navegador, sin penalización por fallo. | 20 min | Solo se abre el mié 25/11 (hora de Canarias) |

**Material de las actividades**

Todo se ejecuta sin internet (las partes **OPCIONAL / NO VERIFICADO** se pueden saltar). Nunca escribas claves de API en el código.

| Notebook | Tema | Tiempo |
|---|---|---|
| `apuntes_series_lenguaje_y_generativa.md` · PDF · ecofriendly | **Apuntes que complementan las diapositivas**: series temporales, NLP (TF-IDF, embeddings), Transformers, RAG, prompt injection y autoencoders explicados con cuentas que puedes hacer a mano | — |

| Notebook | Tema | Tiempo |
|---|---|---|
| `S12_01_series_temporales` | Serie temporal: baselines, descomposición, ARIMA/SARIMAX | 45 min |
| `S12_02_redes_recurrentes` | RNN, LSTM y GRU en Keras vs. baseline | 45 min |
| `S12_03_nlp_clasico` | Reseñas: limpieza, TF-IDF, sentimiento, temas y n-gramas | 55 min |
| `S12_04_embeddings_lsa` | Embeddings con LSA y buscador de reseñas parecidas | 50 min (opcional, en casa) |
| `S12_05_transformers_atencion` | Tokens, atención paso a paso, temperatura (+ Hugging Face opcional) | 40 min |
| `S12_06_mini_rag` | Mini RAG con la política, evaluación y seguridad | 45 min |
| `S12_07_autoencoder_generativos` | Autoencoder para anomalías; idea de GAN y difusión | 50 min (opcional, en casa) |

Plantilla en esta carpeta: `plantilla_informe_cliente.md` (informe de reseñas).

## Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

**Día 1 del S12**

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 1 | Ceremonia | Planning del reto «Escuchar al cliente» y reparto de las cinco áreas | 10 min |
| 2 | Teoría | RNN, LSTM, GRU y series temporales | 20 min |
| 3 | Práctica | Series temporales: *baselines*, descomposición y SARIMAX | 45 min |
| 4 | Práctica | RNN, LSTM y GRU frente al *baseline* | 45 min |
| 5 | Teoría | NLP clásico y embeddings | 15 min |
| 6 | Práctica | Reseñas: limpieza, TF-IDF, sentimiento, temas y n-gramas | 55 min |
| 7 | Práctica | Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día | 10 min |

**Día 2 del S12**

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 8 | Teoría | Transformers y LLM | 30 min |
| 9 | Práctica | Tokens, atención paso a paso y temperatura | 40 min |
| 10 | Práctica | Mini RAG con la política, evaluación y seguridad | 45 min |
| 11 | Práctica | Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día | 10 min |
| 12 | Teoría | Autoencoders y modelos generativos | 10 min |
| 13 | Reto | Reparto y plan (paso 1) y datos y modelos de las partes A (reseñas) y C (asistente) (paso 2) | 1 h 5 min |

**Día 3 del S12**

| Nº | Tipo | Qué se hace | Tiempo |
|---|---|---|---|
| 14 | Reto | Parte B (ocupación), evaluación y seguridad del asistente y cierre (pasos 2–4) | 1 h 5 min |
| 15 | Test | **Test de M4** (redes neuronales), solo se abre hoy | 30 min |
| 16 | Teoría | Visualizar y comunicar resultados (Sprint 13, integrado; versión rápida) | 10 min |
| 17 | Práctica | Matriz de confusión, ROC/PR, importancia, umbral y coste | 35 min |
| 18 | Reto | Reto del Sprint 13: elegir el modelo y los costes → tres o cuatro gráficos → titular y viñetas. Usad el cuaderno plantilla y la plantilla del informe | 25 min |
| 19 | Ceremonia | Entrega en `sprint-12/` (y el informe visual en `sprint-13/`), autoevaluación y coevaluación, review y retrospectiva | 35 min |

## Entrega / Reto · «Escuchar al cliente»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

**Ver el reto completo, explicado paso a paso** (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

**Contexto:** TurisData Canarias recibe decenas de reseñas y mensajes de huéspedes cada semana. Quiere saber qué opinan, prever la ocupación de la próxima semana y probar un asistente que responda con su política sin inventar nada. Los datos son sintéticos: dilo en el informe.

**Entregáis** (carpeta `sprint-12/` del repositorio del equipo):

- `informe_resenas.md` (o PDF), 2 páginas: sentimiento, 3 temas criticados y 3 valorados, 5 citas, 3 recomendaciones y límites.
- Notebook de ocupación: partición temporal, baseline, modelo, tabla de MAE y previsión a 7 días.
- Notebook del asistente RAG con tabla de evaluación: 20 preguntas de referencia + 5 propias + 3 ataques.
- Nota de IA responsable (1 página `.md`): riesgos y medidas medidas.
- `LEEME.md` de 5 líneas para ejecutarlo todo.

**Reglas:**

- Prohibido partir la serie al azar, o escalar/vectorizar antes de partir.
- Todo debe ejecutarse sin internet y sin claves; las cifras salen del código.
- Se presenta en la *review* (5 min por equipo).

**Se valora:** corrección técnica, reproducibilidad (`SEMILLA = 42`), comunicación al cliente e IA responsable (0–4 cada uno).

### Definition of Done · antes de cerrar el sprint

- [ ] Test de conocimientos hecho el mié 25/11
- [ ] Serie partida **por fecha** y con **baseline** en la tabla.
- [ ] Escalado y vectorización ajustados solo con entrenamiento.
- [ ] El asistente cita la fuente y responde «No consta…» cuando no sabe.
- [ ] Probados 3 ataques de prompt injection.
- [ ] Ninguna clave en el código ni en el repositorio.
- [ ] Todo se ejecuta de arriba abajo, sin errores y sin internet.
- [ ] Entregable subido a la carpeta `sprint-12/` del repositorio del equipo.
- [ ] Autoevaluación y coevaluación rellenadas