README Sprint S12 · Lenguaje, secuencias y modelos generativos

¿qué dicen los clientes y qué pasará mañana?

FECHAS
23–25/11

HORAS
18 h (5 h teoría · 6 h práctica · 7 h PBL, con el Sprint 13 integrado en el último día)

ESTE README EN PDF
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

Qué aprenderás

1. A **predecir una serie temporal** (la ocupación) y a comprobar si tu modelo gana de verdad a un método simple (*baseline*).
2. A **leer reseñas con Python**: limpiar texto, medir el sentimiento y descubrir de qué se queja o qué alaba la gente.
3. A representar texto con **vectores (embeddings)** y a entender, con números pequeños, cómo funciona la **atención** de un Transformer.
4. A montar un **mini asistente con RAG** que responde con la política del alojamiento, cita su fuente y sabe decir "no consta".
5. A **evaluar** un asistente (aciertos, alucinaciones) y a reconocer un ataque de *prompt injection*; y a entender la idea de autoencoders, GAN y difusión.

Requisitos previos

- Sprints 9–11: aprendizaje automático con scikit-learn, redes neuronales y Keras básico (capas, `fit`, épocas).
- Saber cargar datos con pandas y hacer gráficos sencillos.
- No necesitas cuenta en ningún servicio de IA: **todo se ejecuta sin internet**. Hay partes opcionales (marcadas **NO VERIFICADO**) para Colab o para un LLM instalado en tu equipo.

Materiales del sprint

Documentos del curso (PDF y .md; las actividades van en la tabla siguiente)

Material	Tema	Tiempo	Cuándo
Guía del sprint (PDF) · ecofriendly	Resumen del sprint: qué aprenderás, temario, material, reto y conclusión	2 páginas	Antes de empezar
Reto completo, paso a paso (.md) · PDF · ecofriendly	Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes	—	Antes del planning y durante el reto
Infografías del reto	2 láminas ilustradas del reto	—	Reto
Cómo se trabaja un reto	El método de trabajo de todos los retos	—	Antes del primer reto
`S12.1_RNN_LSTM_GRU_y_series_temporales.pdf`	RNN, LSTM, GRU y series temporales	20 min	Teoría · lunes 23/11
`S12.2_NLP_clasico_y_embeddings.pdf`	NLP clásico y embeddings	15 min	Teoría · lunes 23/11
`S12.3_Transformers_y_LLM.pdf`	Transformers y LLM	30 min	Teoría · martes 24/11

Material	Tema	Tiempo	Cuándo
S12.4_Autoencoders_y_modelos_generativos.pdf	Autoencoders y modelos generativos	10 min	Teoría · martes 24/11
S13.1_Visualizar_y_comunicar_resultados.pdf	Visualizar y comunicar resultados (Sprint 13, integrado; versión rápida)	10 min	Teoría · miércoles 25/11
Acceso_modelos_de_lenguaje.md	¿Tu proyecto usará un modelo de lenguaje por internet? Guía de acceso gratuito	—	Si tu proyecto usa un modelo de lenguaje
Test de conocimientos	Test de M4 · Redes neuronales · 12 preguntas · individual, en el navegador, sin penalización por fallo.	20 min	Solo se abre el mié 25/11 (hora de Canarias)

Material de las actividades

Todo se ejecuta sin internet (las partes **OPCIONAL / NO VERIFICADO** se pueden saltar). Nunca escribas claves de API en el código.

Notebook	Tema	Tiempo
S12_01_series_temporales	Serie temporal: baselines, descomposición, ARIMA/SARIMAX	45 min
S12_02_redes_recurrentes	RNN, LSTM y GRU en Keras vs. baseline	45 min
S12_03_nlp_clasico	Reseñas: limpieza, TF-IDF, sentimiento, temas y n-gramas	55 min
S12_04_embeddings_lsa	Embeddings con LSA y buscador de reseñas parecidas	50 min (opcional, en casa)
S12_05_transformers_atencion	Tokens, atención paso a paso, temperatura (+ Hugging Face opcional)	40 min
S12_06_mini_rag	Mini RAG con la política, evaluación y seguridad	45 min
S12_07_autoencoder_generativos	Autoencoder para anomalías; idea de GAN y difusión	50 min (opcional, en casa)

Plantilla en esta carpeta: plantilla_informe_cliente.md (informe de reseñas).

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Lunes 23/11

N°	Tipo	Qué se hace	Tiempo
1	Ceremonia	Planning del reto «Escuchar al cliente» y reparto de las cinco áreas	10 min
2	Teoría	RNN, LSTM, GRU y series temporales	20 min
3	Práctica	Series temporales: *baselines*, descomposición y SARIMAX	45 min
4	Práctica	RNN, LSTM y GRU frente al *baseline*	45 min
5	Teoría	NLP clásico y embeddings	15 min
6	Práctica	Reseñas: limpieza, TF-IDF, sentimiento, temas y n-gramas	55 min

Nº	Tipo	Qué se hace	Tiempo
7	Práctica	Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día	10 min

Martes 24/11

Nº	Tipo	Qué se hace	Tiempo
8	Teoría	Transformers y LLM	30 min
9	Práctica	Tokens, atención paso a paso y temperatura	40 min
10	Práctica	Mini RAG con la política, evaluación y seguridad	45 min
11	Práctica	Terminad los cuadernos pendientes, incluido el apartado «en casa», y poneos al día	10 min
12	Teoría	Autoencoders y modelos generativos	10 min
13	Reto	Reparto y plan (paso 1) y datos y modelos de las partes A (reseñas) y C (asistente) (paso 2)	1 h 5 min

Miércoles 25/11

Nº	Tipo	Qué se hace	Tiempo
14	Reto	Parte B (ocupación), evaluación y seguridad del asistente y cierre (pasos 2–4)	1 h 5 min
15	Test	**Test de M4** (redes neuronales), solo se abre hoy	30 min
16	Teoría	Visualizar y comunicar resultados (Sprint 13, integrado; versión rápida)	10 min
17	Práctica	Matriz de confusión, ROC/PR, importancia, umbral y coste	35 min
18	Reto	Reto del Sprint 13: elegir el modelo y los costes → tres o cuatro gráficos → titular y viñetas. Usad el cuaderno plantilla y la plantilla del informe	25 min
19	Ceremonia	Entrega en `sprint-12/` (y el informe visual en `sprint-13/`), autoevaluación y coevaluación, review y retrospectiva	35 min

Entrega / Reto · «Escuchar al cliente»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData Canarias recibe decenas de reseñas y mensajes de huéspedes cada semana. Quiere saber qué opinan, prever la ocupación de la próxima semana y probar un asistente que responda con su política sin inventar nada. Los datos son sintéticos: dilo en el informe.

Entregáis (carpeta `sprint-12/` del repositorio del equipo):

- `informe_resenas.md` (o PDF), 2 páginas: sentimiento, 3 temas criticados y 3 valorados, 5 citas, 3 recomendaciones y límites.
- Notebook de ocupación: partición temporal, baseline, modelo, tabla de MAE y previsión a 7 días.
- Notebook del asistente RAG con tabla de evaluación: 20 preguntas de referencia + 5 propias + 3 ataques.
- Nota de IA responsable (1 página `.md`): riesgos y medidas medidas.
- `LEEME.md` de 5 líneas para ejecutarlo todo.

Reglas:

- Prohibido partir la serie al azar, o escalar/vectorizar antes de partir.
- Todo debe ejecutarse sin internet y sin claves; las cifras salen del código.
- Se presenta en la *review* (5 min por equipo).

Se valora: corrección técnica, reproducibilidad (`SEMILLA = 42`), comunicación al cliente e IA responsable (0–4 cada uno).

Definition of Done · antes de cerrar el sprint

- [ ] Test de conocimientos hecho el mié 25/11
- [ ] Serie partida **por fecha** y con **baseline** en la tabla.
- [ ] Escalado y vectorización ajustados solo con entrenamiento.
- [ ] El asistente cita la fuente y responde «No consta…» cuando no sabe.
- [ ] Probados 3 ataques de prompt injection.
- [ ] Ninguna clave en el código ni en el repositorio.
- [ ] Todo se ejecuta de arriba abajo, sin errores y sin internet.
- [ ] Entregable subido a la carpeta `sprint-12/` del repositorio del equipo.