README Sprint S12 · Lenguaje, secuencias y modelos generativos

¿qué dicen los clientes y qué pasará mañana?

FECHAS
23–25/11

HORAS
18 h (3 h teoría · 8 h práctica · 7 h PBL, con el Sprint 13 integrado en el último día)

ESTE README EN PDF
a color · ecofriendly, para imprimir (descárgalo para que funcionen los enlaces; la vista previa de GitHub no los abre).

Qué aprenderás

1. A **predecir una serie temporal** (la ocupación) y a comprobar si tu modelo gana de verdad a un método simple (*baseline*).
2. A **leer reseñas con Python**: limpiar texto, medir el sentimiento y descubrir de qué se queja o qué alaba la gente.
3. A representar texto con **vectores (embeddings)** y a entender, con números pequeños, cómo funciona la **atención** de un Transformer.
4. A montar un **mini asistente con RAG** que responde con la política del alojamiento, cita su fuente y sabe decir "no consta".
5. A **evaluar** un asistente (aciertos, alucinaciones) y a reconocer un ataque de *prompt injection*; y a entender la idea de autoencoders, GAN y difusión.

Requisitos previos

- Sprints 9–11: aprendizaje automático con scikit-learn, redes neuronales y Keras básico (capas, `fit`, épocas).
- Saber cargar datos con pandas y hacer gráficos sencillos.
- No necesitas cuenta en ningún servicio de IA: **todo se ejecuta sin internet**. Hay partes opcionales (marcadas **NO VERIFICADO**) para Colab o para un LLM instalado en tu equipo.

Materiales del sprint

Documentos del curso (PDF y .md; las actividades van en la tabla siguiente)

Material	Tema	Tiempo	Cuándo
Guía del sprint (PDF) · ecofriendly	Resumen del sprint: qué aprenderás, temario, material, reto y conclusión	2 páginas	Antes de empezar
Código explicado de los cuadernos	Cada cuaderno explicado por escrito: recorrido de 10 minutos con el docente, glosario de sus palabras de código y qué hace cada celda y cada línea (para leerlo con calma, mientras o después de ejecutar)	A tu ritmo	Con cada cuaderno
Carpeta del reto: `Reto_S12/`	Todo el material del reto junto: ficha (.md y PDF), plantillas y material de apoyo, hoja de autoevaluación y coevaluación y láminas del reto	—	Antes del planning y durante el reto
Reto en una página (.md) · PDF · ecofriendly	Lo esencial para trabajar con la ficha abierta: tres niveles (mínimo, estándar, extra), reparto del tiempo y frases para el informe	1 página	Durante el reto

Material	Tema	Tiempo	Cuándo
Reto completo, paso a paso (.md) · PDF · ecofriendly	Qué pide el cliente, pasos, rúbrica, ayudas y errores frecuentes	—	Antes del planning y durante el reto
Resumen del sprint en una página	Lámina con la pregunta guía, qué aprenderás, cómo se reparte el sprint (teoría, práctica y reto) y dónde estás en el curso	—	Antes del planning
El reto paso a paso · PDF con enlaces	Los pasos del reto con su día y minutos, el material de cada paso, los errores frecuentes y el uso de la IA	—	Durante el reto
Esquema del contenido y su relación con el reto	Qué presentación prepara cada pieza del entregable, con el material que se reutiliza después	—	Antes del planning y como guía durante el reto
Infografías del sprint	3 láminas ilustradas	—	Antes del planning y durante el reto
Atlas de algoritmos	Atlas de algoritmos del sprint: series, RNN/LSTM/GRU, NLP, Transformers/LLM y autoencoders	—	Teoría y práctica; consulta cuando elijas modelo
Cómo se trabaja un reto	El método de trabajo de todos los retos	—	Antes del primer reto
`S12.1_RNN_LSTM_GRU_y_series_temporales.pdf`	RNN, LSTM, GRU y series temporales	20 min	Teoría · día 1 del S12
`S12.2_NLP_clasico_y_embeddings.pdf`	NLP clásico y embeddings	15 min	Teoría · día 1 del S12
`S12.3_Transformers_y_LLM.pdf`	Transformers y LLM	30 min	Teoría · día 2 del S12
`S12.4_Autoencoders_y_modelos_generativos.pdf`	Autoencoders y modelos generativos	10 min	Teoría · día 2 del S12
`S13.1_Visualizar_y_comunicar_resultados.pdf`	Visualizar y comunicar resultados (Sprint 13, integrado; versión rápida)	10 min	Teoría · día 3 del S12
`Acceso_modelos_de_lenguaje.md`	¿Tu proyecto usará un modelo de lenguaje por internet? Guía de acceso gratuito	—	Si tu proyecto usa un modelo de lenguaje
Test de conocimientos	Test de M4 · Redes neuronales · 12 preguntas · individual, en el navegador, sin penalización por fallo.	20 min	Solo se abre el mié 25/11 (hora de Canarias)

Material de las actividades

Todo se ejecuta sin internet (las partes **OPCIONAL / NO VERIFICADO** se pueden saltar). Nunca escribas claves de API en el código.

Notebook	Tema	Tiempo
`apuntes_series_lenguaje_y_generativa.md` · PDF · ecofriendly	**Apuntes que complementan las diapositivas**: series temporales, NLP (TF-IDF, embeddings), Transformers, RAG, prompt injection y autoencoders explicados con cuentas que puedes hacer a mano	—
`S12_01_series_temporales`	Serie temporal: baselines, descomposición, ARIMA/SARIMAX	45 min
`S12_02_redes_recurrentes`	RNN, LSTM y GRU en Keras vs. baseline	45 min
`S12_03_nlp_clasico`	Reseñas: limpieza, TF-IDF, sentimiento, temas y n-gramas	55 min
`S12_04_embeddings_lsa`	Embeddings con LSA y buscador de reseñas parecidas	50 min (opcional, en casa)
`S12_05_transformers_atencion`	Tokens, atención paso a paso, temperatura (+ Hugging Face opcional)	40 min
`S12_06_mini_rag`	Mini RAG con la política, evaluación y seguridad	45 min
`S12_07_autoencoder_generativos`	Autoencoder para anomalías; idea de GAN y difusión	50 min (opcional, en casa)

Plantilla en esta carpeta: `plantilla_informe_cliente.md` (informe de reseñas).

Orden de trabajo del sprint

Sigue los pasos **en este orden**: primero la teoría, después la práctica que la aplica y, por último, el reto. Los tiempos son orientativos; si el docente cambia el ritmo, mantén el orden.

Día 1 del S12

Nº	Tipo	Qué se hace	Tiempo
1	Ceremonia	Planning del reto «Escuchar al cliente» y reparto de las cinco áreas	10 min
2	Teoría	RNN, LSTM, GRU y series temporales	20 min
3	Práctica	Series temporales: *baselines*, descomposición y SARIMAX (los ejercicios marcados «en clase»)	45 min
4	Práctica	RNN, LSTM y GRU frente al *baseline* (los ejercicios marcados «en clase»)	45 min
5	Teoría	NLP clásico y embeddings	25 min
6	Práctica	Reseñas: limpieza, TF-IDF, sentimiento, temas y n-gramas (los ejercicios marcados «en clase»)	55 min

Día 2 del S12

Nº	Tipo	Qué se hace	Tiempo
7	Teoría	Transformers y LLM	30 min
8	Práctica	Tokens, atención paso a paso y temperatura (los ejercicios marcados «en clase»)	40 min
9	Práctica	Mini RAG con la política, evaluación y seguridad (los ejercicios marcados «en clase»)	45 min

Nº	Tipo	Qué se hace	Tiempo
10	Teoría	Autoencoders y modelos generativos	10 min
11	Reto	Reparto y plan (paso 1) y datos y modelos de las partes A (reseñas) y C (asistente) (paso 2)	1 h 5 min
12	Práctica	Terminad los cuadernos pendientes y poneos al día	10 min

Día 3 del S12

Nº	Tipo	Qué se hace	Tiempo
13	Reto	Parte B (ocupación), evaluación y seguridad del asistente y cierre (pasos 2–4)	1 h 5 min
14	Test	**Test de M4** (redes neuronales), solo se abre hoy	30 min
15	Teoría	Visualizar y comunicar resultados (Sprint 13, integrado; versión rápida)	10 min
16	Práctica	Matriz de confusión, ROC/PR, importancia, umbral y coste	35 min
17	Reto	Reto del Sprint 13: elegir el modelo y los costes → tres o cuatro gráficos → titular y viñetas. Usad el cuaderno plantilla y la plantilla del informe	25 min
18	Ceremonia	Entrega en `sprint-12/` (y el informe visual en `sprint-13/`), autoevaluación y coevaluación, review y retrospectiva	35 min

Entrega / Reto · «Escuchar al cliente»

Reto en PDF · ecofriendly · Cómo se trabaja un reto

Ver el reto completo, explicado paso a paso (qué se pide, cómo hacerlo, cómo usar la IA, errores frecuentes y autoevaluación).

Contexto: TurisData Canarias recibe decenas de reseñas y mensajes de huéspedes cada semana. Quiere saber qué opinan, prever la ocupación de la próxima semana y probar un asistente que responda con su política sin inventar nada. Los datos son sintéticos: dilo en el informe.

Entregáis (carpeta `sprint-12/` del repositorio del equipo):

- `informe_resenas.md` (o PDF), 2 páginas: sentimiento, 3 temas criticados y 3 valorados, 5 citas, 3 recomendaciones y límites.
- Notebook de ocupación: partición temporal, baseline, modelo, tabla de MAE y previsión a 7 días.
- Notebook del asistente RAG con tabla de evaluación: 20 preguntas de referencia + 5 propias + 3 ataques.
- Nota de IA responsable (1 página `.md`): riesgos y medidas medidas.
- `LEEME.md` de 5 líneas para ejecutarlo todo.

Reglas:

- Prohibido partir la serie al azar, o escalar/vectorizar antes de partir.
- Todo debe ejecutarse sin internet y sin claves; las cifras salen del código.
- Se presenta en la *review* (5 min por equipo).

Se valora: corrección técnica, reproducibilidad (`SEMILLA = 42`), comunicación al cliente e IA responsable (0–4 cada uno).

Definition of Done · antes de cerrar el sprint

- ☐ Test de conocimientos hecho el mié 25/11
- ☐ Serie partida **por fecha** y con **baseline** en la tabla.
- ☐ Escalado y vectorización ajustados solo con entrenamiento.
- ☐ El asistente cita la fuente y responde «No consta…» cuando no sabe.
- ☐ Probados 3 ataques de prompt injection.
- ☐ Ninguna clave en el código ni en el repositorio.
- ☐ Todo se ejecuta de arriba abajo, sin errores y sin internet.

- [ ] Entregable subido a la carpeta `sprint-12/` del repositorio del equipo.
- [ ] Autoevaluación y coevaluación rellenadas