Sprint 13 · Contar lo que hace el modelo

Visualizar y comunicar resultados de IA con claridad y precisión

Los modelos de inteligencia artificial solo generan valor cuando sus resultados son comprensibles y accionables. En este sprint exploraremos las herramientas clave para visualizar el rendimiento, interpretar decisiones y comunicar conclusiones a distintos públicos: desde equipos técnicos hasta la alta dirección.



Importancia de Variables y Valores SHAP

Entender qué variables impulsan las predicciones del modelo es fundamental tanto para validar su comportamiento como para generar confianza en los equipos de negocio.



Importancia por permutación

Mide cuánto empeora el modelo al aleatorizar cada variable. Sencilla de calcular e independiente del algoritmo. Ideal para una primera exploración de relevancia global.



SHAP (Shapley Values)

Basado en teoría de juegos cooperativos, asigna a cada variable su contribución exacta en cada predicción individual. Permite explicaciones locales (caso a caso) y globales (visión de conjunto).



SHAP Beeswarm Plot

Visualización que muestra la distribución de valores SHAP para todas las observaciones y variables simultáneamente. Revela no solo la importancia sino también la dirección del efecto (positivo o negativo).

Grad-CAM: Ver lo que Ve la Red

Gradient-weighted Class Activation Mapping (Grad-CAM) es una técnica de interpretabilidad diseñada específicamente para redes neuronales convolucionales (CNN). Genera un mapa de calor que resalta las regiones de una imagen que más han influido en la predicción del modelo.

1

Propagación hacia atrás

Se calculan los gradientes de la clase objetivo respecto a los mapas de activación de la última capa convolucional.

2

Ponderación de mapas

Los gradientes se promedian globalmente para obtener pesos de importancia de cada mapa de características.

3

Superposición visual

El mapa resultante se redimensiona y superpone sobre la imagen original, destacando las zonas relevantes en color.

Grad-CAM es especialmente útil en medicina (diagnóstico por imagen), industria (inspección visual) y cualquier dominio donde sea necesario justificar por qué el modelo tomó una decisión visual.

Detección de Sesgos en Modelos de IA

Un modelo puede tener una exactitud global alta y aun así discriminar sistemáticamente a ciertos grupos. La detección de sesgos evalúa la equidad (*fairness*) del modelo antes de su despliegue en producción.

Sesgo de datos

Originado cuando los datos de entrenamiento no representan de forma equitativa a todos los grupos relevantes. Se detecta analizando la distribución del conjunto de datos por variables sensibles (género, edad, geografía...).

Sesgo de medición

El modelo rinde de forma diferente según el subgrupo evaluado. Se identifica comparando métricas (precisión, recall, FPR) segmentadas por atributos protegidos.

Herramientas de mitigación

Librerías como **Fairlearn** o **AI Fairness 360** ofrecen métricas estándar y algoritmos de corrección tanto en el preprocesado de datos como en el post-procesado de predicciones.

⚠ Ignorar el sesgo puede tener consecuencias legales y reputacionales severas. La equidad del modelo debe validarse siempre antes de producción.

Estructura de un Informe para Dirección

Un informe técnico bien construido no garantiza impacto si no está estructurado para la audiencia directiva. Los responsables de negocio necesitan conclusiones primero, evidencia después.

1 Resumen ejecutivo

Una sola página con el objetivo del modelo, la métrica principal, el resultado obtenido y la recomendación de acción. Debe ser autosuficiente.

2 Contexto y metodología

Descripción breve del problema, los datos utilizados y el enfoque de modelado. Evitar jerga técnica; usar analogías si es necesario.

3 Resultados y limitaciones

Las métricas más relevantes para el negocio, acompañadas de visualizaciones claras. Incluir siempre las limitaciones conocidas del modelo.

4 Próximos pasos

Acciones concretas y priorizadas: despliegue, monitorización, mejoras planificadas o decisiones que requieren aprobación directiva.



Paneles (*Dashboards*) de Rendimiento de Modelos

Un dashboard de IA bien diseñado permite monitorizar el comportamiento del modelo en producción de forma continua, detectando degradaciones antes de que impacten al negocio.



Monitorización en tiempo real

Métricas de rendimiento actualizadas continuamente: exactitud, latencia de predicción, volumen de solicitudes y tasa de errores del sistema.



Detección de deriva (*data drift*)

Alertas automáticas cuando la distribución de los datos de entrada se aleja significativamente de los datos de entrenamiento, señal de que el modelo puede estar desactualizándose.



Vista ejecutiva y técnica

Los mejores dashboards tienen capas de profundidad: una vista de alto nivel para dirección (semáforos, KPIs) y una vista técnica detallada para el equipo de datos.

S13 · EN EL REPOSITORIO DEL CURSO

Ahora, a practicar

Lo que viene a continuación está en tu repositorio; no hace falta buscar ejercicios fuera.

CUADERNO

S13_01_visualizacion_resultados — 35 min

Matriz de confusión, ROC/PR, importancia, umbral y coste

sprints/S13/notebooks/S13_01_visualizacion_resultados.ipynb

RETO

Reto del sprint — 25 min

Reto del Sprint 13: elegir el modelo y los costes → tres o cuatro gráficos → titular y viñetas. Usad el cuaderno…

sprints/S13/guia/Reto_Sprint_13.md