Sprint 14 · Reto «Proyecto final: definir, tener datos y un punto de partida»

Ficha completa del reto, para consultar. Leedla entera antes de empezar y volved a ella cuando tengáis dudas.

- Volver al README del sprint.
- Si es vuestro primer reto: Cómo se trabaja un reto.
- Reglas del proyecto final (requisitos R1–R11, rúbrica de 100 puntos, anexos A y B): `briefs_y_rubrica.md`.

RETO Ficha del reto

1 Qué os pide el cliente

Qué os pide el cliente. Sois una **consultora de IA** y el docente es el **cliente y Product Owner**. En los sprints 14 a 17 vais a hacer **un proyecto completo de principio a fin**: elegir un problema, conseguir datos reales, construir modelos, evaluarlos con honestidad y defenderlo. Este es el **primer sprint de los cuatro** y en él **todavía no se entrena el mejor modelo**: se decide **qué** vais a hacer y **cómo vais a demostrar que funciona**. Lo que decidáis ahora condiciona los otros tres sprints, así que conviene pensar antes de programar. Al terminar tendréis: un problema bien definido (la **ficha de proyecto**), **datos reales con licencia**, un primer análisis de esos datos (**EDA**), un modelo de referencia muy sencillo (**baseline**), un **backlog** (lista de tareas ordenada), un **registro de riesgos éticos** y un repositorio ordenado.

Cómo se trabaja. No hay un guion con pruebas como en otros retos: **vosotros decidís** el alcance, los datos concretos y las técnicas, dentro de unos mínimos. Elegís uno de **cuatro briefs** (demanda turística, salud de cultivos con imágenes, asistente de FP con un modelo de lenguaje o demanda eléctrica) o proponéis uno propio. Os damos **plantillas** para la ficha, el plan de datos, el backlog, el registro de riesgos y el README; vuestro trabajo es rellenarlas con criterio. En clase tenéis **tres jornadas** (600 minutos de sprint): día 1, elegir brief, validar datos y entregar la ficha **antes de las 14:30**; día 2, el docente responde **go / no-go** y hacéis el EDA y el baseline; día 3, backlog, riesgos, README, entrega, review y retro. El equipo decide hasta dónde llega: mínimo, estándar o extra.

2 · Recursos del reto

Recurso	Para qué lo usaréis	Dónde está
Las reglas del proyecto: `briefs_y_rubrica.md`	Saber qué se evalúa (R1–R11), leer los cuatro briefs y la rúbrica de 100 puntos	Léelo antes del planning; subrayad lo que no entendáis
Presentación S14.1 Lanzamiento del proyecto final y sus apuntes	Aprender a formular un proyecto de IA con un *canvas* (un esquema de una página)	El docente la explica el día 1 (25 minutos)
Plantilla de la ficha `plantilla_ficha_proyecto.md`	Resumir el proyecto en una página (anexo A)	Copiadla como `ficha_proyecto.md`
Plantilla del plan de datos `plantilla_plan_datos_licencias.md`	Documentar fuente, licencia, variables, calidad, linaje y partición	Copiadla como `plan_datos_licencias.md`

Recurso	Para qué lo usaréis	Dónde está
Plantilla del backlog `plantilla_backlog_y_sprints.md`	Historias de usuario, objetivo de cada sprint y retrospectivas	Copiadla como `backlog_y_sprints.md`
Plantilla del registro de riesgos `plantilla_registro_riesgos_eticos.md`	Checklist ético, clasificación RGPD / AI Act y registro de riesgos	Copiadla como `riesgos_eticos.md`
Plantilla del README `plantilla_README_repositorio.md`	Explicar el proyecto para que otra persona lo ejecute solo con ese README	Copiadla como `README.md`. Al final lleva la sección «Revisión con la rúbrica»
Fuentes de datos candidatas (ISTAC, Frontur-Canarias, datos.gob.es, AEMET, REData, PlantVillage, catálogo oficial de FP)	Encontrar datos reales y legales	En la tabla de briefs del paso 2. **Entrad vosotros en la web y leed la licencia**
Acceso gratuito a modelos de lenguaje	Solo si elegís el brief 3 (asistente de FP)	Guía de acceso
Google Colab (o vuestro Python)	Escribir y ejecutar `01_eda.ipynb` y `02_baseline.ipynb`	Colab no necesita instalar nada. Este sprint no tiene cuadernos de práctica propios; os sirven de apoyo los de pandas y limpieza del Sprint 6 (`S06_01` y `S06_02`)
Tablero del equipo (Trello o similar)	Cargar las historias del backlog y mover las tareas	El del equipo. Si no existe, es lo primero que se crea
Cómo entregar en GitHub	Subir los ficheros a `sprint-14/`	Guía de entrega
Autoevaluación y coevaluación	Cada persona rellena su hoja	Hoja del sprint
Un asistente de IA (opcional)	Ideas, borradores y revisión	Con las reglas de la «Ayuda 1» del paso a paso

3 · Qué entregar

Este apartado responde a **dos preguntas distintas**, una tabla para cada una:

Tabla A · Los ficheros: qué ficheros hay, de dónde sale cada uno (ya hecho, lo modificáis, lo creáis o lo genera el programa) y **cuáles se suben y adónde**.

Tabla B · Los requisitos: qué tiene que cumplir lo que entregáis y hasta dónde llegar (mínimo, estándar, extra). **Es lo que se evalúa.**

En total, al final del sprint se suben a `sprint-14/` : 6 ficheros del equipo (`ficha_proyecto.md` , `plan_datos_licencias.md` , `01_eda.ipynb` , `02_baseline.ipynb` , `backlog_y_sprints.md` , `riesgos_eticos.md`) **+ 1 autoevaluación y coevaluación por persona**, es decir, **6 + tantos ficheros como personas haya en el equipo** (un equipo de 3 sube 9). «El reto» no es un fichero aparte: son esos seis documentos y cuadernos. Además, el `README.md` y el `requirements.txt` van a la **raíz** del repositorio del equipo (no a `sprint-14/`), y los datos van a `data/` solo si la licencia lo permite. El tablero se enseña en la review y la *review* y la *retro* se hacen de palabra: no se suben.

Tabla A · Los ficheros: de dónde sale cada uno y cuáles se suben

Todo lo que se sube va al repositorio privado del equipo (`ifcd107-equipo-…`), en la carpeta **`sprint-14/`** , salvo lo que la

última columna indica.

Fichero	Origen	Qué hacéis vosotros	¿Se sube?
`ficha_proyecto.md`	**Lo creáis a partir de una plantilla.** Os damos `plantilla_ficha_proyecto.md` con los nueve apartados	Copiarla con ese nombre y rellenarla en una página; borrar las notas en cursiva	**Sí** · `sprint-14/`. El día 1 antes de las 14:30; si el *go / no-go* pide cambios, se vuelve a subir corregida
`plan_datos_licencias.md`	**Lo creáis a partir de una plantilla.** Os damos `plantilla_plan_datos_licencias.md`	Copiarla y rellenar fuentes, variables, calidad, linaje, partición y privacidad	**Sí** · `sprint-14/`
`01_eda.ipynb`	**Lo creáis.** Cuaderno nuevo de Colab: no hay plantilla	Describir los datos, buscar nulos, duplicados, valores raros y sesgos, y cerrar con el informe de calidad	**Sí** · `sprint-14/`
`02_baseline.ipynb`	**Lo creáis.** Cuaderno nuevo de Colab: no hay plantilla	Dividir los datos, construir el modelo más simple y calcular su métrica	**Sí** · `sprint-14/`
`backlog_y_sprints.md`	**Lo creáis a partir de una plantilla.** Os damos `plantilla_backlog_y_sprints.md` con historias de ejemplo	Copiarla, adaptar las historias a vuestro proyecto (10 a 15) y fijar el objetivo de cada sprint	**Sí** · `sprint-14/`
`riesgos_eticos.md`	**Lo creáis a partir de una plantilla.** Os damos `plantilla_registro_riesgos_eticos.md` (checklist, clasificación normativa y registro)	Copiarla y rellenar la columna S14 del checklist, la clasificación RGPD / AI Act y al menos 5 riesgos específicos	**Sí** · `sprint-14/`
`README.md`	**Lo creáis a partir de una plantilla.** Os damos `plantilla_README_repositorio.md`	Copiarla como `README.md` y rellenar lo que ya sabéis (apartados 1, 3, 4, 6, 7, 8 y 9); los resultados finales y el demostrador se rellenan en los sprints 15 y 16	**Sí** · raíz del repositorio (no en `sprint-14/`)
`requirements.txt`	**Lo creáis.** Una librería por línea, con su versión	Escribir `nombre==versión` de las librerías que usan los cuadernos	**Sí** · raíz del repositorio
Datos descargados	**Ya hecho.** Son datos de una fuente externa con licencia	Nada: se guardan sin cambiar; la limpieza se hace y se explica en el cuaderno	Solo si la licencia permite redistribuirlos y pesan poco · `data/`
`descargar_datos.py` (o un enlace de descarga en el README)	**Lo creáis.** Un script corto que descarga los datos	Escribirlo o, si hay enlace directo, apuntarlo en el README	Solo si no subís los datos · `sprint-14/`

Fichero	Origen	Qué hacéis vosotros	¿Se sube?
Autoevaluación y coevaluación (`autoevaluacion_nombre.md`)	**Ya hecha, en blanco**	Cada persona copia la plantilla con su nombre y la rellena; la coevaluación va **dentro del mismo fichero**	**Sí**, **una por persona** (no una por equipo) · `sprint-14/`
Canvas borrador y puntuación de briefs	**Lo creáis** en papel, pizarra o pantalla	Servirse de ellos para decidir; no hay formato	**No se suben**

Tabla B · Los requisitos: qué tiene que cumplir y hasta dónde llegar

Requisito	Qué se pide exactamente	Nivel	Dónde se comprueba
Brief y pregunta de negocio	Un brief elegido (uno de los cuatro o uno libre que cumpla R1–R11) y la pregunta de negocio en **una frase**, con el cliente y la decisión que apoyará	Mínimo	`ficha_proyecto.md` (apartados 2 y 3)
Ficha a tiempo	Ficha de una página subida **antes de las 14:30 del día 1**; el *go / no-go* se lee el día 2 y, si hace falta, se corrige	Mínimo	`ficha_proyecto.md` y su historial de subidas
Equipo y roles	Scrum Master, responsable técnico, responsable de datos y responsable de IA responsable, con la rotación prevista	Mínimo	`ficha_proyecto.md` (apartado 1)
Datos con fuente y licencia	Cada fuente con enlace, licencia, tamaño, variables, periodo y si hay datos personales. Sin licencia clara, no se usa. Nada de «a la espera de datos»	Mínimo	`plan_datos_licencias.md` (apartado 1)
Métrica de éxito	Métrica de negocio, métrica técnica, umbral de éxito y baseline previsto	Mínimo	`ficha_proyecto.md` (apartado 5)
EDA básico	Describir los datos (filas, columnas, periodo, tipos), contar nulos y duplicados y enseñar al menos tres gráficos o tablas que respondan a la pregunta	Mínimo	`01_eda.ipynb`
Baseline con su métrica	El modelo más simple posible, ejecutado de arriba abajo, con la métrica calculada	Mínimo	`02_baseline.ipynb`
Riesgos en la ficha	Tres riesgos con su mitigación y una clasificación preliminar del AI Act	Mínimo	`ficha_proyecto.md` (apartado 8)
Informe de calidad del dato	Nulos, duplicados, valores raros, **sesgos de muestreo** (¿quién o qué falta?), desequilibrios, posibles fugas y linaje, cada hallazgo con la acción tomada	Estándar	`01_eda.ipynb` y `plan_datos_licencias.md` (apartados 3 y 4)
Métrica y partición antes de ver resultados	La métrica técnica y la partición (temporal si hay series) se escriben **antes** de calcular el baseline y no se cambian después	Estándar	`plan_datos_licencias.md` (apartado 5), `ficha_proyecto.md` y `02_baseline.ipynb`
Backlog y objetivos	Entre 10 y 15 historias con objetivo para los sprints 15, 16 y 17, cargadas en el tablero	Estándar	`backlog_y_sprints.md` y el tablero
Plan ético	Checklist actualizado (columna S14), clasificación RGPD / AI Act justificada y **al menos 5 riesgos específicos** de vuestro proyecto, con probabilidad, impacto, medida y responsable	Estándar	`riesgos_eticos.md`

Requisito	Qué se pide exactamente	Nivel	Dónde se comprueba
Repositorio	README con lo que ya sabéis, `requirements.txt` y *commits* con mensaje claro de **todas las personas**, sin claves ni datos personales	Estándar	`README.md` y el historial del repositorio
Uso de IA	Qué se pidió a la IA, qué fuentes y licencias se comprobaron a mano y qué se cambió	Mínimo	`README.md` (apartado 7)
Revisión y autoevaluación	Alguien que **no escribió esa parte** revisa el trabajo con la rúbrica (justo debajo de estas tablas) y anota nivel y prueba en el README; cada persona sube su hoja de autoevaluación y coevaluación; el equipo hace la review y la retro	Estándar	`README.md` (sección «Revisión con la rúbrica»), `backlog_y_sprints.md` (retro) y `sprint-14/`
EDA ampliado	Además, el análisis por subgrupos (por isla, mes, clase o tipo de pregunta, según el brief) y un hallazgo que **cambia el enfoque** y queda reflejado en la ficha	Extra	`01_eda.ipynb` y `ficha_proyecto.md`
Backlog más detallado	Todas las historias con criterios de aceptación, tamaño, responsable y sprint, y un objetivo medible para cada sprint; las mitigaciones de riesgos enlazadas a historias	Extra	`backlog_y_sprints.md` y `riesgos_eticos.md`

Rúbrica del reto · cómo se puntúa y cómo se revisa

La usan **dos veces**: el equipo, para revisar su propio trabajo antes de entregar (es lo que dice la *Definition of Done*), y el docente, para puntuar el sprint. Se mira **cada criterio por separado** y se pone el nivel de la columna cuyo texto **se cumple entero**: si lo de un nivel se cumple a medias, es el nivel de abajo. **0** significa que no se ha entregado nada de ese criterio.

Orientación: lo que pide el nivel mínimo sale en un **2**, el estándar en un **3** y los extras en un **4**. La nota del **proyecto** final usa además la rúbrica de 100 puntos de `briefs_y_rubrica.md`.

Criterio	1 · Empezado	2 · Mínimo	3 · Estándar	4 · Extra
Corrección técnica (¿está bien hecho?)	Hay documentos, pero falta la pregunta o la métrica, o los cuadernos no se ejecutan	La ficha tiene pregunta, decisión y las dos métricas; `01_eda.ipynb` y `02_baseline.ipynb` se ejecutan de arriba abajo y el baseline da una métrica	La métrica y la partición se escribieron **antes** de ver resultados y no hay fuga (temporal si hay series); el informe de calidad tiene nulos, duplicados, valores raros y sesgos; el baseline es lo más simple posible	Además, un EDA por subgrupos con un hallazgo que cambia el enfoque y aparece en la ficha
Reproducibilidad (¿lo puede repetir otra persona?)	No se sabe de dónde salen los datos o los cuadernos solo funcionan en un ordenador	El plan de datos tiene fuente, enlace y licencia, pero el README no dice cómo descargarlos o ejecutar los cuadernos en orden	Otra persona descarga los datos y obtiene **la misma métrica del baseline** siguiendo solo el README; hay `requirements.txt` y *commits* de todas las personas, sin claves ni datos personales	Además, el linaje está completo (descarga, limpieza, partición), el README indica versión de Python y semilla, y el script de descarga funciona desde cero
Análisis y comunicación al cliente (¿lo entiende quien no programa?)	La pregunta es vaga («analizar el turismo») y no dice qué decisión apoya	La pregunta cabe en una frase y hay cliente, pero la decisión o la métrica de negocio no están claras	La ficha dice **qué decisión mejora y qué pasa hoy sin el modelo**, con un umbral de éxito en términos del cliente; en la review se explica el hallazgo del EDA y el baseline sin jerga	Además, cuantifica el valor para el cliente (euros, horas o errores evitados) y explica qué cambió de la ficha tras el *go / no-go* o el EDA

Criterio	1 · Empezado	2 · Mínimo	3 · Estándar	4 · Extra
IA responsable (¿se sabe qué hizo la IA y qué riesgos hay?)	No dice si se ha usado IA ni hay riesgos	Dice que se ha usado IA sin detalle; la ficha tiene tres riesgos y una clasificación AI Act, aunque sean genéricos	Dice **qué se pidió, qué se comprobó a mano y qué se cambió**; el registro tiene al menos 5 riesgos específicos de vuestros datos con probabilidad, impacto, medida y responsable, y la clasificación RGPD / AI Act está justificada	Además, cada riesgo alto tiene una medida enlazada a una historia del backlog y se cuenta un caso concreto en que la IA inventó o falló en algo y cómo lo detectasteis

Cómo se revisa (unos 10 minutos, antes de la review; lo hace **una persona que no escribió esa parte**):

1. **Ejecutar**, en una carpeta o un Colab limpios, lo que dice el README: descargar los datos y ejecutar `01_eda.ipynb` y `02_baseline.ipynb` en orden. Anotar si algo no funciona o si la métrica del baseline no sale igual.
2. **Leer la ficha como si fuera el cliente**: ¿se entiende la pregunta, la decisión que apoya y cuándo se considerará un éxito? Subrayar lo que no se entienda.
3. **Comprobar los datos y los riesgos**: abrir el enlace de cada fuente, leer la licencia y comprobar que coincide con el plan de datos; leer los cinco riesgos y ver si podrían valer para cualquier otro proyecto (si sí, son genéricos).
4. **Poner un nivel (1 a 4) en cada criterio, con una frase de prueba** (por ejemplo: «3 · la métrica se escribió antes, pero falta el informe de duplicados»; «2 · el README no dice cómo descargar los datos»). Sin prueba escrita, el nivel no vale.
5. **Apuntar el resultado** en la sección «Revisión con la rúbrica» del `README.md` y corregir lo más fácil de arreglar. Lo demás se anota como mejora.

Cada persona, además, se puntúa a sí misma en su hoja de autoevaluación y coevaluación con **esta misma rúbrica**.

---

4 · Guía paso a paso

Son siete pasos, de **600 minutos en total** (tres jornadas). Cada uno dice **qué hacéis** (la lista corta), **cómo se hace** con el detalle, **qué deberíais ver** y **cuándo está hecho**. Las ayudas (IA, errores, atascos) están al final. Si el tiempo aprieta, completad el nivel mínimo y dejad lo demás para casa. **No tengáis prisa por programar:** en este sprint lo importante es pensar bien.

Paso 1 · Planning, píldora y taller (día 1, 75 minutos)

1. Leer las reglas del proyecto y repartir los roles del sprint.
2. Escuchar la píldora de teoría sobre cómo formular un proyecto de IA.
3. Hacer el taller de Design Thinking y salir con uno o dos briefs candidatos y un *canvas* borrador.

Cómo se hace

- **Las reglas (10 minutos de planning).** Abrid `briefs_y_rubrica.md` y leed las reglas comunes, los requisitos **R1 a R11** y la rúbrica de 100 puntos. Subrayad lo que no entendáis y preguntadlo ahora.
- **Los roles.** Hay cuatro: **Scrum Master** (cuida el trabajo del equipo y el tablero), **responsable técnico** (que todo se pueda repetir), **responsable de datos** (fuentes, licencias y calidad) y **responsable de IA responsable** (riesgos y ética). Con tres personas, una asume dos. Los roles **rotan cada sprint**: apuntad quién empieza y quién pasa a qué en el 15 y el 16.
- **La píldora (25 minutos).** El docente explica el *canvas*: la pregunta de negocio, quién usa el resultado, la decisión que mejora, los datos y la métrica. Los apuntes están en `apuntes_formular_un_proyecto_de_ia.md`.
- **El taller (40 minutos).** Pensad en un problema **real y cercano**: ¿quién lo sufre?, ¿qué decisión se toma hoy sin datos? Escribid preguntas del tipo «¿Cómo podríamos…?». Quedaos con **uno o dos briefs candidatos** y rellenad un *canvas* borrador en papel o en una pizarra.

Qué deberíais ver. Cuatro roles con nombre y apellidos en una nota del equipo, y un *canvas* con la pregunta, el cliente, la decisión, los datos posibles y la métrica, aunque sea a lápiz.

Hecho cuando: cada persona sabe su rol y tenéis uno o dos briefs candidatos.

Paso 2 · Elegir el brief (día 1, 15 minutos)

1. Comparar los briefs candidatos con tres criterios.
2. Decidir y apuntar el brief elegido, **antes del descanso**: es el primer hito del día.

Cómo se hace. Los cuatro briefs son:

Brief	Pregunta guía	Pensad en…
1 · Demanda turística	¿Podemos predecir la llegada de turistas con 3–6 meses de antelación y qué factores la explican?	Series temporales. Carga de cómputo baja
2 · Salud de cultivos (visión)	¿Con qué fiabilidad se distingue una hoja sana de una enferma y cuándo no fiarnos?	Imágenes. Carga alta (GPU)
3 · Asistente de FP (LLM/RAG)	¿Puede un asistente responder sin inventar y cómo lo medimos?	Texto. Carga media
4 · Demanda eléctrica	¿Predecimos la demanda de las próximas 24 h mejor que un modelo de referencia?	Series temporales con calendario. Carga media

- **Cómo elegir.** Puntuad cada brief de 1 a 5 en tres criterios: **¿hay datos reales accesibles?**, **¿nos interesa?** y **¿se puede terminar en el tiempo que hay?** (unas 54 horas de proyecto en los tres primeros sprints). Elegid el que más puntos sume.
- **Dos equipos pueden elegir el mismo brief**, pero cada uno define **su propia pregunta y su propia métrica**.
- **Brief libre.** Podéis proponer uno propio si lo presentáis en la ficha **antes del 26/11**, cumple R1–R11, tiene datos reales ya identificados, una dificultad parecida a la de los otros y no usa datos personales sensibles.

Qué deberíais ver. Una tabla con vuestras puntuaciones y un brief marcado como elegido.

Hecho cuando: el equipo ha elegido su brief y todo el mundo sabe cuál es.

Paso 3 · Buscar y validar datos (día 1, 60 minutos)

1. Hacer una lista de fuentes candidatas para vuestro brief.
2. Responder, para cada fuente, a cinco preguntas de validación.
3. Rellenar `plan_datos_licencias.md` con lo que sabéis y quedaros con las fuentes que valen.

Cómo se hace

- **Las cinco preguntas.** Para cada fuente candidata (en la tabla de briefs de la ficha tenéis candidatas como ISTAC, Frontur-Canarias, datos.gob.es, AEMET, REData, PlantVillage o el catálogo oficial de FP):
- ¿Tiene una **licencia** que permita usarla? Si no está clara, **no se usa**.
- ¿Se puede **descargar**, y podemos repetir la descarga con un enlace o un script?
- ¿Qué **tamaño** tiene? ¿Cabe en nuestro ordenador o en Colab?
- ¿Qué **variables y qué periodo** trae? ¿Responden a nuestra pregunta?
- ¿Hay **datos personales**? Si los hay y son sensibles, **no se aceptan**.
- **Reparto.** El responsable de datos lleva la plantilla; las demás personas buscan y validan una fuente cada una. **Entrad vosotros en la web y leed la licencia**: no os fiéis de lo que diga una IA.
- **La plantilla.** Copiad `plantilla_plan_datos_licencias.md` como `plan_datos_licencias.md`. Hoy rellenad el apartado 1 (inventario de fuentes), el 2 (variables) y el 6 (privacidad); el resto se completa el día 2 con el EDA. Las licencias más frecuentes (CC BY, CC BY-SA, CC BY-NC, CC0) están explicadas en la propia plantilla.
- **Brief 3.** Si elegís el asistente de FP, mirad la guía de acceso gratuito a modelos de lenguaje.
- **Regla de oro.** No se aceptan proyectos «a la espera de datos»: los datos han de estar identificados y accesibles hoy.

Qué deberíais ver. Una tabla con al menos una fuente validada (enlace, licencia, tamaño, variables y «datos personales: no») y, si descartasteis alguna, la razón escrita.

Hecho cuando: tenéis al menos una fuente con licencia clara, descargable y sin datos personales sensibles.

Paso 4 · Ficha del proyecto y entrega (día 1, 50 minutos)

1. Copiar `plantilla_ficha_proyecto.md` como `ficha_proyecto.md` y rellenar los nueve apartados en una página.
2. Revisarla entre todos: ¿se entiende sin explicaciones?
3. Subirla a `sprint-14/` **antes de las 14:30**.

Cómo se hace

- **Qué escribís en cada apartado.** La plantilla es corta; cada apartado pide una cosa:

Apartado de la ficha	Qué escribís
1 · Equipo y roles	Los cuatro roles con su nombre y la rotación prevista
2 y 3 · Brief, pregunta, cliente y decisión	La pregunta de negocio en **una frase**, quién usará el resultado y qué decisión mejora (y qué pasa hoy sin el modelo)
4 · Datos	Las fuentes validadas en el paso 3: enlace, licencia, tamaño, variables y limitaciones
5 · Métrica y baseline	Métrica de negocio, **métrica técnica**, umbral de éxito, baseline previsto y cómo partiréis los datos
6 y 7 · Modelos y demostrador	Al menos tres modelos (uno neuronal, o un LLM con RAG en el brief 3) y qué hará el demostrador
8 y 9 · Riesgos y backlog	Tres riesgos con su mitigación, una clasificación AI Act preliminar y las historias principales con el objetivo de cada sprint

- **Un buen resultado se parece a esto.** Pregunta: «¿Podemos predecir la ocupación hotelera de Gran Canaria con 3 meses de antelación con un error menor del 8 %, para planificar plantilla y compras?». Decisión que apoya: «Cuándo contratar refuerzo en temporada media». Baseline: «Predecir lo mismo que el año anterior en la misma semana». Un riesgo específico: «Los datos son de hoteles grandes: no representan a pequeños alojamientos rurales».
- **La métrica, ahora.** Escribid la métrica técnica y el umbral **ahora** y no los cambiéis cuando veáis los resultados.
- **Subirla.** Seguid la guía de entrega: entrad en la carpeta `sprint-14` del repositorio del equipo, *Add file* → *Upload files* (o *Create new file* y pegar el texto), mensaje corto y **Commit changes**. El nombre, en minúsculas y sin espacios. El docente la lee en el repositorio y responde con el *go / no-go* **el día siguiente por la mañana**.

Qué deberíais ver. Una ficha de una página, sin notas en cursiva, y `ficha_proyecto.md` dentro de `sprint-14/` en GitHub con la hora de la subida anterior a las 14:30.

Hecho cuando: la ficha está subida antes de las 14:30 y el docente puede abrirla.

Paso 5 · Go / no-go, EDA, calidad del dato y baseline (día 2, 200 minutos)

1. Leer el *go / no-go* del docente y corregir la ficha si hace falta.
2. Hacer el EDA y el informe de calidad del dato en `01_eda.ipynb`.
3. Fijar la partición de los datos y la métrica técnica **antes** de mirar resultados.
4. Construir el baseline en `02_baseline.ipynb` y calcular su métrica.

Cómo se hace. Reparto sugerido de los 200 minutos:

Bloque	Qué hacéis	Minutos
5.1	Leer el *go / no-go* y corregir la ficha	20
5.2	EDA e informe de calidad	90

Bloque	Qué hacéis	Minutos
5.3	Partición y métrica	20
5.4	Baseline y subida de los cuadernos	70

5.1 · El go / no-go (20 minutos)

Hay tres respuestas posibles: **GO** (adelante), **GO con cambios** o **NO-GO** (hay que cambiar el enfoque). Un *no-go* o un cambio es **normal**: corregid la ficha ese mismo día, subid la versión 2 a `sprint-14/` con otro mensaje de *commit* y seguid. Si el docente cambia el alcance, apuntadlo en la ficha.

5.2 · EDA e informe de calidad (90 minutos)

En Colab, abrid un cuaderno nuevo y guardadlo como `01_eda.ipynb`. La primera celda carga los datos con el enlace o el script del plan de datos. Después, un EDA con estas preguntas:

Orden	Qué miráis	Qué escribís
1	Qué trae el conjunto: filas, columnas, periodo y tipos	Una tabla o un resumen de tres líneas
2	**Nulos** y **duplicados**	Cuántos hay y qué hacéis con ellos
3	**Valores raros** (imposibles o muy extremos)	Qué son y si los quitáis o los dejáis, y por qué
4	**Sesgo de muestreo**: ¿quién o qué falta en los datos?	Una frase, por ejemplo «solo hay hoteles grandes»
5	Tres gráficos o tablas que respondan a **vuestra pregunta**	Un título y una frase de conclusión por gráfico
6	**Fugas posibles**: variables que no se conocen en el momento de decidir	Cuáles hay y si se descartan

En el brief 2 mirad cuántas imágenes hay por clase; en el brief 3, cuántos documentos hay y cómo de largos son. Terminad con el **informe de calidad del dato**: rellenad el apartado 3 de `plan_datos_licencias.md` (hallazgo y acción tomada, uno por fila) y el apartado 4 (**linaje**: de dónde viene el dato y qué le habéis hecho). Elegid **un hallazgo que cambie el enfoque** para contarlo en la review.

5.3 · Partición y métrica (20 minutos)

Antes de ejecutar ningún modelo, escribid en el apartado 5 de `plan_datos_licencias.md` y en el apartado 5 de la ficha:

- **Cómo partís los datos:** si hay series de tiempo, **por fechas** (entrenar con el pasado y evaluar con el futuro); si no, aleatoria y estratificada. Y por qué así se evitan las fugas.
- **Qué tamaño tiene cada parte:** entrenamiento, validación y test. **El test no se toca hasta el final del proyecto.**
- **La métrica técnica** (por ejemplo MAE, MAPE, F1 o aciertos sobre 40 preguntas) y el umbral de éxito.

5.4 · Baseline (70 minutos)

Abrid `02_baseline.ipynb`. Construid el **modelo más simple posible**: «predecir lo mismo que ayer o que el año anterior», la media, la clase más frecuente o una búsqueda por palabras clave. Calculad su métrica sobre la **validación** y dejad escrita una frase: «Nuestro baseline tiene [métrica] de [valor]». Es el **suelo** que intentaréis superar en los sprints siguientes; no lo compliquéis. Después, en cada cuaderno, *Entorno de ejecución → Reiniciar y ejecutar todo*, *Archivo → Descargar → Descargar .ipynb* y subid el fichero a `sprint-14/` (cada cuaderno, una persona distinta).

Qué deberíais ver. La ficha con el *go* (o corregida), un `01_eda.ipynb` que termina con la tabla de calidad, la partición y la métrica escritas, y un `02_baseline.ipynb` que acaba con un número.

Hecho cuando: los dos cuadernos se ejecutan de arriba abajo sin errores, la métrica y la partición están escritas antes del baseline y los cuadernos están en `sprint-14/`.

Paso 6 · Backlog, plan ético y repositorio (día 3, 140 minutos)

1. Hacer el backlog de 10 a 15 historias y fijar el objetivo de cada sprint.
2. Rellenar el plan ético con al menos 5 riesgos específicos.
3. Montar el repositorio: README, `requirements.txt` y *commits* de todas las personas.

Cómo se hace. Reparto sugerido de los 140 minutos: 45 el backlog, 45 el plan ético y 50 el repositorio. Cada parte la lidera una persona distinta, y otra la revisa.

6.1 · Backlog (45 minutos)

Copiad `plantilla_backlog_y_sprints.md` como `backlog_y_sprints.md`. La plantilla trae doce historias de ejemplo: **adaptadlas** a vuestro proyecto y añadid las vuestras hasta tener entre **10 y 15**.

Orden	Qué hacéis	Pista
1	Escribir cada historia como «**Como** [rol] **quiero** [qué] **para** [beneficio]»	Una historia = una tarea que cabe en unas horas
2	Añadir criterios de aceptación, tamaño (S, M o L), sprint y responsable	Si no sabéis cómo comprobarla, no está bien definida
3	Escribir el **objetivo de cada sprint** (14, 15, 16 y 17) en una frase medible	Con los hitos: 3/12 modelo candidato, 10/12 a las 14:30 congelación y 14/12 defensa
4	Cargar las historias en el **tablero**	El Scrum Master lo mantiene al día

6.2 · Plan ético (45 minutos)

Copiad `plantilla_registro_riesgos_eticos.md` como `riesgos_eticos.md`. Este documento **actualiza el checklist de IA responsable del Sprint 1** (`checklist_etico_v1.md`): si lo tenéis, pasad vuestras respuestas a la columna S1.

- **Parte A.** Rellenad la columna **S14** del checklist con , ◐, o n/a y la evidencia (por ejemplo, el plan de datos o el EDA).
- **Parte B.** Contestad si hay datos personales, si haría falta una evaluación de impacto, el **nivel de riesgo del AI Act** y qué obligaciones se derivan.
- **Parte C.** Escribid **al menos 5 riesgos específicos de vuestros datos** (no «cuidado con los sesgos»), con probabilidad y impacto de 1 a 3 (nivel = P × I), la medida y el responsable. Mirad los ejemplos por brief al final de la parte C, pero no los copiéis: ajustadlos con vuestras cifras. Dejad vacía la última columna («cómo se evaluó la mitigación»): se rellena en el sprint 16.

6.3 · Repositorio (50 minutos)

- Copiad `plantilla_README_repositorio.md` como `README.md` y rellenad lo que ya sabéis: el problema en tres líneas (apartado 1), la estructura real del repositorio (apartado 3: anotad que hoy los documentos y cuadernos están en `sprint-14/`), **cómo reproducirlo** (apartado 4: descargar los datos y ejecutar los cuadernos en orden), los datos y licencias (6), el resumen de IA responsable (7), el equipo (8) y el tablero (9). La tabla de resultados y el demostrador se rellenan en los sprints 15 y 16.
- Escribid `requirements.txt`: una librería por línea con su versión, como `nombre==versión`. La versión sale con `pip show nombre` o, en Colab, con `!pip freeze` y buscando el nombre.
- Comprobad que **todas las personas** tienen al menos un *commit* (mensajes del tipo `docs: añado backlog`, `data: añado plan de datos`). Ningún dato personal ni claves.
- En el apartado 7 del README, **declarad el uso de IA**: qué pedisteis y qué comprobasteis a mano.

Qué deberíais ver. `backlog_y_sprints.md` con entre 10 y 15 historias y cuatro objetivos de sprint, `riesgos_eticos.md` con cinco filas rellenas, un `README.md` y un `requirements.txt` en la raíz y un tablero con las historias.

Hecho cuando: los cuatro documentos están escritos, el tablero tiene las historias y otra persona podría descargar los datos y ejecutar los cuadernos solo con el README.

Paso 7 · Revisión, entrega, review y retro (día 3, 60 minutos)

1. Revisar el trabajo con la rúbrica, por alguien que no escribió esa parte, y anotar el resultado en el README.
2. Subir lo que falte a `sprint-14/` y cada persona su autoevaluación y coevaluación.
3. Enseñar el sprint en la review: 5 minutos por equipo.
4. Hacer la retro (15 minutos) y apuntarla.

Cómo se hace

- **La revisión con la rúbrica (10 minutos).** Quien revisa sigue los cinco pasos de «Cómo se revisa» (apartado 3) y rellena la sección **«Revisión con la rúbrica»** del final del `README.md`: un nivel de 1 a 4 por criterio y **una frase de prueba**. Si hay tiempo, arreglad lo más fácil; lo demás queda como «lo primero que mejoraríamos».
- **Subir los ficheros.** Con la guía de entrega: los seis ficheros del equipo a `sprint-14/` y el `README.md` y el `requirements.txt` a la raíz, **en subidas hechas por personas distintas**. Cada persona sube también su `autoevaluacion_nombre.md` (el nombre en minúsculas, sin espacios ni tildes) a `sprint-14/`. En la parte de coevaluación, una **valoración breve de la primera semana**.
- **La review (5 minutos por equipo).** Contad: (1) la pregunta de negocio y la decisión que apoyará; (2) los datos y **un hallazgo del EDA que cambia el enfoque**; (3) el baseline y su métrica; (4) tres riesgos éticos; (5) el backlog de los próximos sprints. Los cambios de alcance después del *go* se negocian en la review.
- **La retro (15 minutos).** Una cosa que seguir haciendo, una que cambiar y **una acción concreta** para el sprint 15. Anotadla en el apartado 5 de `backlog_y_sprints.md` y comprobad en cada retro si cumplisteis la acción anterior.

Qué deberíais ver. En `sprint-14/` del repositorio, los seis ficheros del equipo y una hoja de autoevaluación por persona (**6 + N**); en la raíz, el README con la sección de revisión rellena; y en el historial (el icono del reloj), *commits* de todas las personas.

Hecho cuando: la sección «Revisión con la rúbrica» está rellena, todos los ficheros están subidos, cada persona ha subido su autoevaluación y coevaluación y habéis hecho la review y la retro.

Ayuda 1 · Cómo usar la IA en este reto

En un proyecto largo la IA puede ayudar mucho, pero **la responsabilidad es vuestra** y **puede inventar fuentes, licencias y enlaces**. Reglas:

- **Nunca inventéis una fuente o una licencia.** Si la IA os da un enlace, entrad y comprobadlo.
- **Que el proyecto sea vuestro:** la idea, la pregunta y la métrica salen del equipo. No se acepta copiar un cuaderno de internet.
- **Declarad el uso de IA** en el apartado 7 del README: qué pedisteis y qué comprobasteis a mano.
- **Nada de datos personales ni claves** en una IA ni en el repositorio.

Para qué	Ejemplo de petición	Qué comprobáis
Encontrar fuentes de datos	«Dame fuentes abiertas de datos de llegada de turistas a Canarias y qué licencias suelen tener»	**Entrad vosotros en la web**, leed la licencia y comprobad que los datos existen
Redactar la ficha	«Ayúdame a convertir estas notas en una pregunta de negocio clara con una métrica»	Que sea **vuestra** idea, no una genérica
Planificar	«Convierte este objetivo en 5 historias de usuario pequeñas»	Que son realizables en el tiempo que tenéis
Revisar riesgos	«Para un proyecto de [vuestro brief], ¿qué riesgos éticos y de protección de datos debería considerar?»	Que se aplican a **vuestro** caso y que vuestras medidas son reales

Ayuda 2 · Errores frecuentes (y cómo evitarlos)

Error	Por qué ocurre	Cómo evitarlo
Elegir un problema demasiado grande	Ambición	Preguntaos: ¿se puede hacer en unas 54 horas de proyecto?
Elegir datos sin mirar la licencia	Se quiere avanzar	La licencia es lo primero que se comprueba
Definir la métrica después de ver los resultados	«Para que salga bien»	Escribidla en la ficha y no la cambiéis
Baseline demasiado complicado	Se quiere lucir	El baseline es **lo más simple posible**
Mezclar pasado y futuro al partir los datos	Se parte al azar una serie de tiempo	Con series, partid **por fechas**: entrenad con el pasado y evaluad con el futuro
Backlog con 40 tareas vagas	Se apunta todo	10 a 15 historias concretas con criterio de aceptación
Riesgos éticos genéricos («cuidado con los sesgos»)	Prisa	Cinco riesgos específicos de **vuestros** datos; si valen para cualquier proyecto, no valen
Un solo *commit* del responsable técnico	Es más rápido	Todas las personas hacen *commits* con su cuenta
Dejar la ficha para el final	«Primero los datos»	Entregadla antes de las 14:30 del día 1; sin ella, el docente no puede dar el *go*

Ayuda 3 · Si os atascáis

1. **No nos ponemos de acuerdo en el brief:** votad con criterios (datos disponibles, interés, tiempo) y puntuad cada opción de 1 a 5.
2. **No encontramos datos con licencia:** probad primero con las fuentes de la tabla de briefs y consultad al docente **cuanto antes el día 1**, no por la tarde.
3. **El *go / no-go* pide cambios:** es normal; corregid la ficha ese mismo día y seguid.
4. **El cuaderno da error:** leed el mensaje completo, probad la celda con un trozo pequeño de los datos y preguntad al equipo y, después, al docente.
5. Más ayuda: Cómo se trabaja un reto.