Sprint 14 · Reto «Proyecto final: definir, tener datos y un punto de partida»

Esta es la ficha completa del reto, explicada paso a paso para quien nunca ha trabajado con esta metodología ni con IA. Léela entera **antes de empezar** y vuelve a ella cuando tengas dudas.

- Si es tu primer reto, lee antes Cómo se trabaja un reto.
- Volver al README del sprint · Guía del sprint en PDF · versión ecofriendly para imprimir.
- **Este reto en PDF:** a color · ecofriendly, para imprimir.

RETO Ficha del reto

En pocas palabras (léelo primero)

Qué es el proyecto final. Hasta ahora habéis resuelto retos con un guion. En los **sprints 14 a 17** vais a hacer **un proyecto completo de principio a fin**, igual que en una consultora: elegir un problema, conseguir datos reales, construir modelos, evaluarlos con honestidad, documentarlo y **defenderlo ante un cliente**. Aquí **vosotros decidís** el alcance, los datos concretos y las técnicas, dentro de unos mínimos.

Qué es este sprint (el primero de los cuatro). Aquí **no se entrena todavía el mejor modelo**. Se decide **qué** vais a hacer y **cómo vais a demostrar que funciona**. Lo que decidáis ahora condiciona los otros tres sprints, así que **conviene dedicar tiempo a pensar y no tener prisa por programar**. Al final tendréis: un problema bien definido, datos reales con licencia, un primer análisis y un modelo de referencia (*baseline*).

Qué vais a hacer, en siete pasos:

1. **Elegir un brief** (de los cuatro propuestos o uno propio) y escribir una **ficha de proyecto de una página**.
2. **Encontrar datos reales** que podáis usar legalmente y documentar su fuente y licencia (plan de datos y licencias).
3. **Hacer el EDA** (análisis exploratorio) y un **informe de calidad del dato**.
4. **Construir un baseline**: el modelo más sencillo posible, con una métrica definida **antes** de ver resultados.
5. **Planificar con Scrum**: backlog de 10–15 historias y objetivos para cada sprint.
6. **Anticipar riesgos éticos y legales** (plan ético, RGPD y AI Act).
7. **Montar el repositorio** con README y commits de todas las personas.

Hitos que no se pueden perder:

- **26/11:** elección de brief (antes del descanso (hacia las 11:00)) y **entrega de la ficha antes de las 14:30**.
- **27/11: go / no-go** del docente sobre vuestra ficha.
- **30/11:** review y retro.

Qué vais a aprender haciéndolo: a **formular un proyecto de IA** (pregunta de negocio, decisión que apoya, métricas), a **documentar datos** y a **planificar** con Scrum.

Cuánto tiempo: 18 horas (26 al 30/11), de las que 14 son de proyecto.

Palabras que van a aparecer en este reto

Palabra	Qué significa, en sencillo
Brief	El enunciado de un proyecto: qué problema, qué cliente y qué se espera
Ficha de proyecto	Una página que resume tu proyecto: pregunta, decisión, datos, métricas, riesgos
Métrica de negocio	Lo que le importa al cliente, en sus términos (euros ahorrados, horas, errores evitados)

Palabra	Qué significa, en sencillo
Métrica técnica	Lo que mide el modelo (MAE, AUC, F1…). Se define **antes** de mirar resultados
Datos abiertos	Datos que se pueden usar libremente gracias a una licencia (ISTAC, datos.gob.es, REData…)
Licencia	El permiso que dice qué podéis hacer con unos datos. Sin licencia clara, no se usan
Linaje (procedencia) del dato	De dónde viene, quién lo generó y qué transformaciones ha sufrido
EDA	Análisis exploratorio: tablas y gráficos para entender los datos
Informe de calidad	Resumen de nulos, duplicados, sesgos y límites del dato
Baseline	Modelo muy simple de referencia. Todo modelo posterior debe superarlo
Go / no-go	La decisión del docente: «adelante» o «hay que cambiar esto»
Backlog	Lista de tareas (historias) pendientes, ordenadas por importancia
Historia de usuario	Una tarea escrita desde el punto de vista de quien se beneficia: «Como cliente, quiero…»
Plan ético / registro de riesgos	Lista de riesgos éticos y legales, con su gravedad y su medida
RGPD / AI Act	Normas europeas de protección de datos y de inteligencia artificial
Partición temporal	Entrenar con el pasado y evaluar con el futuro. Obligatoria si hay series temporales

El cliente

Sois una **consultora de IA**. El docente es el **cliente y Product Owner**. Los briefs son abiertos a propósito: vosotros decidís alcance, datos concretos y técnicas dentro de los mínimos. Los cuatro briefs son:

Brief	Pregunta guía	Datos candidatos (validar)	Carga de cómputo
1 · Demanda turística	¿Podemos predecir la llegada de turistas con 3-6 meses de antelación y qué factores la explican?	ISTAC, Frontur-Canarias, datos.gob.es, AEMET	Baja
2 · Salud de cultivos (visión)	¿Con qué fiabilidad se distingue una hoja sana de una enferma, y cuándo no fiarnos?	PlantVillage + fotos propias del equipo	Alta (GPU)
3 · Asistente de FP (LLM/RAG)	¿Puede un asistente responder sin inventar, y cómo lo medimos?	Catálogo oficial de FP y FAQ del centro	Media
4 · Demanda eléctrica	¿Predecimos la demanda de las próximas 24 h mejor que un modelo de referencia?	REData, AEMET, calendario laboral	Media

También podéis presentar un **brief libre** (ficha antes del 26/11), que debe cumplir R1-R11, tener datos reales ya identificados, dificultad comparable y no usar datos personales sensibles.

Qué se entrega

Al cierre del sprint (30/11), en el repositorio del equipo:

1. **Ficha de proyecto de 1 página** (anexo A) — entrega antes del 27/11 para el go / no-go.
2. **Plan de datos y licencias** (fuente, licencia, tamaño, variables, limitaciones, linaje).
3. **Datos + EDA** en un notebook (`notebooks/01_eda.ipynb`) con **informe de calidad del dato**.
4. **Baseline** simple con su métrica (`notebooks/02_baseline.ipynb`).
5. **Backlog** (10-15 historias) con objetivos por sprint, y tablero con las primeras evidencias Scrum.
6. **Plan ético:** checklist del Sprint 1 actualizado y registro de riesgos inicial.
7. **Repositorio** con README (plantilla), requisitos y commits de todas las personas.

Restricciones

- 18 h en total; ~54 h de proyecto en los 3 primeros sprints. Se descartan problemas triviales o irrealizables.
- **Datos reales, accesibles y con licencia.** No se aceptan proyectos «a la espera de datos». No datos personales sensibles ni de terceros sin autorización.
- Dos equipos pueden elegir el mismo brief, pero cada uno define **su propia pregunta y métrica**.
- Equipos de 3-4 personas; los roles (Scrum Master, responsable técnico, de datos y de IA responsable) **rotan** cada sprint.

Criterios de evaluación

El proyecto se evalúa con la **rúbrica de 100 puntos** (documento de briefs, sección 5). En este sprint se evidencian:

Criterio del proyecto	Qué se mira en el Sprint 14
A · Problema y valor de negocio (10)	Pregunta clara, decisión del cliente, métricas de negocio y técnica coherentes
B · Datos y EDA (10)	Fuente y licencia documentadas, EDA orientado a la decisión, calidad del dato
C · Modelado (20)	Baseline razonable y plan de ≥ 3 modelos (incluye redes neuronales o LLM/RAG)
E · IA responsable (10)	Plan ético inicial con riesgos específicos y clasificación RGPD / AI Act preliminar
G · Equipo y metodología (10)	Tablero, backlog, planning y primera retro; commits de todos

Además, para la nota de sprint se usan los cuatro criterios de los retos (corrección técnica, reproducibilidad, análisis y comunicación al cliente, IA responsable).

Pasos sugeridos (resumen día a día)

Día	Paso
26/11	Planning; píldora; taller DT; 2 briefs candidatos; canvas borrador; elegir brief (antes del descanso); buscar y validar datos (¿licencia?, ¿descarga?, ¿tamaño?); rellenar ficha y plan de datos; **entregar la ficha antes de las 14:30**.
27/11	Leer el go / no-go; corregir la ficha si hace falta; EDA con calidad del dato; baseline terminado y registrado.
30/11	Plan ético; backlog completo; README; entrega, review y retro.

Guía paso a paso para principiantes

Antes de empezar: leed las reglas

Leed `briefs_y_rubrica.md` : las reglas comunes, los **requisitos R1–R11**, la **rúbrica de 100 puntos** y los anexos A y B. Es el documento que dice qué se va a evaluar. **Subrayad** lo que no entendáis y llevadlo al planning.

Paso 1 · Planning y taller (26/11 a primera hora, 125 minutos)

1. Roles del sprint: Scrum Master, responsable técnico, **responsable de datos** y **responsable de IA responsable**. Rotan cada sprint.
2. En la **píldora de teoría** aprenderéis a formular el proyecto con un *canvas* (un esquema de una página).
3. En el **taller de Design Thinking** pensad: ¿qué problema real y cercano os interesa? ¿Quién lo sufre? Salid con **uno o dos briefs candidatos**.

Paso 2 · Elegir el brief (26/11, antes del descanso, hacia las 11:00; 25 minutos)

Los cuatro briefs:

Brief	Pregunta guía	Pensad en…
1 · Demanda turística	¿Podemos predecir la llegada de turistas con 3–6 meses de antelación y qué factores la explican?	Series temporales. Carga de cómputo baja

Brief	Pregunta guía	Pensad en…
2 · Salud de cultivos (visión)	¿Con qué fiabilidad se distingue una hoja sana de una enferma y cuándo no fiarnos?	Imágenes. Carga alta (GPU)
3 · Asistente de FP (LLM/RAG)	¿Puede un asistente responder sin inventar y cómo lo medimos?	Texto. Carga media
4 · Demanda eléctrica	¿Predecimos la demanda de las próximas 24 h mejor que un modelo de referencia?	Series temporales con calendario. Carga media

Cómo elegir: el brief que os interese, para el que haya **datos reales accesibles** y que se pueda terminar en el tiempo que hay. **Dos equipos pueden elegir el mismo brief**, pero cada uno define **su propia pregunta y métrica**. También podéis proponer un **brief libre**, con ficha antes del 26/11 y cumpliendo R1–R11.

Paso 3 · Buscar y validar datos (26/11, 80 minutos)

Para cada fuente candidata, responded:

- **¿Tiene licencia que permita usarla?** (si no está clara, no se usa).
- **¿Se puede descargar?** Y ¿podemos repetir la descarga con un enlace o un script?
- **¿Qué tamaño tiene?** ¿Cabe en nuestro ordenador o en Colab?
- **¿Qué variables y qué periodo?** ¿Responden a nuestra pregunta?
- **¿Hay datos personales?** (si los hay y son sensibles, **no se aceptan**).

Rellenad la plantilla `plantilla_plan_datos_licencias.md`.

No se aceptan proyectos «a la espera de datos». Los datos han de estar identificados y accesibles.

Paso 4 · Ficha del proyecto y entrega (26/11, 90 minutos, antes de las 14:30)

Rellenad `plantilla_ficha_proyecto.md` (anexo A del documento de briefs), con:

1. **Pregunta de negocio** y **decisión que apoyará** el proyecto.
2. **Métricas** (de negocio y técnica).
3. **Datos** (fuente, licencia).
4. **Enfoque** previsto (baseline + ≥ 3 modelos + 1 neuronal o LLM/RAG).
5. **Riesgos principales.**
6. **Equipo y roles.**

Entregadla antes de las 14:30 del 26/11. El docente responderá con el **go / no-go** al día siguiente por la mañana.

Paso 5 · EDA, calidad del dato y baseline (27/11, jornada completa)

1. **Leed el go / no-go** y corregid la ficha si hace falta.
2. En `notebooks/01_eda.ipynb`: describid los datos, buscad nulos, duplicados, valores raros y **sesgos de muestreo** (¿quién o qué falta en los datos?). Terminad con un **informe de calidad del dato**.
3. **Definid la partición** de datos (temporal si hay series) y la **métrica técnica ANTES de mirar resultados**.
4. En `notebooks/02_baseline.ipynb`: construid el **modelo más simple posible** (por ejemplo, «predecir lo mismo que ayer», la media, o la clase más frecuente) y calculad su métrica. Es el **suelo** que vais a intentar superar.

Paso 6 · Backlog, plan ético y repositorio (30/11, 4 horas)

1. **Backlog** con `plantilla_backlog_y_sprints.md`: entre 10 y 15 historias con objetivos para los sprints 15, 16 y 17. Cargadlas en el tablero.
2. **Plan ético:** actualizad el checklist del Sprint 1 y rellenad `plantilla_registro_riesgos_eticos.md` con **al menos 5 riesgos específicos** de vuestro proyecto (no genéricos), y una primera clasificación RGPD / AI Act.
3. **Repositorio:** README con `plantilla_README_repositorio.md`, `requirements.txt`, notebooks, datos o script de descarga. **Commits de todas las personas.**
4. **Coevaluación breve** de la primera semana.

Paso 7 · Review (30/11, últimos 80 minutos con la entrega)

5 minutos por equipo: (1) pregunta de negocio y decisión que apoyará; (2) datos y **un hallazgo del EDA que cambia el enfoque**; (3) baseline y su métrica; (4) tres riesgos éticos; (5) backlog de los próximos sprints. Después, retro de 15 minutos.

Cómo usar la IA en este reto

En un proyecto largo, la IA puede ayudar mucho, pero **la responsabilidad es vuestra**.

Para qué	Ejemplo de petición	Qué tenéis que comprobar
Encontrar fuentes de datos	«Dame fuentes abiertas de datos de llegada de turistas a Canarias y qué licencias suelen tener»	**Entrad vosotros en la web**, leed la licencia y comprobad que los datos existen. Una IA puede inventar fuentes
Redactar la ficha	«Ayúdame a convertir estas notas en una pregunta de negocio clara con una métrica»	Que sea **vuestra** idea, no una genérica
Planificar	«Convierte este objetivo en 5 historias de usuario pequeñas»	Que son realizables en el tiempo que tenéis
Revisar riesgos	«Para un proyecto de [vuestro brief], ¿qué riesgos éticos y de protección de datos debería considerar?»	Que se aplican a **vuestro** caso y vuestras medidas son reales

Reglas del reto:

- **Nunca inventéis una fuente o una licencia.** Si la IA os da un enlace, entrad y comprobadlo.
- **No subáis datos personales ni claves** al repositorio.
- Declarad en el README del proyecto el uso de IA.
- Se exige un proyecto **propio**: no se acepta copiar un notebook de internet.

Errores frecuentes (y cómo evitarlos)

Error	Por qué ocurre	Cómo evitarlo
Elegir un problema demasiado grande	Ambición	Preguntaos: ¿se puede hacer en ~55 horas de proyecto?
Elegir datos sin mirar la licencia	Se quiere avanzar	La licencia es lo primero que se comprueba
Definir la métrica después de ver resultados	«Para que salga bien»	Escribidla en la ficha y no la cambiéis
Baseline demasiado complicado	Se quiere lucir	El baseline es **lo más simple posible**
Backlog con 40 tareas vagas	Se apunta todo	10–15 historias concretas
Riesgos éticos genéricos («cuidado con los sesgos»)	Prisa	Cinco riesgos específicos de **vuestros** datos
Un solo commit del responsable técnico	Es más rápido	Todas las personas hacen commits

Un buen resultado se parece a...

- **Pregunta de negocio:** «¿Podemos predecir la ocupación hotelera de Gran Canaria con 3 meses de antelación con un error menor del 8 %, para planificar plantilla y compras?».
- **Decisión que apoya:** «Cuándo contratar refuerzo en temporada media».
- **Baseline:** «Predecir lo mismo que el año anterior en la misma semana → error del 14 %».
- **Un riesgo específico:** «Los datos son de hoteles grandes: no representan a pequeños alojamientos rurales».

Antes de entregar: autoevaluación rápida

Pregunta	Sí / No
¿La ficha se entregó antes del 27/11 y tiene el **go** del docente?	
¿Los datos son reales, con **fuente y licencia**, y el script o enlace de descarga funciona?	
¿El EDA incluye informe de calidad (nulos, duplicados, sesgos, linaje)?	
¿El baseline usa una métrica técnica definida **antes** de mirar resultados?	
¿La partición evita fugas (temporal si hay series)?	
¿Hay un backlog de 10–15 historias y el tablero está actualizado?	
¿El registro de riesgos tiene ≥ 5 riesgos específicos?	
¿El repositorio tiene README, `requirements.txt` y commits de todas las personas?	
¿Hemos hecho coevaluación breve y retro?	

Si os atascáis

- **No nos ponemos de acuerdo en el brief:** votad con criterios (datos disponibles, interés, tiempo) y puntuad cada opción de 1 a 5.
- **No encontramos datos con licencia:** probad primero con las fuentes de la tabla de candidatos (ISTAC, datos.gob.es, REData, PlantVillage…) y consultad al docente **antes del 26/11**.
- **El go / no-go pide cambios:** es normal; corregid la ficha el mismo día.
- Más ayuda: Cómo se trabaja un reto.

Qué se enseña en la review (30/11)

Cada equipo enseña en 5 minutos: (1) la pregunta de negocio y la decisión que apoyará; (2) los datos y un hallazgo del EDA que cambia el enfoque; (3) el baseline y su métrica; (4) tres riesgos éticos; (5) el backlog de los próximos sprints. Después, retrospectiva de 15 minutos.

Definition of Done (lista de comprobación)

Si queda una casilla sin marcar, **el reto no está terminado**.

- [ ] Ficha de proyecto entregada antes del 27/11 y con **go** del docente.
- [ ] Datos reales con **fuente y licencia** documentadas; el script o enlace de descarga funciona desde el README.
- [ ] EDA con informe de calidad del dato (nulos, duplicados, sesgos de muestreo, linaje).
- [ ] Baseline evaluado con una **métrica técnica** definida antes de mirar resultados.
- [ ] Partición de datos definida (y **temporal** si hay series) para evitar fugas.
- [ ] Backlog de 10-15 historias, objetivos por sprint y tablero actualizado.
- [ ] Checklist ético actualizado y registro de riesgos con ≥ 5 riesgos específicos.
- [ ] Repositorio con README, `requirements.txt` y *commits* de **todos** los integrantes.
- [ ] Coevaluación breve de la primera semana y retrospectiva realizadas.