IFCD107 · ESPECIALISTA EN INTELIGENCIA ARTIFICIAL

Seguimiento de experimentos

Probar muchos modelos **sin perder el hilo**: semillas, registro y test una sola vez

Sprint 15 · S15_01 · cuaderno: 50 min en clase (ejercicios 1 a 3; el resto, en casa)

LA IDEA · POR QUÉ SE REGISTRA

Al tercer día nadie recuerda qué dio qué

«¿Aquella prueba tan buena la hice yo o Marta? ¿Con qué ajustes? ¿Antes o después de limpiar los datos?»

Un **experimento** es una prueba: un modelo, unos ajustes y una medida. Si no se anota, no se puede repetir ni defender.

1 · Fijar el azar
Semilla y versiones anotadas · **ejercicio 1**

→

2 · Anotar cada prueba
Una fila por prueba en un CSV · **ejercicio 2**

→

3 · Comparar sin mirar el test
Baseline y validación cruzada · **ejercicio 3** (y el 4, en casa)

→

4 · Test, una sola vez
El examen final del candidato · **ejercicio 5** (en casa)

La rúbrica lo premia: el criterio C (modelado y experimentación) vale 20 de 100 puntos y el nivel «Bueno» pide ajuste de hiperparámetros y registro de experimentos.

EJERCICIO 1 · CUADERNO (CLASE)

Semillas: que el azar se repita

Una **semilla** fija el azar

Partir los datos, mezclarlos o crear un bosque usan azar. Con la misma semilla, el ordenador repite **la misma secuencia**.

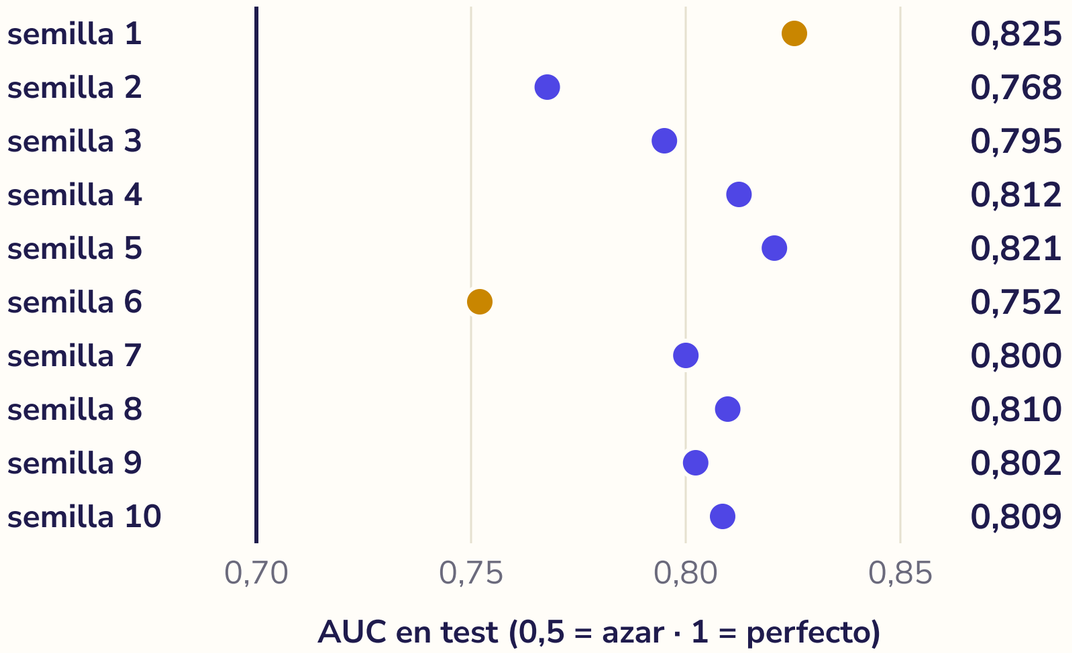
Las **versiones** de las librerías también cambian cifras: se anotan en ENTORNO (python, numpy, pandas y scikit-learn).

Una semilla para todo el equipo

Fijarla (el cuaderno usa SEMILLA = 42) es método.
Cambiarla hasta que salga un número bonito es trampa.

Se pide **fijar_semillas(semilla)**: fija el azar de **random** y de **numpy**, guarda **PYTHONHASHSEED** como texto y **devuelve** un generador.

Ejemplo, gimnasio «Marea»: el mismo modelo con 10 repartos



EJERCICIO 2 · CUADERNO (CLASE)

El registro: una fila por prueba

Qué cuenta	Columnas del registro
Cuándo y quién	id, fecha, responsable
Qué se probó	modelo, hiperparametros
Con qué datos	datos_hash (una huella), semilla
Cómo salió	metrica, valor_cv, desv_cv, tiempo_s
Lo que has pensado	notas

Son **12 columnas**, las de la plantilla **registro_experimentos_plantilla.csv**. **valor_cv** y **desv_cv** son la media y la desviación de la validación cruzada (diapositiva 5).

Ejemplo inventado: gimnasio «Marea», se predice la baja de un socio (6 de las 12 columnas).

id	responsable	modelo	valor_cv	desv_cv	notas
1	Ana	Baseline	0,500	0,000	el listón a batir
2	Ana	RegresionLogistica	0,800	0,029	simple y rápida
3	Luis	RandomForest	0,842	0,020	mejor hasta ahora
4	Marta	HistGradientBoosting	0,807	0,027	casi como la logística

Se pide registrar(...): añade una fila a RUTA_REGISTRO, crea la cabecera solo si el fichero no existe, calcula el id como filas + 1 y lo devuelve.

LA IDEA · COMPARAR SIN MIRAR EL TEST

Validación cruzada: media y desviación

Cinco rondas: cada una mide en el trozo que no ha visto (ejemplo: logística del gimnasio «Marea»)

	trozo 1	trozo 2	trozo 3	trozo 4	trozo 5	
Ronda 1	**mide**	entrena	entrena	entrena	entrena	0,817
Ronda 2	entrena	**mide**	entrena	entrena	entrena	0,759
Ronda 3	entrena	entrena	**mide**	entrena	entrena	0,786
Ronda 4	entrena	entrena	entrena	**mide**	entrena	0,795
Ronda 5	entrena	entrena	entrena	entrena	**mide**	0,845

Media 0,800 · desviación 0,029

En el cuaderno: 5 trozos (**StratifiedKFold**), 4 800 reservas para entrenar y 1 200 de test sin tocar.

Baseline

El modelo más simple, que predice la clase más frecuente. Es el **listón**: su AUC es 0,5.

Test

Datos apartados desde el principio. **No se miran** para comparar ni para ajustar: se usan una sola vez, al final.

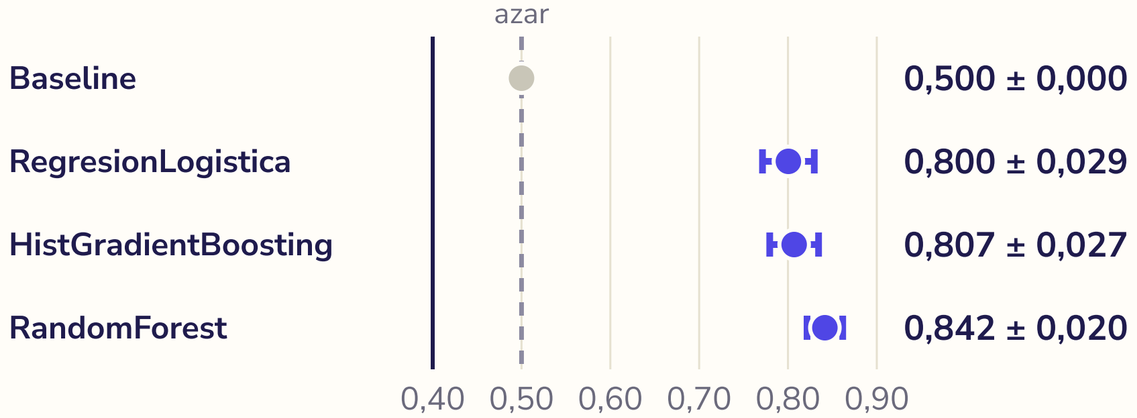
Regla del ruido

Si dos modelos difieren menos que su desviación, **no hay diferencia real**: elige el más simple, rápido o fácil de explicar y anótalo en **notas**.

EJERCICIO 3 · CUADERNO (CLASE)

Comparar modelos y anotar cada uno

Ejemplo, gimnasio «Marea»: AUC en validación cruzada



Más a la derecha, mejor (barra = ± desviación)

Cómo se lee este ejemplo

Logística y boosting: 0,007 de diferencia, menos que su desviación. Empate: mejor la más simple.

Bosque: 0,035 más que el boosting, más que su desviación; se mira también el tiempo y la explicación.

experimento(...) ya viene escrita

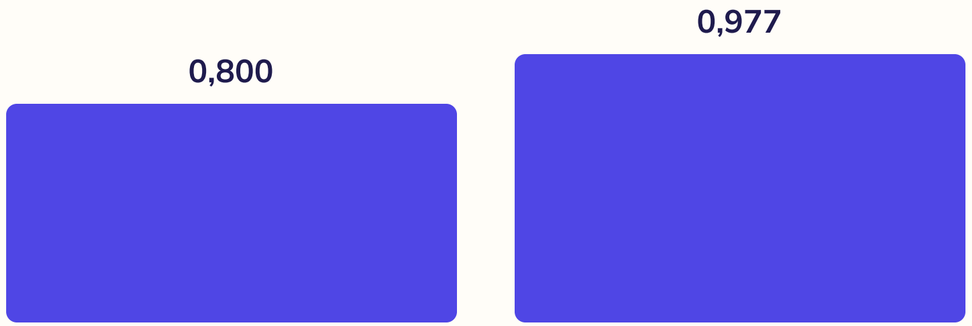
Entrena con validación cruzada, mide el tiempo, **anota la fila** y devuelve (media, desviación).

Se pide: anotar **RandomForest** y **HistGradientBoosting** con **experimento**, leer el registro en **tabla** y guardar en **candidato** el nombre del modelo con mayor **valor_cv**.

LA IDEA · FUGA DE DATOS (CUADERNO, SECCIÓN 5)

Demasiado bueno para ser verdad

AUC en validación cruzada, mismo modelo · gimnasio «Marea» (ejemplo)



- **¿La conocería el día que decido?** Si no, fuera.
- **Sospecha** de lo demasiado bueno antes de celebrar.

Fuga de datos

El modelo ve una pista que, el día que se use de verdad, **todavía no existiría**.

Aquí **baja_tramitada** solo se rellena **después** de que el socio se dé de baja.

Qué se hace

Se anota con **Fuga** en el nombre y una nota de alarma. Se **descarta**: no puede ser el candidato.

- **Preprocesar dentro de un Pipeline** (cadena de pasos que aprende solo del entrenamiento).
- **En series, partir por fechas**, nunca al azar.

LA IDEA · EVALUACIÓN ÚNICA EN TEST

El test se usa una sola vez

1 · Comparar y ajustar
Con validación cruzada, solo con el entrenamiento

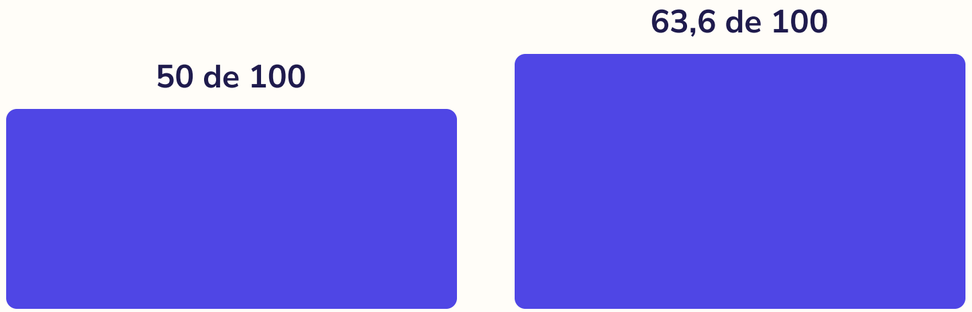
→

2 · Elegir el candidato
Sin mirar el test y sin filas con «Fuga»

→

3 · Test, una vez
El examen final del candidato: se anota y no se vuelve a elegir

Doscientos modelos que **adivinan con una moneda**, medidos en el mismo test de 100 ejemplos:



Si eliges mirando el test

Con tantos intentos, alguno tiene **suerte.** Lo que ves no es un buen modelo: es el que mejor ha adivinado ese test.

Si el resultado decepciona

Se **anota y se explica**. No se vuelve a elegir: un resultado honesto y mediocre vale más que uno bonito con trampa.

LA IDEA · Y EN VUESTRO PROYECTO

Del cuaderno al proyecto, en tres días

Día	Qué hacéis en el proyecto	Queda anotado
Martes 1/12	Semilla, versiones y registro; baseline y primer modelo mejor (130 min)	Baseline en la primera fila
Miércoles 2/12	Más modelos (clásico, red o LLM/RAG, según el brief) y ajustes; **tutoría técnica de 20 min** por equipo	Una fila de cada persona
Jueves 3/12	Comparativa y elección del candidato (70 min); **test una sola vez** (40 min); entrega en **sprint-15/**	Candidato y resultado en test

Plantilla del registro

registro_experimentos_plantilla.csv trae las **12 columnas** del cuaderno. Se recomiendan **≥ 12 filas** y, al menos, **una de cada persona** (**responsable**).

Hito del sprint

3/12: modelo candidato elegido, sin mirar el test.

Los 50 min diarios de «subid de nivel»: más experimentos con otra semilla o una mejora razonada.

EJERCICIOS 4 Y 5 · CUADERNO (CASA)

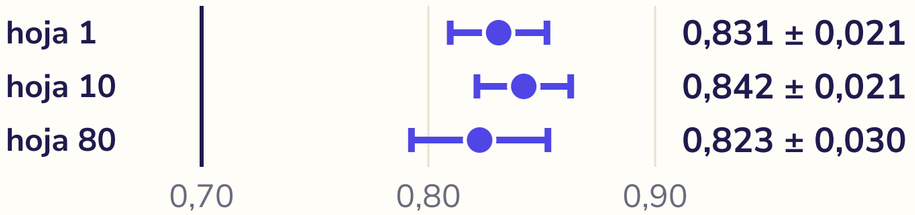
Ajustar y evaluar el candidato

Ejercicio 4 · hiperparámetros

Un **hiperparámetro** es un ajuste que fijas **antes** de entrenar. Cada valor probado es **una fila** del registro.

Se pide: un bosque con **max_depth** = 3, 6 y 10, **resultados_prof** y **mejor_prof**.

Ejemplo (gimnasio): mínimo de filas por hoja



AUC en validación cruzada (barra = ± desviación)

Ejercicio 5 · el test, una vez

Entre las filas del registro **sin** «Fuga» en el nombre, la de mayor **valor_cv**; se reentrena con todo **X_ent**.

Se pide: **auc_test** en **X_test** y **auc_cv_candidato**, para compararlos.

0,842
Validación cruzada

0,826
Test

Ejemplo del gimnasio: **parecidos, buena señal**. Si el test sale muy por debajo, hay **sobreajuste** (memorizar el entrenamiento) o fuga.

PARA CASA · CUADERNO (CASA)

MLflow, mini-reto y preguntas

MLflow (sección 7, opcional)

Herramienta profesional de seguimiento, con interfaz web (**mlflow ui**).

No es obligatoria: el CSV cumple la rúbrica.

Se activa con **USAR_MLFLOW = True** y necesita internet para instalarla.

Mini-reto integrador

Llevad **fijar_semillas**, **registrar** y **experimento** a vuestro proyecto (en el reto, a las primeras celdas de **03_modelos.ipynb**).

Registrad el baseline y al menos 3 modelos con **vuestros datos**.

Cada integrante, **al menos una fila** a su nombre.

Para pensar

1. ¿Qué dos cosas necesita otra persona para reproducir tu mejor resultado?

2. Dos modelos empatan dentro de la desviación: ¿puedes decir que uno es mejor?

3. ¿Por qué no elegir mirando el test?

4. Tu primera prueba da un AUC casi perfecto: ¿qué tres cosas revisas antes de celebrar?

HOY HAS APRENDIDO

Probar con orden para poder defender

Registrar

Una **fila por prueba** en un CSV, con la semilla y las versiones anotadas, para que otra persona obtenga lo mismo

Comparar con honestidad

Baseline, **validación cruzada** y media ± desviación; si la diferencia cabe en la desviación, el más simple. Si es demasiado bueno, **sospecha**

Test, una sola vez

El candidato se elige con la validación y se evalúa **una vez**. El resultado, bueno o malo, se anota

Ahora: cuaderno S15_01 (50 min) y proyecto: baseline y primer modelo mejor (130 min).