Sprint 15 · Reto «El mejor modelo, demostrado»

Ficha completa del reto, para consultar. Para trabajar, el reto en una página. Qué se sube y cómo se evalúa: entrega y rúbrica.

- Volver al README del sprint.
- Si es vuestro primer reto: Cómo se trabaja un reto.

RETO **Ficha del reto**

1 Qué os pide el cliente

Qué os pide el cliente. El cliente (el docente) quiere saber **qué modelo recomendáis para vuestro proyecto y por qué**. No le basta con «el que tiene el número más alto»: quiere saber si la mejora frente al *baseline* (el modelo más simple, que sirve de referencia) **compensa el coste y la complejidad**, si el modelo **funciona con datos que no ha visto** y si vuestros resultados **se pueden repetir** otro día y en otro ordenador. Este sprint es el corazón técnico del proyecto, pero lo que se valora **no es probar muchos modelos**: es **probar con orden, anotar cada prueba y elegir con honestidad**.

Cómo se trabaja. Partís de lo que ya tenéis del Sprint 14 (datos, análisis y *baseline*) y de las herramientas del cuaderno de práctica: una función que fija el azar, otra que anota cada prueba en un fichero y la validación cruzada (evaluar varias veces con trozos distintos de los datos). Vosotros decidís **antes** qué modelos probáis y por qué (como mínimo, tres modelos clásicos y uno neuronal —vale la red de scikit-learn—, o un asistente LLM/RAG si vuestro brief es el 3), los comparáis **con la misma partición**, **elegís el candidato sin mirar el test** y solo después lo evaluáis en el test **una única vez**. Son tres jornadas: **470 minutos de reto** (130 el día 1, 200 el día 2 y 140 el día 3) más 60 de review y retro. El equipo decide hasta dónde llega: mínimo, estándar o extra.

2 · Recursos del reto

Recurso	Para qué lo usaréis	Dónde está
Python 3.11 y las bibliotecas del proyecto (`pandas`, `scikit-learn`, `matplotlib`; la de redes que usasteis en el Sprint 10)	Entrenar, comparar y guardar los modelos	Colab, o el entorno del equipo con las versiones de vuestro `requirements.txt`
Cuaderno del sprint `S15_01_seguimiento_experimentos`	Copiar las funciones `fijar_semillas`, `registrar` y `experimento`, y ver cómo se mide con validación cruzada, cómo se detecta una fuga y cómo se evalúa el test una vez	Colab (50 minutos el día 1). MLflow es **opcional**
Plantilla del registro `registro_experimentos_plantilla.csv`	Solo trae la cabecera de las columnas; es la base de vuestro `registro.csv`	En GitHub: *Raw* → *Download* o copiar el texto
Píldora y apuntes presentación S15.1 · apuntes	El porqué de cada regla (semillas, fuga, media ± desviación, test una vez), con ejemplos numéricos	En el repositorio del curso
Vuestro trabajo del Sprint 14	Los datos, el *baseline* y el cuaderno de partida	El repositorio del equipo (`ifcd107-equipo-…`)
Cómo entregar en GitHub	Subir los ficheros a la carpeta `sprint-15/`	Guía de entrega
Autoevaluación y coevaluación	Cada persona rellena su hoja	Hoja del sprint
Un asistente de IA (opcional)	Entender errores, pedir pistas y revisar si hay fugas	Con las reglas de la «Ayuda 1» del paso a paso

3 · Guía paso a paso

Son cinco pasos, de **470 minutos en total** (130 el día 1, 200 el día 2 y 140 el día 3, junto a la píldora, la práctica, la tutoría, la entrega y la review). Las jornadas de proyecto duran **6 horas completas (250 minutos de trabajo al día)**: los pasos de esta ficha ocupan unos 200 y los **50 minutos restantes de cada día son «subir de nivel»** (pasar del mínimo al estándar con la rúbrica en la mano). Cada uno dice **qué hacéis** (la lista corta), **cómo se hace** con el detalle, **qué deberíais ver** y **cuándo está hecho**. Las ayudas (IA, errores, atascos) están al final. Si el tiempo aprieta, completad el nivel mínimo y dejad lo demás para casa.

Paso 1 · Preparar el terreno y repetir el baseline (día 1, 130 minutos)

1. Fijar la semilla, anotar las versiones y crear el registro con la plantilla.
2. Definir la partición común y escribir qué modelos se van a probar y por qué.
3. Repetir el *baseline* y anotarlo como primera fila del registro.
4. Entrenar el primer modelo clásico y anotarlo.

En sencillo. Este sprint se parece a un laboratorio: vais a probar varios modelos y hay que **apuntar cada prueba**, porque al tercer día nadie recuerda si aquel 0,75 era con la semilla 1 o la 42. Hoy preparáis el terreno: un cuaderno común, una forma de dejar el azar fijo (la **semilla**), un **cuaderno de notas** en forma de tabla (el **registro**) y un reparto de los datos que no se cambia nunca. Con eso hecho, repetís el modelo más simple (el *baseline*) y entrenáis el primero de verdad. No hace falta entender cómo funciona cada modelo: el código viene de la práctica `S15_01` y solo cambiáis las líneas marcadas.

Palabras nuevas de este paso

Palabra	Qué significa, en sencillo
Semilla	Un número fijo (42) que hace que el azar dé siempre lo mismo. Con ella, otra persona obtiene exactamente vuestras cifras.
Registro de experimentos	Una tabla (`registro.csv`) con una fila por prueba: quién, qué modelo, con qué ajustes y qué resultado.
Hiperparámetro	Un ajuste que elegís vosotros antes de entrenar (por ejemplo, la profundidad de un árbol).
Validación cruzada	Partir el entrenamiento en 5 trozos y entrenar 5 veces, probando cada vez en el trozo que no se ha visto. Da una **media** y una **desviación**.
Test	Datos apartados que no se miran hasta el final. Se usan **una sola vez**.
Pipeline	Una cadena de pasos (escalar, codificar, modelo) que se aprende solo con el entrenamiento.
Huella (hash)	Un código corto que cambia si cambian los datos.
AUC	Una métrica de 0 a 1 para clasificar: 0,5 es azar y 1 es perfecto.

Cómo se hace

1. **Crear el cuaderno común (5 minutos).** Una persona (la responsable técnica) abre Colab, *Archivo → Cuaderno nuevo*, lo llama `03_modelos.ipynb` y pulsa **Compartir** (arriba a la derecha) para dar acceso de **editor** al resto. Subid también vuestro archivo de datos (panel de la izquierda). Todo el equipo trabaja en **este mismo cuaderno**: lo común arriba, y debajo una sección por persona con su nombre. **No editéis las celdas de otra persona.**

2. **Semilla y versiones (10 minutos).** Si ya hicisteis `S15_01`, copiad de allí estas celdas. En la primera celda de `03_modelos.ipynb` van las importaciones:

```
import os, sys, time, json, random, hashlib
from datetime import datetime
import numpy as np
import pandas as pd
import sklearn
from sklearn.model_selection import train_test_split, StratifiedKFold, cross_val_score
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.dummy import DummyClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier, HistGradientBoostingClassifier
from sklearn.metrics import roc_auc_score
```

   En la segunda, la semilla y las versiones:

```
def fijar_semillas(semilla):
    random.seed(semilla)
    np.random.seed(semilla)
    os.environ["PYTHONHASHSEED"] = str(semilla)
    return np.random.default_rng(semilla)

SEMILLA = 42
rng = fijar_semillas(SEMILLA)

ENTORNO = {"python": sys.version.split()[0], "numpy": np.__version__, "pandas": pd.__version__, "scikit-learn":
sklearn.__version__}
print(json.dumps(ENTORNO, indent=2))
```

   Qué hace cada línea:

   - `import` carga las herramientas que se usarán; **no se cambian**.
   - `fijar_semillas` fija el azar de `random` y de `numpy`; `SEMILLA = 42` es el número. **No lo cambiéis hasta que salga un resultado bonito: nunca.** Es trampa.
   - `ENTORNO` junta las versiones y `print(json.dumps(...))` las escribe. Salen cuatro líneas: `python`, `numpy`, `pandas` y `scikit-learn` con su versión (con las vuestras, que dependen de Colab). Copiadlas en una celda de texto y más tarde en el README.

3. **Crear el registro (10 minutos).** El registro tiene doce columnas, las mismas que la plantilla `registro_experimentos_plantilla.csv` (que solo trae esa cabecera). No hace falta subir la plantilla: este código crea `registro.csv` con esas columnas.

Columna	Qué se anota
`id`	Un número que sube con cada prueba (1, 2, 3…)
`fecha`, `responsable`	Cuándo y **quién** hizo la prueba (demuestra que participa todo el equipo)
`modelo`, `hiperparametros`	Qué modelo y con qué ajustes
`datos_hash`, `semilla`	Una huella corta de los datos y la semilla usada
`metrica`, `valor_cv`, `desv_cv`	La métrica que fijasteis en el sprint 14, su media y su desviación en validación cruzada
`tiempo_s`, `notas`	Cuánto tardó y lo que habéis aprendido; aquí se marca también si el código lo generó una IA

```
RUTA_REGISTRO = "registro.csv"
COLUMNAS = ["id", "fecha", "responsable", "modelo", "hiperparametros", "datos_hash", "semilla",
            "metrica", "valor_cv", "desv_cv", "tiempo_s", "notas"]
if os.path.exists(RUTA_REGISTRO):
    os.remove(RUTA_REGISTRO)

def registrar(responsable, modelo, hiperparametros, datos_hash, semilla, metrica, valor_cv, desv_cv, tiempo_s, notas=""):
    existe = os.path.exists(RUTA_REGISTRO)
    n = len(pd.read_csv(RUTA_REGISTRO)) if existe else 0
    fila = pd.DataFrame([{
        "id": n + 1, "fecha": datetime.now().strftime("%Y-%m-%d %H:%M"), "responsable": responsable, "modelo": modelo,
        "hiperparametros": json.dumps(hiperparametros, sort_keys=True), "datos_hash": datos_hash, "semilla": semilla,
        "metrica": metrica, "valor_cv": round(float(valor_cv), 4), "desv_cv": round(float(desv_cv), 4),
        "tiempo_s": round(float(tiempo_s), 2), "notas": notas}], columns=COLUMNAS)
    fila.to_csv(RUTA_REGISTRO, mode="a", header=not existe, index=False)
    return n + 1
```

   - `registrar(...)` añade **una fila** al final de `registro.csv`: si el archivo no existe lo crea con la cabecera, y el `id` es el número de filas + 1. **No cambiéis los nombres de las columnas.**
   - Las líneas con `os.remove` borran el registro al empezar para que cada ejecución completa del cuaderno lo **rehaga desde cero** (sin filas repetidas). El `registro.csv` final es, por tanto, el resultado de ejecutar el cuaderno entero.
4. **Datos y partición común (20 minutos).** Una sola partición para todo el equipo, que no se cambia. Es la primera del sprint 14: con la misma semilla sale **el mismo test**. El test se aparta ahora y **no se toca hasta el paso 5**.

```
RUTA = "mis_datos.csv"
OBJETIVO = "cancelada"
QUITAR = ["id_reserva", "fecha_reserva", "fecha_llegada"]

df = pd.read_csv(RUTA, parse_dates=["fecha_reserva", "fecha_llegada"])
df["mes_llegada"] = df["fecha_llegada"].dt.month
X = df.drop(columns=QUITAR + [OBJETIVO])
y = df[OBJETIVO]
X_ent, X_test, y_ent, y_test = train_test_split(X, y, test_size=0.2, stratify=y, random_state=SEMILLA)

DATOS_HASH = hashlib.md5(pd.util.hash_pandas_object(df, index=True).values.tobytes()).hexdigest()[:8]
print("Huella de los datos:", DATOS_HASH, "· entrenamiento:", X_ent.shape, "· test (sin tocar):", X_test.shape)
```

   - **Cambiad** `RUTA`, `OBJETIVO` (la columna a predecir) y `QUITAR` (identificadores y fechas en bruto: no son pistas válidas). Las dos líneas de `parse_dates` y `mes_llegada` son del ejemplo con fechas: adaptadlas o borradlas.
   - `X` son las pistas y `y` la respuesta. `X_ent` es el entrenamiento (con validación cruzada dentro) y `X_test` se guarda.
   - `DATOS_HASH` es la huella. Con `reservas_turisdata.csv` sale `Huella de los datos: 800f40b2 · entrenamiento: (4800, 15) · test (sin tocar): (1200, 15)`. Con vuestros datos saldrán otros números.
5. **Escribir el plan (en una celda de texto).** Debajo de lo anterior, una celda de texto con **qué vais a probar y por qué**. Ejemplo: «Regresión logística (simple y explicable), bosque aleatorio y *gradient boosting* (capturan relaciones que no son líneas rectas) y una red neuronal pequeña. Ajustaremos solo en validación: la profundidad del bosque». **No vale «probar 200 combinaciones y quedarse con la mejor».**

6. **El baseline como fila 1 (30 minutos).** Las funciones de comparación (la cadena de pasos, el reparto de la validación cruzada y `experimento`) y el *baseline* del sprint 14:

```
categoricas = X.select_dtypes("object").columns.tolist()
METRICA = "AUC"
SCORING = "roc_auc"

def crear_pipeline(estimador, columnas):
    numericas = [c for c in columnas if c not in categoricas]
    prep = ColumnTransformer([("num", StandardScaler(), numericas), ("cat", OneHotEncoder(handle_unknown="ignore"),
categoricas)])
    return Pipeline([("prep", prep), ("m", estimador)])

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=SEMILLA)

def experimento(nombre, estimador, hiperparametros, responsable="equipo", notas="", Xd=None):
    Xd = X_ent if Xd is None else Xd
    t0 = time.time()
    puntuaciones = cross_val_score(crear_pipeline(estimador, Xd.columns), Xd, y_ent, cv=cv, scoring=SCORING)
    registrar(responsable, nombre, hiperparametros, DATOS_HASH, SEMILLA, METRICA, puntuaciones.mean(),
puntuaciones.std(), time.time() - t0, notas)
    return puntuaciones.mean(), puntuaciones.std()

media, desv = experimento("Baseline", DummyClassifier(strategy="prior"), {"strategy": "prior"}, responsable="Ana",
notas="referencia mínima")
print(f"Baseline: {media:.3f} ± {desv:.3f}")
```

   - `METRICA` es el nombre que se escribe en el registro y `SCORING` el mismo concepto con el nombre de scikit-learn. **Poned la métrica que fijasteis en el sprint 14**: F1 es `"f1"` y exactitud es `"accuracy"`.
   - `crear_pipeline` convierte los números a una misma escala y los textos en columnas de 0 y 1, **dentro** de la cadena, para que solo se aprenda con el entrenamiento. `cv` define los 5 trozos.
   - `experimento` entrena y evalúa con validación cruzada, mide el tiempo y **registra la fila**. **Cambiad `"Ana"` por vuestro nombre** en el parámetro `responsable`.
   - El `Baseline` con `DummyClassifier(strategy="prior")` no mira las pistas y sale con `Baseline: 0.500 ± 0.000`: eso es el azar. Debe ser la **fila 1**.

7. **El primer modelo (55 minutos).** Una persona entrena el primero mientras las demás preparan el siguiente en su sección. En una celda nueva, con vuestro nombre:

```
media, desv = experimento("RegresionLogistica", LogisticRegression(max_iter=2000), {"C": 1.0}, responsable="Ana")
print(f"Regresión logística: {media:.3f} ± {desv:.3f}")
```

   Con los datos de práctica sale `Regresión logística: 0.755 ± 0.012`. Las cifras de los vuestros serán otras: lo que importa es que **supere al baseline**. Comprobad el registro con `pd.read_csv(RUTA_REGISTRO)`: debe tener las filas 1 (*baseline*) y 2.

8. **Comprobar la semilla.** Elegid *Entorno de ejecución → Reiniciar y ejecutar todo* y mirad que las cifras salen **iguales** que antes. Si cambian, algo usa azar sin semilla.

9. **Si vuestros datos son una serie temporal** (brief 1 o 4), sustituid los apartados 4 y 6 por esto. El reparto es por fechas (los últimos 91 días van al test) y se valida con `TimeSeriesSplit`, que respeta el orden del tiempo:

```
from sklearn.model_selection import TimeSeriesSplit
from sklearn.dummy import DummyRegressor
from sklearn.linear_model import Ridge
from sklearn.ensemble import HistGradientBoostingRegressor
from sklearn.metrics import mean_absolute_error

df = pd.read_csv("mis_datos.csv", parse_dates=["fecha"]).sort_values("fecha")
df["mes"] = df["fecha"].dt.month
df["dia_semana"] = df["fecha"].dt.dayofweek
X = df[["mes", "dia_semana", "festivo"]]
y = df["ocupacion_pct"]
DIAS = 91
X_ent, X_test = X.iloc[:-DIAS], X.iloc[-DIAS:]
y_ent, y_test = y.iloc[:-DIAS], y.iloc[-DIAS:]
print(X_ent.shape, X_test.shape)
DATOS_HASH = hashlib.md5(pd.util.hash_pandas_object(df, index=True).values.tobytes()).hexdigest()[:8]

def crear_pipeline(estimador, columnas):
    return Pipeline([("prep", StandardScaler()), ("m", estimador)])

cv = TimeSeriesSplit(n_splits=5)

def experimento(nombre, estimador, hiperparametros, responsable="equipo", notas="", Xd=None):
    Xd = X_ent if Xd is None else Xd
    t0 = time.time()
    errores = -cross_val_score(crear_pipeline(estimador, Xd.columns), Xd, y_ent, cv=cv,
scoring="neg_mean_absolute_error")
    registrar(responsable, nombre, hiperparametros, DATOS_HASH, SEMILLA, "MAE", errores.mean(), errores.std(),
time.time() - t0, notas)
    return errores.mean(), errores.std()

errores = []
for ent, val in cv.split(X_ent):
    errores.append(mean_absolute_error(y_ent.iloc[val], y_ent.shift(7).iloc[val]))
registrar("Ana", "Baseline_semana_pasada", {"desfase_dias": 7}, DATOS_HASH, SEMILLA, "MAE", np.mean(errores),
np.std(errores), 0, "igual que la semana pasada")
media, desv = experimento("Ridge", Ridge(), {"alpha": 1.0}, responsable="Ana")
print(f"MAE de la semana pasada: {np.mean(errores):.2f} ± {np.std(errores):.2f} · Ridge: {media:.2f} ± {desv:.2f}")
```

   Cambiad el nombre del archivo, `ocupacion_pct` (lo que predecís) y las pistas de X. En series la métrica es un **error** (MAE), y cuanto **menor**, mejor; el signo menos pasa a positivo lo que `scikit-learn` devuelve como negativo. Con `ocupacion_diaria.csv` salen `(1005, 3) (91, 3)` y `MAE de la semana pasada: 4.77 ± 0.36 · Ridge: 8.26 ± 3.88` (dos filas nuevas en el registro, la 1 y la 2).

Qué deberíais ver. Un `registro.csv` con al menos 3 filas (*baseline*, primer modelo y alguna prueba más) y las doce columnas rellenas; el cuaderno ejecutándose de arriba abajo con **las mismas cifras en dos ejecuciones seguidas** (señal de que la semilla funciona); y el *baseline* con la métrica más baja o igual al azar (AUC 0,5 en clasificación).

Hecho cuando: hay semilla, versiones, partición común, plan escrito y el registro tiene el *baseline* y al menos un modelo más.

Si algo falla

Veis…	Qué significa	Qué hacer
`NameError: name 'experimento' is not defined`	La celda donde se define no se ha ejecutado, o Colab se reinició.	Ejecutad desde la primera celda hacia abajo (*Entorno de ejecución → Ejecutar todo*).
`FileNotFoundError: [Errno 2] No such file or directory: 'mis_datos.csv'`	El archivo no está subido en esta sesión de Colab, o `RUTA` no coincide.	Subidlo otra vez con el panel y copiad el nombre exacto. Los archivos subidos se pierden cuando Colab se reinicia.
`KeyError: "['cancelado'] not found in axis"` (con otros nombres)	Un nombre de `OBJETIVO` o de `QUITAR` no es exacto.	Escribid `df.columns` y copiad los nombres tal cual.
`ValueError: All the 5 fits failed.` y, más abajo, `Input X contains NaN`	Hay casillas vacías en columnas numéricas y el modelo no las admite.	Rellenadlas o quitad esas filas dentro de la cadena de pasos (un imputador en el `Pipeline`) o probad `HistGradientBoostingClassifier`, que las acepta.

Veis…	Qué significa	Qué hacer
`ValueError: The least populated classes in y have only 1 member, which is too few`	Una clase tiene una sola fila y `stratify` no puede repartirla.	Quitad `stratify=y` o agrupad esa clase con otra, y apuntadlo en las notas.
El registro tiene filas repetidas o empieza en un `id` raro	Se ejecutó una celda de `experimento` varias veces sin reiniciar.	*Reiniciar y ejecutar todo*: el registro se rehace desde cero.
Cada vez que ejecutáis salen cifras distintas	Falta fijar la semilla en algún paso.	Comprobad que `SEMILLA` se usa en `train_test_split`, `cv` y los modelos (`random_state=SEMILLA`).

Paso 2 · Probar los modelos clásicos y el neuronal (día 2, 140 minutos)

1. Entrenar al menos 3 modelos clásicos con la misma partición y anotar cada prueba.
2. Entrenar al menos un modelo neuronal (o el asistente LLM/RAG en el brief 3).
3. Ajustar 1–2 hiperparámetros clave de cada familia, solo con validación.
4. Comprobar que cada persona ha anotado al menos una fila.

En sencillo. Hoy se prueba, se apunta y se compara. Cada persona entrena un modelo o ajusta uno, y **cada prueba se anota nada más terminarla** con la función `experimento` que dejasteis hecha en el paso 1: hace todo el trabajo (entrenar, medir y escribir la fila del registro). Es como una carrera con cronometraje: todos corren en la misma pista (la misma partición) y se apunta cada tiempo, también los malos. No hace falta saber cómo funciona cada modelo por dentro: cambiáis el nombre del modelo, el responsable y, si toca, un ajuste.

Palabras nuevas de este paso

Palabra	Qué significa, en sencillo
Modelo clásico	Un modelo de aprendizaje automático sin redes neuronales: regresión, bosque aleatorio, *gradient boosting*.
Bosque aleatorio	Muchos árboles de decisión que votan. Ajuste típico: `max_depth` (profundidad de cada árbol).
Gradient boosting	Árboles que se entrenan uno tras otro, cada uno corrigiendo los errores del anterior.
Red neuronal	Un modelo hecho de capas de «neuronas» que aprende combinaciones de las pistas.
Sobreajuste	Que el modelo se aprenda de memoria el entrenamiento y falle con datos nuevos.
Subconjunto	Una parte de los datos para que una prueba pesada tarde menos.

Cómo se hace

1. **Repartir (5 minutos).** Un reparto posible si sois 3 o 4:

Persona	Qué prueba	Minutos
A	Segundo y tercer modelo clásico (por ejemplo, bosque y boosting)	50
B	Modelo neuronal (o RAG/LLM en el brief 3)	60
C	Ajuste de 1–2 hiperparámetros de las familias de A (profundidad, número de árboles…)	40
D (si hay 4)	Repetir una prueba de otra persona con su código para comprobar que sale igual	40

   Cada persona escribe en **su sección** del cuaderno, con una celda de texto con su nombre como título, y **cambia `responsable="..."` por su nombre** en cada llamada.

2. **Persona A: bosque y boosting.** En una celda nueva:

```
media, desv = experimento("RandomForest", RandomForestClassifier(n_estimators=200, min_samples_leaf=5,
random_state=SEMILLA, n_jobs=2),
                          {"n_estimators": 200, "min_samples_leaf": 5}, responsable="Luis")
print(f"Bosque aleatorio: {media:.3f} ± {desv:.3f}")

media, desv = experimento("HistGradientBoosting", HistGradientBoostingClassifier(random_state=SEMILLA),
                          {"defecto": True}, responsable="Luis")
print(f"Gradient boosting: {media:.3f} ± {desv:.3f}")
```

   - El primer argumento es el **nombre** que verá el registro: el mismo modelo debe llamarse **siempre igual**.
   - El segundo es el modelo con sus ajustes; el tercero, un diccionario `{}` con esos mismos ajustes, para que quede escrito (`{"defecto": True}` significa «sin tocar nada»).
   - Cada llamada entrena 5 veces (validación cruzada), escribe una fila en el registro y devuelve la media y la desviación. Con los datos de práctica salen `Bosque aleatorio: 0.739 ± 0.013` y `Gradient boosting: 0.727 ± 0.011`; el boosting puede tardar de unos segundos a casi medio minuto.

3. **Persona C: ajustar sin trampa.** Probad 2 o 3 valores de un ajuste y **anotad cada valor como una fila**:

```
for d in (3, 6, 10):
    media, desv = experimento(f"RandomForest_prof{d}",
                              RandomForestClassifier(n_estimators=200, min_samples_leaf=5, max_depth=d,
random_state=SEMILLA, n_jobs=2),
                              {"n_estimators": 200, "min_samples_leaf": 5, "max_depth": d}, responsable="Marta",
notas="ajuste de profundidad")
    print(f"profundidad {d}: {media:.3f} ± {desv:.3f}")
```

   `for d in (3, 6, 10)` repite el bloque con d igual a 3, luego 6 y luego 10; `f"...{d}"` pone el valor en el nombre. Salen aproximadamente `profundidad 3: 0.742 ± 0.013`, `profundidad 6: 0.745 ± 0.013` y `profundidad 10: 0.742 ± 0.013`: **casi iguales**, y es normal. Anotad también lo que no mejora («empeoró al aumentar la profundidad: sobreajuste»): también es información. **Solo con validación; el test ni se toca.**

4. **Persona B: el modelo neuronal.** La opción más sencilla es la red de scikit-learn, que cabe en la misma función y la misma validación cruzada:

```
from sklearn.neural_network import MLPClassifier

media, desv = experimento("RedNeuronal_MLP", MLPClassifier(hidden_layer_sizes=(32, 16), early_stopping=True,
max_iter=300, random_state=SEMILLA),
                          {"hidden_layer_sizes": [32, 16], "early_stopping": True, "max_iter": 300}, responsable="Pablo",
notas="red neuronal de scikit-learn")
print(f"Red neuronal: {media:.3f} ± {desv:.3f}")
```

   `hidden_layer_sizes=(32, 16)` son dos capas de 32 y 16 neuronas y `early_stopping=True` para de entrenar cuando deja de mejorar. Con los datos de práctica sale aproximadamente `Red neuronal: 0.738 ± 0.019`. Si preferís la red de Keras del sprint 10, copiad `construir_mlp` y el entrenamiento de `S10_04` y anotad la fila a mano con `registrar(...)`, poniendo la métrica de **una sola partición de validación** en `valor_cv`, un `0` en `desv_cv` y en `notas` «una sola partición de validación». En el brief 2 (imágenes) y el brief 3 (asistente), mirad `S11_02` y `S12_06` y anotad también con `registrar`. Si tarda mucho o usa una API de pago, **trabajad con un subconjunto de datos y anotad el coste en `notas`**.

5. **Persona D (si hay cuatro): repetir una prueba.** Copiad en vuestra sección la celda de otra persona (sin cambiar nada salvo `responsable` y `notas="repetición de la prueba de Luis"`) y comprobad que da **las mismas cifras**. Si no, hay azar sin semilla.

6. **Si una prueba la ha generado una IA,** escribidlo en `notas`, por ejemplo `notas="código generado con IA, revisado a mano"`. **Que cada persona toque algo:** si alguien se queda sin fila, que pruebe un ajuste de otra persona y lo anote con su nombre.

7. **Comprobar el registro (10 minutos).** El registro de cada persona vive en su propia sesión de Colab. Para ver todas las filas juntas, la persona con el rol técnico elige *Entorno de ejecución → Reiniciar y ejecutar todo*: se ejecutan todas las secciones, una tras otra, y el registro se rehace completo. Después ejecuta:

   ```
   registro = pd.read_csv(RUTA_REGISTRO)
   print(len(registro), "filas")
   print(registro["responsable"].value_counts())
   ```

   `value_counts()` cuenta cuántas filas tiene cada nombre. Con las pruebas de ejemplo de arriba (ocho en total) salen `8 filas` y `Marta 3`, `Ana 2`, `Luis 2`, `Pablo 1`. Cada persona del equipo debe aparecer **al menos una vez**.

Qué deberíais ver. Un `registro.csv` con unas 8–12 filas de personas distintas, con `valor_cv` y `desv_cv` rellenos. Si dos modelos tienen medias casi iguales y desviaciones parecidas, es normal.

Hecho cuando: hay *baseline* y 3 modelos clásicos y 1 neuronal en el registro con la misma partición, y cada persona tiene al menos una fila.

Si algo falla

Veis…	Qué significa	Qué hacer
`NameError: name 'RandomForestClassifier' is not defined` (o `MLPClassifier`)	Falta importar el modelo, o la celda de importaciones no se ejecutó.	Ejecutad la primera celda del cuaderno; para la red, la línea `from sklearn.neural_network import MLPClassifier` va antes de usarla.
`NameError: name 'experimento' is not defined`	Vuestra sesión de Colab no ha ejecutado las celdas comunes.	*Entorno de ejecución → Ejecutar todo* hasta la celda de `experimento` y volved a vuestra sección.
Solo veis vuestras filas en el registro	Cada persona tiene su propia sesión de Colab y su propio `registro.csv`.	Que la persona técnica haga *Reiniciar y ejecutar todo* en el cuaderno común y comparta el resultado.
Todas las pruebas dan casi lo mismo	Hay poca diferencia real entre los modelos.	Es normal: dejadlo escrito y decidid en el paso 4 por simplicidad y coste.
Una celda tarda mucho o Colab se queda sin memoria	El modelo o los datos son pesados.	Probad con un subconjunto (por ejemplo, la mitad de las filas), reducid `n_estimators` y anotad el coste en `notas`.
Una persona sin ninguna fila	No ha ejecutado `experimento` con su nombre.	Que pruebe un ajuste distinto de otra persona y lo anote con su `responsable`.

Paso 3 · Comprobar que no hay fugas y tutoría (día 2, 60 minutos)

1. Contestar la lista de fugas en una celda de texto de `03_modelos.ipynb`.
2. Corregir lo que falle y repetir las pruebas afectadas.
3. Ir a la tutoría técnica de 20 minutos con el docente.

En sencillo. Una **fuga de datos** es una trampa involuntaria: el modelo ve una pista que, en la vida real, todavía no existiría. Es como un examen en el que la respuesta está escrita en el enunciado: sacas un 10, pero no has aprendido nada. Por eso, si un resultado parece **demasiado bueno para ser verdad**, hay que sospechar. Hoy contestáis cinco preguntas por escrito, limpiáis el registro y habláis con el docente. No hay que programar mucho: una demostración opcional y tres líneas para revisar el registro.

Palabras nuevas de este paso

Palabra	Qué significa, en sencillo
Fuga de datos	Usar, sin querer, información del futuro o de la propia respuesta para predecir.
«En el momento de decidir»	El instante en que se usaría el modelo. Solo vale lo que ya se conoce entonces.
Variable de fuga	Una columna que solo existe después del suceso (por ejemplo, `reembolso_emitido`, que solo hay si la reserva se canceló).
Duplicados	Filas que son la misma prueba repetida.
Tutoría técnica	Una conversación de 20 minutos con el docente para revisar vuestro trabajo.

Cómo se hace

1. **La lista de fugas (20 minutos).** En `03_modelos.ipynb`, añadid una celda de texto (botón **+ Texto**) titulada «Comprobación de fugas» y copiad estas cinco preguntas. Contestad **Sí / No con una frase** a cada una:

   1. ¿Las variables se conocerían **en el momento de decidir**?
   2. ¿El escalado, la imputación y la codificación se aprenden **solo con el entrenamiento** (dentro de un `Pipeline`)?
   3. ¿La partición respeta el **tiempo** o los **grupos**?
   4. ¿Se ha ajustado algo mirando el test? Si sí, hay que rehacer la evaluación.
   5. ¿La métrica es **demasiado buena para ser verdad**? Sospechad.

   Ejemplo de respuestas con los datos de práctica (las vuestras dependen de vuestros datos): «1 · Sí: antelación, noches, canal, depósito… se conocen al reservar; quitamos el identificador y las fechas en bruto. 2 · Sí: usamos `crear_pipeline`, que aprende dentro de cada trozo de la validación cruzada. 3 · No hay series ni fotos del mismo objeto: reparto aleatorio estratificado. 4 · No: `X_test` no se ha usado. 5 · No: un AUC de 0,75 es creíble en este problema».

2. **Ver cómo suena una fuga (5 minutos, recomendable).** Para reconocer una, provocad una a propósito en vuestra sección, con la columna inventada `reembolso_emitido`, que «sabe» la respuesta:

   ```
   X_fuga = X_ent.copy()
   X_fuga["reembolso_emitido"] = ((y_ent == 1) & (rng.random(len(y_ent)) < 0.9)).astype(int)
   media, desv = experimento("LogisticaConFuga", LogisticRegression(max_iter=2000), {"C": 1.0}, responsable="Ana",
                             notas="ALARMA: AUC sospechosamente alto (fuga: reembolso_emitido)", Xd=X_fuga)
   print(f"AUC con la variable con fuga: {media:.3f}")
   ```

   Qué hace cada línea:

   - `X_fuga` es una copia de las pistas a la que se añade una columna que vale 1 casi siempre que la reserva se canceló: es la respuesta disfrazada de pista.
   - `Xd=X_fuga` le dice a `experimento` que use esa tabla en lugar de `X_ent`. La fila queda en el registro con el nombre `LogisticaConFuga` y la nota `ALARMA`.

   Con los datos de práctica sale aproximadamente `AUC con la variable con fuga: 0.975`, frente a ≈ 0,75 sin ella: **demasiado bueno**. Este modelo **no se puede elegir** (en el paso 4 se excluye por llevar «Fuga» en el nombre); sirve para contar en la *review* **una fuga que detectasteis**.

3. **Si una respuesta falla, corregid y repetid.** Si descubrís una variable que no se conocería al decidir, quitadla de `X` y repetid las pruebas afectadas. **No borréis la celda antigua**: dejadla y añadid en su `notas=` que tenía una fuga (por ejemplo, `notas="tenía fuga: variable X; repetida sin ella"`). Así el registro cuenta lo que pasó, y sirve para la rúbrica.

4. **Tutoría técnica (20 minutos).** El docente indica la franja de cada equipo. Llevad la tabla del registro, que se muestra con:

   ```
   registro = pd.read_csv(RUTA_REGISTRO)
   registro[["id", "responsable", "modelo", "valor_cv", "desv_cv", "tiempo_s", "notas"]]
   ```

   Contad **qué comparación estáis haciendo** y **qué fuga podría haber**. Anotad las respuestas del docente en una celda de texto («Tutoría»).

5. **Limpiar el registro (15 minutos).** Revisad columnas vacías, filas repetidas y nombres distintos para el mismo modelo:

   ```
   print(registro.isna().sum())
   print(registro["modelo"].value_counts())
   print("Repetidas:", registro.duplicated(subset=["modelo", "hiperparametros"]).sum())
   ```

   - `isna().sum()` cuenta las casillas vacías por columna: solo `notas` puede tener algunas; las demás deben estar a 0.
   - `value_counts()` cuenta cuántas filas tiene cada nombre de modelo: si veis `RandomForest` y `randomforest`, son el mismo modelo con dos nombres; corregid el nombre en la celda donde lo escribisteis.
   - La última línea cuenta pruebas con el mismo modelo y los mismos ajustes. Con las pruebas de ejemplo sale `Repetidas: 0`; las repeticiones hechas a propósito (persona D) llevan una nota que lo dice y no cuentan como error.

Qué deberíais ver. La celda «Comprobación de fugas» con cinco respuestas, un registro sin columnas vacías (salvo `notas`) ni filas repetidas por error y, si ha habido una fuga, una fila anotada que lo explica. Ninguna prueba con un resultado casi perfecto sin explicación.

Hecho cuando: la lista está contestada, el registro está limpio y la tutoría ha quedado anotada.

Si algo falla

Veis…	Qué significa	Qué hacer
Un modelo da un AUC de 0,97 o más a la primera	Casi seguro, hay una fuga.	Mirad la lista de columnas: ¿alguna solo existe después de la respuesta? Quitadla y repetid.
`NameError: name 'rng' is not defined`	No se ejecutó la celda de `fijar_semillas`.	Ejecutad desde la primera celda hacia abajo.
El registro tiene dos o tres filas `LogisticaConFuga`	Se ejecutó la celda de la demostración varias veces.	*Reiniciar y ejecutar todo* rehace el registro y deja una sola fila.
`value_counts()` muestra `RandomForest` y `randomforest` como dos modelos	El mismo modelo se anotó con dos nombres distintos.	Corregid el nombre en la celda donde lo escribisteis y volved a ejecutar todo.
`FileNotFoundError: [Errno 2] No such file or directory: 'registro.csv'`	Se reinició Colab y el archivo no se ha vuelto a crear.	*Reiniciar y ejecutar todo*, que rehace el registro desde cero.
No sabéis si una variable es una fuga	Cuesta decidir qué se conoce «al decidir».	Preguntaos: «¿La tendría ya en la mano el día que uso el modelo?». Si no, es fuga: preguntadlo en la tutoría.

Paso 4 · Elegir el candidato sin tocar el test (día 3, 70 minutos)

1. Calcular media ± desviación de cada modelo.
2. Comparar teniendo en cuenta la incertidumbre y añadir coste y complejidad.
3. Elegir el candidato y escribir la justificación de una página.

En sencillo. Ya tenéis un montón de pruebas apuntadas; hoy toca **elegir cuál os lleváis**, sin mirar el test. No gana siempre el que tiene el número más alto: si dos modelos van casi igual, la diferencia puede ser **ruido** (casualidad del reparto), y entonces conviene el más simple, el más rápido o el más fácil de explicar. Es como elegir coche: dos modelos con casi el mismo consumo, pero uno es mucho más barato de mantener. El código es corto: ordenar la tabla del registro y comparar. Lo difícil y valioso es **escribir por qué**.

Palabras nuevas de este paso

Palabra	Qué significa, en sencillo
Media ± desviación	Resultado medio de las 5 pruebas de la validación cruzada y cuánto se separan entre sí. `0,755 ± 0,012` significa «0,755, con un margen de ≈ 0,012».
Solapar / ruido	Dos modelos se solapan si la diferencia entre sus medias es **menor que su desviación**: no se puede afirmar que uno sea mejor.
Candidato	El modelo que elegís para evaluar en el test y llevar al demostrador.
Explicabilidad	Lo fácil que es contar por qué el modelo decide lo que decide.
Coste y complejidad	Tiempo de entrenamiento y lo difícil que es mantenerlo o explicarlo.
Justificación	Una página que cuenta qué modelo elegís y por qué, para que lo entienda quien no programa.

Cómo se hace

1. **La tabla ordenada (15 minutos, con los puntos 2 y 3).** En `03_modelos.ipynb`, una celda nueva, tras *Reiniciar y ejecutar todo* para tener el registro completo. Quitad las pruebas con fuga:

```
tabla = pd.read_csv(RUTA_REGISTRO)
legitimos = tabla[~tabla["modelo"].str.contains("Fuga")]
ordenada = legitimos.sort_values("valor_cv", ascending=False)[["id", "responsable", "modelo", "valor_cv", "desv_cv",
"tiempo_s"]]
print(ordenada.to_string(index=False))
```

   - `legitimos` conserva las filas cuyo nombre **no** contiene «Fuga» (la ~ significa «no»).
   - `sort_values("valor_cv", ascending=False)` ordena de mayor a menor. **Si vuestra métrica es un error (MAE), el mejor es el menor: usad `ascending=True`.**
   - Muestra una fila por prueba con quién la hizo, el modelo, la media, la desviación y el tiempo.

2. **Ver si la diferencia es ruido.** Esta función aplica la regla del solape, y el bucle compara cada modelo con el mejor:

```
def parecen_iguales(a, b):
    return abs(a["valor_cv"] - b["valor_cv"]) < max(a["desv_cv"], b["desv_cv"])

mejor = legitimos.loc[legitimos["valor_cv"].idxmax()]
for _, fila in legitimos.iterrows():
    if fila["modelo"] != mejor["modelo"]:
        print(fila["modelo"], "→ ¿diferencia dentro del ruido?", parecen_iguales(mejor, fila))
```

   - `parecen_iguales` devuelve `True` si la diferencia de medias es menor que la mayor de las dos desviaciones.
   - `idxmax()` da la fila con la mayor media (con MAE, usad `idxmin()`). Cada línea impresa dice si ese modelo está dentro del ruido del mejor. **Es una regla práctica, no una prueba estadística.**

   Con las pruebas de ejemplo (datos de práctica) el mejor es la regresión logística (0,755 ± 0,012): el *baseline*, el bosque sin ajustar, el boosting y el bosque de profundidad 3 salen `False` (hay diferencia clara) y el bosque de profundidad 6 y 10 y la red neuronal salen `True` (**solapan**: la diferencia puede ser ruido).

3. **(Opcional) Un gráfico de la comparación.** Con barras de error de un vistazo:

```
import matplotlib.pyplot as plt

t = legitimos.sort_values("valor_cv")
fig, ax = plt.subplots(figsize=(7, 3.5))
ax.barh(t["modelo"], t["valor_cv"], xerr=t["desv_cv"], color="tab:blue", capsize=4)
ax.axvline(0.5, color="gray", linestyle="--", label="Azar (AUC 0,5)")
ax.set_xlim(0.4, 0.85)
ax.set_xlabel("AUC medio en validación cruzada (± desviación)")
ax.set_title("Comparativa de modelos (validación cruzada, sin usar el test)")
ax.legend(loc="lower right")
plt.tight_layout()
plt.show()
```

   Sale una barra horizontal por modelo con un «bigote» que marca su desviación y una línea discontinua en 0,5 (el azar). Si los bigotes de dos barras se solapan, esos modelos son indistinguibles. Con un MAE, quitad la línea del azar y el `set_xlim`.

4. **Coste y complejidad (15 minutos).** Añadid a la comparación: el **tiempo de entrenamiento** (`tiempo_s`), lo difícil que es **mantener** el modelo y lo fácil que es **explicar** su decisión (por ejemplo, la regresión logística tiene un peso por variable que se puede leer; una red neuronal es más difícil de explicar). Escribidlo en una tabla de cuatro columnas en la justificación (el punto 6).

5. **Elegir (15 minutos).** Reglas: se elige con la **validación**, **no se mira el test**; si dos modelos van casi igual, **elegid el más simple y explicadlo**. Una frase del tipo: «Elegimos la regresión logística (0,755 ± 0,012) frente al bosque de profundidad 6 (0,745 ± 0,013): la diferencia puede ser ruido y la logística es mucho más rápida y fácil de explicar» (es el ejemplo con datos de práctica).

6. **Escribir `justificacion_candidato.md` (25 minutos).** En `sprint-15` de GitHub: *Add file → Create new file*, nombre `justificacion_candidato.md`. Una página con esta tabla, rellenada con **vuestras cifras**, y unas líneas debajo que digan por qué gana:

Modelo	Métrica (media ± desv.)	Tiempo	Explicabilidad	Comentario
Baseline	0,500 ± 0,000	≈ 0,1 s	—	Azar: no mira las pistas
Regresión logística	0,755 ± 0,012	≈ 0,1 s	Alta: cada variable tiene un peso	**Candidata**
Bosque (profundidad 6)	0,745 ± 0,013	≈ 2 s	Media	Solapa con la logística: puede ser ruido
Red neuronal (MLP)	0,738 ± 0,019	≈ 1 s	Baja	Solapa con la logística; más difícil de explicar

   Debajo, 3–5 líneas con: qué modelo elegís, **si la diferencia con el siguiente puede ser ruido**, el coste y el beneficio, y qué no sabéis. Dejad ya un hueco para el resultado en test y para la «Revisión con la rúbrica» del paso 5. Si vais a por el nivel extra, añadid una **hipótesis de por qué gana**: por ejemplo, «los datos tienen relaciones no lineales entre antelación y canal que un árbol captura mejor que una regresión» (ejemplo de redacción; la vuestra se contrasta con la explicación del paso 5).

Qué deberíais ver. Una tabla ordenada con una fila por prueba legítima, un candidato elegido y una frase del tipo «Elegimos X (0,71 ± 0,02) frente a Y (0,72 ± 0,04): la diferencia puede ser ruido y X es mucho más rápido» (cifras de ejemplo). Y `justificacion_candidato.md` en `sprint-15`.

Hecho cuando: `justificacion_candidato.md` tiene la tabla comparativa y el candidato razonado, y nadie ha mirado el test.

Si algo falla

Veis…	Qué significa	Qué hacer
`NameError: name 'RUTA_REGISTRO' is not defined`	Colab se reinició y las celdas comunes no se ejecutaron.	*Reiniciar y ejecutar todo*; así se rehace el registro.
`KeyError: 'valor_cv'`	El nombre de la columna está mal escrito, o la tabla no es el registro.	Escribid `tabla.columns` y comprobad que salen las doce columnas.
La fila `LogisticaConFuga` sale la primera	Falta el filtro `legitimos` o se ha usado `tabla` en vez de `legitimos`.	Usad `legitimos` en todas las líneas siguientes.
El «mejor» tiene la métrica más baja	Con un error (MAE) el mejor es el menor.	Cambiad `ascending=True` y `idxmin()`.
Dos modelos empatan	Es normal cuando solapan.	Elegid el más simple, rápido o fácil de explicar, y escribidlo.
Alguien ha mirado el test para decidir	El test deja de ser una prueba limpia.	Decidid solo con validación, anotadlo en la justificación y no volváis a elegir con él.

Paso 5 · Test una sola vez, explicación, revisión y entrega (día 3, 70 minutos)

1. Evaluar el candidato en el test, una sola vez.
2. Guardar el modelo con `metadatos.json` y hacer la primera explicación.
3. Revisar con la rúbrica y anotar el resultado.
4. Subir los ficheros a `sprint-15/`.

En sencillo. Es el día de la verdad. Hasta ahora el test estaba guardado en un cajón; hoy lo abrís **una sola vez** para ver cómo se portaría el modelo elegido con datos que nunca ha visto. Es como el examen final: no se puede repetir para sacar mejor nota. Después guardáis el modelo en un archivo (para que otra persona lo use sin reentrenarlo), hacéis un primer gráfico de **qué pistas pesan más** en sus decisiones, os revisáis entre vosotros y subís todo. Hay código, pero cada bloque es corto y viene probado.

Palabras nuevas de este paso

Palabra	Qué significa, en sencillo
Test, una sola vez	Se evalúa el candidato en el test después de elegirlo. Si el resultado no gusta, **no se vuelve a elegir con él**.
`joblib`	Una herramienta para guardar un modelo entrenado en un archivo (`.joblib`) y volver a abrirlo después.

Palabra	Qué significa, en sencillo
Metadatos (`metadatos.json`)	Un archivo de texto con los datos del modelo: qué modelo es, cuándo se entrenó, versiones, resultados y variables.
Importancia por permutación	Se desordena una variable y se mira cuánto empeora el modelo: cuanto más empeora, más pesa esa variable.
Explicabilidad	Poder contar qué pistas usa el modelo y por qué decide lo que decide.
Commit	Cada subida a GitHub con su mensaje y su autor.

Cómo se hace

1. **Test, una vez (10 minutos).** En una celda nueva, con el candidato que elegisteis en el paso 4 (aquí la regresión logística):

```
candidato = LogisticRegression(max_iter=2000)
final = crear_pipeline(candidato, X_ent.columns).fit(X_ent, y_ent)
auc_test = roc_auc_score(y_test, final.predict_proba(X_test)[:, 1])
print(f"AUC en test: {auc_test:.3f}")
```

   Qué hace cada línea:

   - `candidato` es el modelo que elegisteis (**cambiadlo** por el vuestro, con los mismos ajustes que anotasteis en el registro). `crear_pipeline(...).fit(X_ent, y_ent)` lo entrena con **todo** el entrenamiento.
   - `roc_auc_score(y_test, final.predict_proba(X_test)[:, 1])` calcula el AUC en el test (con series, `mean_absolute_error(y_test, final.predict(X_test))`).

   Con los datos de práctica sale `AUC en test: 0.745`, muy cerca del 0,755 de la validación cruzada: es lo esperable. Si el test saliera muy por debajo (más de unas seis centésimas), sospechad sobreajuste o fuga. Copiad el resultado a la justificación. **No cambiéis de candidato después de verlo**: si no os gusta, anotadlo y explicadlo.

2. **Guardar el modelo y los metadatos (10 minutos).**

```
import joblib
from datetime import date

joblib.dump(final, "modelo_candidato.joblib")
metadatos = {
    "modelo": "RegresionLogistica",
    "entrenado": str(date.today()),
    "semilla": SEMILLA,
    "datos_hash": DATOS_HASH,
    "metrica": METRICA,
    "valor_validacion": round(float(tabla.loc[tabla["modelo"] == "RegresionLogistica", "valor_cv"].iloc[0]), 3),
    "valor_test": round(float(auc_test), 3),
    "variables": list(X_ent.columns),
    "versiones": ENTORNO,
}
with open("metadatos.json", "w", encoding="utf8") as f:
    json.dump(metadatos, f, ensure_ascii=False, indent=2)
print(open("metadatos.json").read())
```

   Qué hace cada línea:

   - `joblib.dump(final, ...)` guarda el modelo **entero** (con su escalado y su codificación) en `modelo_candidato.joblib`; con los datos de práctica pesa unos 5 KB.
   - El diccionario `metadatos` recoge versión de las bibliotecas (`ENTORNO`), fecha, semilla, huella de los datos, métrica en validación y en test, y los nombres de las variables. **Cambiad `"RegresionLogistica"` (dos veces) por el nombre de vuestro candidato en el registro.**
   - `json.dump(...)` lo escribe en `metadatos.json` y el último `print` lo enseña.

   Salen las líneas del archivo, con `"valor_validacion": 0.755` y `"valor_test": 0.745` en el ejemplo. En el brief 3, guardad el asistente tal como lo ejecutáis y apuntad en `metadatos.json` el modelo de lenguaje, los parámetros y el modo de recuperar los textos. Si el modelo es una red de Keras, se guarda con el formato de la red (`.keras`).

3. **Primera explicación (20 minutos).** Importancia de variables por permutación, calculada sobre el **entrenamiento** (para no usar el test una segunda vez):

```
from sklearn.inspection import permutation_importance
import matplotlib.pyplot as plt

resultado = permutation_importance(final, X_ent, y_ent, scoring="roc_auc", n_repeats=5, random_state=SEMILLA)
importancias = pd.Series(resultado.importances_mean, index=X_ent.columns).sort_values(ascending=False)
print(importancias.head(8).round(3))

fig, ax = plt.subplots(figsize=(7, 4))
importancias.head(8)[::-1].plot.barh(ax=ax, color="tab:blue")
ax.set_xlabel("Caída del AUC al desordenar la variable")
ax.set_title("Variables que más pesan en el modelo candidato")
plt.tight_layout()
plt.savefig("explicacion_modelo.png", dpi=150)
plt.show()
```

   Qué hace cada línea:

   - `permutation_importance` desordena cada variable 5 veces (`n_repeats=5`) y mide cuánto cae el AUC. Con series, `scoring="neg_mean_absolute_error"`.
   - `pd.Series(...).sort_values(...)` ordena las variables de más a menos importante; `head(8)` se queda con las ocho primeras.
   - `plt.savefig("explicacion_modelo.png", dpi=150)` guarda el gráfico (**antes** de `plt.show()`).

   Con los datos de práctica salen, aproximadamente, `antelacion_dias` 0,103, `deposito` 0,059, `canal` 0,042 y `tarifa` 0,037. Escribid **2–3 frases de lectura** en la justificación: «La variable más importante es la antelación, lo que tiene sentido porque, en los datos, se cancela el 30 % de las reservas con poca antelación y el 67 % de las de más de 120 días». El gráfico solo dice qué pistas usa el modelo, **no** que sean la causa. Si los datos son tabulares y queréis ir más allá, se puede usar SHAP, y con imágenes, Grad-CAM; se profundiza en el sprint 16.

4. **La revisión con la rúbrica (10 minutos).** Quien revisa **no escribió** esa parte y sigue los cinco pasos de «Cómo se revisa» de entrega y rúbrica: ejecutar `03_modelos.ipynb` de arriba abajo y comparar las cifras con la tabla de la justificación; mirar el registro (*baseline* en la fila 1, columnas rellenas, una fila de cada persona); buscar fugas y trampas; leer la justificación como el cliente y poner un nivel de 1 a 4 en cada criterio **con una frase de prueba**; y anotar el resultado. Añadid al final de `justificacion_candidato.md` una sección como esta:

```
## Revisión con la rúbrica
**Revisado por:** <nombre> · **Fecha:** <dd/mm/aaaa>

| Criterio | Nivel (1–4) | Prueba: una frase de lo que has comprobado |
|---|---|---|
| Corrección técnica | | |
| Reproducibilidad | | |
| Análisis y comunicación al cliente | | |
| IA responsable | | |

**Lo primero que mejoraríamos:** <una cosa concreta>
```

5. **Subir los ficheros (la vía del curso, desde el navegador).** Seguid Cómo entregar en GitHub. Descargad del panel de Colab (clic derecho sobre cada archivo → *Descargar*) `registro.csv`, `modelo_candidato.joblib`, `metadatos.json` y `explicacion_modelo.png`; y el cuaderno con *Archivo → Descargar → Descargar .ipynb*. Después: (1) abrid el repositorio del equipo y **entrad primero en la carpeta `sprint-15`**; (2) *Add file → Upload files*; (3) arrastrad los ficheros; (4) escribid un mensaje corto y pulsad **Commit changes**. Cada subida es un *commit* con el nombre de quien la hace. Un reparto posible: la persona A sube `03_modelos.ipynb` («Añado cuaderno de modelos»), la B sube `registro.csv` y `explicacion_modelo.png`, la C sube `justificacion_candidato.md`, `modelo_candidato.joblib` y `metadatos.json`. Los nombres de archivo, **en minúsculas y sin espacios**. Cada persona sube además su `autoevaluacion_nombre.md`.

Qué deberíais ver. En la carpeta `sprint-15` del repositorio, los seis ficheros del equipo y una hoja de autoevaluación por persona (**6 + N**); y en el historial (el icono del reloj), al menos tres *commits* con nombres distintos.

Hecho cuando: el test se ha evaluado una vez, el modelo y su explicación están guardados, la sección «Revisión con la rúbrica» está rellena y todo está en `sprint-15/`.

Después, 60 minutos de review y retro. Cada persona sube su autoevaluación y coevaluación a `sprint-15/` (en el tiempo de entrega). En la *review*, cada equipo enseña en 5 minutos: (1) la tabla de modelos con media ± desviación, (2) el candidato elegido y

por qué (no solo la métrica), (3) una fuga que evitó o detectó, (4) una hipótesis sobre por qué gana ese modelo y (5) su registro de experimentos. El resto de equipos pregunta: *«¿cómo sabéis que la diferencia no es ruido?»*

Si algo falla

Veis…	Qué significa	Qué hacer
`NameError: name 'final' is not defined`	La celda del test no se ejecutó antes de guardar o explicar.	Ejecutad desde la primera celda: *Entorno de ejecución → Ejecutar todo*.
`TypeError: Object of type int64 is not JSON serializable` (o `float32`)	Hay un número de NumPy dentro de `metadatos` y JSON no sabe escribirlo.	Convertidlo con `float(...)` o `int(...)`, como en el código de arriba.
`FileNotFoundError: [Errno 2] No such file or directory: 'modelo_candidato.joblib'`	Se reinició Colab y el archivo guardado se perdió, o el nombre no coincide.	Volved a ejecutar la celda que guarda el modelo y descargad los archivos antes de cerrar.
El test sale mucho peor que la validación	Sobreajuste o fuga.	No cambiéis de candidato por verlo: anotad la diferencia en la justificación y explicad la causa probable.
`ModuleNotFoundError: No module named 'shap'`	SHAP no está instalado en la sesión.	Usad la importancia por permutación de este paso, que no necesita instalar nada.
El navegador no deja subir el modelo	Pesa más de 25 MB.	No lo subáis por el navegador: avisad al docente y dejad escrito en `metadatos.json` cómo volver a generarlo con vuestro cuaderno.

Ayuda 1 · Cómo usar la IA en este reto

La IA puede ahorrar tiempo, pero **da código que parece funcionar y no se entiende**, y puede pasar por alto una fuga o ver una que no existe. Reglas:

- **Todo lo que dé, lo ejecutáis y lo entendéis.** Si el docente pregunta por una línea, tenéis que saber explicarla.
- **El test se usa una sola vez, con el modelo ya elegido.** Elegir por el test invalida el resultado.
- **Declaradlo** en `justificacion_candidato.md` y **marcad en el registro** las pruebas hechas con código generado por IA.
- **Nada de datos personales ni claves** en una IA ni en el repositorio.

Para qué	Ejemplo de petición	Qué comprobáis
Entender un modelo	«Explícame cuándo conviene un modelo de boosting frente a una regresión logística, con un ejemplo sencillo»	Que la explicación encaja con **vuestros datos**
Depurar un error	«Este código de scikit-learn da este error: *[error]*. Datos: *[estructura]*»	Que entendéis la causa
Detectar fugas	«Aquí está mi pipeline: *[código]*. ¿Hay alguna operación que use el test o el futuro?»	Que **verificáis** la respuesta; la IA puede pasarlas por alto o ver fugas inexistentes
Interpretar SHAP	«Tengo este gráfico SHAP (descripción). ¿Qué significa que la variable X tenga ese efecto?»	Contrastadlo con el sentido del negocio

Ayuda 2 · Errores frecuentes (y cómo evitarlos)

Error	Por qué ocurre	Cómo evitarlo
Elegir el modelo mirando el test	«Para ver cuál es mejor»	Elegid solo con validación; el test, una vez
Resultados «increíbles» (99 %)	Fuga de datos	Revisad variables y partición con la lista del paso 3
Registro con 3 filas de una sola persona	El responsable técnico lo hace todo	Cada persona prueba algo y lo anota con su nombre
Cada persona tiene su propio `registro.csv`	Se trabaja en copias distintas del cuaderno	Un único `03_modelos.ipynb` compartido (Compartir → editor), con una sección por persona: el `registro.csv` sale de «Reiniciar y ejecutar todo»
Comparar con particiones distintas	Cada uno prueba por su lado	Una partición común, guardada y compartida

Error	Por qué ocurre	Cómo evitarlo
Mejor número = mejor modelo	Se mira solo la métrica	Añadid tiempo, simplicidad y explicabilidad
Mezclar fotos del mismo objeto entre entrenamiento y test	En imágenes es fácil	Particionad por objeto o por parcela
Cambiar la semilla hasta que salga un resultado bonito	Prisa o ganas de ganar	Una semilla para todo el equipo; si cambia mucho, el modelo es inestable y hay que decirlo

Ayuda 3 · Si os atascáis

1. **No sabemos qué modelos probar:** repasad el *leaderboard* del Sprint 8 y la red del Sprint 10, y usad las mismas familias.
2. **Dos modelos dan casi lo mismo:** perfecto; elegid el más simple y explicadlo.
3. **No tenemos GPU o va lenta:** usad un subconjunto de los datos y anotad el coste en el registro.
4. **El modelo guardado pesa más de 25 MB:** no lo subáis por el navegador; avisad al docente, subid `metadatos.json` y dejad escrito en él cómo volver a generar el modelo con vuestro cuaderno.
5. Preguntad al equipo y, después, al docente. Más ayuda: Cómo se trabaja un reto.